

0. Intro

과정명: [Level 3] Data Science 역량강화 심화과정

강사: 멀티캠퍼스 강선구

전자 DX Level 3에 출제되는 내용을 중심으로 구성된 고급 데이터 분석 강의입니다.

1. 과정의 컨셉

1. 이론과 구현을 하나의 문서로 구성하였습니다.

이론과 함께 주요 개념을 파이썬 코드로 구현하여 이해도를 높이도록 구성했습니다.

구현된 내용들은 실기 시험 환경과 동일하고, 실기 시험에서도 그대로 적용할 수 있는 기법들로 구성이 됩니다.

▷ 이론 과정에서 나오는 코드들을 이해하면 자연스럽게 실기 시험에서 사용하는 구현들에 익숙해질 수 있습니다.

단, 코드의 상세한 구동 원리는 강의에서는 직접 언급하지는 않습니다.

처음 나오는 기법들은 최대한 상세하게 주석을 만들었습니다. 설명이 필요하신 부분은 의견을 부탁드립니다.

2. Level2의 언급된 내용들은 보다 깊게 다루기도 하고, 단편적인 내용들은 간단히 언급만합니다.

2. 교재의 구성

1. Jupyter Notebook 파일

6장 딥러닝을 제외하고 시험장과 동일한 환경을 기준으로 제작된 Jupyter Notebook 파일로 강의를 진행합니다.

6장 딥러닝은 **Tensorflow 2.X** 환경을 기반으로 진행이 됩니다.

2. 요약집

주요 내용이 요약된 파일이 제공됩니다.

3. 선수 지식

- DX Level2의 이론 및 Python 기반 데이터 분석 능력

선형 대수 (Linear Algebra)

벡터의 내적

$$x = [x_1 \quad x_2 \quad \dots \quad x_n]^T$$

$$y = [y_1 \quad y_2 \quad \dots \quad y_n]^T$$

$$x^T y = \sum_{i=1}^n x_i y_i$$

행렬곱

$$A = \begin{bmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ a_{2,1} & a_{2,2} & \dots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1} & a_{m,2} & \dots & a_{m,n} \end{bmatrix}, B = \begin{bmatrix} b_{1,1} & b_{1,2} & \dots & b_{1,n} \\ b_{2,1} & b_{2,2} & \dots & b_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{m,1} & b_{m,2} & \dots & b_{m,n} \end{bmatrix}$$

$$A^T B = \begin{bmatrix} \sum_{i=1}^n a_{1,i} b_{i,1} & \sum_{i=1}^n a_{1,i} b_{i,2} & \cdots & \sum_{i=1}^n a_{1,i} b_{i,m} \\ \sum_{i=1}^n a_{2,i} b_{i,1} & \sum_{i=1}^n a_{2,i} b_{i,2} & \cdots & \sum_{i=1}^n a_{2,i} b_{i,m} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n a_{m,i} b_{i,1} & \sum_{i=1}^n a_{m,i} b_{i,2} & \cdots & \sum_{i=1}^n a_{m,i} b_{i,m} \end{bmatrix}$$

4. 시험장 환경을 가상 환경으로 구축

PC에 있는 Python 환경을 유지하면서, 시험장 환경의 Python 환경을 별도로 구축하는 방법입니다.

OS: Windows 10 (Windows 11도 가능하지만 결과에 차이가 있을 수 있습니다.)

1. **패키지** 압축 파일을 다운로드 받습니다. C:\패키지 에 압축을 풉니다.

(C:\패키지에 위치할 필요는 없지만, 이후 설명은 C:\패키지 를 기준으로 합니다.)

2. 패키지에 안에 있는 시험장 환경의 python(3.7.4 version) 설치 파일 python-3.7.4-amd64.exe을 실행시킵니다.

3. Python 설치 경로를 C:\python37로 합니다. (마찬가지로 따를 필요는 없지만, 설명은 C:\python37 를 기준으로 합니다.)

4. Python 가상 환경 구축

- 명령프롬프트를 실행시킵니다.(Windows 실행 → cmd.exe)
- 설치된 버전의 python 실행 파일을 사용하여 python37이란 이름으로 가상환경을 만듭니다.

cmd

```
C:\python37\python -m venv python37
```

- 성공하면 python37 경로가 생깁니다.

5. 패키지 설치

```
python37\Scripts\activate
cd c:\패키지
pip install --upgrade --no-index --find-links . pip
pip install --no-index --find-links . -r requirements.txt
```

가상 환경 전환

일단 가상환경이 구축이 되면, 이후에는 활성화를 통해 환경 전환이 가능합니다.

```
python37\Scripts\activate
```

가상 환경 해제

가상환경 이전의 환경으로 돌아옵니다.

```
deactivate
```

```
In [ ]: #!pip install mlxtend
        #!pip install xgboost
```

```
In [5]: import warnings
        warnings.filterwarnings(action = 'ignore')

        from IPython.display import Image

        # 주요 라이브러리

        # 데이터 처리 라이브러리
        import pandas as pd
        # 수치 연산 라이브러리
        import numpy as np
        # 과학용 데이터 처리 및 연산 라이브러리
```

```
import scipy
# 통계 모델 라이브러리
import statsmodels
# 머신러닝 라이브러리
import sklearn
# 머신러닝 라이브러리(확장)
import mlxtend
# (Over/Under)Sampling 라이브러리
import imblearn
# Extra Gradient Boosting 라이브러리
import xgboost as xgb
# 시각화 라이브러리
import matplotlib as mpl
# 차트 라이브러리
import seaborn as sns

import sys

print('Python: ', sys.version)

for i in [pd, np, scipy, statsmodels, sklearn, mlxtend, imblearn, xgb, mpl, sns]:
    print(i.__name__, i.__version__)
```

```
Python: 3.11.7 | packaged by Anaconda, Inc. | (main, Dec 15 2023, 18:05:47) [MSC v.1916 64 bit (AMD64)]
pandas 2.1.4
numpy 1.26.4
scipy 1.11.4
statsmodels 0.14.0
sklearn 1.2.2
mlxtend 0.23.1
imblearn 0.11.0
xgboost 2.0.3
matplotlib 3.8.0
seaborn 0.12.2
```

※ Python 버전과 빌드가 다르거나, 라이브러리의 버전이 다른면 제공하는 코드가 동작을 하지 않거나, 결과가 다를 수 있습니다.

5. 데이터셋 소개

In [6]: `Image('1.png')`

Out[6]: **Titanic**

[Titanic](#) 탑승객의 생존 유무를 담은 데이터셋입니다.

Data	Description	Dictionary
PassengerId	Passenger Id, Index	
Survived	Survival	0 = No, 1 = Yes
Pclass	Ticket class	1 = 1st, 2 = 2nd, 3 = 3rd
Name	Name	
Sex	Sex	
Age	Age in years	
Sibsp	# of siblings / spouses aboard the Titanic	
Parch	# of parents / children aboard the Titanic	
Ticket	Ticket number	
Fare	Passenger fare	
Cabin	Cabin number	
Embarked	Port of Embarkation	C = Cherbourg, Q = Queenstown, S = Southampton

다양한 형식의 데이터를 가지고 있으며, 여러 가지 아이디어를 생각하고 시도할 만한 요소가 많게끔 기획된 데이터셋입니다.

In [3]: `df_titanic = pd.read_csv('data/titanic.csv', index_col='PassengerId')`
`df_titanic.head()`

Out[3]:

	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
PassengerId											
1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

In [7]: Image('2.png')

Out[7]: **Space titanic**

[Space Titanic](#) 생존자 데이터셋을 모태로하여 미래의 우주 여행선을 주제로 만들어진, 데이터 분석 입문용 데이터셋입니다.

variable name	description
PassengerId	A unique Id for each passenger. Each Id takes the form gggg_pp where gggg indicates a group the passenger is travelling with and pp is their number within the group. People in a group are often family members, but not always.
HomePlanet	The planet the passenger departed from, typically their planet of permanent residence.
CryoSleep	Indicates whether the passenger elected to be put into suspended animation for the duration of the voyage. Passengers in cryosleep are confined to their cabins.
Cabin	The cabin number where the passenger is staying. Takes the form deck/num/side, where side can be either P for Port or S for Starboard.
Destination	The planet the passenger will be debarking to.
Age	The age of the passenger.
VIP	Whether the passenger has paid for special VIP service during the voyage.
RoomService, FoodCourt, ShoppingMall, Spa, VRDeck	Amount the passenger has billed at each of the Spaceship Titanic's many luxury amenities.
Name	The first and last names of the passenger.
Transported	Whether the passenger was transported to another dimension. This is the target, the column you are trying to predict.

Titanic 데이터 보다 생각해볼 요소를 보다 폭넓게 담아 놓은 데이터셋입니다.

```
In [4]: df_space = pd.read_csv('data/space_titanic.csv', index_col='PassengerId')
df_space.head()
```

Out[4]:

	HomePlanet	CryoSleep	Cabin	Destination	Age	VIP	RoomService	FoodCourt	ShoppingMall	Spa	VRDeck	Nar
PassengerId												
0001_01	Europa	False	B/0/P	TRAPPIST-1e	39.0	False	0.0	0.0	0.0	0.0	0.0	Maha Ofracci
0002_01	Earth	False	F/0/S	TRAPPIST-1e	24.0	False	109.0	9.0	25.0	549.0	44.0	Juan Vir
0003_01	Europa	False	A/0/S	TRAPPIST-1e	58.0	True	43.0	3576.0	0.0	6715.0	49.0	Alta Suse
0003_02	Europa	False	A/0/S	TRAPPIST-1e	33.0	False	0.0	1283.0	371.0	3329.0	193.0	Sola Suse
0004_01	Earth	False	F/1/S	TRAPPIST-1e	16.0	False	303.0	70.0	151.0	565.0	2.0	W Santantir

In [8]: Image('3.png')

Out[8]: **Wild blueberry**

[Wild blueberry](#) 야생 블루베리의 수확량을 시뮬레이션한 데이터셋입니다.

Features	Unit	Description
Row#		Index
clonesize	m2	The average blueberry clone size in the field
honeybee	bees/m2/min	Honeybee density in the field
bumbles	bees/m2/min	Bumblebee density in the field
andrena	bees/m2/min	Andrena bee density in the field
osmia	bees/m2/min	Osmia bee density in the field
MaxOfUpperTRange	°C	The highest record of the upper band daily air temperature during the bloom season
MinOfUpperTRange	°C	The lowest record of the upper band daily air temperature
AverageOfUpperTRange	°C	The average of the upper band daily air temperature
MaxOfLowerTRange	°C	The highest record of the lower band daily air temperature
MinOfLowerTRange	°C	The lowest record of the lower band daily air temperature
AverageOfLowerTRange	°C	The average of the lower band daily air temperature
RainingDays	Day	The total number of days during the bloom season, each of which has precipitation larger than zero
AverageRainingDays	Day	The average of raining days of the entire bloom season
fruitset		The amount of fruit per tree
fruitmass		The mass of a fruit
seeds		The mass of a seed
yield		The amount of yield

간단하게 여러 아이디어를 실험해볼 수 있는 데이터셋입니다.

```
In [5]: df_berry = pd.read_csv('data/wild_blueberry.csv', index_col='Row#')
df_berry.head()
```

Out[5]:

	clonesize	honeybee	bumbles	andrena	osmia	MaxOfUpperTRange	MinOfUpperTRange	AverageOfUpperTRange	MaxOfLowerTF
Row#									
0	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	
1	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	
2	37.5	0.75	0.25	0.25	0.25	94.6	57.2	79.0	
3	37.5	0.75	0.25	0.25	0.25	94.6	57.2	79.0	
4	37.5	0.75	0.25	0.25	0.25	86.0	52.0	71.9	

In [9]:

Image('4.png')

Out[9]: **Abalone**

[Abalone](#) 데이터셋: 전복의 생육 정보 데이터입니다.

Name	Data Type	Meas.	Description
Sex	nominal		M, F, and I (infant)
Length	continuous	mm	Longest shell measurement
Diameter	continuous	mm	perpendicular to length
Height	continuous	mm	with meat in shell
Whole	continuous	grams	whole abalone
Shucked	continuous	grams	weight of meat
Viscera	continuous	grams	gut weight (after bleeding)
Shell	continuous	grams	after being dried
Rings	integer		+1.5 gives the age in years

분류와 회귀 문제 모두를 다루어 볼 수 있는 데이터셋입니다.

```
In [6]: df_abalone = pd.read_csv('data/abalone.csv')
df_abalone.head()
```

```
Out[6]:
```

	Sex	Length	Diameter	Height	Whole	Shucked	Viscera	Shell	Rings
0	M	0.455	0.365	0.095	0.5140	0.2245	0.1010	0.150	15
1	M	0.350	0.265	0.090	0.2255	0.0995	0.0485	0.070	7
2	F	0.530	0.420	0.135	0.6770	0.2565	0.1415	0.210	9
3	M	0.440	0.365	0.125	0.5160	0.2155	0.1140	0.155	10
4	I	0.330	0.255	0.080	0.2050	0.0895	0.0395	0.055	7

SMS Spam dataset

Spam: SMS 텍스트로 메시지와 Spam 여부를 나타낸 데이터셋입니다.

Name	Type	Description
target	binary	ham or spam
message	text	SMS message

텍스트를 입력으로 분류를 연습하기 위한 데이터셋입니다.

```
In [7]: df_spam = pd.read_csv('data/SMSSpamCollection.tsv', sep='\t')
df_spam
```

Out[7]:

	target	message
0	ham	Go until jurong point, crazy.. Available only ...
1	ham	Ok lar... Joking wif u oni...
2	spam	Free entry in 2 a wkly comp to win FA Cup fina...
3	ham	U dun say so early hor... U c already then say...
4	ham	Nah I don't think he goes to usf, he lives aro...
...	...	...
5567	spam	This is the 2nd time we have tried 2 contact u...
5568	ham	Will ü b going to esplanade fr home?
5569	ham	Pity, * was in mood for that. So...any other s...
5570	ham	The guy did some bitching but I acted like i'd...
5571	ham	Rofl. Its true to its name

5572 rows × 2 columns

Gene expression

유전자 발현 microarray라는 측정 방법을 사용하여,

급성 골수성 백혈병 환자와 급성 림프구성 백혈병환자를 대상으로 유전자 발현도를 측정한 데이셋입니다.

해당 데이터는 총 7131개의 컬럼과 72개의 행을 가진 데이터로,

표본의 수보다 속성의 수가 훨씬 많은 데이터셋입니다.

주요 변수 설명

Name	Type	Description
patient	integer	patient no
cancer	binary	AML: acute myeloid leukemia ALL:acute lymphoblastic leukemia
train	binary	학습 데이터 여부

그외 변수는 유전자의 발현도를 정수로 나타낸 변수들 입니다.

데이터 수에 비해서 입력 변수의 수가 많은 데이터셋입니다.

```
In [8]: df_gene = pd.read_csv('data/gene.csv', index_col='patient')  
df_gene
```

Out[8]:

	AFFX-BioB-5_at	AFFX-BioB-M_at	AFFX-BioB-3_at	AFFX-BioC-5_at	AFFX-BioC-3_at	AFFX-BioDn-5_at	AFFX-BioDn-3_at	AFFX-CreX-5_at	AFFX-CreX-3_at	AFFX-BioB-5_st	...	U73738_at	X06956_at	X16699_at	X83863_at	...
patient																
1	-214	-153	-58	88	-295	-558	199	-176	252	206	...	-125	389	-37	793	
2	-139	-73	-1	283	-264	-400	-330	-168	101	74	...	-36	442	-17	782	
3	-76	-49	-307	309	-376	-650	33	-367	206	-215	...	33	168	52	1138	
4	-135	-114	265	12	-419	-585	158	-253	49	31	...	218	174	-110	627	
5	-106	-125	-76	168	-230	-284	4	-122	70	252	...	57	504	-26	250	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
65	-62	-198	-5	141	-256	-206	-298	-218	-14	100	...	-34	239	-78	707	
66	-58	-217	63	95	-191	-230	-86	-152	-6	-249	...	36	358	2	423	
63	-161	-215	-46	146	-172	-596	-122	-341	171	-147	...	-27	548	-39	809	
64	-48	-531	-124	431	-496	-696	-1038	-441	235	157	...	-121	197	-108	466	
62	-176	-284	-81	9	-294	-493	-393	-141	166	-37	...	132	618	-9	551	

72 rows × 7131 columns



Credit Card Fraud Detection

신용 카드 사기 거래 탐지 데이터 셋입니다.

Name	Type	Description
Time	integer	첫 거래와의 시간 차, 초(second)단위
V1, V2, ... V28	continuous	PCA를 통해 처리된 속성 데이터

Name	Type	Description
amount	continuous	거래 금액
Class	binary	1: Fraud, 0: Other

284,807 건의 거래 중에서 492 건 만이 fraud 입니다.

굉장히 치우침이 심한 데이터셋입니다.

```
In [9]: df_credit = pd.read_pickle('data/credit.pkl')
df_credit.head()
```

Out[9]:		Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	
	0	0	-1.359375	-0.072754	2.537109	1.377930	-0.338379	0.462402	0.239624	0.098694	0.363770	...	-0.018311	0.277832	-0.110
	1	0	1.191406	0.266113	0.166504	0.448242	0.060028	-0.082336	-0.078796	0.085083	-0.255371	...	-0.225830	-0.638672	0.101
	2	1	-1.358398	-1.339844	1.773438	0.379883	-0.503418	1.800781	0.791504	0.247681	-1.514648	...	0.248047	0.771484	0.909
	3	1	-0.966309	-0.185181	1.792969	-0.863281	-0.010307	1.247070	0.237549	0.377441	-1.386719	...	-0.108276	0.005272	-0.190
	4	2	-1.158203	0.877930	1.548828	0.403076	-0.407227	0.095947	0.592773	-0.270508	0.817871	...	-0.009430	0.798340	-0.137

5 rows × 31 columns



Dinosaur List

공룡이름 데이터셋

Name	Type	Description
Name	string	영문 이름
Period	nominal	서식 시기

Name	Type	Description
Diet	nominal	식성
Country	nominal	발견 국가
Name_kr	string	한글 이름
Continent	nominal	발견 대륙

철자 속에 있는 의미를 추출하여 활용해보기 위해 선정한 데이터 입니다.

```
In [10]: df_dino = pd.read_csv('data/dino_cleaned.csv')
df_dino.head()
```

```
Out[10]:
```

	Name	Period	Diet	Country	Name_kr	Continent
0	Aardonyx	Jurassic	herbivore	South Africa	아르도닉스	Africa
1	Abelisaurus	Cretaceous	carnivore	South America	아벨리사우르스	South America
2	Abriktosaurus	Jurassic	herbivore	South Africa	아브릭토사우르스	Africa
3	Abrosaurus	Jurassic	herbivore	China	아브로사우르스	Asia
4	Abydosaurus	Cretaceous	herbivore	North America	아비도사우르스	North America

MoiveLens 100K

[MovieLens 100K](#)

영화 정보: movies_100k.csv

Name	Type	Description
movie id	integer	영화 id
movie title	string	영화 제목

Name	Type	Description
release date	string	출시 시점
unknown, Action, Adventure, ...	boolean	장르 여부

사용자 정보: users_100k.csv

Name	Type	Description
user id	integer	사용자 id
age	integer	나이
gender	boolean	성별
occupation	nominal	직업
zip code	nominal	거주지 우편번호

평점 이력: ratings_100k.csv

Name	Type	Description
user id	integer	사용자 id
item id	integer	영화 id
rating	integer	평점
timestamp	integer	평점 시점, timestamp

카디날리티가 큰 범주형 데이터를 지닌 데이터 셋입니다.

```
In [11]: df_movie = pd.read_csv('data/movies_100k.csv', index_col='movie id')
df_movie.head()
```

Out[11]:

	movie title	release date	unknown	Action	Adventure	Animation	Children's	Comedy	Crime	Documentary	...	Fantasy	Film-Noir	Horror
movie id														
1	Toy Story (1995)	01-Jan-1995	0	0	0	1	1	1	0		0 ...	0	0	
2	GoldenEye (1995)	01-Jan-1995	0	1	1	0	0	0	0		0 ...	0	0	
3	Four Rooms (1995)	01-Jan-1995	0	0	0	0	0	0	0		0 ...	0	0	
4	Get Shorty (1995)	01-Jan-1995	0	1	0	0	0	1	0		0 ...	0	0	
5	Copycat (1995)	01-Jan-1995	0	0	0	0	0	0	1		0 ...	0	0	

5 rows × 21 columns



```
In [13]: df_user = pd.read_csv('data/users_100k.csv', index_col='user id')
df_user.head()
```

Out[13]:

	age	gender	occupation	zip code
user id				

user id				
1	24	M	technician	85711
2	53	F	other	94043
3	23	M	writer	32067
4	24	M	technician	43537
5	33	F	other	15213

In [14]: `df_ratings = pd.read_csv('data/ratings_100k.csv')`
`df_ratings.head()`

Out[14]:

	user id	item id	rating	timestamp
0	196	242	3	881250949
1	186	302	3	891717742
2	22	377	1	878887116
3	244	51	2	880606923
4	166	346	1	886397596

In []: