

```
In [2]: import pandas as pd
import numpy as np
import scipy

import matplotlib as mpl
import matplotlib.pyplot as plt
import seaborn as sns

import warnings
warnings.filterwarnings(action = 'ignore')

from IPython.display import Image

for i in [pd, np, scipy, mpl, sns]:
    print(i.__name__, i.__version__)
```

```
pandas 2.1.4
numpy 1.26.4
scipy 1.11.4
matplotlib 3.8.0
seaborn 0.12.2
```

```
In [2]: Image('34.png')
```

Out[2]:

2-2 확률 분포

확률 변수

- 확률적인 과정의 결과를 수치적으로 표현하기 위한 임의의 수입니다. (일반적으로 대문자로 표기)

기대값 $E[X]$

- 확률 변수의 평균적인 예상값으로 중심 경향성을 표현합니다.

$$E[X + Y] = E[X] + E[Y]$$

$$E[aX] = aE[X]$$

분산 $V(X)$

- 데이터의 변동 정도를 측정하는 지표로 사용되며, 데이터가 중심(평균)으로 부터 흩어진 정도를 나타내는 지표입니다.

$$V(X) = E[(X - E[X])^2] = E[X^2] - E[X]^2$$

$$V(X + Y) = V(X) + 2COV(X, Y) + V(Y)$$

$$\begin{aligned} V(X + Y) &= E[(X + Y - E[X + Y])^2] = E[(X - E(X) + Y - E(Y))^2] \\ &= E[X^2] - E(X)^2 + E[Y^2] - E(Y)^2 + 2E[(X - E[X])(Y - E[Y])] = V(X) + V(Y) + 2COV(X, Y) \end{aligned}$$

$$V(aX) = a^2 V(X)$$

$$V(X - Y) = V(X) + V(Y) - 2COV(X, Y)$$

$$V(-aX) = a^2 V(X)$$

공분산 $COV(X, Y)$

- 두 변수가 함께 변하는 정도를 나타냅니다.

$$COV(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

- 두 변수가 독립이라면, $COV(X, Y) = 0$ 이 됩니다.

이 경우, $V(X + Y) = V(X) + V(Y)$ 가 됩니다.

In [3]: `Image('35.png')`

Out[3]: 표본평균의 모평균과 모분산

- 표본평균은 가설 검정과 신뢰구간등 두루 사용되는 통계량입니다.
- 표본평균도 확률 변수입니다. 표본평균의 모평균과 모분산을 대상 확률 변수의 모평균과 모분산에서 유도해 봅니다.

모평균이 μ , 모분산이 σ^2 인 모집단에서 n 개의 표본을 추출했습니다.

$$X_1, X_2, X_3, \dots, X_n$$

표본평균 $\bar{X}$ 는

$$\bar{X} = \frac{(X_1 + X_2 + \dots + X_n)}{n}$$

입니다.

$$E(\bar{X}) = E\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{E(X_1) + E(X_2) + \dots + E(X_n)}{n}$$

$X_1, \dots, X_n$ 의 모평균이 μ 이므로 $E(X_1), \dots, E(X_n)$ 모두 μ 입니다.

$$\text{따라서, } E(\bar{X}) = \frac{n\mu}{n} = \mu$$

$V(\bar{X}) = V\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right)$ 입니다.

n 개의 표본이 서로 독립이라면,

$X_1, \dots, X_n$ 간의 공분산은 모두 $COV(X_1, X_2) = 0, \dots, COV(X_{n-1}, X_n) = 0$ 입니다.

$$V(\bar{X}) = V\left(\frac{X_1}{n}\right) + V\left(\frac{X_2}{n}\right) + \dots + V\left(\frac{X_n}{n}\right)$$

$X_1, \dots, X_n$ 은 모두 분산이 σ^2 이므로 $V(X_1), \dots, V(X_n)$ 모두 σ^2 이고, $V(aX) = a^2 V(X)$ 이므로

$$V(\bar{X}) = \frac{\sigma^2}{n^2} + \frac{\sigma^2}{n^2} \dots + \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n} \text{ 이 됩니다.}$$

In [4]: `Image('36.png')`

Out[4]: **1. 이산형 확률 분포**

- 이산형(Discrete) 확률 변수가 취하는 값에 대한 확률을 나타내는 분포

분포	확률 변수	매개변수	확률 질량 함수	E(X)	V(X)
베르누이(Bernoulli) 분포	베르누이 시행(0 또는 1)의 결과	p: 1이 나올 확률	$p(1) = p$	p	$p(1 - p)$
이항(Binomial) 분포	연속된 n번의 베르누이 시행에서 n번 중 1이 나온 횟수	p: 1이 나올 확률, n: 총 시행수	$p(x) = \binom{n}{x} p^x (1 - p)^{n-x}$	np	$np(1 - p)$
푸아송(Poisson) 분포	단위 시간 또는 공간에서 발생하는 사건수	λ : 단위 시간 또는 공간에서 발생하는 평균 사건수	$p(x) = \frac{e^{-\lambda} (\lambda)^x}{x!}$	λ	λ

In [5]: `Image('37.png')`

Out[5]: 2. 연속형 확률 분포

- 연속형(Continuous) 확률 변수가 취하는 값에 대한 확률을 나타내는 분포

분포	확률 변수	매개변수	확률 밀도 함수	E(X)	V(X)
지수 (Exponential) 분포	다음 사건이 발생하는 시간	λ : 단위 또는 시간 공간에서 발생하는 평균 사건 수	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
감마 (Gamma) 분포	다음 α 개의 사건이 발생하는 평균 시간	α : 사건의 발생 횟수, β : 단위 시간 또는 공간에서 발생하는 평균 사건 수	$\frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)}$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$
정규(Normal) 분포	좌우 대칭의 종모양 분포	μ : 평균, σ^2 : 분산	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
t 분포	$t = \frac{\bar{X} - \mu}{s/\sqrt{n}}$ $\bar{X}$: 표본 평균 μ : 모평균, s : 표본분산	ν : 자유도	$\frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi\nu}\Gamma(\frac{\nu}{2})} \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}$	$0, \nu > 1$	$\frac{\nu}{\nu-2}, \nu > 2$
카이 제곱 (Chi-Square)	표준 정규 분포를 따르는 k개의 독립인 확률 변수의 제곱의 합 분포	k: 자유도	$\frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}$	k	2k
F 분포	두 개의 카이 제곱 분포를 따르는 확률 변수의 비율	d1: 분자의 자유도 d2: 분모의 자유도 별도 기재		$\frac{d_2}{d_2-2}, d_2 > 2$	$\frac{2 d_2^2 (d_1 + d_2 - 2)}{d_1 (d_2 - 2)^2 (d_2 - 4)}, d_2 > 4$

F 분포의 확률 밀도 함수:

$$\frac{\Gamma\left(\frac{d_1+d_2}{2}\right)}{\Gamma\left(\frac{d_1}{2}\right)\Gamma\left(\frac{d_2}{2}\right)}\left(\frac{d_1}{d_2}\right)^{d_1/2}\frac{x^{d_1/2-1}}{\left(1+\frac{d_1}{d_2}x\right)^{\frac{d_1+d_2}{2}}}$$

```
In [6]: Image('38.png')
```

Out[6]: 자유도의 직관적 이해

- 주어진 확률 변수 중에서 임의로 변경이 가능한 값의 수입니다.

예] 표본 분산: $S = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{n-1}$, ← 표본 분산의 분모(자유도)가 1 차감이 됩니다.

$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$ 표본 분산을 구할 때 표본평균을 사용합니다.

표본 분산을 구하는 과정에서 표본 평균이 고정됩니다. $X_1, \dots, X_n$ 변수중에서 하나의 값은 값이 고정됩니다.

n개의 확률 변수에서 한 개가 고정이 되므로 자유도가 n - 1이 됩니다.

scipy.stats

- 확률 관련 메소드(method) 정리

메소드명	메소드명 기능	설명
rvs	random variates	확률 변수를 생성
pdf	probability density function	확률 밀도 함수
pmf	probability mass function	확률 질량 함수
cdf	cumulative density function	누적 밀도 함수
ppf	percent point function, inverse of cdf	백분위 함수, cdf의 역함수: 0~1사이의 분위의 역함수
sf	survival function, 1 - cdf	1 - cdf

```
In [2]: from scipy.stats import binom, poisson, chi2, f, t, norm, expon, gamma
```

[Ex.1]

$n = 100$, $p = 0.3$ 인 이항분포에서 서로 독립인 표본 500개를 만들어 봅니다.

```
In [3]: '''
이 코드는 Python의 matplotlib 라이브러리를 사용하여
이항 분포의 확률 질량 함수를 시각화하는 데 사용됩니다.
여기에서는 `sns.scatterplot` 함수를 사용하여
이산적인 확률 값을 포함하는 산점도를 생성합니다.

1. `x=np.arange(0, 101)` :
   x축 값으로 0부터 100까지의 숫자 배열을 생성합니다.
   이는 이항 분포의 가능한 모든 결과를 나타냅니다.

2. `y=binom.pmf(np.arange(0, 101), n, p)` :
   y축 값으로는 0부터 100까지의 숫자에 대한 이항 분포의 확률을
   계산합니다. 여기서 `binom.pmf`는 이항 확률 질량 함수를 계산하는
   SciPy의 함수입니다. 이 함수는 이항 분포에서
   특정 값에 대한 확률을 계산합니다.
   `n`은 시행 횟수이고, `p`는 각 시행에서 성공할 확률입니다.

3. `ax=plt.gca().twinx()` :
   이 코드는 현재의 축을 복사하여 새로운 축을 만듭니다.
   `twinx()` 함수는 현재의 축과 x축을 공유하면서
   y축을 별도로 가지는 새로운 축을 생성합니다.
   이렇게 하면 산점도와 선 그래프를 동시에 표시할 수 있습니다.

4. `color='orange', label='Probability'` :
   산점도의 색상을 주황색으로 설정하고,
   범례에 "Probability"라는 레이블을 추가합니다.

5. `plt.show()` : 마지막으로 그래프를 표시합니다.

결과적으로, 이 코드는 0부터 100까지의 값에 대한
이항 분포의 확률 질량 함수를 시각화합니다.
x축은 가능한 결과를, y축은 해당 결과의 확률을 나타냅니다.
동시에 주황색 선 그래프로 이산 확률 값을 시각적으로 나타냅니다.
'''

n = 100 # 베르누이 시행의 수
p = 0.3 # 결과가 1일 확률
```




```

X = binom.rvs(n, p, size=500, random_state=123)
print("표본의 평균:", np.mean(X),
      "모집단(이론적) 평균:", n * p)
print("표본의 분산:", np.var(X, ddof=1),
      "모집단(이론적) 분산:", n * p * (1 - p))
sns.histplot(X)
sns.scatterplot(
    x=np.arange(0, 101),
    y=binom.pmf(np.arange(0, 101), n, p),
    ax=plt.gca().twinx(), color='orange', label='Probability')
plt.show()

```

표본의 평균: 29.924 모집단(이론적) 평균: 30.0

표본의 분산: 21.569362725450905 모집단(이론적) 분산: 21.0



[Ex.2]

1. X 는 $n = 100$, $p = 0.3$ 인 이항분포를 따릅니다. $P(X = 20)$ 을 구합니다.
2. X 는 $n = 100$, $p = 0.3$ 인 이항분포를 따릅니다. $P(X \leq 20)$ 를 구합니다.
3. X 는 $n = 100$, $p = 0.3$ 인 이항분포를 따릅니다. $P(X \leq A) = 0.1$ 를 구합니다.
이 때, A 를 구합니다.

```
In [4]: print("1. {}".format(binom.pmf(20, n=100, p=0.3)))
```

```
1. 0.007575644925726051
```

```
In [5]: print("2. {}".format(binom.cdf(20, n=100, p=0.3)))
```

```
2. 0.016462853241869434
```

```
In [6]: print("3. {}".format(binom.ppf(0.1, n=100, p=0.3)))
```

```
3. 24.0
```


[Ex.3]

λ 가 10인 포아송 분포에서 서로 독립인 표본 500개를 만들어 봅니다.

```
In [7]: lamb = 10
X = poisson.rvs(lamb, size=500, random_state=123)
print("표본의 평균:", np.mean(X), "모집단(이론적) 평균:", lamb)
print("표본의 분산:", np.var(X, ddof=1), "모집단(이론적) 분산:", lamb)
sns.histplot(X)
sns.scatterplot(x=np.arange(0, 31),
                y=poisson.pmf(np.arange(0, 31), 10),
                ax=plt.gca().twinx(), color='orange')
plt.show()
```

표본의 평균: 10.014 모집단(이론적) 평균: 10

표본의 분산: 9.152108216432866 모집단(이론적) 분산: 10



[Ex.4]

손님이 10분 동안에 평균 5명 온다고 할 때,
 새로운 손님이 4분 이내에 올 확률을 지수 분포를 이용하여 구해봅시다.
 손님이 오는 사건은 서로 독립입니다.

[풀이]

$\lambda = 5$, 4분의 확률변수 $X = 4\text{분} / 10\text{분}$,

$P(X \leq 0.4; \lambda = 5)$

In [8]: # 풀이 과정의 내용을 계산해봅니다.

```
expon.cdf(0.4, scale=1/5)
```

Out[8]: 0.8646647167633873

3. 주요 분포의 특징

정규분포

표준정규분포: 평균이 0, 분산이 1인 정규 분포

중심극한정리: 표본평균의 분포는 모집단의 분포와 상관 없이

표본의 크기가 커질 수록 정규 분포에 가까워진다.

[Ex.5]

λ 가 5인 포아송 분포에서 확률 변수를 n 개씩 1000번 뽑아 각 표집의 표본평균을 구합니다.

n 을 5, 10, 30, 100 바꾸어 가며, Kolmogorov-Smirnov로 정규성 검정을 하여 pvalue를 구합니다.

(pvalue는 0과 1사이의 수이며 높을 수록 정규분포일 확률이 높음을 뜻합니다.)

In [9]: '''

코드는 Python의 matplotlib와 scipy.stats를 사용하여
포아송 분포의 표본 평균에 대한 카이제곱 검정(Kolmogorov-Smirnov test)을


수행하고, 그 결과를 시각화하는 것입니다.

1. ``np.random.seed(123)``:
난수 생성기의 시드를 설정하여 결과의 재현성을 보장합니다.
2. ``from scipy.stats import kstest``:
`scipy` 라이브러리에서 카이제곱 검정을 수행하기 위해
필요한 `kstest` 함수를 가져옵니다.
3. ``fig, axes = plt.subplots(2, 2, figsize=(12, 7))``:
2x2 행렬 모양의 서브플롯을 생성하여 그림의 크기를 설정합니다.
4. ``for i, ax in zip([3, 10, 30, 100], axes.ravel()):``:
각각의 `subplot`에 대해 반복합니다.
``zip()`` 함수를 사용하여 `subplot`과 샘플 크기(3, 10, 30, 100)를 묶습니다.
5. ``sam_mean = list()``:
표본 평균을 저장할 빈 리스트를 생성합니다.
6. ``for _ in range(1000):``:
- ``X = poisson.rvs(mu=5, size=i)``:
크기가 ``i``인 포아송 분포의 랜덤 표본을 생성합니다.
이 때, ``mu``는 포아송 분포의 평균(λ)을 나타냅니다.
- ``sam_mean.append(X.mean())``:
생성된 표본의 평균을 ``sam_mean`` 리스트에 추가합니다.
7. ``sns.histplot(sam_mean, ax=ax)``:
`seaborn` 라이브러리를 사용하여 현재 `subplot`에
표본 평균의 히스토그램을 그립니다.
8. ``_, pvalue = kstest(sam_mean, norm.cdf, args=[np.mean(sam_mean),
np.std(sam_mean)])``:
`kstest` 함수를 사용하여 표본 평균의 카이제곱 검정을 수행합니다.
이때, 정규분포의 누적 분포 함수인 ``norm.cdf``를 사용합니다.
카이제곱 검정의 결과는 `p-value`로 반환됩니다.
9. ``ax.set_title('sample size: {}, pvalue:{:.3f}'.format(i, pvalue))``:
현재 `subplot`의 제목을 설정합니다.
이때, 표본 크기와 카이제곱 검정의 `p-value`를 포함하여 표시합니다.
10. ``plt.tight_layout()``:
`subplot`들 간의 간격을 조절하여 레이아웃을 조정합니다.
11. ``plt.show()``: 그림을 화면에 표시합니다.

결과적으로, 이 코드는 포아송 분포의 다양한 크기의 표본을 생성하고,
각 표본의 평균에 대해 카이제곱 검정을 수행하여 정규성을 평가합니다.
그 결과를 히스토그램과 함께 시각화하여 표시합니다.
...

`np.random.seed(123)`

```
from scipy.stats import kstest
fig, axes = plt.subplots(2, 2, figsize=(12, 7))
for i, ax in zip([3, 10, 30, 100], axes.ravel()):
    sam_mean = list()
    for _ in range(1000):
        X = poisson.rvs(mu=5, size=i) #  $\mu \leftarrow \lambda$ 
        sam_mean.append(X.mean())
    sns.histplot(sam_mean, ax=ax)
    _, pvalue = kstest(sam_mean, norm.cdf,
                      args=[np.mean(sam_mean), np.std(sam_mean)])
    ax.set_title('sample size: {}, pvalue:{:.3f}'.format(i, pvalue))
plt.tight_layout()
plt.show()
```



표본의 크기가 커질 수록 pvalue가 높아 집니다. 이는 곧 정규분포에 가까워짐을 의미합니다.

In [3]: `Image('39.png')`

Out[3]: **카이제곱분포**

$Z_1, \dots, Z_k$ 이 서로 독립이고 표준정규분포인 확률 함수 일 때,

$$Q = \sum_{i=1}^k Z_i^2$$

$$Q \sim \chi_k^2$$

감마분포와의 관계

$$\chi_k^2 = \Gamma\left(\frac{k}{2}, \frac{1}{2}\right)$$

t 분포

- t분포는 표준정규분포(Z)와 χ_{n-1}^2 과의 아래와 결합으로 구성된 분포입니다. (n은 표본수)
- 태생적으로, t분포는 모집단이 정규분포를 따른다는 가정을 하고 있습니다.

$$t = \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}}, \text{ s는 표본표준편차. } s = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$t_{n-1} = \frac{Z}{\sqrt{\frac{\chi_{n-1}^2}{n-1}}}$$

$$t_v = \frac{Z}{\sqrt{\frac{\chi_v^2}{v}}}, v = n - 1$$

In [4]: Image('40.png')

Out[4]: 유도 과정

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$(n-1)s^2 = \sum_{i=1}^n (X_i - \mu + \mu - \bar{X})^2$$

$$(n-1)s^2 = \sum_{i=1}^n \left((X_i - \mu)^2 + 2(X_i - \mu)(\mu - \bar{X}) + (\mu - \bar{X})^2 \right)$$

$$\sum_{i=1}^n 2(X_i - \mu)(\mu - \bar{X}) = \sum_{i=1}^n 2(X_i\mu - X_i\bar{X} - \mu^2 + \mu\bar{X})$$

$$= 2n(\bar{X}\mu - \bar{X}^2 - \mu^2 + \mu\bar{X})$$

$$= -2n(\bar{X} - \mu)^2$$

$$(n-1)s^2 = \sum_{i=1}^n (X_i - \mu)^2 - 2n(\bar{X} - \mu)^2 + n(\mu - \bar{X})^2$$

$$= \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

$$(n-1)\frac{s^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - n \left(\frac{\bar{X} - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - \left(\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \right)^2$$

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi_n^2, \left(\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \right)^2 \sim \chi_1^2$$

$$chi_{n-1}^2 = chi_n^2 - chi_1^2$$

$$\text{따라서, } (n-1)\frac{s^2}{\sigma^2} \sim chi_{n-1}^2$$

$$\begin{aligned}
 t &= \frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} = \frac{\frac{\bar{X} - \mu}{\sigma}}{\frac{\frac{s}{\sigma}}{\sqrt{n}}} \\
 &= \frac{\frac{\bar{X} - \mu}{\sigma}}{\frac{s}{\sigma}} \\
 &= \frac{Z}{\sqrt{\frac{(n-1) \frac{s^2}{\sigma^2}}{n-1}}} \sim \frac{Z}{\sqrt{\frac{\chi_{n-1}^2}{n-1}}}
 \end{aligned}$$

In [5]: Image('41.png')

Out[5]: **F 분포**

$$F(d_1, d_2) = \frac{S_1/d_1}{S_2/d_2}$$

$$S_1 \sim \chi_{d_1}^2$$

$$S_2 \sim \chi_{d_2}^2$$

즉, F 분포는 분자는 자유도가 d_1 인 카이제곱분포, 분모는 자유도가 d_2 인 카이제곱분포인 형태를 하고 있습니다

In [8]: Image('42.png')

Out[8]:

4. 신뢰 구간

- 신뢰 구간: 모집단의 모수에 대한 추정값이 존재할 것으로 예상되는 범위 나타냅니다.

표본에서 얻은 정보를 이용하여 모집단의 모수에 대한 가능한 값의 범위를 제시합니다.

- 신뢰 수준: 모집단의 모수가 신뢰 구간 내에 있을 확률입니다.

신뢰 구간을 95% 정한다면, 모수가 신뢰 구간에 있을 확률이 95%라는 것입니다.

- 신뢰 구간의 형태

점 추정치(Point Estimate) $\pm$ 주변 오차 범위(Margin of Error)

- 표본평균을 통한 신뢰 구간의 추정

$$P(-c \leq \text{통계량} \leq c) = \text{신뢰 수준}$$

$$P(\text{통계량} < -c) = \frac{\alpha}{2}, \alpha(\text{유의 수준}) = 1 - \text{신뢰 수준}$$

$$-c = F^{-1}(\alpha/2), F^{-1} \text{는 통계량의 분포의 누적확률함수의 역함수(Percentile Point Function)}$$

$$c = -F^{-1}(\alpha/2)$$

In [9]: Image('43.png')

Out[9]: 1. 모분산을 알고 있을 경우

정규분포를 사용합니다.

$$Z(\text{통계량}) = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

$c = -Z_{\alpha/2}, -Z_{\alpha/2}$ 는 정규분포에서의 $F^{-1}(\alpha/2)$ 입니다.

$$-Z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq Z_{\alpha/2}$$

$$\bar{X} - Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

2. 모분산을 모를 경우

t-분포를 사용합니다.

$$t(\text{통계량}) = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

$c = -t_{\alpha/2, v=n-1}, -t_{\alpha/2, v=n-1}$ 는 t분포에서의 $F^{-1}(\alpha/2)$ 입니다.

$$-t_{\alpha/2, v=n-1} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{\alpha/2, v=n-1}$$

$$\bar{X} - t_{\alpha/2, v=n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2, v=n-1} \frac{S}{\sqrt{n}}$$

In [10]: Image('44.png')

Out[10]: **[Ex.6]**

모분산이 4인 모집단에서 100개의 표본을 뽑았습니다. 이 때, 표본 평균이 124 입니다.
 표본수 100개는, 표본평균의 분포가 정규분포를 따르기에 충분한 수라고 가정합니다.
 이 때, 모평균의 신뢰구간을 구하세요.(신뢰수준이 95%)

[풀이]

$$\alpha = 1 - 0.95 = 0.05$$

$$124 - Z_{0.025} \frac{2}{10} \leq \mu \leq 124 + Z_{0.025} \frac{2}{10}$$

In [10]: # 풀이 과정의 내용을 계산해봅니다.

```
sigma2 = 4
n_sample = 100
x_bar_std = (sigma2 / n_sample) ** 0.5
x_bar = 124
c = -norm.ppf(0.025)
x_bar - x_bar_std * c, x_bar + x_bar_std * c
```

Out[10]: (123.60800720309199, 124.39199279690801)

In [11]: Image('45.png')

Out[11]: **[Ex.7]**

모집단은 정규분포를 따르고 25개 표본을 뽑았습니다.

이 때, 표본 평균이 104이고, 표본 분산이 9입니다.

모평균의 신뢰구간을 구하세요.(신뢰수준이 95%)

[풀이]

$$104 - t_{0.025, v=24} \frac{3}{5} \leq \mu \leq 104 + t_{0.025, v=24} \frac{3}{5}$$

In [11]: *# 풀이 과정의 내용을 계산해봅니다.*

```
s2 = 9
n_sample = 25
s_div_sq = (s2 / n_sample) ** 0.5
x_bar = 104
c = -t.ppf(0.025, df=n_sample-1)
x_bar - s_div_sq * c, x_bar + s_div_sq * c
```

Out[11]: (102.76166086302318, 105.23833913697682)

In []: