

ADP(데이터분석 전문가) 실기시험 준비자료

1부 — 시험개요/답안작성전략 · 1단계 전처리&EDA · 2단계 통계검정 · 3단계 분류모델링 · 4단계 회귀모델링

[사용자] 자 이젠 실기시험을 준비해 줘. 필기시험처럼 마찬가지로 실기시험을 위해 알아야 할 내용과 실제 기출 시험문제나 그에 준하는 문제를 내고 답변을 작성해 줘. 답변을 작성하는 기준과 점수를 많이 받을 수 있는 내용을 빠뜨리지 말고 시험은 파이썬으로 준비하고 있어. 단계별로 하나씩 진행해 줘

ADP 실기시험 대비 자료 (1) — 시험 개요 및 답안 작성 전략

실기시험은 필기와 완전히 다른 성격의 시험입니다. "아는 것"을 넘어 **코드로 구현하고, 그 결과를 논리적으로 설명하는 능력**을 평가하기 때문에, 이론 정리보다 **실전 답안 작성 방식**이 합격을 좌우합니다. 단계별로 하나씩 진행하되, 먼저 시험의 전체 구조와 점수를 좌우하는 **답안 작성 원칙**을 확실히 잡고 시작하겠습니다.

1. 실기시험 개요

항목	내용
시험시간	240분 (4시간)
방식	CBT(Computer Based Test), 오픈북(단, 인터넷 검색은 불가한 경우가 대부분이므로 사전 준비 자료 반입 여부는 공지 확인 필요)
배점	100점 만점, 75점 이상 합격
언어	R 또는 Python 중 선택 (본 자료는 Python 기준)
문제 구성	일반적으로 대문제 3개(각기 다른 데이터셋), 각 대문제당 2~4개의 소문제로 구성 — 전처리, 통계분석(검정), 머신러닝 모델링, 시각화가 섞여서 출제됨
출제 방향	최근 회차부터는 시험 시행 전 주최측(K-data)이 출제 방향을 사전 공지하는 경우가 있어, 반드시 응시 전 공지사항을 확인해야 함

최근 출제경향: 단순 코드 실행 능력보다 ① **왜 그 방법을 선택했는지 근거를 서술**하고 ② **결과를 해석**하는 능력을 강하게 요구하는 추세입니다. 정형 데이터 전처리·통계검정·머신러닝 모델링이 핵심 축이며, 텍스트(비정형) 데이터 문제도 종종 출제됩니다.

2. 답안 작성 전략 — 점수를 좌우하는 핵심 원칙

이 부분이 실기 합격의 실질적인 관건입니다. 코드가 맞아도 **서술이 빈약하면 감점**되고, 반대로 코

드에 사소한 오류가 있어도 논리적 근거와 해석이 탄탄하면 부분점수를 받을 수 있습니다.

① 답안의 기본 구조 (매 소문제마다 이 순서를 지킬 것)

- 1) 분석 방법/모델 선정 및 그 이유 서술
- 2) 코드 작성 (주석 포함, 가정 명시)
- 3) 실행 결과(수치, 표, 그래프) 제시
- 4) 결과에 대한 해석 및 결론 서술

- 코드만 던지고 끝내는 답안은 **절대 고득점 불가**. 반드시 "무엇을, 왜, 어떻게 해석했는지"를 문장으로 서술해야 합니다.
- 실제 합격 수기에서도 "답안에 일관성이 있을 것, 모델 선택 시 선택한 이유를 설명할 것, 선택한 모델이 다른 모델에 비해 가지는 장단점과 근본적 한계를 설명할 것" 등이 채점 가이드라인으로 안내된 사례가 있습니다.

② 통계 분석/가설검정 문제에서 절대 빠뜨리면 안 되는 요소

필수 요소	설명
가정(assumption) 명시	"정규성을 만족한다고 가정한다" 등 문제에서 준 조건을 명확히 restate
귀무가설(H0)/대립가설(H1)	검정 문제는 반드시 가설을 먼저 명시
유의수준(α)	문제에 제시된 유의수준을 명시 (예: 유의수준 5%)
검정통계량 & p-value	코드 실행 결과의 수치를 반드시 답안에 그대로 제시
결론(기각/채택) 및 해석	"p-value가 α 보다 작으므로 귀무가설을 기각한다. 즉, ~~라는 것을 의미한다"까지 문장으로 마무리

③ 머신러닝 모델링 문제에서 놓치면 안 되는 요소

- **데이터 분할 근거**: train/test 분할 비율과 이유(예: 데이터가 적어 8:2로 분할)
- **전처리 근거**: 결측치/이상치 처리, 인코딩, 스케일링을 왜 했는지 한 줄이라도 서술
- **모델 선택 이유**: "종속변수가 이진 범주형이므로 로지스틱 회귀와 랜덤포레스트를 비교" 등
- **평가지표 선택 근거**: 불균형 데이터라면 Accuracy 대신 F1-score/AUC 를 쓰는 이유 명시
- **모델 간 비교 및 최종 선택**: 성능 지표를 표로 정리하고 최종 모델과 그 근거를 서술
- **한계/개선방안 언급**: "데이터 수가 적어 과적합 가능성이 있으며, 추가 데이터 수집이나 정규화 기법 적용을 고려할 수 있다" 같은 한 줄이 가점 요소가 됨

④ 시각화 문제

- 그래프만 그리고 끝내지 말고, 그래프가 보여주는 패턴을 1~2 문장으로 반드시 해석
- 축 레이블, 제목, 범례를 반드시 포함 (실무성 평가)

⑤ 서술형(개념 설명) 문제

- 필기시험 대비 자료에서 정리한 "정의 → 특징 → 예시" 구조를 그대로 활용
- 실제 채점 사례에서 "정확도와 F1-score 계산 공식을 자세히 적었다"는 것이 고득점 요인으로 언급된 바 있음 — **공식을 안다면 반드시 명시적으로 적을 것**

3. 파이썬 실기 필수 라이브러리 체크리스트

목적	라이브러리
데이터 처리	pandas, numpy
통계분석/검정	scipy.stats, statsmodels
머신러닝	scikit-learn
시각화	matplotlib, seaborn
(텍스트) 자연어처리	re, konlpy(한국어 형태소분석), sklearn.feature_extraction.text
시계열	statsmodels.tsa

1 단계: 데이터 전처리 & 탐색적 데이터 분석(EDA)

실기시험의 모든 대문제는 **전처리에서 시작**합니다. 첫 소문제에서 틀리면 이후 문제 전체가 흔들리므로 가장 기본이자 중요한 단계입니다.

핵심 체크리스트

항목	확인할 것
데이터 구조 파악	df.info(), df.shape, df.head()
결측치 확인	df.isnull().sum()
결측치 처리	삭제 vs 대치(평균/중앙값/최빈값/모델 기반) — 왜 그 방법을 선택했는지 근거 필수
이상치 확인	박스플롯, IQR 기준($Q1 - 1.5IQR \sim Q3 + 1.5IQR$)
이상치 처리	제거 vs 대치 vs 유지 — 도메인 근거로 판단
자료형 변환	범주형 변수를 문자열이 아닌 category형으로, 날짜는 datetime으로
인코딩	순서형 → Label Encoding, 명목형 → One-Hot Encoding
스케일링	표준화(StandardScaler) vs 정규화(MinMaxScaler) — 거리 기반 모델(SVM, KNN, 군집)에는 필수, 트리 기반 모델(RF, XGB)은 불필요

항목	확인할 것
파생변수 생성	문제에서 힌트를 주는 경우가 많음 (예: 날짜에서 요일/월 추출)

실기유형 연습문제 (1) — 데이터 전처리 & EDA

※ ADP 실기는 문제 원문을 공식적으로 공개하지 않으므로, 아래는 실제 시행된 시험의 출제 패턴(제공된 CSV 데이터 → 전처리 → 통계/모델링으로 이어지는 구조)을 반영하여 재구성한 기출유형 연습문제입니다.

[문제]

다음은 어느 온라인 쇼핑몰의 고객 구매 데이터(customer.csv)이다. 변수는 다음과 같다.

- age: 고객 나이 (일부 결측치 존재)
- gender: 성별 (M/F)
- region: 거주 지역 (범주형, 5 개 지역)
- visit_count: 최근 3 개월 방문 횟수
- total_spent: 최근 3 개월 총 구매금액 (일부 이상치 존재로 추정)
- membership_years: 회원 가입 연차

(1-1) 데이터의 기본 구조를 파악하고, 결측치와 이상치를 확인하시오. **(1-2)** 결측치와 이상치에 대한 적절한 처리 방안을 근거와 함께 제시하고 처리하시오. **(1-3)** 처리된 데이터를 바탕으로 total_spent와 visit_count, membership_years 간의 관계를 시각화하고 해석하시오.

모범 답안

(1-1) 데이터 구조 파악 및 결측치/이상치 확인

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('customer.csv')

# 1) 기본 구조 파악
print(df.shape)
print(df.info())
print(df.head())
print(df.describe())

# 2) 결측치 확인
print(df.isnull().sum())

# 3) 이상치 확인 (박스플롯 + IQR)
```

```
plt.figure(figsize=(6,4))
sns.boxplot(y=df['total_spent'])
plt.title('total_spent 분포 및 이상치 확인')
plt.show()

Q1 = df['total_spent'].quantile(0.25)
Q3 = df['total_spent'].quantile(0.75)
IQR = Q3 - Q1
lower = Q1 - 1.5 * IQR
upper = Q3 + 1.5 * IQR
outliers = df[(df['total_spent'] < lower) | (df['total_spent'] > upper)]
print(f"이상치 경계: {lower:.1f} ~ {upper:.1f}")
print(f"이상치 개수: {len(outliers)}건")
```

[서술] df.info()와 isnull().sum() 결과, age 컬럼에 결측치가 존재함을 확인하였다. total_spent는 박스플롯 확인 결과 우측 꼬리가 긴 분포를 보이며, IQR 기준($Q1 - 1.5 \times IQR \sim Q3 + 1.5 \times IQR$)을 벗어나는 이상치가 다수 존재함을 확인하였다.

(1-2) 결측치·이상치 처리 (근거 포함)

```
# 결측치 처리: age는 연속형이며 극단적으로 치우친 분포가 아니라고 가정,
# 평균 대치 시 분산이 과소추정될 수 있으므로 중앙값(median)으로 대치하여 이상치 영향 최소화
df['age'] = df['age'].fillna(df['age'].median())

# 이상치 처리: total_spent는 실제 '고액 구매 고객'일 가능성이 있어 무작정 삭제 시
# 정보 손실 위험이 크므로, 삭제 대신 상/하한 경계값으로 대체(Capping)하는 방법을 선택
df['total_spent'] = np.where(df['total_spent'] > upper, upper,
                             np.where(df['total_spent'] < lower, lower, df['total_spent']))

print(df.isnull().sum())
print(df['total_spent'].describe())
```

[서술] age의 결측치는 평균 대치 시 이상치(왜도)의 영향을 받을 수 있어 **중앙값 대치**를 선택하였다. total_spent의 이상치는 실제 우수 고객(VIP)일 가능성을 배제할 수 없어 **단순 삭제 대신 IQR 상한/하한값으로 대체(Winsorizing/Capping)**하는 방법을 적용하여 데이터 손실 없이 극단값의 영향을 완화하였다. (※ 만약 문제에서 "이상치가 명백한 오류"라는 조건을 제시했다면 삭제가 더 적절할 수 있으므로, 문제의 조건에 따라 처리 방법의 근거를 다르게 서술하는 것이 중요하다.)

(1-3) 변수 간 관계 시각화 및 해석

```
fig, axes = plt.subplots(1, 2, figsize=(12,5))

sns.scatterplot(data=df, x='visit_count', y='total_spent', ax=axes[0])
axes[0].set_title('방문횟수 vs 총구매금액')

sns.scatterplot(data=df, x='membership_years', y='total_spent', ax=axes[1])
axes[1].set_title('가입연차 vs 총구매금액')

plt.tight_layout()
plt.show()
```

```
# 상관계수로 관계의 강도 확인
print(df[['visit_count', 'total_spent', 'membership_years']].corr())
```

[서술] 산점도 확인 결과, visit_count가 증가할수록 total_spent도 함께 증가하는 **양(+)**의 선형 관계가 관찰되며, 상관계수 역시 이를 뒷받침한다. 반면 membership_years와 total_spent 간에는 뚜렷한 패턴이 관찰되지 않아, 가입 연차 자체보다는 **실제 방문 빈도가 구매금액에 더 직접적인 영향을 미치는 요인**으로 해석된다. 이는 이후 예측 모델링 시 visit_count를 중요 변수로 우선 고려해야 함을 시사한다.

이 답안에서 점수를 받는 핵심 포인트 정리

- ☒ 결측치/이상치를 확인하는 코드와 수치적 근거(경계값, 개수)를 명시했는가
- ☒ 처리 방법을 선택한 이유를 논리적으로 서술했는가 (단순 "제거했다"가 아니라 "왜"가 있어야 함)
- ☒ 그래프에 제목·축 레이블을 포함했는가
- ☒ 시각화 결과에 대한 해석 문장이 있는가
- ☒ 발견한 패턴을 다음 분석 단계와 연결지어 서술했는가 (모델링에 어떤 시사점을 주는지)

[사용자] 네

ADP 실기시험 대비 자료 (2) — 통계 분석 및 가설검정

통계 검정 문제는 ADP 실기에서 **가장 정형화된 답안** 틀을 가진 파트입니다. 앞서 필기에서 정리한 개념을 그대로 코드로 구현하고, **가설 설정 → 검정 수행 → 결론 도출**의 형식만 정확히 지키면 안정적으로 점수를 확보할 수 있는 영역입니다.

핵심 체크리스트 — 검정 방법 선택 기준

상황	검정 방법	Python 함수
한 집단의 평균이 특정값과 다른지	단일표본 t-검정	scipy.stats.ttest_1samp
두 독립 집단 간 평균 비교	독립표본 t-검정	scipy.stats.ttest_ind
동일 집단의 사전/사후 비교	대응표본 t-검정	scipy.stats.ttest_rel
3개 이상 집단 간 평균 비교	분산분석(ANOVA)	scipy.stats.f_oneway / statsmodels ols
두 범주형 변수 간 독립성	카이제곱 독립성 검정	scipy.stats.chi2_contingency

상황	검정 방법	Python 함수
관찰빈도가 특정 분포를 따르는지	카이제곱 적합도 검정	scipy.stats.chisquare
두 연속형 변수의 선형관계	상관분석	scipy.stats.pearsonr / spearmanr
정규성 검정	Shapiro-Wilk 검정	scipy.stats.shapiro
등분산성 검정	Levene 검정	scipy.stats.levene

⚠ **중요:** t-검정이나 ANOVA를 수행하기 전, 문제에서 명시적으로 요구하지 않아도 **정규성·등분산성 가정을 먼저 언급**하면 가점 요소가 됩니다. (단, 시간이 부족하면 "정규분포를 따른다고 가정한다"는 문제의 조건을 그대로 인용해도 무방합니다.)

답안 작성 표준 틀 (반드시 이 순서를 지킬 것)

- ① 가설 설정: H_0 (귀무가설), H_1 (대립가설)을 명확한 문장으로 서술
- ② 유의수준 명시: $\alpha = 0.05$ (문제에서 제시한 값)
- ③ (필요시) 정규성/등분산성 검정 결과 언급
- ④ 검정 수행 코드 및 통계량, p-value 출력
- ⑤ 결론: p-value와 α 비교 → 기각/채택 → 실무적 의미까지 서술

실기유형 연습문제 (2) — 독립표본 t-검정

※ 아래 문제는 실제 시행된 시험의 출제 패턴을 반영하여 재구성한 기출유형 연습문제입니다.

[문제]

어느 제조공장에서 기존 설비(A)와 신규 설비(B)로 생산한 부품의 강도(kg/cm²)를 각각 15개, 18개 측정하였다. 신규 설비가 기존 설비보다 부품 강도를 유의하게 향상시켰는지 유의수준 5%에서 검정하시오. (단, 두 집단 모두 정규분포를 따른다고 가정한다.)

A 설비: [72.1, 68.5, 70.2, 71.8, 69.4, 73.0, 70.5, 68.9, 71.2, 69.8, 72.5, 70.1, 71.0, 69.5, 70.8]
 B 설비: [75.2, 73.8, 76.1, 74.5, 77.0, 75.8, 74.2, 76.5, 75.0, 73.5, 76.8, 75.5, 74.8, 77.2, 76.0, 75.3, 74.6, 76.3]

모범 답안

① 가설 설정

- H_0 (귀무가설): 신규 설비(B)와 기존 설비(A)의 평균 강도에는 차이가 없다 ($\mu_A = \mu_B$)
- H_1 (대립가설): 신규 설비(B)의 평균 강도가 기존 설비(A)보다 크다 ($\mu_A < \mu_B$) — 단측검정

② 유의수준: $\alpha = 0.05$

③④ 등분산성 검정 및 t-검정 수행

```
import numpy as np
from scipy import stats

A = np.array([72.1, 68.5, 70.2, 71.8, 69.4, 73.0, 70.5, 68.9, 71.2, 69.8, 72.5, 70.1,
71.0, 69.5, 70.8])
B = np.array([75.2, 73.8, 76.1, 74.5, 77.0, 75.8, 74.2, 76.5, 75.0, 73.5, 76.8, 75.5,
74.8, 77.2, 76.0, 75.3, 74.6, 76.3])

# 등분산성 검정 (Levene)
levene_stat, levene_p = stats.levene(A, B)
print(f"Levene 검정 통계량: {levene_stat:.4f}, p-value: {levene_p:.4f}")

# 등분산 가정 여부에 따라 equal_var 옵션 결정
equal_var = levene_p > 0.05

# 독립표본 t-검정 (단측검정: alternative='less' → A가 B보다 작다)
t_stat, p_value = stats.ttest_ind(A, B, equal_var=equal_var, alternative='less')
print(f"t-통계량: {t_stat:.4f}")
print(f"p-value: {p_value:.6f}")
print(f"A 평균: {A.mean():.2f}, B 평균: {B.mean():.2f}")
```

[서술] Levene 검정 결과 p-value가 0.05보다 크게 나와(등분산 가정 만족 시) 등분산을 가정한 t-검정을 수행하였다(만약 등분산 가정이 기각되면 equal_var=False로 Welch's t-test를 수행해야 함을 병행 서술).

⑤ 결론

[서술] 독립표본 t-검정 결과 p-value가 0.05보다 작게 산출되었으므로(실제 데이터 기준 p-value ≈ 0.0000 수준), 유의수준 5%에서 귀무가설을 기각한다. 즉, **신규 설비(B)로 생산한 부품의 평균 강도(약 75.4kg/cm²)가 기존 설비(A)의 평균 강도(약 70.6kg/cm²)보다 통계적으로 유의하게 높다고 판단할 수 있다.** 따라서 신규 설비 도입이 부품 강도 향상에 실질적인 효과가 있었다고 결론 지을 수 있다.

실기유형 연습문제 (3) — 카이제곱 독립성 검정

[문제]

아래는 연령대(20대/30대/40대이상)에 따른 특정 스마트폰 브랜드(A/B/C) 선호도를 조사한 교차표이다. 연령대와 브랜드 선호도 간에 유의미한 관계가 있는지 유의수준 5%에서 검정하시오.

구분	브랜드A	브랜드B	브랜드C
20대	50	30	20
30대	30	40	30
40대이상	20	30	50

모범 답안

① 가설 설정

- H_0 (귀무가설): 연령대와 브랜드 선호도는 서로 독립이다 (관련이 없다)
- H_1 (대립가설): 연령대와 브랜드 선호도는 서로 독립이 아니다 (관련이 있다)

② 유의수준: $\alpha = 0.05$

③ 검정 수행

```
import numpy as np
from scipy.stats import chi2_contingency

table = np.array([
    [50, 30, 20], # 20대
    [30, 40, 30], # 30대
    [20, 30, 50], # 40대 이상
])

chi2, p, dof, expected = chi2_contingency(table)

print(f"카이제곱 통계량: {chi2:.4f}")
print(f"자유도: {dof}")
print(f"p-value: {p:.6f}")
print("기대빈도표:\n", np.round(expected, 2))
```

④ 결론

[서술] 카이제곱 독립성 검정 결과, 카이제곱 통계량은 약 27.8(예시 수치), 자유도는 $(3-1) \times (3-1) = 4$, p-value는 0.05보다 작게 산출되었다. 따라서 유의수준 5%에서 귀무가설을 기각하며, **연령대에 따라 스마트폰 브랜드 선호도에 통계적으로 유의미한 차이가 존재한다고 결론지을 수 있다.** 실제 교차표를 살펴보면 20대는 브랜드A를, 40대 이상은 브랜드C를 상대적으로 더 선호하는 경향이 관찰되어, **연령대별 타겟 마케팅 전략 수립 시 이러한 선호 차이를 반영할 필요가 있다는** 실무적 시사점을 제시할 수 있다.

실기유형 연습문제 (4) — 일원배치 분산분석(One-way ANOVA)

[문제]

세 가지 비료(A, B, C)를 사용한 작물의 수확량(kg) 데이터가 아래와 같다. 비료 종류에 따라 평균 수확량에 유의한 차이가 있는지 유의수준 5%에서 검정하고, 차이가 있다면 사후검정을 통해 어느 그룹 간 차이인지 확인하시오.

```
비료A: [23, 25, 21, 24, 22]
비료B: [28, 30, 27, 29, 31]
```

비료C: [20, 19, 22, 18, 21]

모범 답안

① 가설 설정

- H_0 : 세 비료 그룹의 평균 수확량은 모두 같다 ($\mu_A = \mu_B = \mu_C$)
- H_1 : 적어도 한 그룹의 평균은 다르다

② 유의수준: $\alpha = 0.05$

③④ 검정 수행 및 사후검정

```
import numpy as np
from scipy import stats
import pandas as pd
from statsmodels.stats.multicomp import pairwise_tukeyhsd

A = [23, 25, 21, 24, 22]
B = [28, 30, 27, 29, 31]
C = [20, 19, 22, 18, 21]

# 정규성 검정 (각 그룹)
for name, data in zip(['A','B','C'], [A,B,C]):
    stat, p = stats.shapiro(data)
    print(f"{name} 정규성 검정 p-value: {p:.4f}")

# 등분산성 검정
levene_stat, levene_p = stats.levene(A, B, C)
print(f"Levene 등분산 검정 p-value: {levene_p:.4f}")

# 일원배치 분산분석
f_stat, p_value = stats.f_oneway(A, B, C)
print(f"F-통계량: {f_stat:.4f}, p-value: {p_value:.6f}")

# 사후검정 (Tukey HSD) - ANOVA 결과 유의할 경우 수행
values = A + B + C
groups = ['A']*5 + ['B']*5 + ['C']*5
tukey = pairwise_tukeyhsd(endog=values, groups=groups, alpha=0.05)
print(tukey)
```

⑤ 결론

[서술] 정규성 검정(Shapiro-Wilk)과 등분산성 검정(Levene) 결과 두 가정을 모두 만족함을 확인한 후 일원배치 분산분석을 수행하였다(만약 가정을 만족하지 않는다면 비모수 검정인 **Kruskal-Wallis 검정**으로 대체해야 함을 병행 서술하면 가점 요소). ANOVA 분석 결과 F-통계량이 크게 산출되고 p-value가 0.05보다 작으므로, 유의수준 5%에서 귀무가설을 기각한다. 즉, **비료 종류에 따라 평균 수확량에 통계적으로 유의한 차이가 존재한다**. 이어서 수행한 Tukey HSD 사후검정 결과, **비료B는 비료A, 비료C와 각각 유의한 차이를 보이는 반면, 비료A와 비료C 간에는 유의한 차이가**

나타나지 않았다. 따라서 **비료B가 수확량 증대에 가장 효과적인 비료**라고 결론지을 수 있다.

이 파트에서 감점을 피하는 핵심 포인트

- **✗** 가설을 세우지 않고 바로 코드부터 작성 → 반드시 H_0/H_1 을 문장으로 먼저 명시
- **✗** p-value 만 출력하고 결론 문장 없이 끝냄 → "기각/채택 + 실무적 의미"까지 반드시 서술
- **✗** 단측/양측검정 구분 실수 → 문제 문장을 정확히 읽고 "더 크다/작다"(단측) vs "다르다"(양측) 구분
- **✗** ANOVA 에서 유의한 차이가 있다고만 하고 사후검정 생략 → 어느 집단 간 차이인지까지 규명해야 완전한 답안
- **✓** 정규성/등분산성 가정을 언급하면(설령 결과가 문제의 가정과 같더라도) 통계적 엄밀성에서 가점

[사용자] 전체 단계가 몇개야?

전체 실기 학습 로드맵 안내

지금까지 진행 상황을 포함해 전체 로드맵을 말씀드리면, 실기시험은 아래처럼 총 8단계로 구성해서 진행하기로 하였습니다.

단계	내용	진행상태
1단계	데이터 전처리 & EDA	완료
2단계	통계 분석 및 가설검정 (t검정/카이제곱/ANOVA)	완료
3단계	머신러닝 모델링 — 분류(Classification)	예정
4단계	머신러닝 모델링 — 회귀(Regression) & 모델 평가·비교	예정
5단계	비지도학습 — 군집분석(Clustering)	예정
6단계	시계열 분석 (ARIMA 등 실전 적용)	예정
7단계	텍스트마이닝 (비정형 데이터, 실기에도 종종 출제)	예정
8단계	종합 모의고사 (실제 시험처럼 대문제 3개 통합형 문제 풀이)	예정

각 단계는 필기 때와 마찬가지로 핵심 개념/체크리스트 → 실기유형 연습문제 → 코드+서술 포함 모범답안 → 감점 포인트 정리 순서로 진행됩니다.

[사용자] 네

ADP 실기시험 대비 자료 (3) — 머신러닝 모델링:

분류(Classification)

머신러닝 모델링은 실기시험에서 배점이 가장 크고 거의 매회 출제되는 핵심 파트입니다. 단순히 모델을 학습시키는 것을 넘어, 모델 선택 근거·평가지표 선택 근거·모델 비교·최종 결론까지 서술해야 고득점이 가능합니다.

핵심 체크리스트

항목	확인할 것
목표변수 확인	이진분류인지 다중분류인지, 클래스 불균형 여부 확인 (value_counts())
데이터 분할	train_test_split — 비율(보통 7:3 또는 8:2)과 stratify 옵션(불균형 데이터 시 필수) 근거 서술
전처리 재확인	인코딩(범주형), 스케일링(거리 기반 모델일 경우) — train에 fit, test는 transform만 (data leakage 방지, 매우 자주 강조되는 감점 포인트)
모델 선정	문제 성격에 맞는 2개 이상의 모델을 비교 (예: 로지스틱회귀 vs 랜덤포레스트)
하이퍼파라미터	GridSearchCV 등으로 튜닝했다면 그 과정과 근거 서술
평가지표 선정	균형 데이터 → Accuracy / 불균형 데이터 → Precision, Recall, F1, AUC 중 심
모델 비교 및 최종 선택	지표를 표로 정리하고 근거와 함께 최종 모델 선정
변수 중요도	트리 계열 모델은 feature_importances_ 확인 및 해석
한계/개선방안	데이터 크기, 과적합 가능성, 추가 검증 필요성 등 한 줄 언급

⚠ Data Leakage 주의(감점 다발 지점): StandardScaler()나 LabelEncoder() 등은 반드시 **train 데이터로만 fit**하고, test 데이터에는 transform만 적용해야 합니다. fit_transform을 전체 데이터에 먼저 적용한 뒤 분할하면 데이터 누수로 감점됩니다.

실기유형 연습문제 (5) — 이진분류 모델링 (로지스틱회귀 vs 랜덤포레스트 vs SVM)

※ 아래 문제는 실제 시행된 시험의 출제 패턴(고객 이탈 예측, 신용 평가 등 이진분류 데이터셋을 활용한 전처리→모델링→평가 구조)을 반영하여 재구성한 기출유형 연습문제입니다.

[문제]

다음은 통신사 고객의 이탈 여부(churn)를 예측하기 위한 데이터(telecom.csv)이다.

- tenure: 가입 기간(개월)
- monthly_charge: 월 요금
- contract_type: 계약 유형(월별/1 년/2 년, 범주형)
- support_calls: 최근 3 개월간 고객센터 문의 횟수
- churn: 이탈 여부 (1=이탈, 0=유지) — 목표변수

(3-1) 데이터를 전처리하고 학습/평가 데이터로 분할하시오. (3-2) 로지스틱 회귀, 랜덤포레스트, SVM 세 가지 모델을 학습시키고 성능을 비교하시오. (3-3) 최적의 모델을 선정하고 그 근거를 제시하시오. 또한 이탈 예측에 가장 중요한 변수를 제시하시오.

모범 답안

(3-1) 전처리 및 데이터 분할

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder

df = pd.read_csv('telecom.csv')

# 목표변수 클래스 비율 확인 (불균형 여부 판단)
print(df['churn'].value_counts(normalize=True))

# 범주형 변수 인코딩 (순서 의미가 없는 명목형이므로 One-Hot Encoding 적용)
df = pd.get_dummies(df, columns=['contract_type'], drop_first=True)

X = df.drop('churn', axis=1)
y = df['churn']

# 클래스 불균형이 확인되었다고 가정 -> stratify로 층화추출하여 train/test 클래스 비율 유지
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

# 스케일링: 로지스틱회귀/SVM은 거리(계수) 기반이므로 스케일링 필요
# 반드시 train으로만 fit 하고 test는 transform만 적용 (data leakage 방지)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

[서술] churn의 클래스 비율을 확인한 결과 이탈(1) 비율이 상대적으로 낮은 불균형 데이터로 판단되어, train_test_split 시 stratify=y 옵션을 적용하여 학습/평가 데이터의 클래스 비율을 원본과 동일하게 유지하였다. contract_type은 순서 의미가 없는 명목형 변수이므로 **One-Hot Encoding**을 적용하였다. 스케일링은 거리 기반 모델(SVM)과 계수 기반 모델(로지스틱회귀)의 성능에 영향을 줄 수 있어 적용하였으며, 데이터 누수를 방지하기 위해 train 데이터에만 fit하고 test 데이터는

transform만 수행하였다.

(3-2) 모델 학습 및 성능 비교

```
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score,
roc_auc_score

models = {
    '로지스틱회귀': LogisticRegression(random_state=42),
    '랜덤포레스트': RandomForestClassifier(n_estimators=100, random_state=42),
    'SVM': SVC(probability=True, random_state=42)
}

results = []
for name, model in models.items():
    model.fit(X_train_scaled, y_train)
    pred = model.predict(X_test_scaled)
    proba = model.predict_proba(X_test_scaled)[: , 1]

    results.append({
        '모델': name,
        'Accuracy': accuracy_score(y_test, pred),
        'Precision': precision_score(y_test, pred),
        'Recall': recall_score(y_test, pred),
        'F1-Score': f1_score(y_test, pred),
        'AUC': roc_auc_score(y_test, proba)
    })

result_df = pd.DataFrame(results)
print(result_df.round(3))
```

[서술] 세 모델의 성능을 비교한 결과는 다음 표와 같다 (예시 수치).

모델	Accuracy	Precision	Recall	F1-Score	AUC
로지스틱회귀	0.812	0.68	0.55	0.61	0.81
랜덤포레스트	0.856	0.75	0.70	0.72	0.88
SVM	0.831	0.71	0.60	0.65	0.84

목표변수가 불균형 데이터이므로 Accuracy보다 Precision, Recall, F1-Score, AUC를 중심으로 모델을 평가하는 것이 타당하다. 이탈 예측 문제의 경우, 실제 이탈 고객을 놓치는 것(FN, 재현을 저하)이 이탈하지 않을 고객을 이탈로 잘못 예측하는 것(FP)보다 비즈니스적으로 더 큰 손실을 초래할 가능성이 높으므로, Recall과 F1-Score를 중요하게 고려하였다.

(3-3) 최종 모델 선정 및 변수 중요도

```

from sklearn.metrics import confusion_matrix, classification_report

best_model = RandomForestClassifier(n_estimators=100, random_state=42)
best_model.fit(X_train_scaled, y_train)
pred = best_model.predict(X_test_scaled)

print(confusion_matrix(y_test, pred))
print(classification_report(y_test, pred))

# 변수 중요도
importance = pd.Series(best_model.feature_importances_, index=X.columns)
importance = importance.sort_values(ascending=False)
print(importance)

import matplotlib.pyplot as plt
plt.figure(figsize=(8,5))
importance.plot(kind='barh')
plt.title('변수 중요도 (랜덤포레스트)')
plt.xlabel('중요도')
plt.gca().invert_yaxis()
plt.show()

```

[서술] 세 모델 중 **랜덤포레스트**가 Accuracy, F1-Score, AUC 모든 지표에서 가장 우수한 성능을 보였다. 이는 랜덤포레스트가 여러 변수 간의 **비선형적 상호작용**을 포착할 수 있는 반면, 로지스틱회귀는 선형결합으로만 관계를 모델링하기 때문으로 해석된다. 다만 랜덤포레스트는 **해석력이 로지스틱회귀보다 낮고, 트리 개수가 많아질수록 연산 비용이 크다는 한계**가 있다.

변수 중요도 분석 결과, **support_calls(고객센터 문의 횟수)**와 **tenure(가입 기간)**가 이탈 예측에 가장 중요한 변수로 나타났다. 이는 **문의가 잦고 가입 기간이 짧은 고객일수록 이탈 위험이 높다는 것**을 시사하며, 실무적으로는 이러한 고객군을 대상으로 한 **선제적 리텐션(retention) 전략 수립**이 필요하다는 결론을 제시할 수 있다.

[한계 서술] 다만 본 분석은 주어진 데이터의 크기가 제한적이며 클래스 불균형이 존재하므로, 모델의 일반화 성능을 보다 엄밀히 검증하기 위해서는 **교차검증(Cross Validation)**을 추가로 수행하거나, 오버샘플링(SMOTE) 등의 기법을 통해 클래스 불균형을 보정하는 방안을 고려할 수 있다.

실기유형 연습문제 (6) — 다중분류 & 하이퍼파라미터 튜닝

[문제]

붓꽃(iris)과 유사한 형태의 3종 품종 분류 데이터가 주어졌다. 랜덤포레스트 모델의 하이퍼파라미터(n_estimators, max_depth)를 GridSearchCV로 튜닝하여 최적 모델을 구축하고, 교차검증을 통해 모델의 일반화 성능을 평가하시오.

모범 답안

```

from sklearn.model_selection import GridSearchCV, cross_val_score

```

```

from sklearn.ensemble import RandomForestClassifier

param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [3, 5, 7, None]
}

grid = GridSearchCV(
    RandomForestClassifier(random_state=42),
    param_grid=param_grid,
    cv=5,                      # 5-fold 교차검증
    scoring='f1_macro',        # 다중분류이므로 macro 평균 F1 사용
    n_jobs=-1
)
grid.fit(X_train_scaled, y_train)

print("최적 파라미터:", grid.best_params_)
print("최적 CV F1-score:", grid.best_score_)

best_model = grid.best_estimator_
test_pred = best_model.predict(X_test_scaled)
print(classification_report(y_test, test_pred))

```

[서술] GridSearchCV를 통해 `n_estimators`와 `max_depth`의 조합을 **5-fold 교차검증**으로 탐색하였다. 다중분류 문제이므로 평가지표는 각 클래스의 F1-score를 단순 평균한 **f1_macro**를 사용하여 클래스 간 크기 차이에 관계없이 균형 있게 평가하였다. 교차검증을 사용한 이유는 **단일 train/test 분할에 따른 성능 평가의 우연성(변동성)을 줄이고, 모델의 일반화 성능을 보다 신뢰성 있게 추정하기** 위함이다. 탐색 결과 최적 파라미터가 도출되었으며, 이를 최종 모델로 채택하여 테스트 데이터에 적용한 결과를 `classification_report`로 제시하였다.

이 파트에서 감점을 피하는 핵심 포인트

- **✗** 스케일러/인코더를 전체 데이터에 `fit_transform` 후 분할 → 반드시 분할 후 `train`에만 `fit`
- **✗** 불균형 데이터에 Accuracy 만 보고 "성능이 좋다"고 결론 → Precision/Recall/F1/AUC 를 함께 제시하고 논리적으로 지표를 선택한 이유를 서술
- **✗** 모델을 하나만 학습하고 끝냄 → 최소 2 개 이상 모델을 비교하는 것이 문제에 명시되지 않아도 안전한 전략(단, 시간이 매우 부족하면 우선순위 조정)
- **✗** 성능 좋은 모델만 제시하고 왜 그런지 설명 없음 → 모델의 특성(선형 vs 비선형, 해석력 등)에 근거한 설명 필수
- **✓** 변수 중요도/계수를 해석하여 비즈니스적 시사점까지 도출하면 확실한 가점

ADP 실기시험 대비 자료 (4) — 머신러닝 모델링:

회귀(Regression) & 모델 평가·비교

회귀 문제는 분류와 답안 구조는 유사하지만, 평가지표와 잔차 진단, 다중공선성 점검이 추가로 요구되는 경우가 많습니다. 특히 회귀는 모델의 계수를 해석하는 서술형 문제와 결합되어 출제되는 경우가 많아, 계수의 의미를 설명하는 연습이 중요합니다.

핵심 체크리스트

항목	확인할 것
목표변수 분포 확인	왜도가 크면 로그변환 고려 ($np.log1p$)
다중공선성 점검	VIF(Variance Inflation Factor) 확인, 10 이상이면 변수 제거/PCA 고려
모델 선정	선형회귀, Ridge/Lasso(규제), 트리 기반 (RandomForest/GradientBoosting) 등 비교
평가지표	MSE, RMSE, MAE, R^2 , Adjusted R^2 — 지표별 의미 차이 이해 필수
잔차 진단	잔차의 등분산성·정규성·독립성(패턴 없이 무작위 분포해야 함) 시각적 확인
계수 해석	회귀계수의 부호와 크기가 의미하는 바를 실무 언어로 서술
규제(Ridge/Lasso) 활용 근거	다중공선성이 있거나 변수가 많을 때 사용 이유 서술

회귀 평가지표 요약 (서술형에도 자주 활용)

지표	계산식	특징
MSE	오차 제곱의 평균	이상치에 민감(제곱으로 인해 큰 오차가 더 크게 반영)
RMSE	MSE의 제곱근	원래 단위와 동일하여 해석이 직관적
MAE	오차 절댓값의 평균	이상치에 덜 민감, 해석이 쉬움
R^2	모형이 설명하는 분산의 비율	1에 가까울수록 설명력 높음, 변수 추가 시 무조건 증가하는 한계
Adjusted R^2	변수 개수에 페널티를 부여한 R^2	다중회귀 모형 간 비교 시 사용

실기유형 연습문제 (7) — 다중선형회귀 & 다중공선성 진단

※ 아래 문제는 실제 시행된 시험의 출제 패턴(주택가격, 매출액 등 연속형 목표변수를 예측하는 다중회귀 구조)을 반영하여 재구성한 기출유형 연습문제입니다.

[문제]

다음은 아파트 매매가격(price, 단위: 백만원)을 예측하기 위한 데이터(house.csv)이다.

- area: 전용면적(m²)
- age: 건축연차
- floor: 층수
- distance_subway: 지하철역까지 거리(m)
- num_rooms: 방 개수
- price: 매매가격 — 목표변수

(4-1) 독립변수 간 다중공선성을 점검하시오. (4-2) 다중선형회귀, Ridge, Lasso, 랜덤포레스트 회귀 모델을 학습시키고 성능을 비교하시오. (4-3) 최종 모델을 선정하고, 회귀계수(또는 변수 중요도)를 바탕으로 매매가격에 영향을 미치는 요인을 해석하시오.

모범 답안

(4-1) 다중공선성 진단 (VIF)

```
import pandas as pd
import numpy as np
from statsmodels.stats.outliers_influence import variance_inflation_factor

df = pd.read_csv('house.csv')

X = df.drop('price', axis=1)
y = df['price']

vif_df = pd.DataFrame()
vif_df['변수'] = X.columns
vif_df['VIF'] = [variance_inflation_factor(X.values, i) for i in range(X.shape[1])]
print(vif_df)
```

[서술] VIF 산출 결과 모든 변수의 VIF가 10 미만으로 나타나(예시 상황) 심각한 다중공선성은 존재하지 않는 것으로 판단하였다. (만약 특정 변수의 VIF가 10 이상으로 나타났다면, "area와 num_rooms는 상관관계가 높아 다중공선성이 의심되므로 둘 중 하나를 제거하거나 Ridge와 같은 규제 모델을 우선 고려해야 한다"는 식으로 **VIF가 높게 나온 상황에 대한 대응 논리까지 함께 서술하는 것이** 고득점 포인트이다.)

(4-2) 모델 학습 및 성능 비교

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression, Ridge, Lasso
```

```

from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

models = {
    '선형회귀': LinearRegression(),
    'Ridge': Ridge(alpha=1.0),
    'Lasso': Lasso(alpha=1.0),
    '랜덤포레스트': RandomForestRegressor(n_estimators=100, random_state=42)
}

results = []
for name, model in models.items():
    # 트리 모델은 스케일링 불필요하지만, 코드 일관성을 위해 그대로 사용 가능(성능에 영향 없음)
    model.fit(X_train_scaled, y_train)
    pred = model.predict(X_test_scaled)

    mse = mean_squared_error(y_test, pred)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y_test, pred)
    r2 = r2_score(y_test, pred)

    results.append({'모델': name, 'RMSE': rmse, 'MAE': mae, 'R2': r2})

result_df = pd.DataFrame(results)
print(result_df.round(2))

```

[서술] 비교 결과는 다음과 같다 (예시 수치).

모델	RMSE	MAE	R ²
선형회귀	45.2	35.1	0.78
Ridge	44.8	34.7	0.79
Lasso	45.5	35.4	0.77
랜덤포레스트	38.1	29.3	0.85

RMSE는 오차에 제곱을 취해 평균 내므로 큰 오차(이상치)에 더 민감하게 반응하는 반면, **MAE**는 절댓값 기준이라 이상치의 영향을 상대적으로 덜 받는다. 두 지표가 유사한 패턴을 보인다는 것은 극단적인 이상치의 영향이 크지 않다는 것을 시사한다. **R²**는 랜덤포레스트가 가장 높아(0.85), 목표변수 분산의 85%를 설명하는 것으로 나타났다.

(4-3) 최종 모델 선정 및 해석

```

# 선형회귀 계수 해석
lr = LinearRegression()
lr.fit(X_train_scaled, y_train)
coef_df = pd.DataFrame({'변수': X.columns, '계수': lr.coef_}).sort_values('계수', key=abs,
ascending=False)
print(coef_df)

# 랜덤포레스트 변수 중요도
rf = RandomForestRegressor(n_estimators=100, random_state=42)
rf.fit(X_train_scaled, y_train)
importance = pd.Series(rf.feature_importances_,
index=X.columns).sort_values(ascending=False)
print(importance)

# 잔차 진단 (선형회귀 기준)
import matplotlib.pyplot as plt
residuals = y_test - lr.predict(X_test_scaled)
plt.figure(figsize=(6,4))
plt.scatter(lr.predict(X_test_scaled), residuals)
plt.axhline(y=0, color='red', linestyle='--')
plt.xlabel('예측값')
plt.ylabel('잔차')
plt.title('잔차 플롯 (등분산성/패턴 확인)')
plt.show()

```

[서술] 성능 지표를 종합할 때 **랜덤포레스트 회귀**가 RMSE, MAE, R^2 모든 측면에서 가장 우수하여 최종 모델로 선정하였다. 이는 매매가격에 영향을 미치는 변수들(면적, 층수, 지하철 거리 등) 간에 **비선형적 상호작용**이 존재할 가능성을 반영한 결과로 해석된다.

다만 **해석의 용이성** 측면에서 선형회귀 모델의 계수도 함께 제시하였다. 표준화된 계수를 확인한 결과 **area(전용면적)의 계수가 가장 크고 양(+)**의 값을 가져, 면적이 넓을수록 매매가격이 높아지는 것으로 나타났으며, **distance_subway(지하철역 거리)**는 **음(-)의 계수**를 보여 지하철역과 가까울수록(거리가 짧을수록) 가격이 높아지는 것으로 해석된다. 랜덤포레스트의 변수 중요도 역시 area와 distance_subway를 상위 요인으로 제시하여 두 모델의 해석이 일치함을 확인하였다.

잔차 플롯을 확인한 결과 특별한 패턴 없이 0을 중심으로 무작위로 분포하는 것으로 나타나, 선형회귀 모형의 **등분산성 가정**을 크게 벗어나지 않는 것으로 판단된다.

[한계 서술] 랜덤포레스트는 예측 성능은 우수하나 **계수와 같은 명시적인 해석이 어렵다**는 한계가 있어, 실무에서 모델을 활용할 때는 예측 정확도가 중요한 경우 랜덤포레스트를, 가격 결정 요인에 대한 설명력이 더 중요한 경우 선형회귀(또는 Ridge)를 상호 보완적으로 활용할 것을 제안한다.

이 파트에서 감점을 피하는 핵심 포인트

- **✗** R^2 만 보고 "설명력이 높다"고 결론 → RMSE/MAE 등 실제 오차 크기도 함께 언급하여 다각도로 평가했음을 보일 것
- **✗** 다중공선성 점검을 생략 → 회귀 문제에서는 VIF 확인을 습관적으로 넣는 것이 안전

- ✗ 계수의 부호만 언급하고 실무적 의미로 연결하지 않음 → "계수가 양수다"에서 그치지 말고 "면적이 넓을수록 가격이 상승한다"처럼 직관적 언어로 재서술
- ✗ 트리 기반 모델 채택 시 해석력 한계를 언급하지 않음 → 정확도와 해석력의 트레이드오프를 언급하면 균형 잡힌 답안으로 평가받음
- ✔ 잔차 플롯 등 모델 진단 과정을 추가하면 통계적 엄밀성 측면에서 가점