

ADP(데이터분석 전문가) 필기시험 준비자료

1부 — 시험개요 / 1~3과목 / R기초 및 데이터 마트

[사용자] ADP 시험 준비를 하고 있어. 우선 필기 시험부터 준비해야 하는데 최근 시험출제 경향을 반영해서 필기시험 준비하는 자료를 제공해 줘. 필기 시험의 각 범위별로 하나씩 자료를 정리해 주고 관련된 기출 문제를 같이 제공해 줘. 기출 문제는 문제와 풀이를 따로 제공해 줘야 해. 자 지금부터 하나씩 진행 해 줘. 반드시 자세하고 충실한 내용을 제공해 줘야 하고 기출문제는 5개이상 제시해 줘야 해.

ADP 필기시험 대비 자료 (1) — 데이터 이해

안녕하세요! ADP(데이터분석 전문가) 필기시험 준비를 도와드리겠습니다. 먼저 시험 구조와 최근 출제경향을 간단히 정리한 뒤, 첫 번째 과목인 "데이터 이해" 부터 하나씩 진행하겠습니다.

시험 개요 (참고)

과목명	객관식	서술형	배점
데이터 이해	10문항	-	10점
데이터 처리 기술 이해	10문항	-	10점
데이터분석 기획	10문항	-	10점
데이터분석	40문항	-	40점
데이터 시각화	10문항	1문항	10점+20점
합계	80문항	1문항	100점

- 합격기준: 총점 70 점 이상, 과목별 40% 미만 시 과락
- 최근 출제경향: 단순 키워드 암기보다 개념을 실제 사례·상황에 적용하는 문제가 늘고 있으며, 특히 4 과목(데이터분석)의 통계·기계학습 이론(회귀, 분류모델, SVM, 인공신경망/MLP 등)의 작동원리·평가지표·결과해석을 묻는 문제 비중이 커지는 추세입니다. 서술형은 배점(20 점)은 크지만 범위가 매우 넓어 보너스 개념으로 접근하고, 객관식 80 점 중 70 점 내외 확보를 목표로 하는 전략이 일반적으로 권장됩니다.

1 과목: 데이터 이해

1-1. 데이터의 이해

① 데이터와 정보

- **데이터(Data)**: 객관적 사실이며 다른 것과 구별되는 존재의 특성. 정형/반정형/비정형으로 구분됨.

- 정형 데이터: 관계형 DB, 스프레드시트처럼 고정된 필드에 저장 (예: RDB 테이블)
- 반정형 데이터: 형식이 있으나 형태가 고정적이지 않음 (예: XML, JSON, HTML, 로그 파일)
- 비정형 데이터: 형태와 구조가 없는 데이터 (예: 텍스트, 이미지, 동영상, 음성)

- **DIKW 피라미드** (데이터→정보→지식→지혜):

- 데이터(Data): 가공되지 않은 순수한 사실
- 정보(Information): 데이터를 가공·처리하여 의미를 부여한 것 (데이터 간 상관관계와 맥락 파악)
- 지식(Knowledge): 정보를 구조화하여 유의미한 정보를 분류·통합, 상호 이해를 통해 개인적 경험으로 체화한 것
- 지혜(Wisdom): 지식의 축적과 아이디어가 결합된 창의적 산물

② 데이터베이스의 정의와 특징

- 정의: 통합 저장된 운영 데이터의 집합 (공용 데이터, 통합 데이터, 저장 데이터, 운영 데이터)
- 특징: 실시간 접근성, 지속적인 변화, 동시 공유, 내용에 의한 참조
- 데이터베이스 관리 시스템 발전: 1 세대(계층형/망형) → 2 세대(관계형 RDB) → 3 세대(객체지향형/객체관계형) → 4 세대(빅데이터 지원, NoSQL, NewSQL)

③ 데이터베이스 활용

- 기업 내부: ERP, SCM, CRM 등 업무 프로세스 효율화
- 산업별 활용: 유통(POS 데이터 기반 재고관리), 제조(품질관리), 금융(리스크 관리) 등

1-2. 데이터의 가치와 미래

① 빅데이터의 이해

- 정의: 기존 데이터베이스 관리도구로 데이터를 수집·저장·관리·분석하는 역량을 넘어서는 대량의 정형/비정형 데이터 집합
- **3V (기본 특징)**: Volume(규모), Velocity(속도), Variety(다양성)
- 확장 개념: **5V** (3V + Veracity(정확성/신뢰성) + Value(가치)), 혹은 **4V**(3V+Value)로도 자주 출제됨
- 빅데이터 등장 배경: 사물인터넷(IoT), 소셜미디어 확산, 저장/처리 기술 발전(하둡 등), 클라우드 컴퓨팅

② 빅데이터의 가치와 영향

- 가치 산정이 어려운 이유: 데이터 재사용·재조합·다목적용 개발 증가, 새로운 가치 창출 방법의 반복적 시행, 분석 기술 발전에 따른 가치 변화
- 영향: 기업(경쟁력 강화, 생산성 증대), 정부(공공복지 증진, 위기관리), 개인(맞춤형 서비스)

③ 비즈니스 모델

- 활용 사례: 구글의 자동번역(다량의 텍스트 데이터 기반), 넷플릭스의 추천 알고리즘, 오바마 대선 캠프의 유권자 데이터 분석 등
- 데이터 사이언스 기반 비즈니스 모델: 최적화, 인사이트, 업무프로세스 혁신

④ 위기 요인과 통제 방안

위기 요인	내용	통제 방안
사생활 침해	익명화된 데이터도 재조합 시 개인 식별 가능	동의제 → 책임제(사후 책임 부과) 전환
책임 원칙 훼손	데이터에 기반한 예측으로 부당하게 불이익을 받을 가능성 (범죄예측 등)	결과 기반 책임 원칙 강화
데이터 오용	잘못된 데이터·모델로 잘못된 결과 도출	알고리즘 접근권 허용, 알고리즘미스트(algorithmist) 활용

⑤ 미래의 빅데이터

- 데이터 사이언스 중심 사회로의 변화, 산업 간 데이터 융합 가속화

1-3. 가치 창조를 위한 데이터 사이언스와 전략 인사이트

① 빅데이터 분석과 전략 인사이트

- 데이터 사이언스: 정형/비정형을 막론한 다양한 유형의 데이터로부터 지식과 인사이트를 추출하기 위해 통계학, 컴퓨터공학, 분석적 마인드, 인문학적 요소(도메인 지식)를 종합한 학문
- 데이터 사이언스의 특징:
 - 분석 대상 자체가 정형화되지 않은 경우가 많음
 - **전략적 통찰(Strategic Insight)** 을 강조: 단순 상관관계 분석을 넘어 왜(why)에 대한 답을 찾는 것

② 전략 인사이트 도출을 위한 필요 역량

- **하드 스킬(Hard Skill)**: 이론적 지식(통계학, 머신러닝 등), 분석 기술에 대한 숙련도
- **소프트 스킬(Soft Skill)**: 통찰력 있는 분석을 위한 비판적 사고(Critical Thinking), 창의적 사고, 커뮤니케이션 능력(설득력 있는 전달, 시각화 표현력)
- 데이터 사이언티스트는 하드 스킬과 소프트 스킬을 모두 갖춰야 함이 강조됨

③ 빅데이터, 데이터 사이언스의 미래

- 데이터 사이언티스트 역할 확대, 조직 내 데이터 기반 의사결정 문화(Data-Driven Decision Making) 정착

1 과목 기출유형 문제 (문제)

※ ADP는 공식적으로 기출문제 원문을 공개하지 않으므로, 아래는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제입니다. 실제 출제된 문항의 정확한 원문이 아닌 점 참고 부탁드립니다.

문제 1. 다음 중 데이터, 정보, 지식, 지혜로 이어지는 DIKW 계층 구조에 대한 설명으로 옳지 않은 것은?

- ① 데이터는 객관적 사실로서 다른 데이터와의 상관관계나 맥락이 반영되어 있지 않다. ② 정보는 데이터 간의 상관관계와 의미가 도출된 유의미한 가공 데이터이다. ③ 지식은 상호 연결된 정보 패턴을 이해하여 이를 토대로 예측한 결과물이다. ④ 지혜는 근본 원리에 대한 깊은 이해를 바탕으로 도출되는 창의적 아이디어이다.

문제 2. 빅데이터의 특징을 설명하는 3V에 해당하지 않는 것은?

- ① Volume ② Velocity ③ Variety ④ Visibility

문제 3. 빅데이터 시대의 위기 요인과 통제 방안을 짝지은 것으로 가장 적절하지 않은 것은?

- ① 사생활 침해 – 동의제에서 책임제로의 전환 ② 책임원칙 훼손 – 결과 기반 책임 원칙 도입 ③ 데이터 오용 – 알고리즘에 대한 접근권 허용 ④ 데이터 오용 – 개인정보의 무기한 저장 허용

문제 4. 데이터 사이언티스트에게 요구되는 역량 중 소프트 스킬(Soft Skill)에 해당하는 것을 모두 고른 것은?

ㄱ. 통계학적 지식 ㄴ. 비판적 사고 ㄷ. 설득력 있는 커뮤니케이션 ㄹ. 머신러닝 알고리즘 이해

- ① ㄱ, ㄴ ② ㄴ, ㄷ ③ ㄱ, ㄹ ④ ㄷ, ㄹ

문제 5. 다음 중 데이터베이스의 특징으로 옳지 않은 것은?

- ① 통합 데이터(Integrated Data) ② 저장 데이터(Stored Data) ③ 개별 데이터(Individual Data) ④ 공용 데이터(Shared Data)

문제 6. 데이터 사이언스가 기존 통계학과 구분되는 가장 중요한 특징으로 옳은 것은?

- ① 정형 데이터만을 분석 대상으로 한다. ② 왜(Why)에 대한 답을 찾는 전략적 통찰을 강조한다. ③ 수학적 계산 능력만을 요구한다. ④ 데이터 분석 결과의 시각화는 다루지 않는다.

1 과목 기출유형 문제 (풀이)

문제 1. 정답 ③

- 해설: 상호 연결된 정보 패턴을 이해하는 것은 **지식(Knowledge)** 단계의 정의로 맞지만, "이를 토대로 예측한 결과물"이라는 설명은 지혜(Wisdom)의 영역인 창의적 산물·아이디어와 혼동한 서술입니다. 지식은 정보의 구조화·이해·체화 단계이고, 이를 바탕으로 한 창의적 아이디어·산물이 지혜입니다. 따라서 ③번의 설명이 부정확하여 정답입니다.
- ①,②,④는 각각 데이터/정보/지혜에 대한 표준적 정의로 옳은 설명입니다.

문제 2. 정답 ④

- 해설: 빅데이터의 기본 3대 특징은 **Volume(규모), Velocity(속도), Variety(다양성)** 입니다. Visibility(가시성)는 3V에 포함되지 않으며, 확장 개념으로 자주 등장하는 것은 Veracity(정확성/신뢰성)와 Value(가치)입니다.

문제 3. 정답 ④

- 해설: 데이터 오용에 대한 통제 방안은 알고리즘에 대한 접근권 허용, 알고리즘미스트(제3자 검증 전문가) 활용 등입니다. "개인정보의 무기한 저장 허용"은 오히려 사생활 침해 위험을 키우는 조치이므로 통제 방안으로 적절하지 않습니다.

문제 4. 정답 ②

- 해설: 소프트 스킬은 비판적 사고(ㄴ), 커뮤니케이션 능력(ㄷ)과 같이 통찰력 있는 분석과 전달을 위한 역량입니다. 통계학적 지식(ㄱ)과 머신러닝 알고리즘 이해(ㄹ)는 이론적·기술적 역량인 **하드 스킬**에 해당합니다.

문제 5. 정답 ③

- 해설: 데이터베이스의 4대 특징은 **통합 데이터, 저장 데이터, 공용 데이터, 운영 데이터**입니다. "개별 데이터"는 데이터베이스의 특징이 아니며, 오히려 데이터베이스는 여러 사용자가 공동으로 사용하는 **공용 데이터**라는 점에서 반대 개념에 가깝습니다.

문제 6. 정답 ②

- 해설: 데이터 사이언스는 정형·비정형 데이터를 모두 다루며, 단순 상관관계 파악을 넘어 현상의 원인(Why)을 규명하는 **전략적 통찰(Strategic Insight)**을 지향한다는 점이 기존 통계학적 접근과 차별화된 핵심 특징입니다. ①③④는 모두 데이터 사이언스의 범위를 축소하거나 왜곡한 설명입니다.

1과목 정리는 여기까지입니다. 이어서 **2과목: 데이터 처리 기술 이해**로 진행할까요? 아니면 1과목에서 더 다루고 싶은 세부 주제(예: 특정 개념 심화, 추가 문제)가 있으시면 말씀해 주세요.

[사용자] 2과목을 진행해 주

ADP 필기시험 대비 자료 (2) — 데이터 처리 기술 이해

2 과목: 데이터 처리 기술 이해

2-1. 데이터 처리 프로세스

① ETL (Extraction, Transformation, Load)

- 정의: 다양한 원천 시스템으로부터 데이터를 **추출(Extraction)**하고, 사용 목적에 맞게 **변환(Transformation)**한 후, 목표 시스템(DW, DM 등)에 **적재(Load)**하는 일련의 프로세스
- 특징: 데이터웨어하우스(DW) 구축의 핵심 과정이며, 배치(Batch) 방식으로 주기적(일/주/월 단위)으로 수행되는 경우가 많음
- ELT(Extract-Load-Transform)와 구분: 최근 빅데이터/클라우드 환경에서는 먼저 적재 후 필요 시점에 변환하는 ELT 방식도 활용됨 (변환 부담을 목표 시스템의 컴퓨팅 자원으로 이전)

② CDC (Change Data Capture)

- 정의: 데이터베이스 내에서 변경(삽입/수정/삭제)이 발생한 데이터만을 추출하여 다른 시스템에 반영하는 기술
- 목적: 전체 데이터를 매번 복제하지 않고 **변경분만** 실시간/준실시간으로 동기화하여 시스템 부하 최소화
- 방식: 로그 기반(Log-based) 방식이 대표적 (DB의 트랜잭션 로그를 분석하여 변경 이력 캡처, 소스 시스템 부하가 적음), 이 외 트리거 기반, 스냅샷 비교 방식 등

③ EAI (Enterprise Application Integration)

- 정의: 기업 내 상이한 애플리케이션(ERP, CRM, SCM 등) 간의 데이터와 프로세스를 연계·통합하기 위한 솔루션/체계
- 연계 방식(구성 유형):
 - **Point-to-Point**: 시스템 간 1:1 직접 연결 (단순하지만 시스템 수가 늘어나면 관리 복잡도 급증)
 - **Hub & Spoke**: 중앙 허브를 통해 연계 (허브 장애 시 전체 영향)
 - **Message Bus (ESB)**: 버스를 통한 표준화된 메시지 교환, 확장성이 가장 좋음
 - **Hybrid**: 위 방식들을 혼합

④ 데이터 연계 및 통합 기법 요약

구분	ETL	EAI	CDC
주 목적	DW/DM 적재를 위한 데이터 변환	애플리케이션 간 실시간 프로세스 연계	변경 데이터만 캡처하여 동기화
처리 방식	주로 배치	실시간/이벤트 기반	실시간/준실시간
활용 예	데이터웨어하우스 구축	기간제 시스템 통합	실시간 데이터 복제, 무중단 마이그레이션

⑤ 대용량 비정형 데이터 처리

- 기존 RDB 기반 ETL 로는 비정형(텍스트, 로그, 이미지 등) 대용량 데이터 처리에 한계 → 분산 처리 프레임워크(하둡 등) 필요성 대두
- 대표 기술: 하둡 에코시스템의 **Flume**(로그 수집), **Sqoop**(RDB ↔ 하둡 간 데이터 이관), **Kafka**(실시간 스트리밍 메시징) 등

2-2. 데이터 처리 기술

① 분산 데이터 저장 기술

- **HDFS (Hadoop Distributed File System)**: 대용량 파일을 블록 단위(기본 128MB)로 분할하여 여러 노드에 분산 저장. **NameNode**(메타데이터 관리)와 **DataNode**(실제 블록 저장)로 구성. 블록을 기본 3 중 복제(Replication)하여 장애 대응
- **NoSQL**: 정형화된 스키마 없이 대규모 데이터를 유연하게 저장
 - Key-Value 형: Redis, DynamoDB
 - Column-Family 형: HBase, Cassandra
 - Document 형: MongoDB
 - Graph 형: Neo4j
- **CAP 이론**: 분산 시스템은 **일관성(Consistency)**, **가용성(Availability)**, **분할내성(Partition Tolerance)** 중 최대 2 가지만 동시에 만족 가능 (NoSQL 설계 시 자주 출제되는 핵심 개념)

② 분산 컴퓨팅 기술

- **맵리듀스(MapReduce)**: 대용량 데이터를 **Map(분할·매핑)**과 **Reduce(집계·병합)** 두 단계로 나누어 분산 처리하는 프로그래밍 모델
 - Map: 입력 데이터를 Key-Value 쌍으로 변환
 - Shuffle & Sort: 같은 Key 끼리 재배치
 - Reduce: Key 별로 집계 연산 수행
- **Apache Spark**: 인메모리(In-Memory) 기반 분산 처리 프레임워크로, 디스크 기반의 MapReduce 보다 반복 연산(머신러닝 등)에서 훨씬 빠른 속도를 보임. RDD(Resilient Distributed Dataset) 개념 사용
- **Hive**: 하둡 기반 데이터를 SQL 과 유사한 HiveQL 로 조회할 수 있게 해주는 데이터웨어하우스 도구
- **YARN**: 하둡 2.0 부터 도입된 자원 관리(리소스 매니저) 계층, MapReduce 외 다양한 처리 엔진(Spark 등)을 지원

③ 클라우드 인프라 기술

- **IaaS(Infrastructure as a Service)**: 서버, 스토리지, 네트워크 등 인프라 자원 제공 (예: AWS EC2)

- **PaaS(Platform as a Service):** 애플리케이션 개발·실행 플랫폼 제공 (예: AWS Elastic Beanstalk, Heroku)
- **SaaS(Software as a Service):** 완성된 소프트웨어를 서비스 형태로 제공 (예: Google Workspace, Salesforce)
- 가상화 기술: 하이퍼바이저 기반 가상머신(VM), 컨테이너 기반 가상화(Docker) — 컨테이너는 VM 대비 경량화되어 자원 효율성이 높음

2 과목 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 데이터베이스의 트랜잭션 로그를 분석하여 변경된 데이터만을 추출하고 이를 다른 시스템에 반영하는 기술로 가장 적절한 것은?

- ① ETL ② EAI ③ CDC ④ OLAP

문제 2. EAI(Enterprise Application Integration)의 구성 유형 중, 중앙 집중형 허브를 두어 각 시스템이 허브를 거쳐 데이터를 주고받는 방식은?

- ① Point-to-Point ② Hub & Spoke ③ Message Bus ④ Peer-to-Peer

문제 3. 분산 시스템의 특성을 설명하는 CAP 이론에서, 하나의 시스템이 동시에 만족할 수 없는 세 가지 속성이 아닌 것은?

- ① Consistency(일관성) ② Availability(가용성) ③ Partition Tolerance(분할내성) ④ Scalability(확장성)

문제 4. 하둡 분산 파일 시스템(HDFS)의 구성 요소 중, 파일 시스템의 메타데이터(파일명, 블록 위치 등)를 관리하는 역할을 담당하는 것은?

- ① DataNode ② NameNode ③ JobTracker ④ ResourceManager

문제 5. 맵리듀스(MapReduce)의 처리 단계를 순서대로 바르게 나열한 것은?

- ① Reduce → Map → Shuffle ② Map → Shuffle & Sort → Reduce ③ Shuffle → Reduce → Map ④ Map → Reduce → Shuffle

문제 6. Apache Spark가 기존 MapReduce에 비해 반복적인 연산(머신러닝 등)에서 빠른 처리 속도를 보이는 가장 핵심적인 이유는?

- ① 디스크 기반 저장 방식을 사용하기 때문에 ② 인메모리(In-Memory) 방식으로 데이터를 처리하기 때문에 ③ SQL 문법을 지원하기 때문에 ④ 반드시 클라우드 환경에서만 동작하기 때문에

문제 7. 클라우드 서비스 제공 모델 중, 사용자가 애플리케이션 개발 및 배포를 위한 실행 환경(플랫폼)을 제공받는 형태는?

- ① IaaS ② PaaS ③ SaaS ④ DaaS

2 과목 기출유형 문제 (풀이)

문제 1. 정답 ③

- 해설: **CDC(Change Data Capture)**는 데이터베이스의 변경 이력(주로 트랜잭션 로그)을 캡처하여 변경분만 다른 시스템으로 전파하는 기술입니다. ETL 은 전체 데이터의 추출-변환-적재 과정이며, EAI 는 애플리케이션 간 연계 체계, OLAP 은 다차원 데이터 분석 기법으로 이 설명과는 거리가 있습니다.

문제 2. 정답 ②

- 해설: **Hub & Spoke** 방식은 중앙에 허브(Hub)를 두고 각 시스템(Spoke)이 허브를 경유하여 연계되는 구조입니다. Point-to-Point 는 시스템 간 1:1 직접 연결 방식이고, Message Bus(ESB)는 버스를 통한 표준 메시지 교환 방식으로 확장성이 가장 뛰어납니다.

문제 3. 정답 ④

- 해설: CAP 이론의 3 요소는 **Consistency(일관성), Availability(가용성), Partition Tolerance(분할내성)**이며, 분산 시스템은 이 중 최대 2 가지만 동시에 만족할 수 있습니다. Scalability(확장성)는 CAP 이론의 구성 요소가 아닙니다.

문제 4. 정답 ②

- 해설: **NameNode** 는 HDFS 의 마스터 노드로서 파일의 메타데이터(디렉터리 구조, 블록의 위치 정보 등)를 관리합니다. 실제 데이터 블록은 **DataNode** 에 저장됩니다. JobTracker/ResourceManager 는 자원 관리 및 작업 스케줄링과 관련된 구성 요소입니다.

문제 5. 정답 ②

- 해설: 맵리듀스는 **Map(입력을 Key-Value 로 변환) → Shuffle & Sort(같은 Key 끼리 재정렬) → Reduce(Key 별 집계)** 순서로 진행됩니다.

문제 6. 정답 ②

- 해설: Spark 는 중간 연산 결과를 디스크가 아닌 **메모리(RAM)**에 유지하며 반복 연산을 수행하기 때문에, 매 단계마다 디스크 입출력이 필요한 MapReduce 보다 특히 반복적인 머신러닝 연산 등에서 훨씬 빠릅니다.

문제 7. 정답 ②

- 해설: **PaaS(Platform as a Service)**는 운영체제, 미들웨어, 런타임 등 애플리케이션 개발·실행에 필요한 플랫폼을 서비스로 제공합니다. IaaS 는 하드웨어 인프라, SaaS 는 완성된 소프트웨어를 제공하는 모델입니다.

2과목 정리를 마쳤습니다. 이어서 **3과목: 데이터분석 기획**으로 진행할까요?

[사용자] 네

3 과목: 데이터분석 기획

3-1. 데이터분석 기획의 이해

① 분석 기획 방향성 도출

분석 기획은 **분석 대상(What)**과 **분석 방법(How)**을 아는지 모르는지에 따라 4가지 유형으로 구분됩니다.

구분	분석 대상(What)을 아는 경우	분석 대상(What)을 모르는 경우
분석 방법(How)을 아는 경우	최적화(Optimization): 기존 분석 대상 및 방법을 최적화하여 수행	통찰(Insight): 기존 문제에 대해 새로운 분석 방법을 적용하여 인사이트 도출
분석 방법(How)을 모르는 경우	솔루션(Solution): 새로운 문제에 대해 기존 분석 방법을 응용	발견(Discovery): 분석 대상과 방법을 모두 새롭게 발굴

- 조직 내 분석 준비도(Analytics Readiness)와 분석 성숙도(Analytics Maturity) 진단이 선행되어야 함

- **분석 준비도**: 분석 업무, 인력·조직, 분석 기법, 분석 데이터, IT 인프라, 분석 문화 등 6 가지 영역 진단
- **분석 성숙도 모델(단계)**: 도입단계 → 활용단계 → 확산단계 → 최적화단계

② 분석 방법론

● KDD (Knowledge Discovery in Databases) 분석 방법론

- 데이터셋 선택(Selection) → 데이터 전처리(Preprocessing) → 데이터 변환(Transformation) → 데이터 마이닝(Data Mining) → 해석과 평가(Interpretation/Evaluation)

● CRISP-DM (Cross Industry Standard Process for Data Mining) 방법론 — 가장 자주 출제되는 핵심 방법론

- **업무 이해(Business Understanding)**: 비즈니스 목표 파악, 상황 평가, 데이터마이닝 목표 설정, 프로젝트 계획 수립
- **데이터 이해(Data Understanding)**: 데이터 수집, 데이터 속성 탐색(Describe), 데이터 품질 확인
- **데이터 준비(Data Preparation)**: 분석용 데이터셋 구성, 정제, 통합, 포매팅 — 전체 프로젝트에서 시간이 가장 많이 소요되는 단계
- **모델링(Modeling)**: 모델링 기법 및 모수 선택, 모델 작성, 모델 평가
- **평가(Evaluation)**: 모델링 결과가 비즈니스 목적에 부합하는지 평가, 프로젝트 검토
- **전개/배포(Deployment)**: 모델 적용 및 실 업무 반영, 모니터링/유지보수 계획 수립

○ 각 단계는 순차적이면서도 **반복적(Iterative)**으로 진행됨이 특징

- **빅데이터 분석 방법론(일반적 절차)**: 분석 기획 → 데이터 준비 → 데이터 분석 → 시스템 구현 → 평가 및 전개

③ 분석 과제 발굴

- **하향식 접근법(Top-Down Approach)**: 문제가 사전에 명확히 정의된 경우, 문제 탐색(Problem Discovery) → 문제 정의(Problem Definition) → 해결방안 탐색(Solution Search) → 타당성 검토(Feasibility Study) 순으로 진행
 - 문제 탐색 시 **비즈니스 모델 캔버스**, 외부 벤치마킹, 시장/고객 분석 등 활용
- **상향식 접근법(Bottom-Up Approach)**: 문제 정의 자체가 어려운 경우, 데이터를 탐색(디자인 사고 접근법)하여 문제를 도출. 비지도학습 방법(군집분석 등)을 통해 문제 자체를 새롭게 도출
- 실제로는 두 접근법을 **혼합(Hybrid)**하여 사용하는 경우가 많음
- 분석 과제 우선순위 평가 기준: **시급성(비즈니스 성과/ROI 중심)**과 **난이도(데이터 획득/적용 비용 중심)**의 2 가지 축으로 포트폴리오 사분면 분석 수행. 일반적으로 "시급성이 높고 난이도가 낮은" 영역을 우선적으로 추진 권고

④ 분석 프로젝트 관리 방안

- 일반적인 프로젝트 관리 영역(PMBOK)에 추가하여 분석 프로젝트는 다음 5 가지 특성을 추가로 고려해야 함:
 - **Data Size**(데이터 크기), **Data Complexity**(데이터 복잡도), **Speed**(속도), **Data Confidentiality**(데이터 보안), **Analytic Complexity**(분석 복잡도)

3-2. 분석 마스터 플랜

① 마스터 플랜 수립

- 정의: 분석 과제를 대상으로 **우선순위**를 설정하고 **로드맵**을 수립하는 것
- 우선순위 고려요소: 전략적 중요도, 비즈니스 성과/ROI, 실행 용이성
- **적용 범위/방식에 따른 우선순위**:
 - 업무 내재화 여부(단위 업무 적용 vs. 시스템 내재화)
 - 분석 데이터 적용 수준(내부 데이터 vs. 외부 데이터 결합)
 - 기술 적용 수준(운영 시스템 vs. 실시간 분석 등)
- 로드맵 수립 시 고려 우선순위: 업무 내재화 적용 수준, 분석 데이터 적용 수준, 기술 적용 수준을 고려하여 단계적 실행계획 수립 (일반적으로 3 단계: 데이터 분석 체계 도입 → 데이터 분석 유효성 검증 → 데이터 분석 확산 및 고도화)

② 분석 거버넌스 체계 수립

- 정의: 조직 전체적으로 분석 문화를 내재화하고 지속적으로 분석 과제를 발굴·관리하기 위한 체계
- 거버넌스 구성 요소:
 - **Organization(조직)**: 분석 전담 조직 구조 (예: 집중형, 기능형, 분산형)
 - **Process(프로세스)**: 과제 발굴부터 실행까지의 체계화된 프로세스
 - **System(시스템)**: 분석 관련 IT 인프라(분석 도구, 시스템 등)
 - **Data(데이터)**: 데이터 표준화, 데이터 관리 체계, 마스터 데이터 관리(MDM)
 - **Human Resource(인적자원)**: 분석 전문 인력 확보 및 역량 강화 체계
- 데이터 분석 조직 구조 유형:
 - **집중형(Centralized)**: 전사 분석 조직이 별도로 존재, 전략적 중요도가 높은 분석 우선 수행 가능하나 현업 부서와 소통 이슈 발생 가능
 - **기능형(Functional)**: 별도 조직 없이 각 부서에서 분석 수행, 전사적 핵심 분석 어려움
 - **분산형(Distributed)**: 분석 조직 인력들을 현업 부서에 배치, 전사 및 부서 수준 분석 모두 수행 가능하나 관리 어려움 존재

3 과목 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 분석 대상(What)과 분석 방법(How)에 따른 분석 기획 유형 중, 기존에 인지하고 있던 문제에 대해 새로운 분석 방법을 적용하여 인사이트를 도출하는 유형은?

- ① 최적화(Optimization) ② 솔루션(Solution) ③ 통찰(Insight) ④ 발견(Discovery)

문제 2. CRISP-DM 방법론의 프로세스 단계를 순서대로 바르게 나열한 것은?

- ① 데이터 이해 → 업무 이해 → 데이터 준비 → 모델링 → 평가 → 전개 ② 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개 ③ 업무 이해 → 데이터 준비 → 데이터 이해 → 모델링 → 평가 → 전개 ④ 데이터 준비 → 업무 이해 → 데이터 이해 → 평가 → 모델링 → 전개

문제 3. CRISP-DM 방법론의 단계 중, 프로젝트 전체 기간에서 일반적으로 가장 많은 시간이 소요되는 단계는?

- ① 업무 이해(Business Understanding) ② 데이터 준비(Data Preparation) ③ 모델링(Modeling) ④ 전개(Deployment)

문제 4. 분석 과제 발굴 접근법 중, 문제 정의가 어려운 상황에서 데이터를 탐색하며 문제 자체를 새롭게 도출해 나가는 방식은?

- ① 하향식 접근법(Top-Down) ② 상향식 접근법(Bottom-Up) ③ 수직적 접근법 ④ 확산적 접근법

문제 5. 분석 과제 우선순위를 선정할 때 사용하는 포트폴리오 사분면 분석의 두 축으로 가장 적절한 것은?

- ① 데이터 크기, 분석 인력 수 ② 시급성, 난이도 ③ 예산, 조직 규모 ④ 기술 수준, 보안 등급

문제 6. 데이터 분석 조직 구조 유형 중, 분석 전문 인력을 현업 부서에 배치하여 전사 및 부서 차원의 분석을 모두 수행할 수 있으나 관리의 어려움이 있는 구조는?

- ① 집중형(Centralized) ② 기능형(Functional) ③ 분산형(Distributed) ④ 독립형(Independent)

문제 7. 분석 거버넌스 체계의 구성 요소로 옳지 않은 것은?

- ① Organization(조직) ② Process(프로세스) ③ System(시스템) ④ Marketing(마케팅)

3 과목 기출유형 문제 (풀이)

문제 1. 정답 ③

- 해설: 분석 대상(What)을 알고 있지만 분석 방법(How)을 모르는 경우가 **통찰(Insight)**에 해당합니다. 반대로 최적화는 대상과 방법을 모두 아는 경우, 솔루션은 대상은 모르지만 방법은 아는 경우, 발견은 대상과 방법을 모두 모르는 경우입니다. ※ 참고: 표의 축 설정에 따라 교재별로 용어 배치가 다르게 설명되기도 하니, 두 축(What/How)의 인지 여부 조합 자체를 정확히 이해하는 것이 중요합니다.

문제 2. 정답 ②

- 해설: CRISP-DM 은 **업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개(배포)**의 6 단계로 구성되며, 실제로는 단계 간 반복(Iteration)이 빈번히 발생합니다.

문제 3. 정답 ②

- 해설: **데이터 준비(Data Preparation)** 단계는 데이터 정제, 결측치/이상치 처리, 통합, 파생변수 생성 등을 포함하며 실무에서 전체 분석 프로젝트 시간의 상당 부분(흔히 70~80% 수준으로 언급됨)을 차지하는 것으로 알려져 있습니다.

문제 4. 정답 ②

- 해설: **상향식 접근법(Bottom-Up)**은 문제를 사전에 명확히 정의하기 어려운 경우, 데이터 자체를 탐색(비지도학습, 디자인 사고 등)하며 문제를 발굴해 나가는 방식입니다. 반면 하향식 접근법은 문제가 이미 정의된 상태에서 이를 세분화하여 해결방안을 찾아가는 방식입니다.

문제 5. 정답 ②

- 해설: 분석 과제 우선순위 평가는 일반적으로 **시급성(비즈니스 성과·ROI)**과 **난이도(데이터 획득·적용의 용이성)**를 두 축으로 하는 포트폴리오 사분면을 통해 수행되며, 시급성이 높고 난이도가 낮은 과제를 우선 추진하는 것이 일반적 전략입니다.

문제 6. 정답 ③

- 해설: **분산형(Distributed)** 구조는 분석 인력을 각 현업 부서에 배치하여 전사적 관점과 부서 관점의 분석을 모두 수행할 수 있는 장점이 있으나, 인력에 대한 관리·통제가 어렵다는 단점이 있습니다. 집중형은 별도의 전사 분석 조직을 두는 구조이며, 기능형은 별도 조직 없이 각 부서가 개별적으로 분석을 수행하는 구조입니다.

문제 7. 정답 ④

- 해설: 분석 거버넌스 체계의 구성 요소는 **Organization(조직), Process(프로세스), System(시스템), Data(데이터), Human Resource(인적자원)**의 5 가지입니다. Marketing(마케팅)은 이에 해당하지 않습니다.

3과목 정리를 마쳤습니다. 다음은 배점 비중이 가장 큰(40점) **4과목: 데이터분석**입니다. 범위가 넓어(R기초/데이터마트, 통계분석, 정형 데이터마이닝, 비정형 데이터마이닝) 세부 주제별로 나누어 진행하는 것이 효율적일 것 같습니다.

[사용자] 잠시만 나는 실기시험에서 파이썬으로 시험을 칠건데 R을 알아야 하는거야?

R 필기시험 필요 여부에 대한 답변

네, 좋은 질문입니다. 결론부터 말씀드리면 **필기시험에는 R 관련 문제가 출제되므로 R 기초는 어느 정도 알아야 합니다.** 다만 실기시험에서 사용할 언어와는 별개의 문제입니다.

왜 R 을 알아야 하나요?

- **필기시험 출제기준 자체에 "R 기초와 데이터 마트"가 명시되어 있습니다.** (4 과목 "데이터분석"의 세부 항목 중 하나)
- **실기시험은 R 또는 Python 중 편한 언어를 선택하여 실제 데이터를 분석하는 방식이므로,** 파이썬으로 응시하시는 데 전혀 문제가 없습니다.
- 즉, **필기(이론) ≠ 실기(실습 언어)** 관계입니다. 필기에서는 R 의 기본 문법과 함수를 "알아야" 하고, 실기에서는 그것과 무관하게 파이썬으로 코딩하시면 됩니다.

필기시험에서 요구되는 R 수준

ADsP/ADP 계열 시험의 R 문제는 실무에서 코드를 직접 짜는 능력보다는 다음 수준을 주로 묻습니다.

유형	예시
기본 자료구조	vector, factor, matrix, data.frame, list의 차이와 특징
기본 함수 의미 파악	str(), summary(), apply() 계열(sapply, lapply, tapply), merge(), which() 등의 결과 해석
결측값/이상값 처리 함수	is.na(), complete.cases(), na.omit() 등

유형	예시
코드 해석형 문제	짧은 R 코드를 보고 "이 코드의 실행 결과는?" 또는 "빈칸에 들어갈 함수는?"
문법 오류 찾기	여러 R 코드 중 문법적으로 잘못된 것 고르기

즉, "이 코드를 짜라"보다는 "이 코드가 뭘 하는지, 결과가 뭔지 맞혀라" 유형이 훨씬 많습니다. 실제로 나무위키의 ADsP 관련 설명에서도 계산보다 결과해석, 개념구분이 중요하며, R언어는 실제 코딩 능력을 깊게 요구하지 않고 주로 함수 의미, 결과 해석, 문법구분 수준이라고 언급하고 있어, ADP도 이와 유사한 기조로 출제되는 경향이 있습니다.

학습 전략 제안

파이썬에 익숙하신 상태라면, R을 처음부터 깊게 공부하기보다는:

- **핵심 함수 30~40 개 정도의 "의미와 용도"를 매핑해서 암기** (예: `apply` 는 리스트/벡터의 각 요소에 함수 적용 후 벡터/행렬로 반환)
- **파이썬 개념과 1:1 대응시켜 이해** (예: R 의 `data.frame` ↔ Python 의 `pandas DataFrame`, `apply()` ↔ `pandas .apply()`)
- 실제로 R 을 설치해서 코드를 짜는 연습보다는, **기출/예상 문제에 나오는 R 코드를 눈으로 읽고 해석**하는 연습에 시간을 집중하는 것이 효율적입니다.

이제 다시 4과목으로 돌아가서, 말씀하신 대로 "R기초와 데이터 매트"부터 진행할까요? R 코드 해석 문제 위주로 준비해 드리겠습니다.

[사용자] 네 진행해줘

ADP 필기시험 대비 자료 (4-1) — 데이터분석: R 기초와 데이터 매트

4 과목 - R 기초와 데이터 매트

4-1-1. R 기초

① R의 기본 자료구조

자료구조	특징	비고
Vector	동일한 자료형(type)의 1차원 데이터 집합	<code>c(1,2,3)</code> — 가장 기본이 되는 자료구조
Factor	범주형(명목/순서형) 데이터를 표현. 내부적으로 정수로	<code>factor(c("남","여"))</code>

자료구조	특징	비고
	저장되고 레벨(level)을 가짐	
Matrix	동일 자료형으로 구성된 2차원 배열	matrix(1:6, nrow=2)
Array	3차원 이상의 동일 자료형 배열	
Data.frame	서로 다른 자료형을 열(column)마다 가질 수 있는 2차원 테이블 — 실무·시험에서 가장 중요	각 컬럼은 vector, 길이는 동일해야 함
List	자료형이 다른 여러 객체를 하나로 묶은 구조 (가장 유연함)	list(1, "a", TRUE)

- 핵심 구분 포인트(자주 출제): **matrix** 는 모든 원소가 같은 자료형이어야 하지만, **data.frame** 은 얼마다 다른 자료형을 가질 수 있음

② 주요 함수 (결과 해석 중심으로 암기)

함수	기능	Python 대응 개념
str()	객체의 구조(자료형, 크기 등) 요약 출력	df.info()
summary()	기술통계 요약(최소/최대/사분위수/평균 등)	df.describe()
head() / tail()	앞/뒤 일부 행 출력	df.head() / df.tail()
sapply(X, FUN)	X의 각 원소에 FUN 적용, 결과를 벡터/행렬로 단순화하여 반환	df.apply() (단순화)
lapply(X, FUN)	X의 각 원소에 FUN 적용, 결과를 리스트로 반환 (단순화 안 함)	map()
apply(X, MARGIN, FUN)	행렬/데이터프레임에서 MARGIN=1(행별)/2(열별) 기준으로 FUN 적용	df.apply(axis=)
tapply(X, INDEX, FUN)	X를 INDEX(그룹) 기준으로 나누어 FUN 적용	df.groupby().agg()
mapply(FUN, ...)	여러 벡터를 동시에 순회하며 FUN 적용	map(func, iter1, iter2)
merge(x, y, by=)	두 데이터프레임을 특정 키(key) 기준으로 결합(join)	pd.merge()
which()	조건을 만족하는 원소의 인덱스(위치) 반환	np.where()
ifelse(조건, T, F)	벡터 단위 조건부 값 반환	np.where()

③ 결측값(Missing Value) 처리

함수	기능
is.na(x)	결측치 여부를 논리값(TRUE/FALSE)으로 반환
complete.cases(df)	행 단위로 결측치가 없는 완전한 행이면 TRUE 반환
na.omit(df)	결측치가 포함된 행을 제거한 데이터프레임 반환
sum(is.na(x))	결측치 개수 세기 (자주 결함 출제)

결측값 처리 방법론(개념 문제로 출제):

- **완전 제거법(Complete Case Analysis):** 결측이 있는 행/열 전체를 삭제 — 정보 손실 위험
- **평균/중앙값/최빈값 대치법(Imputation):** 대표값으로 채워 넣음 — 분산 과소추정 위험
- **단순확률 대치법:** Hot-deck 방법 등, 무작위성을 고려하여 대치
- **다중 대치법(Multiple Imputation):** 결측값을 여러 번(예: m 회) 대치하여 m 개의 완전한 데이터셋을 생성 후 결과를 결합 — 대치 과정의 불확실성까지 반영하는 가장 정교한 방법

④ 이상값(Outlier) 검색

- **박스플롯(Box-plot) 기준:** 1 사분위수(Q1) - 1.5×IQR 미만 또는 3 사분위수(Q3) + 1.5×IQR 초과 값 (IQR = Q3-Q1)
- **ESD(Extreme Studentized Deviate):** 평균으로부터 3 표준편차 이상 떨어진 값
- **마할라노비스 거리(Mahalanobis Distance):** 다변량 데이터에서 변수 간 상관관계를 고려한 거리 기반 이상치 탐지
- **밀도 기반 클러스터링(DBSCAN):** 밀도가 낮은 영역에 있는 점을 이상치(noise)로 분류

4-1-2. 데이터 마트(Data Mart)

① 정의 및 특징

- 데이터 웨어하우스(DW)로부터 특정 부서/목적에 맞게 **추출·가공된 소규모 데이터 저장소**
- 전사 차원의 DW 보다 규모가 작고, 특정 분석 목적에 최적화된 형태로 구성
- 구축 방식: DW 로부터 추출하는 **하향식(Dependent)** 방식과, DW 없이 원천 데이터에서 직접 구축하는 **상향식(Independent)** 방식

② 데이터 마트 구축 절차

- 요구사항 분석 → 데이터 설계(스키마 설계) → ETL 처리(데이터 추출·변환·적재) → 검증 및 배포

③ 파생변수/요약변수

- **파생변수(Derived Variable):** 기존 변수를 조합·가공하여 새롭게 생성한 변수 (예: 생년월일 → 나이)

- **요약변수(Summary Variable)**: 다수의 관측치를 대표하는 요약된 값 (예: 고객별 월평균 구매액)
- 데이터 분석의 성패를 좌우하는 중요한 전처리 작업으로 자주 강조됨

4 과목(R 기초/데이터마트) 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 다음 중 R의 자료구조에 대한 설명으로 옳지 않은 것은?

- ① vector는 동일한 자료형의 원소로만 구성된다. ② matrix는 서로 다른 자료형의 원소를 얼마다 다르게 가질 수 있다. ③ data.frame은 열(column)마다 서로 다른 자료형을 가질 수 있다. ④ list는 자료형이 서로 다른 객체들을 하나로 묶을 수 있다.

문제 2. 다음 R 코드의 실행 결과로 가장 적절한 것은?

```
x <- list(a = 1:3, b = 4:6)
result <- sapply(x, sum)
print(result)
```

- ① 리스트 형태로 각 원소의 합이 반환된다. ② 벡터 형태로 a=6, b=15 값이 반환된다. ③ 데이터 프레임 형태로 반환된다. ④ 오류가 발생한다.

문제 3. 데이터프레임 df에서 결측치가 하나도 없는 완전한 행(row)만을 논리값(TRUE/FALSE)으로 판별하는 함수는?

- ① is.na(df) ② na.omit(df) ③ complete.cases(df) ④ which(df)

문제 4. 결측값 대체 방법 중, 결측값을 여러 번 대체하여 여러 개의 완전한 데이터셋을 만들고 그 결과를 결합함으로써 대체 과정에서 발생하는 불확실성까지 반영하는 방법은?

- ① 단순 확률 대체법 ② 평균 대체법 ③ 다중 대체법(Multiple Imputation) ④ 완전 제거법

문제 5. 박스플롯(Box-plot)을 이용한 이상값 판단 기준으로 옳은 것은? ($IQR = Q3 - Q1$)

- ① 평균 ± 1 표준편차를 벗어나는 값 ② $Q1 - 1.5 \times IQR$ 미만 또는 $Q3 + 1.5 \times IQR$ 초과인 값 ③ 최댓값과 최솟값의 평균을 벗어나는 값 ④ 중앙값의 2배를 초과하는 값

문제 6. apply(X, MARGIN, FUN) 함수에서 MARGIN 인자에 대한 설명으로 옳은 것은?

- ① MARGIN=1이면 열(column) 단위, MARGIN=2이면 행(row) 단위로 함수를 적용한다. ② MARGIN=1이면 행(row) 단위, MARGIN=2이면 열(column) 단위로 함수를 적용한다. ③ MARGIN은 반드시 0이어야 한다. ④ MARGIN 값에 관계없이 항상 전체 데이터에 함수를 적용한다.

문제 7. 데이터 마트(Data Mart)에 대한 설명으로 가장 적절하지 않은 것은?

- ① 특정 부서나 목적에 맞게 최적화된 소규모 데이터 저장소이다. ② 데이터 웨어하우스보다 일반적으로 규모가 작다. ③ 반드시 데이터 웨어하우스를 거쳐서만 구축할 수 있다. ④ 상향식

(Independent) 방식으로도 구축이 가능하다.

문제 8. 기존 변수를 가공하여 새롭게 생성한 변수로, 예를 들어 '생년월일'로부터 '나이'를 계산하여 만든 변수를 지칭하는 용어는?

- ① 요약변수(Summary Variable) ② 파생변수(Derived Variable) ③ 종속변수(Dependent Variable)
④ 잠재변수(Latent Variable)

4 과목(R 기초/데이터마트) 기출유형 문제 (풀이)

문제 1. 정답 ②

- 해설: **matrix** 는 vector 와 마찬가지로 모든 원소가 동일한 자료형이어야 합니다. 열마다 서로 다른 자료형을 가질 수 있는 것은 **data.frame** 의 특징입니다. ①③④는 모두 옳은 설명입니다.

문제 2. 정답 ②

- 해설: `apply()`는 리스트의 각 원소(a, b)에 `sum()` 함수를 적용한 뒤, 결과가 스칼라 값들로 단순화 가능하면 이름이 붙은 벡터(named vector) 형태로 반환합니다. $a = 1+2+3 = 6$, $b = 4+5+6 = 15$ 이므로 $a=6$, $b=15$ 인 벡터가 결과로 나옵니다. 참고로 동일한 연산에 `lapply()`를 사용하면 벡터가 아닌 리스트 형태로 반환된다는 차이를 함께 기억해두시면 좋습니다.

문제 3. 정답 ③

- 해설: `complete.cases(df)`는 행 단위로 결측치가 전혀 없으면 TRUE, 하나라도 있으면 FALSE 를 반환합니다. `is.na()`는 원소 단위로 결측 여부를 판별하고, `na.omit()`은 결측 행을 아예 제거한 데이터프레임 자체를 반환한다는 차이가 있습니다.

문제 4. 정답 ③

- 해설: 다중 대치법(Multiple Imputation)은 결측값을 한 번이 아니라 여러 번(m 회) 대치하여 m 개의 완전한 데이터셋을 만들고, 각각 분석한 결과를 결합(pooling)함으로써 단일 대치법이 가지는 "대치값을 마치 실제 관측값처럼 취급하는" 불확실성 과소평가 문제를 보완하는 방법입니다.

문제 5. 정답 ②

- 해설: 박스플롯 기반 이상값 판정의 표준 기준은 $Q1 - 1.5 \times IQR$ 미만 또는 $Q3 + 1.5 \times IQR$ 초과인 값입니다. ④은 ESD(Z-score) 방식에 대한 설명에 가깝습니다.

문제 6. 정답 ②

- 해설: `apply()`에서 **MARGIN=1** 은 행(row) 단위, **MARGIN=2** 는 열(column) 단위로 함수를 적용합니다. (예: `apply(df, 1, sum)`은 각 행의 합, `apply(df, 2, mean)`은 각 열의 평균)

문제 7. 정답 ③

- 해설: 데이터 마트는 데이터 웨어하우스로부터 추출하는 **하향식(Dependent)** 방식뿐 아니라, DW 를 거치지 않고 원천 데이터로부터 직접 구축하는 **상향식(Independent)** 방식으로도 구축될 수 있습니다. 따라서 "반드시 DW 를 거쳐서만 구축 가능하다"는 설명은 옳지 않습니다.

문제 8. 정답 ②

- 해설: 기존 변수를 가공·조합하여 새롭게 만든 변수는 **파생변수(Derived Variable)**입니다. 다수의 관측치를 요약한 대표값(예: 고객별 평균 구매액)은 **요약변수(Summary Variable)**로 구분됩니다.

R기초/데이터마트 파트를 마쳤습니다. 다음은 4과목의 핵심이자 배점 비중이 가장 큰 "통계분석" 파트로 넘어가겠습니다.

[사용자] R에 대해서 좀 더 세부적으로 더 공부하고 다음 과정으로 넘어갔으면 해 특히 R의 수행결과를 해석하는 내용을 더 보완해줘. 물론 시험에 많이 나오는 내용위주로 알려 줘

ADP 필기시험 대비 자료 (4-1 보완) — R 수행결과 해석 심화

말씀하신 대로 R의 **실행 결과 해석**에 초점을 맞춰 시험에 자주 나오는 패턴들을 실제 출력 예시와 함께 정리해 드리겠습니다.

1. 기본 함수의 실제 출력 형태 이해

① str() 출력 해석

```
> str(iris)
'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 ...
 $ Sepal.Width : num 3.5 3 3.2 3.1 3.6 ...
 $ Species      : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 ...
```

- **해석 포인트:** "150 obs. of 5 variables"는 관측치(행) 150 개, 변수(열) 5 개를 의미. Species 가 "Factor w/ 3 levels"로 표시된 것은 **범주형 변수이며 3 개의 범주(레벨)를 가짐**을 뜻함 — 시험에서 "이 변수는 몇 개의 범주를 갖는가?"를 str() 출력만 보고 맞히는 문제가 자주 출제됨

② summary() 출력 해석 — 숫자형 vs 범주형의 차이 (매우 자주 출제)

```
> summary(iris$Sepal.Length)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
4.300  5.100   5.800   5.843  6.400   7.900

> summary(iris$Species)
  setosa versicolor virginica
    50         50         50
```

- **숫자형 변수**: 최솟값, 1 사분위수, 중앙값, **평균**, 3 사분위수, 최댓값의 6 가지 요약통계량 출력
- **범주형(Factor) 변수**: 각 범주(level)별 **빈도수(개수)**가 출력됨 — 평균/중앙값이 아니라 개수라는 점이 핵심 함정 포인트

③ table() — 교차표(분할표) 해석

```
> table(mtcars$cyl, mtcars$am)
```

```
      0  1
4     3  8
6     4  3
8    12  2
```

- table(행변수, 열변수) 형태로, 행은 첫 번째 인자, 열은 두 번째 인자 기준으로 빈도 교차표 생성
- 해석 문제 예: "cyl=8 이면서 am=0 인 관측치는 몇 개인가?" → 표에서 (8 행, 0 열) 교차값 = **12**

④ which(), which.max(), which.min() — 인덱스(위치) vs 값 구분 (매우 자주 출제되는 함정)

```
> x <- c(10, 25, 3, 47, 8)
> which(x > 10)
[1] 2 4
> which.max(x)
[1] 4
> max(x)
[1] 47
```

- **핵심 함정**: which(x>10)은 조건을 만족하는 **원소의 위치(인덱스)**를 반환(값 25, 47 이 아니라 **2 번째, 4 번째**라는 뜻)
- which.max(x)도 최댓값 **자체(47)**가 아니라 **최댓값이 위치한 인덱스(4)**를 반환 — 최댓값 자체는 max(x)

⑤ apply 계열 함수 - 반환 형태 차이 총정리 (필기 단골 문제)

```
> lst <- list(a=1:3, b=4:6, c=7:9)

> sapply(lst, sum)      # 벡터로 반환 (단순화 가능하면)
  a  b  c
6 15 24

> lapply(lst, sum)      # 리스트로 반환 (단순화 안 함)
$a
[1] 6
$b
[1] 15
$c
[1] 24
```

```
> m <- matrix(1:6, nrow=2)
> apply(m, 1, sum)      # 행(row) 기준 합
[1]  9 12 15
> apply(m, 2, sum)      # 열(column) 기준 합
[1]  3  7 11
```

- 자주 나오는 질문 유형: "동일한 연산에 sapply 대신 lapply 를 쓰면 결과의 자료구조가 무엇으로 바뀌는가?" → list

⑥ tapply() — 그룹별 통계 (그룹연산 해석 문제)

```
> tapply(iris$Sepal.Length, iris$Species, mean)
      setosa versicolor  virginica 
      5.006      5.936      6.588
```

- Species(그룹)별로 Sepal.Length 의 평균을 계산 — pandas 의 groupby().mean()과 동일 개념

⑦ %in%, union, intersect, setdiff — 집합 연산 (결과값 헷갈리기 쉬움)

```
> a <- c(1,2,3,4)
> b <- c(3,4,5,6)

> a %in% b
[1] FALSE FALSE  TRUE  TRUE
> union(a, b)
[1] 1 2 3 4 5 6
> intersect(a, b)
[1] 3 4
> setdiff(a, b)
[1] 1 2
```

- 핵심: a %in% b 는 a 의 각 원소가 b 에 존재하는지 여부를 a 와 같은 길이의 논리벡터로 반환 (교집합 자체를 반환하는 게 아님) — intersect(a,b)와 혼동하지 않도록 주의

⑧ 결측치(NA) 관련 연산 결과 (매우 자주 출제되는 함정)

```
> x <- c(1, 2, NA, 4)
> sum(x)
[1] NA
> sum(x, na.rm=TRUE)
[1] 7
> mean(x)
[1] NA
> is.na(x)
[1] FALSE FALSE  TRUE FALSE
```

- 핵심: R 에서 NA 가 포함된 벡터는 na.rm=TRUE 옵션 없이 sum(), mean() 등을 적용하면 결과가 NA 로 전파(propagation)됨 — "다음 코드의 실행 결과는?"류 문제에서 이 옵션 누락을 이용한 함정이 매우 흔함

⑨ cut() — 연속형 변수의 구간화(범주화) 결과 해석

```
> age <- c(15, 25, 35, 45, 55)
> cut(age, breaks=c(0,20,40,60), labels=c("청소년","중년","장년"))
```

[1] 청소년 중년 중년 장년 장년
Levels: 청소년 중년 장년

- 파생변수(연령대 그룹) 생성 시 자주 사용되는 함수로, 결과가 **Factor** 형으로 반환된다는 점이 포인트

⑩ merge() — Join 방식별 결과 행 개수 차이 (실무형 해석 문제)

```
> df1 <- data.frame(id=c(1,2,3), name=c("A","B","C"))
> df2 <- data.frame(id=c(2,3,4), score=c(90,85,70))

> merge(df1, df2, by="id") # inner join: 공통 id만
  id name score
1  2   B    90
2  3   C    85

> merge(df1, df2, by="id", all=TRUE) # full outer join: 전체 id, 없는 값은 NA
  id name score
1  1   A    NA
2  2   B    90
3  3   C    85
4  4 <NA>    70
```

- all=TRUE(전체), all.x=TRUE(왼쪽 기준), all.y=TRUE(오른쪽 기준) 옵션에 따라 **결과 행 개수와 NA 발생 위치**가 달라짐을 정확히 이해해야 함

⑪ 정렬 관련 함수 - sort() vs order() (구분 어려운 대표 함정)

```
> x <- c(30, 10, 20)
> sort(x)
[1] 10 20 30
> order(x)
[1] 2 3 1
```

- **핵심 차이**: sort(x)는 정렬된 값 자체를 반환하지만, order(x)는 정렬했을 때의 원래 인덱스 순서를 반환함. order()는 여러 변수 기준 정렬이나 데이터프레임 정렬(df[order(df\$col),])에 실무적으로 많이 쓰이므로 개념 구분 문제가 자주 출제됨

R 수행결과 해석 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 다음 R 코드를 실행한 결과로 옳은 것은?

```
x <- c(5, 12, 8, 20, 3)
print(which.max(x))
```

① 20 ② 4 ③ 5 ④ 3

문제 2. 다음 R 코드의 실행 결과로 옳은 것은?

```
x <- c(2, 4, NA, 8)
print(sum(x))
```

- ① 14 ② NA ③ 0 ④ 오류 발생

문제 3. 다음 R 코드의 실행 결과로 옳은 것은?

```
a <- c(1, 3, 5, 7)
b <- c(3, 5, 9)
print(a %in% b)
```

- ① [1] 3 5 ② [1] FALSE TRUE TRUE FALSE ③ [1] TRUE FALSE ④ 오류 발생

문제 4. 다음 R 코드를 실행했을 때 result의 자료구조로 옳은 것은?

```
lst <- list(a=1:3, b=4:7)
result <- lapply(lst, sum)
```

- ① vector ② list ③ data.frame ④ matrix

문제 5. iris 데이터셋에 대해 summary(iris\$Species)를 실행했을 때 출력되는 값의 의미로 가장 적절한 것은?

- ① 각 종(species)별 Sepal.Length의 평균값 ② 각 종(species)의 최솟값과 최댓값 ③ 각 종(species)에 해당하는 관측치의 개수(빈도) ④ 각 종(species)의 상관계수

문제 6. 다음 R 코드의 실행 결과로 옳은 것은?

```
x <- c(30, 10, 20)
print(order(x))
```

- ① [1] 10 20 30 ② [1] 2 3 1 ③ [1] 1 2 3 ④ [1] 3 1 2

문제 7. 두 데이터프레임 df1(id: 1,2,3)과 df2(id: 2,3,4)에 대해 merge(df1, df2, by="id")를 실행했을 때(옵션 없음, 기본값), 결과에 포함되는 id 값으로 옳은 것은?

- ① 1, 2, 3, 4 ② 2, 3 ③ 1 ④ 4

문제 8. 다음 R 코드를 실행했을 때 tapply()의 기능에 대한 설명으로 가장 적절한 것은?

```
tapply(iris$Petal.Length, iris$Species, mean)
```

- ① Petal.Length 전체의 평균을 하나의 값으로 반환한다. ② Species 그룹별로 Petal.Length의 평균을 각각 계산하여 반환한다. ③ Species와 Petal.Length 간의 상관계수를 계산한다. ④ 데이터프레임 전체를 정렬하여 반환한다.

R 수행결과 해석 기출유형 문제 (풀이)

문제 1. 정답 ②

- 해설: which.max(x)는 최댓값 자체(20)가 아니라 **최댓값이 위치한 인덱스**를 반환합니다. 벡터 x = c(5,12,8,20,3)에서 20은 4번째 위치에 있으므로 결과는 **4**입니다. 최댓값 자체를 구하려면 max(x)를 사용해야 합니다.

문제 2. 정답 ②

- 해설: sum()은 벡터에 NA가 포함되어 있고 na.rm=TRUE 옵션을 지정하지 않으면 결과가 **NA로 전파**됩니다. 즉, "결측치를 무시하고 계산해줄 것"이라고 착각하기 쉬운 대표적인 함정 문제입니다. 결측치를 제외하고 합을 구하려면 sum(x, na.rm=TRUE)라고 명시해야 합니다.

문제 3. 정답 ②

- 해설: a %in% b는 a의 각 원소(1,3,5,7)가 b(3,5,9)에 존재하는지를 **a와 동일한 길이의 논리벡터**로 반환합니다. 1(없음)→FALSE, 3(있음)→TRUE, 5(있음)→TRUE, 7(없음)→FALSE 이므로 결과는 FALSE TRUE TRUE FALSE입니다. 교집합 값 자체(3, 5)를 반환하는 것은 intersect(a,b)이므로 혼동하지 않아야 합니다.

문제 4. 정답 ②

- 해설: lapply()는 입력이 리스트든 벡터든 관계없이 결과를 항상 **리스트(list)** 형태로 반환합니다. 동일한 연산을 sapply()로 수행하면 결과가 단순화 가능할 경우 벡터로 반환된다는 차이를 기억해야 합니다.

문제 5. 정답 ③

- 해설: Species는 범주형(Factor) 변수이므로, summary()를 적용하면 숫자형 변수처럼 평균·사분위수가 아니라 **각 범주(level)별 관측치 개수(빈도)**가 출력됩니다. 이는 변수의 자료형(숫자형 vs 범주형)에 따라 summary()의 출력 내용이 완전히 달라진다는 점을 확인하는 대표적인 문제 유형입니다.

문제 6. 정답 ②

- 해설: order(x)는 벡터를 오름차순으로 정렬했을 때 **각 위치에 원래 몇 번째 원소가 와야 하는지**를 나타내는 인덱스를 반환합니다. x=c(30,10,20)을 오름차순 정렬하면 10(2번째)→20(3번째)→30(1번째) 순서가 되므로 결과는 2 3 1입니다. 정렬된 값 자체(10,20,30)를 반환하는 것은 sort(x)입니다.

문제 7. 정답 ②

- 해설: 옵션 없이 사용한 merge()는 기본적으로 **inner join**으로 동작하여 두 데이터프레임에 **공통으로 존재하는 id 값**만을 결과에 포함합니다. df1(1,2,3)과 df2(2,3,4)의 공통 id는 **2와 3**입니다. 전체 id(1,2,3,4)를 모두 포함하려면 all=TRUE 옵션을 추가해야 합니다.

문제 8. 정답 ②

- 해설: tapply(데이터, 그룹변수, 함수)는 데이터를 그룹변수의 범주별로 나눈 뒤 각 그룹에 함수를 적용합니다. 즉 이 코드는 **Species(setosa/versicolor/virginica) 그룹별로 Petal.Length의 평균을 각각 계산하여 반환**합니다. 전체 평균 하나만 반환하는 것이 아니라는 점이 핵심입니다.

R 수행결과 해석 심화 내용을 마쳤습니다. 이제 다음 순서인 "통계분석" (통계학개론 → 기초통계분석 → 다변량분석 → 시계열예측)으로 진행할 예정입니다.