

ADP(데이터분석 전문가) 필기시험 준비자료

2부 — 통계분석(다변량/시계열) / 정형·비정형 데이터마이닝 / 데이터 시각화

[사용자] 네 다음진행 해 줘

ADP 필기시험 대비 자료 (4-2) — 데이터분석: 통계분석 (1)

통계학개론 & 기초통계분석

4 과목 - 통계분석

통계분석은 4과목(데이터분석, 40문항) 중에서도 비중이 가장 크고 심화된 이해를 요구하는 파트입니다. 범위가 넓어 오늘은 통계학개론과 기초통계분석을 먼저 다루고, 다음에 다변량분석과 시계열예측을 이어서 진행하겠습니다.

4-2-1. 통계학개론

① 통계학의 기본 개념

용어	정의
모집단(Population)	분석 대상이 되는 전체 집합
표본(Sample)	모집단에서 추출한 일부 관측치 집합
모수(Parameter)	모집단의 특성을 나타내는 값 (모평균 μ , 모분산 σ^2)
통계량(Statistic)	표본으로부터 계산된 값 (표본평균 $\bar{x}$, 표본분산 s^2)
표집분포(Sampling Distribution)	표본통계량이 가지는 확률분포

- **중심극한정리(Central Limit Theorem, CLT):** 모집단의 분포와 관계없이, 표본의 크기(n)가 충분히 크면 표본평균의 분포는 정규분포에 근사한다 — 통계적 추론의 핵심 근거로 매우 자주 출제됨
- **대수의 법칙(Law of Large Numbers):** 표본 크기가 커질수록 표본평균이 모평균에 가까워짐

② 확률분포

분포	특징	예시/용도
이항분포(Binomial)	n번의 독립시행에서 성공 횟수의 분포	동전 던지기, 불량품 개수
포아송분포(Poisson)	단위시간/공간에서 발생하는 희귀 사건의	콜센터 시간당 전화 건수

분포	특징	예시/용도
	발생 횟수	
정규분포(Normal)	좌우 대칭의 종형 분포, 평균=중앙값=최빈값	키, 몸무게 등 연속형 자연현상
표준정규분포	평균 0, 분산 1로 표준화한 정규분포 (Z분포)	Z-검정
t분포	정규분포와 유사하나 꼬리가 두꺼움, 표본크기가 작고 모분산 미지일 때 사용	소표본 평균 검정
카이제곱분포(χ^2)	표준정규분포를 따르는 확률변수의 제곱합	적합도 검정, 독립성 검정, 분산 검정
F분포	두 카이제곱분포의 비율	분산분석(ANOVA), 회귀모형 유의성 검정

- **핵심 구분 포인트(자주 출제):** 모분산을 알 때 평균 검정은 **Z-검정**, 모분산을 모르고 표본이 작을 때는 **t-검정** 사용

③ 통계적 추정과 가설검정

- **점추정(Point Estimation):** 모수를 하나의 값으로 추정 (예: 표본평균으로 모평균 추정)
- **구간추정(Interval Estimation):** 신뢰수준을 반영해 모수가 포함될 구간을 추정 (예: 95% 신뢰구간)
- **가설검정(Hypothesis Testing):**
 - **귀무가설(H_0):** 기각을 전제로 세우는 가설 (차이/효과가 "없다")
 - **대립가설(H_1):** 연구자가 입증하고자 하는 가설 (차이/효과가 "있다")
 - **유의수준(α):** 귀무가설이 참인데도 기각할 확률의 허용 기준 (보통 0.05)
 - **p-value:** 귀무가설이 참이라는 가정 하에, 관측된 통계량 이상의 극단적인 값이 나올 확률. **p-value < α 이면 귀무가설 기각**
- **1 종 오류(Type I Error):** 귀무가설이 참인데 기각하는 오류 (α 로 표시)
- **2 종 오류(Type II Error):** 귀무가설이 거짓인데 채택하는 오류 (β 로 표시)
- **검정력(Power):** 대립가설이 참일 때 이를 올바르게 채택할 확률 = $1 - \beta$
- **핵심 관계(자주 출제):** 유의수준(α)을 낮추면 1 종 오류는 줄어들지만 2 종 오류(β)는 증가하는 **trade-off** 관계 존재

4-2-2. 기초통계분석

① 기술통계량

구분	지표
중심경향치	평균(Mean), 중앙값(Median), 최빈값(Mode)
산포도	분산(Variance), 표준편차(SD), 범위(Range), 사분위범위(IQR)
분포의 형태	왜도(Skewness) — 좌우 비대칭 정도, 첨도(Kurtosis) — 뾰족한 정도

- **왜도**: 양수(Positive Skew, 오른쪽 꼬리 김) → 평균 > 중앙값 > 최빈값 / 음수(Negative Skew, 왼쪽 꼬리 김) → 평균 < 중앙값 < 최빈값
- **첨도**: 정규분포의 첨도를 3(또는 초과첨도 기준 0)으로 기준, 이보다 크면 뾰족한 분포(Leptokurtic), 작으면 평평한 분포(Platykurtic)

② 상관분석(Correlation Analysis)

- **피어슨 상관계수(Pearson)**: 두 연속형 변수 간 선형관계의 강도와 방향(-1~1)을 나타냄. 등간/비율 척도, 정규성 가정 하에 사용
- **스피어만 상관계수(Spearman)**: 순위 기반 상관계수. 순서형 변수나 비선형 단조관계, 정규성을 만족하지 않는 경우에 사용
- 상관계수는 인과관계를 의미하지 않음 (상관관계 ≠ 인과관계) — 시험에서 자주 강조되는 개념

③ 회귀분석(Regression Analysis)

- **단순선형회귀**: 독립변수 1 개, $Y = \beta_0 + \beta_1 X + \varepsilon$
- **다중선형회귀**: 독립변수 2 개 이상, $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \varepsilon$
- **최소제곱법(OLS, Ordinary Least Squares)**: 잔차제곱합(SSE)을 최소화하는 회귀계수를 추정하는 방법
- **결정계수(R^2 , R-squared)**: 회귀모형이 종속변수의 총 변동을 설명하는 비율 (0~1, 1에 가까울수록 설명력 높음)
- **수정된 결정계수(Adjusted R^2)**: 독립변수 개수가 늘어나면 R^2 이 무조건 증가하는 문제를 보정, 다중회귀 모형 비교 시 사용
- **다중공선성(Multicollinearity)**: 독립변수들 간 강한 상관관계가 존재하는 문제.
VIF(분산팽창지수) 10 이상이면 다중공선성 의심 (기준을 5로 보는 경우도 있음)
- **정규화(규제) 회귀**:
 - **Ridge 회귀**: 회귀계수의 제곱합(L2)에 페널티 부여, 계수를 0에 가깝게는 하지만 완전히 0으로 만들지는 않음
 - **Lasso 회귀**: 회귀계수의 절댓값 합(L1)에 페널티 부여, 일부 계수를 정확히 0으로 만들어 변수선택 효과가 있음
 - **Elastic Net**: Ridge와 Lasso를 결합한 방식

- **잔차 분석:** 회귀모형의 가정(선형성, 등분산성, 독립성, 정규성) 검증을 위해 잔차의 패턴을 확인. 잔차가 특정 패턴 없이 무작위로 흩어져 있어야 가정을 만족

④ 가설검정의 주요 기법

기법	목적	비고
t-검정	두 집단 간 평균 차이 검정 (단일표본/대응표본/독립표본)	모집단이 정규분포를 따른다는 가정
분산분석(ANOVA)	3개 이상 집단 간 평균 차이 검정	F-통계량 사용, 사후검정(Tukey 등)으로 어느 집단 간 차이인지 추가 확인
카이제곱검정(Chi-square Test)	범주형 변수 간의 독립성 검정, 관찰빈도와 기대빈도의 적합도 검정	두 범주형 변수 관계 확인 시 사용

4 과목(통계학개론/기초통계분석) 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 모집단의 분포 형태와 관계없이 표본의 크기가 충분히 크면 표본평균의 분포가 정규분포에 근사한다는 이론은?

- ① 대수의 법칙 ② 중심극한정리 ③ 베이즈 정리 ④ 큰 수의 법칙

문제 2. 가설검정에서 귀무가설이 실제로 참임에도 불구하고 이를 기각하는 오류를 무엇이라 하는가?

- ① 1종 오류 ② 2종 오류 ③ 표준오차 ④ 검정력

문제 3. 유의수준(α)을 낮출 경우 나타나는 현상으로 가장 적절한 것은?

- ① 1종 오류와 2종 오류가 모두 감소한다. ② 1종 오류는 감소하지만 2종 오류는 증가할 수 있다.
③ 1종 오류는 증가하지만 2종 오류는 감소한다. ④ 유의수준은 오류와 아무런 관계가 없다.

문제 4. 표본의 크기가 작고 모분산을 알 수 없을 때 모평균에 대한 가설검정에 주로 사용하는 확률분포는?

- ① 정규분포 ② 이항분포 ③ t분포 ④ 포아송분포

문제 5. 다음 중 상관분석에 대한 설명으로 옳지 않은 것은?

- ① 피어슨 상관계수는 두 연속형 변수 간 선형관계의 강도를 나타낸다. ② 스피어만 상관계수는 순위(순서형) 데이터에 적합하다. ③ 상관계수가 높다는 것은 두 변수 간 인과관계가 존재함을 의미한다. ④ 상관계수의 값은 -1에서 1 사이의 값을 가진다.

문제 6. 다중회귀분석에서 독립변수 간 강한 상관관계로 인해 회귀계수 추정이 불안정해지는 문제

를 지칭하는 용어는?

- ① 이분산성(Heteroscedasticity) ② 다중공선성(Multicollinearity) ③ 자기상관(Autocorrelation) ④ 과대적합(Overfitting)

문제 7. Lasso 회귀와 Ridge 회귀의 가장 핵심적인 차이점으로 옳은 것은?

- ① Lasso는 L2 페널티, Ridge는 L1 페널티를 사용한다. ② Lasso는 일부 회귀계수를 정확히 0으로 만들 수 있어 변수선택 효과가 있지만, Ridge는 계수를 0에 가깝게 줄일 뿐 정확히 0으로 만들지는 않는다. ③ Ridge는 회귀계수에 페널티를 부여하지 않는다. ④ 둘 다 동일한 방식으로 작동하며 차이가 없다.

문제 8. 3개 이상의 집단 간 평균 차이를 검정하기 위해 사용하는 통계 기법과, 이때 사용되는 검정통계량을 바르게 짝지은 것은?

- ① t-검정 - t통계량 ② 분산분석(ANOVA) - F통계량 ③ 카이제곱검정 - Z통계량 ④ 회귀분석 - t통계량

문제 9. 다중회귀모형에서 독립변수의 개수가 증가할 때 나타나는 R^2 (결정계수)의 특성과, 이를 보완하기 위해 사용하는 지표를 바르게 짝지은 것은?

- ① R^2 은 변수가 늘어도 변하지 않는다 - VIF ② R^2 은 무조건 증가하거나 유지된다 - 수정된 결정계수(Adjusted R^2) ③ R^2 은 항상 감소한다 - 표준오차 ④ R^2 은 무작위로 변한다 - p-value

4 과목(통계학개론/기초통계분석) 기출유형 문제 (풀이)

문제 1. 정답 ②

- 해설: **중심극한정리(Central Limit Theorem)**는 모집단의 분포 형태와 무관하게 표본크기(n)가 충분히 크면(일반적으로 $n \geq 30$) 표본평균의 표집분포가 정규분포에 근사한다는 이론으로, 통계적 추론(신뢰구간, 가설검정)의 이론적 근거가 됩니다. 대수의 법칙은 표본크기가 커질수록 표본평균이 모평균에 "수렴"한다는 것으로 정규성과는 별개의 개념입니다.

문제 2. 정답 ①

- 해설: **1 종 오류(Type I Error)**는 귀무가설이 실제로 참인데도 이를 기각하는 오류이며, 그 확률이 유의수준(α)입니다. 반대로 **2 종 오류(Type II Error)**는 귀무가설이 거짓인데도 채택하는 오류(확률 β)입니다.

문제 3. 정답 ②

- 해설: 유의수준(α)을 낮추면 귀무가설을 기각하는 기준이 엄격해져 **1 종 오류의 확률은 감소**하지만, 그만큼 대립가설이 참인 경우를 채택하기 어려워져 **2 종 오류(β)의 확률이 증가**할 수 있는 trade-off 관계가 존재합니다.

문제 4. 정답 ③

- 해설: 모분산을 모르고 표본크기가 작은 경우(일반적으로 $n < 30$) 정규분포 대신 꼬리가 더 두꺼운 **t 분포**를 사용하여 모평균에 대한 가설검정 및 신뢰구간 추정을 수행합니다. 표본크기가 충분히 크면 t 분포는 정규분포에 근사합니다.

문제 5. 정답 ③

- 해설: 상관계수는 두 변수 간의 **선형적 연관성의 강도와 방향**만을 나타낼 뿐, **인과관계를 의미하지 않습니다**. 두 변수가 강하게 상관되어 있어도 제 3의 변수에 의한 우연적 상관(허위상관)일 수 있으므로, "상관관계 ≠ 인과관계"는 통계 해석에서 매우 중요하게 강조되는 원칙입니다.

문제 6. 정답 ②

- 해설: **다중공선성(Multicollinearity)**은 독립변수들 간에 강한 상관관계가 존재하여 회귀계수의 추정이 불안정해지고 해석이 어려워지는 문제입니다. 일반적으로 VIF(분산팽창지수)가 10(또는 5) 이상이면 다중공선성을 의심합니다. 이분산성은 잔차의 분산이 일정하지 않은 문제, 자기상관은 오차항 간에 상관관계가 있는 문제로 서로 다른 개념입니다.

문제 7. 정답 ②

- 해설: **Lasso 회귀는 L1(절댓값 합) 페널티**를 사용하여 일부 회귀계수를 정확히 0으로 만들어 변수선택 효과를 가지며, **Ridge 회귀는 L2(제곱합) 페널티**를 사용하여 계수를 0에 가깝게 축소하지만 정확히 0으로 만들지는 않습니다. ①번은 Lasso와 Ridge의 페널티 종류가 서로 뒤바뀌어 서술되어 있으므로 틀린 설명입니다.

문제 8. 정답 ②

- 해설: 3개 이상 집단 간 평균 차이를 검정할 때는 **분산분석(ANOVA)**을 사용하며, 이때의 검정통계량은 집단 간 분산과 집단 내 분산의 비율인 **F 통계량**입니다. t-검정은 2개 집단 간 평균 비교에, 카이제곱검정은 범주형 변수의 독립성/적합도 검정에 사용됩니다.

문제 9. 정답 ②

- 해설: 다중회귀모형에서는 독립변수를 추가할수록 그 변수가 통계적으로 유의미하지 않더라도 **R^2 이 감소하지 않고 무조건 증가하거나 최소한 유지되는** 특성이 있습니다. 이 문제를 보완하기 위해 변수의 개수에 페널티를 부여한 **수정된 결정계수(Adjusted R^2)**를 모형 비교 시 활용합니다.

통계학개론과 기초통계분석 파트를 마쳤습니다. 다음은 다변량분석(주성분분석, 요인분석, 판별분석, 군집분석 관련 통계적 접근)과 시계열예측으로 이어서 진행하겠습니다.

[사용자] 네

ADP 필기시험 대비 자료 (4-3) — 데이터분석: 통계분석 (2)

다변량분석 & 시계열예측

4-2-3. 다변량분석 (Multivariate Analysis)

다변량분석은 2개 이상의 변수를 동시에 고려하여 변수 간의 관계를 분석하거나 데이터의 차원을 축소·분류하는 기법들을 다룹니다.

① 주성분분석 (PCA, Principal Component Analysis)

- **목적:** 서로 상관관계가 있는 다수의 변수를 **선형결합**을 통해 상관관계가 없는 소수의 **주성분(Principal Component)**으로 변환하여 **차원을 축소**하는 기법
- **원리:** 데이터의 분산을 가장 많이 설명하는 방향을 **제 1 주성분(PC1)**, 그다음으로 분산을 많이 설명하면서 PC1 과 **직교(독립)**하는 방향을 **제 2 주성분(PC2)**으로 순차적으로 도출
- **고유값(Eigenvalue):** 각 주성분이 설명하는 분산의 크기. 고유값이 1 이상인 주성분만 선택하는 **카이저 기준(Kaiser's rule)**이 자주 사용됨
- **스크리 도표(Scree Plot):** 주성분의 개수를 결정하기 위해 고유값을 크기 순으로 그린 그래프. 기울기가 급격히 완만해지는 지점(elbow point)까지의 주성분을 선택
- **분석 전 표준화(Standardization) 필요:** 변수 간 척도(단위) 차이가 크면 분산이 큰 변수가 주성분을 왜곡할 수 있으므로 표준화 후 분석하는 것이 일반적
- **활용:** 차원축소, 다중공선성 해결(주성분회귀), 데이터 시각화(2~3 차원으로 압축)

② 요인분석 (Factor Analysis)

- **목적:** 여러 변수들 사이에 존재하는 공통적인 **잠재요인(Latent Factor)**을 찾아내는 기법

PCA와의 차이(자주 출제되는 비교 포인트):

구분	주성분분석(PCA)	요인분석(FA)
목적	데이터의 분산을 최대한 보존하며 차원 축소	변수들 뒤에 숨은 잠재적 공통요인 탐색
접근 방향	관측변수 → 주성분 (변수의 선형결합)	잠재요인 → 관측변수를 설명(요인이 변수를 발생시킨다고 가정)
오차항	고려하지 않음	각 변수의 고유분산(오차)을 별도로 고려

- **요인적재량(Factor Loading):** 각 관측변수가 특정 요인과 얼마나 관련되어 있는지를 나타내는 값 (절댓값이 클수록 해당 요인과 관련성이 높음)
- **회전(Rotation):** 요인의 해석을 쉽게 하기 위해 요인축을 회전(예: Varimax 회전 — 직교회전 방식)

③ 판별분석 (Discriminant Analysis)

- **목적:** 이미 그룹(범주)이 알려진 데이터를 이용하여, 새로운 관측치가 어느 그룹에 속하는지 **분류**하는 판별함수를 도출
- 종속변수는 **범주형**, 독립변수는 **연속형**이라는 점에서 회귀분석과 구분됨
- **선형판별분석(LDA, Linear Discriminant Analysis):** 그룹 간 분산은 최대화, 그룹 내 분산은 최소화하는 방향으로 판별함수를 구성. 각 그룹의 공분산행렬이 동일하다고 가정
- 로지스틱 회귀와 유사한 목적(분류)을 갖지만, 로지스틱 회귀는 확률모형에 기반하고 판별분석은 다변량 정규분포 가정에 기반한다는 차이가 있음

④ 군집분석 (Clustering) — 다변량 관점

- 정형 데이터마이닝 파트에서 별도로 자세히 다루지만, 다변량분석에서는 **유사성/거리** 측도의 개념이 중요하게 등장
- **유클리드 거리(Euclidean Distance):** 두 점 사이의 직선 거리
- **맨해튼 거리(Manhattan Distance):** 각 축 방향 거리의 절댓값 합
- **마할라노비스 거리(Mahalanobis Distance):** 변수 간 상관관계(공분산)를 고려한 거리
- **코사인 유사도(Cosine Similarity):** 두 벡터가 이루는 각도 기반의 유사도 (텍스트마이닝에서 자주 사용)

⑤ 다차원척도법 (MDS, Multi-Dimensional Scaling)

- 개체들 간의 유사성(거리) 정보를 이용하여 개체들을 **저차원 공간(주로 2 차원)에 배치**함으로써 관계를 시각적으로 파악하는 기법

4-2-4. 시계열예측 (Time Series Forecasting)

① 시계열 자료의 구성요소

구성요소	설명
추세(Trend)	장기적으로 증가/감소하는 경향
계절성(Seasonality)	일정한 주기(1년, 1주 등)로 반복되는 패턴
순환(Cycle)	계절성보다 긴 불규칙한 주기의 변동 (경기순환 등)
불규칙성(Irregular/White Noise)	추세·계절성·순환으로 설명되지 않는 무작위 잔차

② 정상성 (Stationarity) — 매우 자주 출제되는 핵심 개념

- **정상 시계열**의 조건: 시간의 흐름과 관계없이 **평균이 일정**하고, **분산이 일정**하며, **공분산이 시차(lag)에만 의존**(특정 시점에 의존하지 않음)

- 대부분의 시계열 분석 기법(ARIMA 등)은 정상성을 가정하므로, 비정상 시계열은 정상화 과정을 거쳐야 함
- **비정상 시계열의 정상화 방법:**
 - **차분(Differencing):** 현재 값에서 이전 시점의 값을 빼는 방법. 추세를 제거하는 데 효과적 (1 차 차분으로 부족하면 2 차 차분 수행)
 - **계절차분(Seasonal Differencing):** 계절 주기만큼 떨어진 시점끼리 차분하여 계절성을 제거
 - **로그변환/제곱근변환:** 분산이 시간에 따라 커지는 경우(이분산성) 안정화

③ 자기상관함수(ACF)와 부분자기상관함수(PACF) — 모형 식별의 핵심

- **ACF(Autocorrelation Function):** 시차(lag)에 따른 시계열 자기 자신과의 상관관계
- **PACF(Partial Autocorrelation Function):** 중간 시차의 영향을 제거한 순수한 시차 간 상관관계

모형 식별 규칙(자주 출제):

모형	ACF 패턴	PACF 패턴
AR(p) (자기회귀)	지수적으로 감소	p시차 이후 절단(cut-off)
MA(q) (이동평균)	q시차 이후 절단(cut-off)	지수적으로 감소
ARMA(p,q)	지수적으로 감소	지수적으로 감소

④ ARIMA 모형 (AutoRegressive Integrated Moving Average)

- **ARIMA(p, d, q)**로 표기:
 - **p:** AR(자기회귀) 차수 — 과거 값들이 현재에 미치는 영향
 - **d:** 차분(Integrated) 횟수 — 정상화를 위해 몇 번 차분했는지
 - **q:** MA(이동평균) 차수 — 과거 예측오차(잔차)가 현재에 미치는 영향
- **d=0 인 경우** ARIMA(p,0,q)는 **ARMA(p,q)**와 동일 (이미 정상 시계열)
- **계절성 ARIMA(SARIMA):** 계절 주기를 반영한 확장 모형 (P,D,Q)_m 파라미터 추가

⑤ 지수평활법 (Exponential Smoothing)

- 과거 관측값에 **최근 값일수록 더 큰 가중치**를 지수적으로 부여하여 예측하는 기법
- **단순지수평활:** 추세·계절성이 없는 시계열에 적용
- **홀트(Holt) 지수평활:** 추세가 있는 시계열에 적용
- **홀트-윈터스(Holt-Winters):** 추세와 계절성이 모두 있는 시계열에 적용

4 과목(다변량분석/시계열예측) 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 주성분분석(PCA)에 대한 설명으로 옳지 않은 것은?

- ① 서로 상관된 변수들을 상관관계가 없는 주성분으로 변환한다. ② 제1주성분은 데이터의 분산을 가장 많이 설명하는 방향이다. ③ 변수 간 척도 차이가 클 경우 일반적으로 표준화 후 분석을 수행한다. ④ 주성분분석은 반드시 종속변수가 필요한 지도학습 기법이다.

문제 2. 주성분분석(PCA)과 요인분석(Factor Analysis)의 차이에 대한 설명으로 가장 적절한 것은?

- ① 두 기법은 완전히 동일한 기법으로 차이가 없다. ② PCA는 관측변수의 선형결합으로 주성분을 도출하지만, 요인분석은 관측변수 뒤에 숨은 잠재요인이 변수를 설명한다고 가정한다. ③ 요인분석은 반드시 종속변수가 있어야 하는 지도학습 기법이다. ④ PCA는 오차항(고유분산)을 명시적으로 모형에 포함시킨다.

문제 3. 이미 그룹(범주)이 알려진 데이터를 바탕으로 새로운 관측치가 어느 그룹에 속하는지 분류하는 판별함수를 도출하는 다변량 분석 기법은?

- ① 요인분석 ② 판별분석 ③ 주성분분석 ④ 다차원척도법

문제 4. 정상 시계열(Stationary Time Series)의 조건으로 옳지 않은 것은?

- ① 시간에 관계없이 평균이 일정하다. ② 시간에 관계없이 분산이 일정하다. ③ 공분산은 특정 시점에 의존하며 시차(lag)와는 무관하다. ④ 추세나 계절성이 없다.

문제 5. 비정상(non-stationary) 시계열 자료에서 추세를 제거하여 정상 시계열로 변환하는 대표적인 방법은?

- ① 이동평균법 ② 차분(Differencing) ③ 표준화 ④ 정규화

문제 6. ARIMA(p, d, q) 모형에서 파라미터 d가 의미하는 것은?

- ① 자기회귀(AR) 항의 차수 ② 이동평균(MA) 항의 차수 ③ 정상화를 위한 차분(differencing)의 횟수 ④ 계절 주기의 길이

문제 7. 자기상관함수(ACF)와 부분자기상관함수(PACF)를 이용한 모형 식별에서, ACF는 지수적으로 감소하고 PACF는 p시차 이후 절단(cut-off)되는 패턴을 보일 때 적합한 모형은?

- ① MA(q) 모형 ② AR(p) 모형 ③ ARMA(p,q) 모형 ④ 백색잡음(White Noise) 모형

문제 8. 추세와 계절성이 모두 존재하는 시계열 자료의 예측에 적합한 지수평활법은?

- ① 단순지수평활법 ② 홀트(Holt) 지수평활법 ③ 홀트-윈터스(Holt-Winters) 지수평활법 ④ 이동평균법

4 과목(다변량분석/시계열예측) 기출유형 문제 (풀이)

문제 1. 정답 ④

- 해설: 주성분분석(PCA)은 종속변수 없이 변수들 간의 분산 구조만을 이용해 차원을 축소하는 **비지도학습(Unsupervised Learning)** 기법입니다. ①②③은 모두 PCA 의 정확한 특징입니다.

문제 2. 정답 ②

- 해설: PCA 는 관측된 변수들을 선형결합하여 분산을 최대한 보존하는 주성분을 만드는 반면, 요인분석은 "관측변수들 뒤에 이들을 발생시키는 잠재적인 공통요인이 존재한다"고 가정하고 그 요인을 추정합니다. 이 방향성(관측변수→주성분 vs 잠재요인→관측변수)의 차이가 핵심입니다. 요인분석은 각 변수의 고유분산(오차)을 별도로 고려하지만, PCA 는 이를 명시적으로 분리하지 않습니다.

문제 3. 정답 ②

- 해설: **판별분석(Discriminant Analysis)**은 그룹(범주)이 이미 알려진 훈련 데이터를 바탕으로 판별함수를 학습하여, 새로운 관측치를 어느 그룹으로 분류할지 결정하는 기법입니다. 종속변수가 범주형이라는 점에서 지도학습적 성격을 가집니다.

문제 4. 정답 ③

- 해설: 정상 시계열은 공분산이 **시차(lag)에만 의존**하고 특정 시점 자체에는 의존하지 않아야 합니다. "공분산이 특정 시점에 의존한다"는 것은 오히려 비정상성을 나타내는 설명이므로 옳지 않습니다. ①②④는 정상성의 조건에 해당합니다.

문제 5. 정답 ②

- 해설: **차분(Differencing)**은 현재 시점의 값에서 이전 시점의 값을 빼는 방법으로, 시계열에 존재하는 추세를 효과적으로 제거하여 정상 시계열로 변환하는 가장 대표적인 방법입니다. 표준화·정규화는 척도를 조정하는 기법이지 추세 제거를 위한 시계열 특화 기법은 아닙니다.

문제 6. 정답 ③

- 해설: ARIMA(p, d, q)에서 **d**는 **정상화를 위해 시계열을 몇 번 차분했는지**를 나타내는 차분 횟수입니다. p 는 AR(자기회귀) 차수, q 는 MA(이동평균) 차수를 의미합니다.

문제 7. 정답 ②

- 해설: **AR(p) 모형**은 ACF 가 지수적으로 서서히 감소하고, PACF 는 p 시차 이후 급격히 절단(0 에 가까워짐)되는 패턴을 보입니다. 반대로 MA(q) 모형은 ACF 가 q 시차 이후 절단되고 PACF 가 지수적으로 감소하는 패턴을 보입니다.

문제 8. 정답 ③

- 해설: **홀트-윈터스(Holt-Winters) 지수평활법**은 추세(Trend)와 계절성(Seasonality)을 모두 반영할 수 있도록 확장된 지수평활 기법입니다. 단순지수평활은 추세·계절성이 없는 경우, 홀트 지수평활은 추세만 있는 경우에 적합합니다.

이것으로 통계분석 파트(통계학개론, 기초통계분석, 다변량분석, 시계열예측)를 모두 마쳤습니다. 다음은 4과목의 나머지 부분인 정형 데이터 마이닝(분류분석, 군집분석, 연관분석)으로 진행하겠습니다.

[사용자] 네

ADP 필기시험 대비 자료 (4-4) — 데이터분석: 정형 데이터 마이닝

4-3. 정형 데이터 마이닝

4-3-1. 데이터 마이닝 개요

- **정의:** 대용량 데이터로부터 숨겨진 패턴, 규칙, 관계를 탐색하여 유용한 정보와 지식을 추출하는 과정
- **분석 목적에 따른 분류:**
 - **지도학습(Supervised Learning):** 정답(레이블/목표변수)이 있는 데이터를 학습 — **분류(Classification), 회귀(Regression)**
 - **비지도학습(Unsupervised Learning):** 정답 없이 데이터 자체의 구조·패턴을 탐색 — **군집분석(Clustering), 연관분석(Association), 차원축소(PCA 등)**
- **데이터 마이닝 프로세스(일반적):** 목적 정의 → 데이터 수집 → 데이터 전처리 → 데이터 분할(훈련/검증/테스트) → 모델링 → 평가 → 적용
- **데이터 분할:** 일반적으로 훈련(Train)/검증(Validation)/테스트(Test) 데이터로 분할. **교차검증(Cross Validation)**, 특히 **K-fold 교차검증**은 데이터를 K 개로 나누어 K 번 반복 학습·검증함으로써 데이터가 적을 때도 안정적인 모형 평가가 가능
- **과적합(Overfitting):** 훈련 데이터에만 지나치게 최적화되어 새로운 데이터(테스트)에 대한 일반화 성능이 떨어지는 현상. 모델 복잡도가 지나치게 높을 때 발생하며, 정규화(Regularization), 가지치기(Pruning), 교차검증, 데이터 증강 등으로 완화

4-3-2. 분류분석 (Classification)

① 로지스틱 회귀(Logistic Regression)

- 종속변수가 범주형(주로 이진, 0/1)인 경우 사용하는 회귀 기반 분류 기법
- **로짓변환(Logit Transformation):** 사건 발생 확률 p 를 오즈비(Odds Ratio, $p/(1-p)$)로 변환한 후 자연로그를 취해 선형모형과 결합 → $\log(p/(1-p)) = \beta_0 + \beta_1 X_1 + \dots$
- 출력값을 0~1 사이의 확률로 해석 가능 (Sigmoid 함수 사용)

② 의사결정나무(Decision Tree)

- 데이터를 특정 기준(분리 기준)으로 반복적으로 분할하여 트리 구조의 분류/회귀 규칙을 생성

● **분리 기준(불순도 지표):**

- **지니지수(Gini Index):** 불순도(불확실성)를 나타내는 지표, 값이 작을수록 순수(한 클래스로 구성)함 — CART 알고리즘에서 사용
- **엔트로피(Entropy)/정보이득(Information Gain):** 정보의 불확실성을 측정, 정보이득이 클수록 좋은 분리 기준 — ID3, C4.5 알고리즘에서 사용
- **카이제곱 통계량:** CHAID 알고리즘에서 사용

● **가지치기(Pruning):** 트리가 지나치게 깊어져 과적합되는 것을 방지하기 위해 불필요한 가지를 제거

● **장점:** 해석이 직관적이고 쉬움 / **단점:** 과적합되기 쉽고 데이터의 작은 변화에도 트리 구조가 크게 달라질 수 있음(불안정성)

③ **앙상블(Ensemble) 기법 — 매우 자주 출제**

기법	원리	대표 알고리즘
배깅(Bagging)	훈련 데이터에서 복원추출(Bootstrap)로 여러 표본을 만들어 각각 모델을 학습시킨 후 결과를 평균/다수결로 결합	랜덤포레스트(Random Forest)
부스팅(Boosting)	이전 모델이 잘못 예측한 데이터에 가중치를 높여 순차적으로 다음 모델을 학습, 약한 모델들을 순차적으로 결합해 강한 모델을 만들	AdaBoost, Gradient Boosting, XGBoost
스태킹(Stacking)	여러 서로 다른 모델의 예측 결과를 입력으로 하는 메타 모델을 추가로 학습	-

● **배깅 vs 부스팅 핵심 차이(단골 문제):** 배깅은 각 모델을 병렬적·독립적으로 학습(분산 감소 목적), 부스팅은 이전 모델의 오차를 보완하며 순차적으로 학습(편향 감소 목적)

● **랜덤포레스트:** 배깅에 추가로 각 분할 시 일부 변수만 무작위로 선택하여 트리 간 상관성을 낮추고 일반화 성능을 높인 기법

④ **서포트벡터머신 (SVM, Support Vector Machine)**

● 두 클래스를 분리하는 초평면(Hyperplane) 중 **마진(Margin, 경계와 가장 가까운 데이터 간 거리)**을 최대화하는 초평면을 찾는 기법

● **서포트벡터(Support Vector):** 결정경계에 가장 가까이 위치하여 마진을 결정짓는 데이터 포인트

● **커널 트릭(Kernel Trick):** 선형으로 분리되지 않는 데이터를 고차원 공간으로 매핑하여 선형 분리가 가능하게 함 (선형/다항/RBF(가우시안)/시그모이드 커널 등)

● **비용(Cost, C) 파라미터:** 오분류에 대한 페널티 정도를 조절 (C가 크면 마진이 좁아지고 훈련 데이터에 더 민감 → 과적합 위험)

⑤ 인공신경망 (ANN) / 다층퍼셉트론 (MLP)

- **퍼셉트론(Perceptron)**: 입력값의 가중합에 활성화함수를 적용해 출력을 내는 최소 단위, 단층 퍼셉트론은 선형분리가 불가능한 문제(예: XOR)를 해결할 수 없음
- **다층퍼셉트론(MLP)**: 입력층-은닉층(1 개 이상)-출력층으로 구성, 은닉층의 존재로 비선형 문제 해결 가능
- **활성화 함수(Activation Function)**: Sigmoid, Tanh, **ReLU**(현재 가장 널리 사용, 기울기 소실 문제 완화) 등
- **역전파(Backpropagation)**: 예측값과 실제값의 오차(손실함수)를 출력층에서 입력층 방향으로 전파하며 가중치를 경사하강법으로 갱신하는 학습 알고리즘
- **기울기 소실(Vanishing Gradient)**: 층이 깊어질수록 역전파 과정에서 기울기가 0 에 가까워져 학습이 잘 안 되는 문제 (Sigmoid 에서 주로 발생, ReLU 로 완화)

⑥ 분류모형 평가 (매우 자주 출제)

혼동행렬(Confusion Matrix) 기반 지표:

지표	계산식	의미
정확도(Accuracy)	$(TP+TN)/(TP+TN+FP+FN)$	전체 중 올바르게 예측한 비율
정밀도(Precision)	$TP/(TP+FP)$	양성으로 예측한 것 중 실제 양성 비율
재현율(Recall, 민감도)	$TP/(TP+FN)$	실제 양성 중 양성으로 예측한 비율
특이도(Specificity)	$TN/(TN+FP)$	실제 음성 중 음성으로 예측한 비율
F1-Score	$2 \times (Precision \times Recall) / (Precision + Recall)$	정밀도와 재현율의 조화평균

- **ROC curve**: 임계값 변화에 따른 (1-특이도, 민감도)를 그린 곡선
- **AUC(Area Under Curve)**: ROC 곡선 아래 면적, 1 에 가까울수록 모형 성능이 우수 (0.5 는 무작위 수준)
- **불균형 데이터(Imbalanced Data)**에서는 Accuracy 보다 **정밀도·재현율·F1-Score** 가 더 중요한 지표로 강조됨 (예: 희귀 질병 진단에서 대부분 음성인 경우 정확도만으로는 왜곡된 평가)

4-3-3. 군집분석 (Clustering)

① 계층적 군집분석(Hierarchical Clustering)

- 개체 간의 거리(유사도)를 기준으로 가장 가까운 개체/군집부터 순차적으로 병합(**응집형, Agglomerative**) 또는 분할(**분리형, Divisive**)해 나가는 방법

- **덴드로그램(Dendrogram)**: 병합 과정을 트리 형태로 시각화, 원하는 군집 수만큼 특정 높이에서 절단하여 군집 결정
- **군집 간 거리 측정 방법**: 최단연결법(Single Linkage), 최장연결법(Complete Linkage), 평균연결법(Average Linkage), **와드연결법(Ward's Method, 군집 내 분산 증가를 최소화)**

② 비계층적(분할적) 군집분석 — K-평균(K-means)

- 사전에 군집의 개수(K)를 지정하고, 각 개체를 가장 가까운 군집 중심(Centroid)에 할당한 뒤 중심을 재계산하는 과정을 반복
- **알고리즘 절차**: ① K 개의 초기 중심 임의 설정 → ② 각 데이터를 가장 가까운 중심에 할당 → ③ 각 군집의 중심(평균) 재계산 → ④ 중심이 변하지 않을 때까지(수렴할 때까지) ②③ 반복
- **최적 K 결정: 엘보우 기법(Elbow Method)** — 군집 내 분산(SSE)이 급격히 감소하다 완만해지는 지점(팔꿈치)의 K 선택 / **실루엣 계수(Silhouette Coefficient)** — 군집 내 응집도와 군집 간 분리도를 함께 고려, -1~1 사이 값으로 1에 가까울수록 군집화 품질이 좋음
- **한계**: 이상치에 민감, 군집이 구형(spherical)이 아니거나 크기가 다를 때 성능 저하, 초기 중심값에 따라 결과가 달라질 수 있음

③ 밀도기반 군집분석 — DBSCAN

- 데이터의 **밀도**가 일정 기준 이상인 영역을 하나의 군집으로 인식하는 방법. **군집의 개수를 사전에 지정할 필요가 없고**, 구형이 아닌 임의의 형태의 군집도 탐지 가능하며, 밀도가 낮은 점은 **노이즈(이상치)**로 분류

4-3-4. 연관분석 (Association Analysis)

- **목적**: "장바구니 분석(Market Basket Analysis)"처럼 항목 간의 **동시 발생 규칙**을 발견 (예: "기저귀를 사면 맥주도 산다")

연관규칙 평가 지표(매우 자주 출제, 계산 문제로도 등장):

지표	계산식	의미
지지도(Support)	$P(A \cap B) = \text{A와 B를 동시에 포함하는 거래 수} / \text{전체 거래 수}$	전체 거래 중 두 항목이 함께 나타나는 빈도
신뢰도(Confidence)	$P(B A) = P(A \cap B) / P(A)$	A를 포함한 거래 중 B도 포함할 조건부 확률
향상도(Lift)	$P(A \cap B) / (P(A) \times P(B)) = \text{Confidence} / P(B)$	A, B가 독립일 때보다 얼마나 더 자주 동시 발생하는지. Lift=1이면 독립, 1보다 크면 양의 연관, 1보다 작으면 음의 연관

- **Apriori 알고리즘:** 최소 지지도를 만족하지 못하는 항목집합은 그 상위집합도 만족할 수 없다는 "반발항목집합의 부분집합도 반발하다(anti-monotone)" 성질을 이용해 탐색 공간을 줄이는 대표적 연관규칙 탐색 알고리즘

4 과목(정형 데이터 마이닝) 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 앙상블 기법 중 배깅(Bagging)과 부스팅(Boosting)에 대한 설명으로 옳지 않은 것은?

- ① 배깅은 여러 모델을 병렬적·독립적으로 학습시킨다. ② 부스팅은 이전 모델이 잘못 예측한 데이터에 가중치를 높여 다음 모델을 순차적으로 학습시킨다. ③ 랜덤포레스트는 부스팅 기법의 대표적인 예이다. ④ 배깅은 훈련 데이터에서 복원추출로 여러 표본을 생성한다.

문제 2. 다음 혼동행렬(Confusion Matrix)을 바탕으로 계산한 정밀도(Precision)로 옳은 것은?
(TP=80, FP=20, FN=10, TN=90)

- ① 80/90 ② 80/100 ③ 80/110 ④ 90/100

문제 3. 서포트벡터머신(SVM)에서 결정경계와 가장 가까이 위치하여 마진을 결정짓는 데이터 포인트를 지칭하는 용어는?

- ① 센트로이드(Centroid) ② 서포트벡터(Support Vector) ③ 아웃라이어(Outlier) ④ 클러스터 중심(Cluster Center)

문제 4. 다층퍼셉트론(MLP)이 단층 퍼셉트론과 달리 해결할 수 있는 대표적인 문제로 자주 언급되는 것은?

- ① AND 연산 ② OR 연산 ③ XOR 연산 ④ NOT 연산

문제 5. K-평균(K-means) 군집분석에서 최적의 군집 개수(K)를 결정하기 위해 사용하는 방법으로 옳지 않은 것은?

- ① 엘보우 기법(Elbow Method) ② 실루엣 계수(Silhouette Coefficient) ③ 덴드로그램 절단 ④ 지니지수(Gini Index)

문제 6. DBSCAN 밀도기반 군집분석의 특징으로 옳지 않은 것은?

- ① 군집의 개수를 사전에 미리 지정해야 한다. ② 구형이 아닌 임의의 형태의 군집도 탐지할 수 있다. ③ 밀도가 낮은 영역의 데이터는 노이즈(이상치)로 분류될 수 있다. ④ 밀도가 일정 기준 이상인 영역을 하나의 군집으로 인식한다.

문제 7. 연관분석에서 두 항목 A, B에 대해 향상도(Lift)가 1보다 큰 경우가 의미하는 것은?

- ① A와 B는 서로 독립적이다. ② A와 B는 양의 연관관계를 가지며, 함께 나타날 가능성이 독립일 때보다 높다. ③ A와 B는 음의 연관관계를 가진다. ④ A와 B의 지지도가 0이다.

문제 8. 전체 거래 1,000건 중 A와 B를 동시에 구매한 거래가 100건, A를 구매한 거래가 250건일

때, 연관규칙 "A → B"의 신뢰도(Confidence)로 옳은 것은?

- ① 0.1 ② 0.25 ③ 0.4 ④ 0.5

4 과목(정형 데이터 마이닝) 기출유형 문제 (풀이)

문제 1. 정답 ③

- 해설: 랜덤포레스트(Random Forest)는 배깅(Bagging) 기법을 기반으로 하는 대표적인 알고리즘입니다. 여기에 각 분할 시 일부 변수만 무작위로 선택하는 과정이 추가된 것이 특징입니다. 부스팅의 대표적인 예는 AdaBoost, Gradient Boosting, XGBoost 등입니다. ①②④는 배깅/부스팅에 대한 옳은 설명입니다.

문제 2. 정답 ②

- 해설: 정밀도(Precision) = $TP/(TP+FP) = 80/(80+20) = 80/100 = 0.8$ 입니다. 참고로 재현율(Recall)은 $TP/(TP+FN) = 80/(80+10) = 80/90$ 이 되므로, 분모를 혼동하지 않도록 주의해야 합니다.

문제 3. 정답 ②

- 해설: 서포트벡터(Support Vector)는 SVM 에서 결정경계(초평면)에 가장 가까이 위치하여 마진의 크기를 결정짓는 데이터 포인트입니다. 센트로이드는 군집분석에서 사용되는 군집의 중심 개념입니다.

문제 4. 정답 ③

- 해설: 단층 퍼셉트론은 선형분리가 불가능한 XOR 문제를 해결할 수 없다는 한계가 있으며, 이는 은닉층을 갖춘 다층퍼셉트론(MLP)의 필요성을 보여주는 대표적인 역사적 사례로 시험에 자주 언급됩니다.

문제 5. 정답 ④

- 해설: 지니지수(Gini Index)는 의사결정나무에서 노드의 불순도를 측정하는 지표이지, K-means 의 최적 군집 개수를 결정하는 방법이 아닙니다. K 결정에는 엘보우 기법, 실루엣 계수가 대표적으로 사용되며, 덴드로그램 절단은 계층적 군집분석에서 군집 수를 결정하는 방법입니다(K-means 에도 참고용으로 함께 언급되기도 함).

문제 6. 정답 ①

- 해설: DBSCAN 은 K-means 와 달리 군집의 개수를 사전에 지정할 필요가 없다는 것이 핵심 특징입니다. 밀도를 기준으로 군집을 자동으로 형성하며, 밀도가 낮은 데이터는 노이즈로 분류합니다. 따라서 "군집 개수를 사전에 지정해야 한다"는 ①번 설명이 옳지 않습니다.

문제 7. 정답 ②

- 해설: 향상도(Lift) = $P(A \cap B)/(P(A) \times P(B))$ 에서 $Lift > 1$ 이면 A 와 B 가 독립일 때 기대되는 것보다 실제로 더 자주 함께 발생한다는 의미로, 양(+)의 연관관계를 나타냅니다. $Lift = 1$ 이면 독립, $Lift < 1$ 이면 음(-)의 연관관계입니다.

문제 8. 정답 ③

- 해설: 신뢰도(C Confidence) = $P(A \cap B) / P(A)$ = (A와 B 동시구매 거래 수) / (A 구매 거래 수) = $100 / 250 = 0.4$ 입니다. 전체 거래 수(1,000 건)는 지지도(Support) 계산 시에는 필요하지만, 신뢰도 계산에서는 A를 포함한 거래 수만 분모로 사용된다는 점에 주의해야 합니다.

정형 데이터 마이닝(데이터 마이닝 개요, 분류분석, 군집분석, 연관분석) 파트를 마쳤습니다. 이제 4과목의 마지막 부분인 비정형 데이터 마이닝(텍스트 마이닝, 사회연결망 분석)으로 진행하겠습니다.

[사용자] 네

ADP 필기시험 대비 자료 (4-5) — 데이터분석: 비정형 데이터 마이닝

4-4. 비정형 데이터 마이닝

4-4-1. 텍스트 마이닝 (Text Mining)

① 텍스트 마이닝의 개념 및 프로세스

- 정의: 비정형 텍스트 데이터로부터 유의미한 정보와 패턴을 추출하는 기법
- 일반적 프로세스: 텍스트 수집 → **전처리(Preprocessing)** → 토큰화 → 특징 추출(벡터화) → 분석/모델링(분류, 군집, 감성분석 등) → 시각화/해석

② 텍스트 전처리 (Preprocessing) — 자주 출제되는 실무 개념

단계	내용
토큰화(Tokenization)	문장을 단어/형태소 등 최소 의미 단위로 분리
형태소 분석(Morphological Analysis)	한국어처럼 교착어인 언어에서 단어를 어간/어미/조사 등으로 분해 (한국어 텍스트마이닝에서 특히 중요)
품사 태깅(POS Tagging)	각 토큰에 품사(명사, 동사 등) 정보 부여
불용어 제거(Stopword Removal)	분석에 의미 없는 조사, 관사 등을 제거 (예: "은,는,이,가", "the, a, is")
어간 추출(Stemming)	단어의 어미를 단순 규칙으로 잘라내어 원형을 근사 (형태가 부정확할 수 있음, 예: studies→studi)
표제어 추출(Lemmatization)	사전과 형태소 분석을 이용해 단어의 정확한 기본형(표제어)을 추출 (예: studies→study, went→go)

- **Stemming vs Lemmatization 구분(단골 출제):** Stemming 은 규칙 기반의 단순 절단이라 결과가 실제 단어가 아닐 수 있는 반면, Lemmatization 은 품사/사전 정보를 활용하여 문법적으로 올바른 원형을 반환

③ 문서의 벡터화(Vectorization)

- **BoW(Bag of Words):** 문서를 단어의 순서를 무시하고 단어의 출현 빈도만으로 표현하는 방식
- **TF-IDF(Term Frequency - Inverse Document Frequency):** 매우 자주 출제되는 핵심 지표
 - **TF(단어빈도):** 특정 문서 내에서 단어가 등장한 빈도 — 값이 클수록 해당 문서에서 중요한 단어일 가능성
 - **IDF(역문서빈도):** 전체 문서 집합에서 그 단어가 등장하는 문서 수의 역수(로그 스케일) — 여러 문서에 공통적으로 자주 등장하는 단어(예: "그리고", "the")의 가중치를 낮춤
 - **TF-IDF = TF × IDF:** 특정 문서에서는 자주 등장하지만 전체 문서 집합에서는 드물게 등장하는 단어에 높은 가중치를 부여 → 그 문서를 대표/구별하는 단어를 찾는 데 효과적
- **워드 임베딩(Word Embedding):** 단어를 저차원의 밀집 벡터(dense vector)로 표현하여 단어 간 의미적 유사성을 벡터 공간상의 거리로 반영
 - **Word2Vec:** 주변 단어로 중심 단어를 예측(CBOW) 하거나, 중심 단어로 주변 단어를 예측(Skip-gram)하는 방식으로 학습되는 대표적 임베딩 기법
 - BoW/TF-IDF 와 달리 단어 간 **의미적 유사도**(예: "왕"-"남자"+"여자"≈"여왕")를 벡터 연산으로 표현 가능하다는 점이 차별점

④ 감성분석 (Sentiment Analysis)

- 텍스트에 담긴 감정(긍정/부정/중립)이나 의견을 분석하는 기법
- **감성사전(Lexicon) 기반 방법:** 미리 구축된 긍정/부정 단어 사전을 이용해 점수를 집계
- **기계학습 기반 방법:** 레이블이 있는 텍스트 데이터로 분류모델(나이브베이즈, SVM, 딥러닝 등)을 학습시켜 감성을 예측

⑤ 토픽모델링 (Topic Modeling)

- 문서 집합에서 숨겨진 주제(토픽)를 자동으로 추출하는 비지도학습 기법
- **LDA(Latent Dirichlet Allocation):** 대표적인 토픽모델링 기법으로, 각 문서는 여러 토픽의 혼합으로, 각 토픽은 여러 단어의 확률분포로 구성되어 있다고 가정

4-4-2. 사회연결망 분석 (Social Network Analysis, SNA)

① 기본 개념

- 정의: 개체(노드, Node/Vertex)들과 그들 간의 관계(엣지, Edge/Link)로 이루어진 네트워크 구조를 분석하여 관계의 패턴과 영향력을 파악하는 기법
- **노드(Node)**: 분석 대상이 되는 개체 (사람, 조직 등) / **엣지(Edge)**: 노드 간의 관계·연결
- **방향성**에 따라 **무방향 그래프**(예: 친구관계)와 **방향 그래프**(예: 팔로우 관계)로 구분
- **가중치(Weight)**: 관계의 강도(예: 상호작용 빈도)를 엣지에 부여할 수 있음

② 중심성(Centrality) 지표 — 매우 자주 출제되는 핵심 개념

중심성 지표	정의	의미
연결정도 중심성(Degree Centrality)	노드가 직접 연결된 다른 노드의 수 (연결선의 개수)	얼마나 많은 직접적 관계를 갖는가 — 인기/활동성
근접 중심성(Closeness Centrality)	한 노드에서 다른 모든 노드까지의 최단거리 합의 역수	네트워크 전체에 얼마나 빨리 (효율적으로) 접근할 수 있는가
매개 중심성(Betweenness Centrality)	다른 두 노드 사이의 최단경로에 해당 노드가 놓이는 빈도	정보 흐름의 중개자/다리 역할을 얼마나 하는가 — 값이 높으면 네트워크의 "허브(중개자)" 역할
위세 중심성(Eigenvector Centrality)	자신과 연결된 노드의 중요도(중심성)까지 함께 고려	단순히 연결 수가 아니라 "영향력 있는 노드와 연결되어 있는가" — 구글 PageRank의 기본 아이디어와 유사

- **핵심 구분 문제**: "연결선은 적지만 서로 다른 두 그룹을 이어주는 유일한 다리 역할을 하는 노드"는 연결정도 중심성은 낮아도 **매개 중심성(Betweenness Centrality)**은 매우 높게 나타남 — 이 차이를 묻는 문제가 단골로 출제됨

③ 네트워크 구조 관련 개념

- **밀도(Density)**: 네트워크 내에서 실제 존재하는 연결 수 / 가능한 최대 연결 수
- **컴포넌트(Component)**: 네트워크 내에서 서로 연결된 노드들의 집합(부분 네트워크)
- **클러스터링 계수(Clustering Coefficient)**: 한 노드의 이웃들끼리 서로 얼마나 연결되어 있는지(응집도)를 나타내는 지표

4 과목(비정형 데이터 마이닝) 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 텍스트 전처리 기법 중, 단어의 어미를 단순 규칙으로 잘라내어 원형을 근사하기 때문에 결과가 실제 사전에 존재하지 않는 형태가 될 수도 있는 기법은?

① 표제어 추출(Lemmatization) ② 어간 추출(Stemming) ③ 품사 태깅(POS Tagging) ④ 토큰화(Tokenization)

문제 2. TF-IDF에 대한 설명으로 옳지 않은 것은?

① TF는 특정 문서 내에서 단어가 등장한 빈도를 의미한다. ② IDF는 여러 문서에 공통적으로 자주 등장하는 단어의 가중치를 높이기 위한 지표이다. ③ TF-IDF는 특정 문서를 구별짓는 데 중요한 단어를 찾는 데 활용된다. ④ TF-IDF는 TF와 IDF를 곱하여 계산한다.

문제 3. Word2Vec과 같은 워드 임베딩 기법이 BoW/TF-IDF 방식과 구별되는 가장 핵심적인 특징은?

① 단어의 출현 빈도만을 고려한다. ② 단어를 저차원 밀집 벡터로 표현하여 단어 간 의미적 유사성을 반영할 수 있다. ③ 문서의 순서 정보만을 저장한다. ④ 반드시 지도학습 방식으로만 학습된다.

문제 4. 다음 중 사회연결망 분석(SNA)에서 사용하는 중심성 지표에 대한 설명으로 옳지 않은 것은?

① 연결정도 중심성은 노드가 직접 연결된 다른 노드의 수를 의미한다. ② 매개 중심성이 높은 노드는 서로 다른 그룹을 연결하는 다리(중개자) 역할을 하는 경우가 많다. ③ 위세 중심성은 연결된 이웃 노드의 중요도까지 함께 고려한다. ④ 근접 중심성은 노드와 직접 연결된 이웃의 수만을 단순히 계산한 값이다.

문제 5. 두 개의 서로 다른 그룹을 이어주는 유일한 연결선 위에 위치하여, 정보의 흐름을 중개하는 역할이 큰 노드가 상대적으로 가장 높은 값을 가지게 되는 중심성 지표는?

① 연결정도 중심성(Degree Centrality) ② 근접 중심성(Closeness Centrality) ③ 매개 중심성(Betweenness Centrality) ④ 위세 중심성(Eigenvector Centrality)

문제 6. 문서 집합에서 숨겨진 주제(토픽)를 자동으로 추출하는 대표적인 비지도학습 기반 토픽모델링 기법은?

① LDA(Latent Dirichlet Allocation) ② SVM ③ K-means ④ ARIMA

4 과목(비정형 데이터 마이닝) 기출유형 문제 (풀이)

문제 1. 정답 ②

- 해설: **어간 추출(Stemming)**은 단어의 어미 등을 단순한 규칙에 따라 잘라내는 방식이기 때문에 처리 속도는 빠르지만, 결과물이 실제 사전에 존재하지 않는 형태가 될 수 있습니다(예: studies → studi). 반면 **표제어 추출(Lemmatization)**은 품사 정보와 사전을 활용하여 문법적으로 올바른 기본형을 반환합니다.

문제 2. 정답 ②

- 해설: IDF(역문서빈도)는 여러 문서에 공통적으로 자주 등장하는 단어(예: "그리고", "은/는")의 **가중치를 낮추는** 역할을 합니다. "가중치를 높이기 위한 지표"라는 설명은 IDF의 목적과 반대되므로 옳지 않습니다. 특정 문서에서만 자주 등장하고 다른 문서에서는 드물게 등장하는 단어일수록 IDF 값(및 TF-IDF 값)이 커집니다.

문제 3. 정답 ②

- 해설: Word2Vec과 같은 워드 임베딩 기법은 단어를 저차원의 밀집 벡터로 표현함으로써, BoW/TF-IDF가 표현하지 못하는 **단어 간의 의미적 유사성**(예: 벡터 연산을 통한 유사 관계)을 반영할 수 있다는 점이 핵심적인 차별점입니다.

문제 4. 정답 ④

- 해설: 노드와 직접 연결된 이웃의 수를 단순히 계산하는 지표는 **연결정도 중심성(Degree Centrality)**입니다. **근접 중심성(Closeness Centrality)**은 해당 노드에서 네트워크 내 다른 모든 노드까지의 최단거리 합을 기반으로 계산되는, 전체 네트워크에 대한 접근 효율성을 나타내는 지표입니다.

문제 5. 정답 ③

- 해설: **매개 중심성(Betweenness Centrality)**은 다른 두 노드 사이의 최단경로 상에 해당 노드가 얼마나 자주 놓이는지를 측정합니다. 서로 다른 그룹을 잇는 유일한 다리 역할을 하는 노드는 직접 연결된 노드 수(연결정도 중심성)는 적을 수 있지만, 그룹 간 정보 흐름의 중개 역할을 도맡기 때문에 매개 중심성 값이 매우 높게 나타납니다.

문제 6. 정답 ①

- 해설: **LDA(Latent Dirichlet Allocation)**는 문서가 여러 토픽의 혼합으로, 각 토픽은 단어들의 확률분포로 구성된다고 가정하는 대표적인 토픽모델링 기법입니다. SVM과 K-means는 각각 분류/군집 기법, ARIMA는 시계열 예측 기법으로 토픽모델링과는 관련이 없습니다.

이것으로 4과목: 데이터분석의 전체 범위(R기초와 데이터마트, 통계분석, 정형 데이터마이닝, 비정형 데이터마이닝)를 모두 마쳤습니다. 마지막으로 남은 과목은 5과목: 데이터 시각화(시각화 인사이트 프로세스, 시각화 디자인, 시각화 구현)이며, 이 과목에는 배점 20점의 서술형 문제도 포함되어 있습니다.

[사용자] 네

ADP 필기시험 대비 자료 (4-6) — 데이터 시각화

5 과목: 데이터 시각화

5과목은 객관식 10문항(10점) 외에 **서술형 1문항(20점)**이 포함되어 있는 유일한 과목입니다. 서술형은 범위가 매우 넓어 완벽 대비는 어렵지만, 핵심 개념과 프로세스를 논리적으로 서술할 수 있도

록 준비하는 것이 중요합니다.

5-1. 시각화 인사이트 프로세스

① 시각화 인사이트 프로세스의 의미

- 데이터 시각화는 단순히 "예쁘게 그리는 것"이 아니라, 데이터로부터 **통찰(Insight)**을 도출하고 이를 효과적으로 전달하기 위한 체계적인 과정
- 일반적으로 **탐색(1 단계) → 분석(2 단계) → 활용(3 단계)**의 3 단계로 구성

② 탐색(1단계) — Exploration

- 목적: 데이터의 전반적인 특성과 구조를 파악하는 단계
- **EDA(Exploratory Data Analysis, 탐색적 데이터 분석)**: 본격적인 분석 전에 데이터의 분포, 이상치, 변수 간 관계 등을 시각적·통계적으로 살펴보는 과정
- 이 단계에서는 히스토그램, 박스플롯, 산점도 등 기본적인 그래프를 활용하여 데이터의 대략적인 패턴을 파악

③ 분석(2단계) — Analysis

- 목적: 탐색 단계에서 발견한 패턴이나 가설을 통계적/분석적 기법으로 심층 검증
- 다양한 분석 기법(회귀, 군집, 분류 등)과 결합하여 시각화를 통해 분석 결과의 신뢰성과 의미를 검토

④ 활용(3단계) — Utilization

- 목적: 분석 결과를 의사결정권자나 최종 사용자에게 효과적으로 전달하고 실제 업무에 활용
- 스토리텔링(Storytelling)을 통한 설득력 있는 전달, 대시보드(Dashboard) 구축을 통한 지속적 모니터링 등이 이 단계에 해당

5-2. 시각화 디자인

① 시각화의 정의

- 데이터를 그래픽 요소(점, 선, 면, 색상, 크기 등)로 변환하여 정보를 직관적으로 전달하는 과정

② 시각화 프로세스

- 일반적 절차: 정보 구조화(어떤 데이터를, 어떤 목적으로) → 시각화 유형 선택 → 디자인 구현 → 평가 및 개선

③ 시각화 방법 — 데이터 유형별 대표 차트 (자주 출제)

목적	대표 시각화 방법
시간에 따른 변화(추세) 비교	선 그래프(Line Chart)

목적	대표 시각화 방법
범주 간 값의 크기 비교	막대 그래프(Bar Chart)
전체 대비 구성비(비율) 표현	파이 차트(Pie Chart), 도넛 차트, 트리맵(Treemap)
두 변수 간의 관계(상관관계) 파악	산점도(Scatter Plot)
데이터의 분포와 이상치 확인	히스토그램(Histogram), 박스플롯(Box Plot)
다변량 데이터의 패턴 비교	레이더 차트(Radar Chart), 평행좌표plot(Parallel Coordinates)
지리적 데이터 표현	지도 시각화(Choropleth Map 등)
네트워크(관계) 구조 표현	노드-링크 다이어그램(Network Graph)
계층 구조 표현	트리맵(Treemap), 덴드로그램(Dendrogram)

- **시각화 디자인 원칙:** 데이터-잉크 비율(Data-Ink Ratio, 불필요한 잉크/장식을 최소화), 색상은 의미를 왜곡하지 않게 신중히 사용(예: 순서형 데이터는 단일 색조의 명도 변화, 범주형 데이터는 서로 구분되는 색상 사용), 3D 효과나 과도한 장식은 오히려 정보 전달을 왜곡할 수 있어 지양

④ 빅데이터와 시각화 디자인

- 대용량/고차원 데이터 시각화 시 고려사항: 데이터를 요약·집계하여 표현(과도한 데이터포인트로 인한 오버플로팅(Overplotting) 방지), 인터랙티브 시각화(확대/필터링/드릴다운)를 통한 탐색 지원

5-3. 시각화 구현

① 시각화 구현 개요

- 시각화 결과물이 실제로 사용자에게 전달되는 형태(정적 이미지, 동적/인터랙티브 웹, 대시보드 등)로 구현하는 단계

② 분석 도구를 이용한 시각화 구현

- R: ggplot2(Grammar of Graphics 기반, 레이어를 쌓아가는 방식으로 시각화), plotly(인터랙티브)
- Python: matplotlib, seaborn, plotly
- BI 도구: Tableau, Power BI 등 — 코딩 없이 대시보드 형태의 시각화 구현 가능

③ 라이브러리 기반의 시각화 구현: D3.js

- **D3.js(Data-Driven Documents):** 웹 표준 기술(HTML, SVG, CSS, JavaScript)을 기반으로 데이터를 문서(DOM)에 바인딩하여 매우 자유도 높은 **인터랙티브 웹 시각화**를 구현할 수 있는 자바스크립트 라이브러리

- 특징: 낮은 수준(low-level)의 API 를 제공하여 학습 곡선은 있지만, 원하는 형태의 커스텀 시각화를 자유롭게 구현 가능하다는 점에서 시험에 자주 언급됨

5-4. 서술형 문제 대비 (참고)

- 서술형(20 점)은 데이터 이해~데이터 시각화 전 범위에서 출제될 수 있어 범위가 매우 넓습니다.
- 일반적으로 권장되는 전략: 특정 개념을 **정의** → **특징/구성요소** → **예시** 순서로 논리적으로 서술하는 답안 틀을 미리 연습해두는 것이 효과적입니다.
- 자주 언급되는 서술형 대비 주제 예시: CRISP-DM 각 단계 설명, 빅데이터의 위기요인과 통제방안, 정형/비정형 데이터 마이닝 기법의 차이, 앙상블(배깅/부스팅) 원리, 시각화 인사이트 프로세스 3 단계 등 — 이미 앞서 정리한 객관식 이론 내용을 **자신의 말로 3~5 줄 서술하는 연습**을 해보시는 것을 권장드립니다.

5 과목(데이터 시각화) 기출유형 문제 (문제)

※ 아래 문제는 실제 시행된 시험의 출제 패턴과 개념을 반영하여 재구성한 기출유형 연습문제이며, 실제 출제 원문이 아닌 점 참고 부탁드립니다.

문제 1. 시각화 인사이트 프로세스의 3단계를 순서대로 바르게 나열한 것은?

- ① 분석 → 탐색 → 활용 ② 탐색 → 분석 → 활용 ③ 활용 → 탐색 → 분석 ④ 탐색 → 활용 → 분석

문제 2. 본격적인 통계 분석에 앞서 데이터의 분포, 이상치, 변수 간 관계 등을 시각적·통계적으로 살펴보는 과정을 지칭하는 용어는?

- ① ETL ② EDA(탐색적 데이터 분석) ③ CRISP-DM ④ ROC 분석

문제 3. 다음 중 두 연속형 변수 간의 관계(상관관계)를 파악하기에 가장 적합한 시각화 방법은?

- ① 파이 차트(Pie Chart) ② 막대 그래프(Bar Chart) ③ 산점도(Scatter Plot) ④ 워드클라우드(Word Cloud)

문제 4. 전체에서 각 범주가 차지하는 구성비(비율)를 표현하기에 적합한 시각화 방법으로 짝지어진 것은?

- ① 선 그래프, 산점도 ② 파이 차트, 트리맵 ③ 히스토그램, 박스플롯 ④ 레이더 차트, 덴드로그램

문제 5. 다음 중 시각화 디자인 원칙에 대한 설명으로 가장 적절하지 않은 것은?

- ① 불필요한 장식(잉크)을 최소화하여 데이터 자체에 집중하도록 한다. ② 순서형 데이터를 표현할 때는 서로 관련 없는 여러 색상을 무작위로 사용하는 것이 가장 바람직하다. ③ 3D 효과나 과도한 장식은 정보 전달을 왜곡할 수 있어 지양하는 것이 좋다. ④ 대용량 데이터 시각화 시 오버플로팅(Overplotting)을 방지하기 위해 데이터를 요약·집계하여 표현할 수 있다.

문제 6. 웹 표준 기술(HTML, SVG, CSS, JavaScript)을 기반으로 데이터를 문서(DOM)에 바인딩하여

자유도 높은 인터랙티브 웹 시각화를 구현하는 대표적인 자바스크립트 라이브러리는?

① pandas ② D3.js ③ NumPy ④ Hadoop

문제 7. 계층 구조나 부분-전체 관계를 표현하기에 적합한 시각화 방법으로 옳은 것은?

① 산점도(Scatter Plot) ② 트리맵(Treemap) ③ 히스토그램(Histogram) ④ 막대 그래프(Bar Chart)

5 과목(데이터 시각화) 기출유형 문제 (풀이)

문제 1. 정답 ②

- 해설: 시각화 인사이트 프로세스는 데이터의 전반적인 특성을 파악하는 **탐색(1 단계)**, 발견된 패턴을 심층 검증하는 **분석(2 단계)**, 결과를 전달하고 실제 업무에 적용하는 **활용(3 단계)** 순서로 진행됩니다.

문제 2. 정답 ②

- 해설: **EDA(Exploratory Data Analysis, 탐색적 데이터 분석)**는 본격적인 모델링이나 통계적 검정에 앞서 데이터의 분포, 이상치, 결측치, 변수 간 관계 등을 시각화와 기초통계를 통해 파악하는 과정입니다. ETL은 데이터 처리 프로세스, CRISP-DM은 데이터마이닝 방법론, ROC 분석은 분류모형 평가 기법으로 이 설명과는 거리가 있습니다.

문제 3. 정답 ③

- 해설: **산점도(Scatter Plot)**는 두 연속형 변수를 각각 x 축, y 축에 배치하여 점으로 표현함으로써 두 변수 간의 선형/비선형 관계, 상관관계의 방향과 강도를 직관적으로 파악할 수 있게 해주는 대표적인 시각화 방법입니다.

문제 4. 정답 ②

- 해설: 전체 대비 구성비(비율)를 표현하는 데는 **파이 차트(Pie Chart)**와 계층적 구성비를 사각형 면적으로 표현하는 **트리맵(Treemap)**이 대표적입니다. 선 그래프/산점도는 추세나 관계 파악에, 히스토그램/박스플롯은 분포 파악에, 레이더 차트/덴드로그램은 다변량 비교나 계층 구조 표현에 더 적합합니다.

문제 5. 정답 ②

- 해설: 순서형(순위가 있는) 데이터를 표현할 때는 무작위의 서로 다른 색상보다는, 값의 크기 순서를 직관적으로 반영할 수 있는 **단일 색조의 명도(밝기) 변화**를 사용하는 것이 시각화 디자인의 일반적인 원칙입니다. 서로 관련 없는 색상을 무작위로 사용하면 오히려 순서 정보가 왜곡되어 전달될 수 있습니다.

문제 6. 정답 ②

- 해설: **D3.js(Data-Driven Documents)**는 웹 표준 기술을 기반으로 데이터와 문서(DOM 요소)를 결합(바인딩)하여, 자유도 높은 커스텀 인터랙티브 시각화를 구현할 수 있는 대표적인 자바스크립트 시각화 라이브러리입니다. pandas와 NumPy는 파이썬의 데이터 처리 라이브러리, Hadoop은 분산처리 프레임워크입니다.

문제 7. 정답 ②

- 해설: **트리맵(Treemap)**은 전체를 구성하는 하위 항목들을 사각형의 면적과 계층적 중첩 구조로 표현하여, 계층 구조와 각 항목이 차지하는 비중을 동시에 파악할 수 있게 해주는 대표적인 시각화 방법입니다.

전체 정리 및 다음 제안

이것으로 ADP 필기시험의 5개 과목 전체(데이터 이해, 데이터 처리 기술 이해, 데이터분석 기획, 데이터분석, 데이터 시각화) 이론 정리와 기출유형 문제를 모두 마쳤습니다.

- 지금까지 정리한 5개 과목의 이론 + 문제/풀이는 상당한 분량입니다. 원하시면 **전체 범위를 아우르는 최종 모의고사(실제 시험과 동일하게 5 과목 혼합, 80 문항 구성 등)**를 만들어 드릴 수도 있습니다.
- 또는 특정 과목/주제 중 **취약하다고 느끼시는 부분을 다시 짚어드리거나 심화 문제**를 추가로 제공해 드릴 수 있습니다.