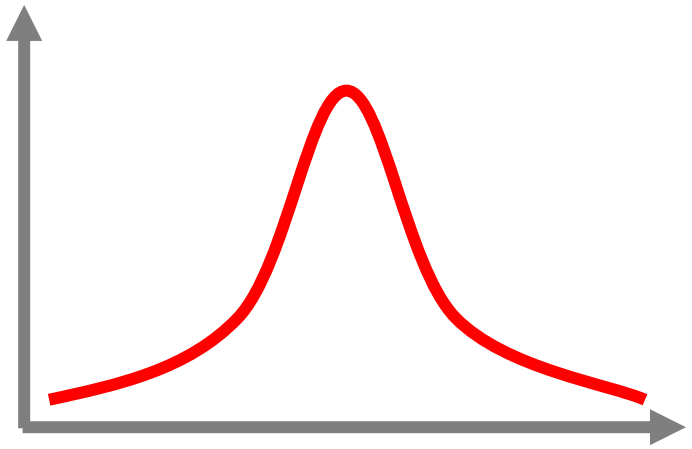
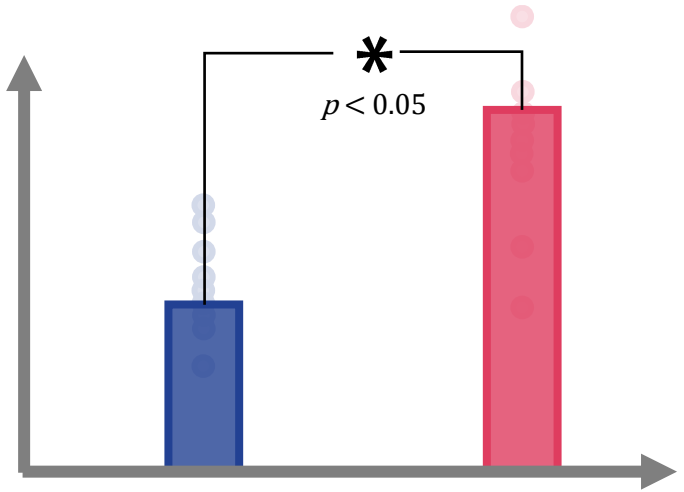
인공지능을 위한
Machine Learning101
머신러닝을 위한
기초 통계 개념들







안녕하세요 여러분! 신박Ai입니다

신박AI

오늘은 머신러닝의 기초를 위해 필요한
다음과 같은 가장 기본적인 통계의
개념들을 알아보도록 하겠습니다.

변수, 변량, 평균, 분산, 표준편차, 정규분포, 독립변수, 종속변수, 그리고 p-값

신박AI

옛날 옛적에 어느 마을에 한 농부가 살고 있었습니다.

신박AI

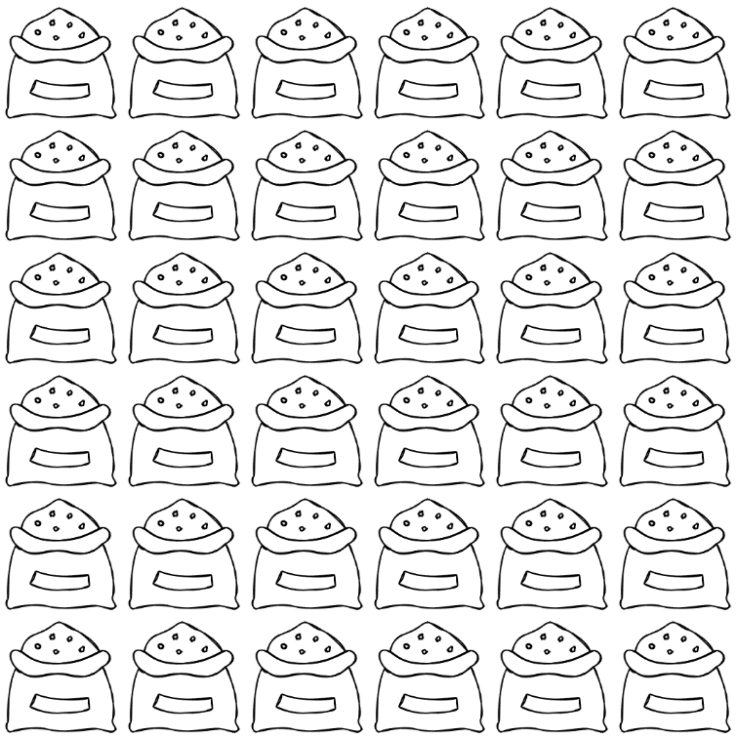
옛날 옛적에 어느 마을에 한 농부가 살고 있었습니다.



신박AI

농부는 매년 수확량이 달라지는 것을 보고 궁금증을 느꼈습니다.

2012





2013

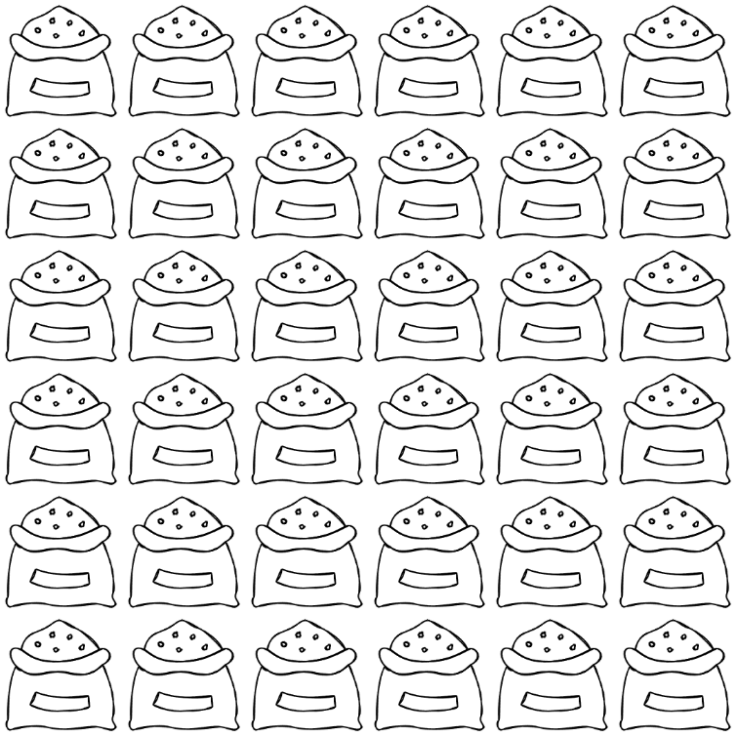


'왜 어떤 해는 수확이 많고, 어떤 해는 적을까? '

신박AI

이렇게 그는 수확량이라는 변수에 관심을 갖게 되었습니다.

2012





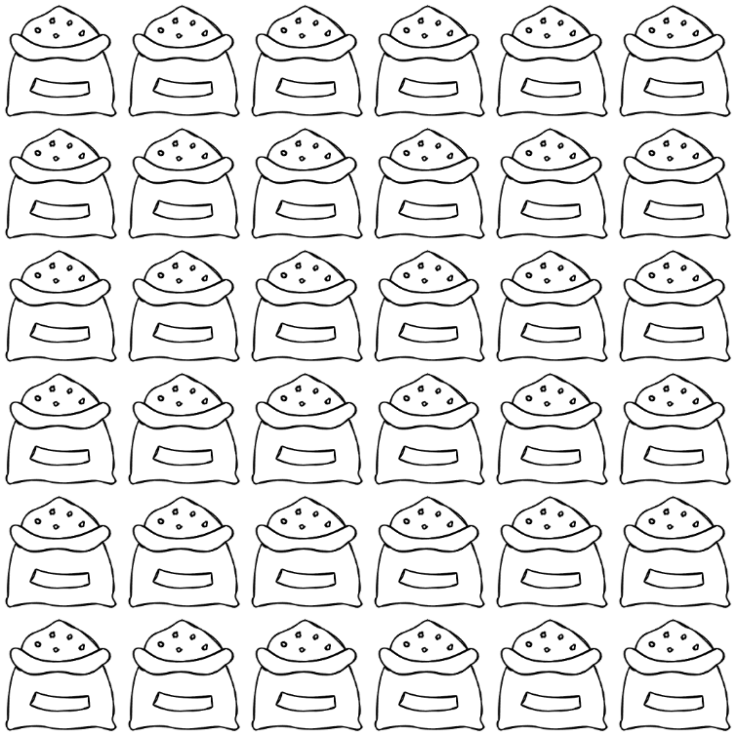
2013



신박AI

여기서 우리는 '변수'라는 개념을 생각해 볼 수 있습니다.

2012





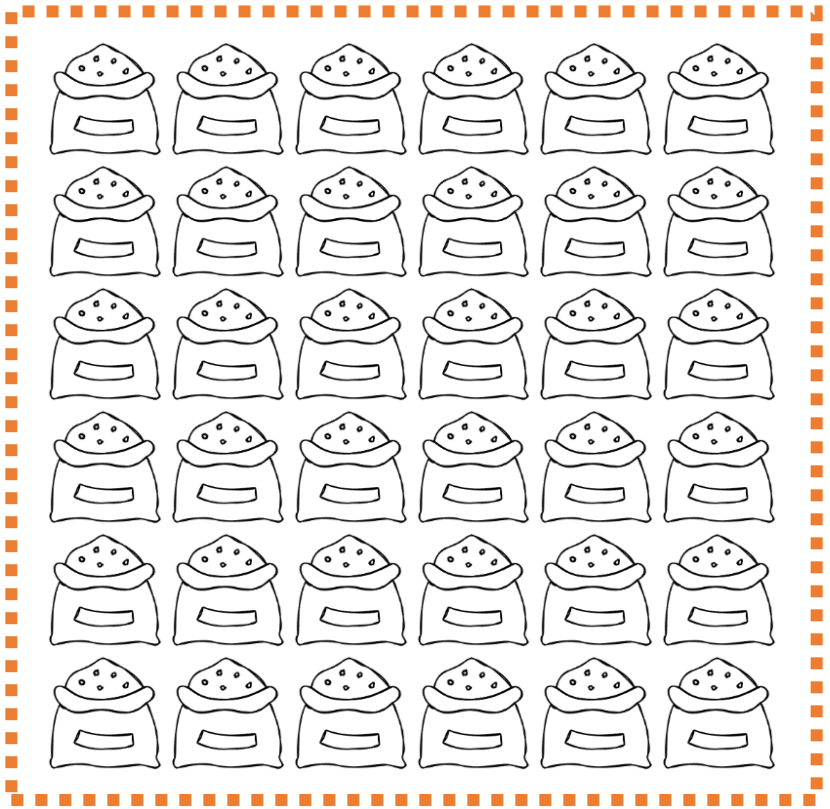
2013



신박AI

변수란 변하는 값, 즉 숫자로 표현될 수 있고, 값이 달라질 수 있는 것을 말합니다.

2012





2013

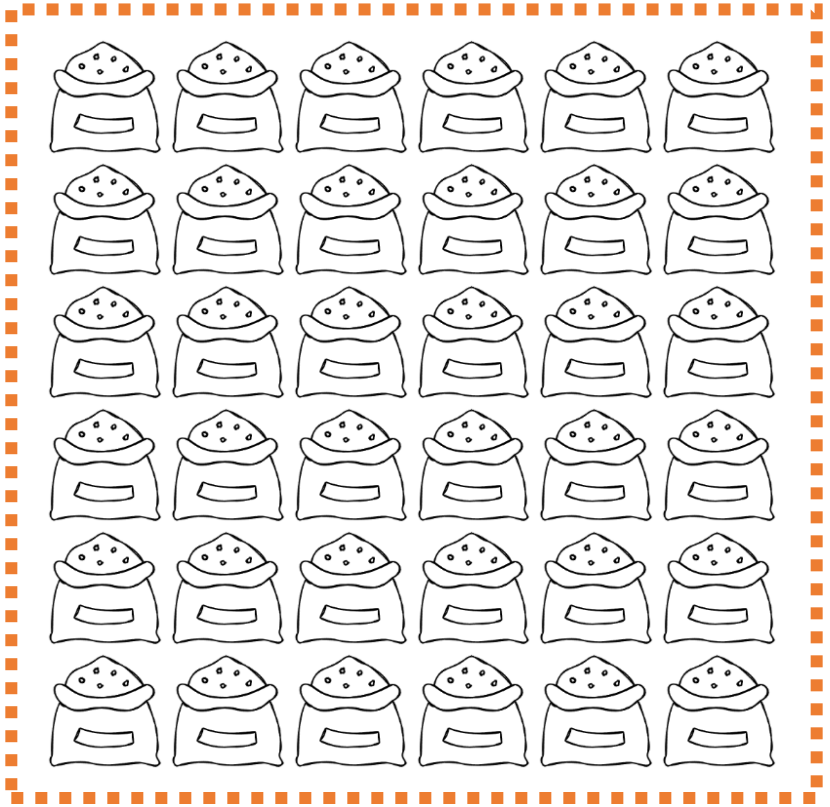


신박AI

예를 들어, 수확량은 해마다 다르니 변수가 되는 것이죠.

수확량: 720kg

2012





수확량: 60kg

2013

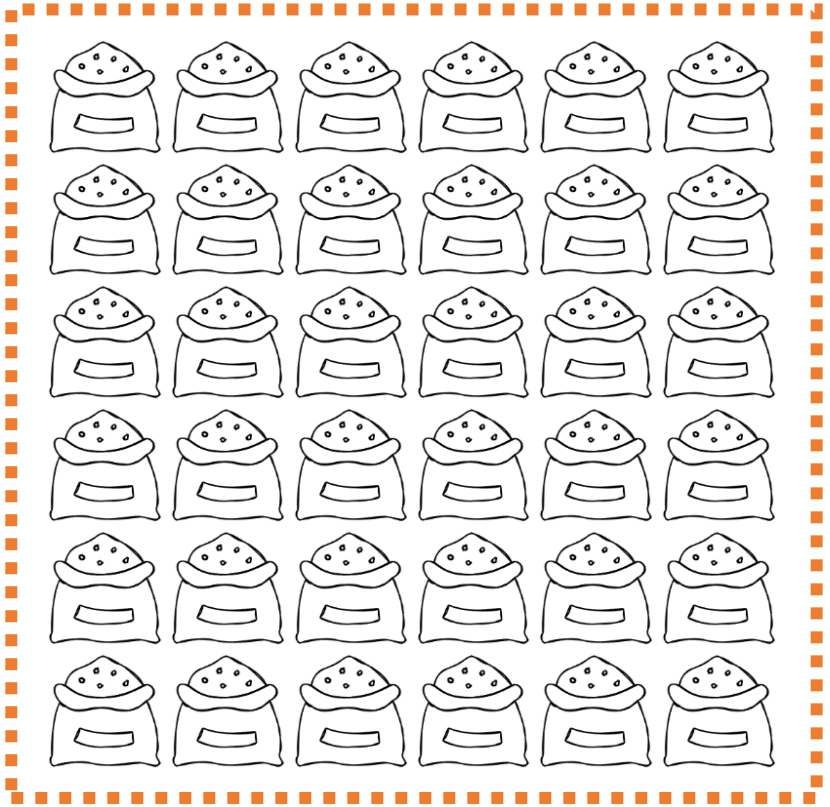


신박AI

수확량이라는 자연현상을 객관적인 수치로 수학의 영역으로 끌어들이는 첫 번째 단계가 바로 변수입니다.

수확량: 720kg

2012





수확량: 60kg

2013

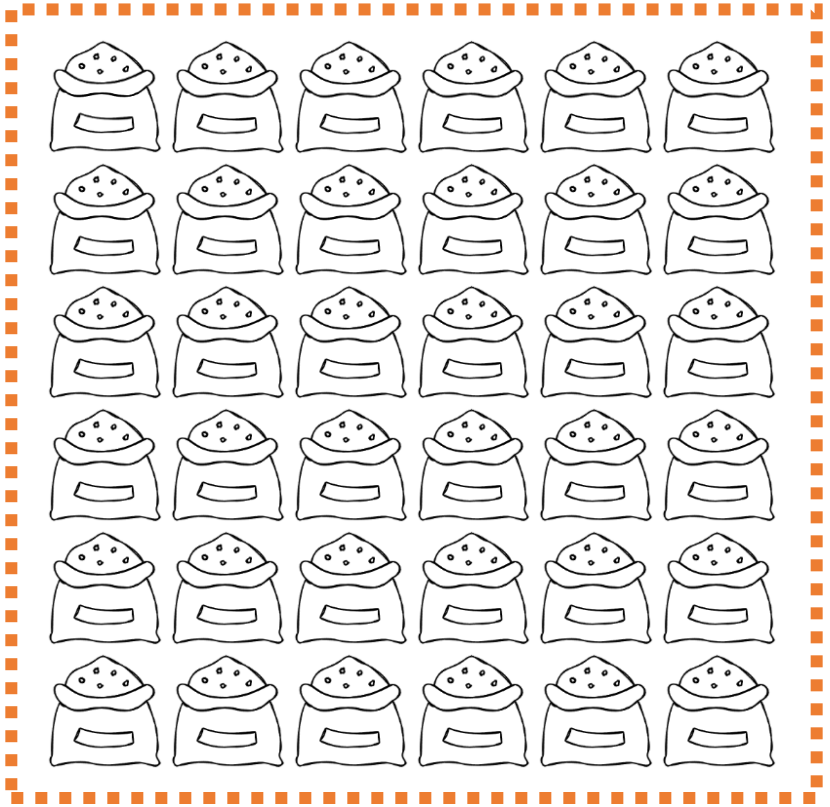


신박AI

그러므로 숫자로 표현되는 모든 자연현상을 변수라고 말할 수 있습니다.

수확량: 720kg

2012





수확량: 60kg

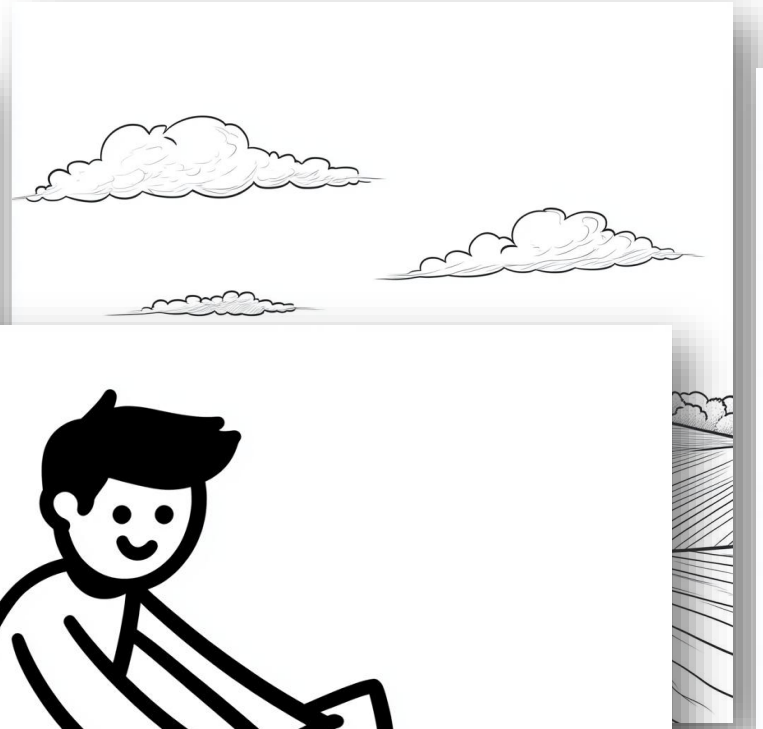
2013



신박AI

예를 들어, 농부가 사는 마을의 인구수, 농부가 소유한 논의 넓이, 올해 내린 비의 양, 농부가 뿌린 비료의 양 모두 변수가 됩니다.









신박AI

예를 들어, 농부가 사는 마을의 인구수, 농부가 소유한 논의 넓이, 올해 내린 비의 양, 농부가 뿌린 비료의 양 모두 변수가 됩니다.



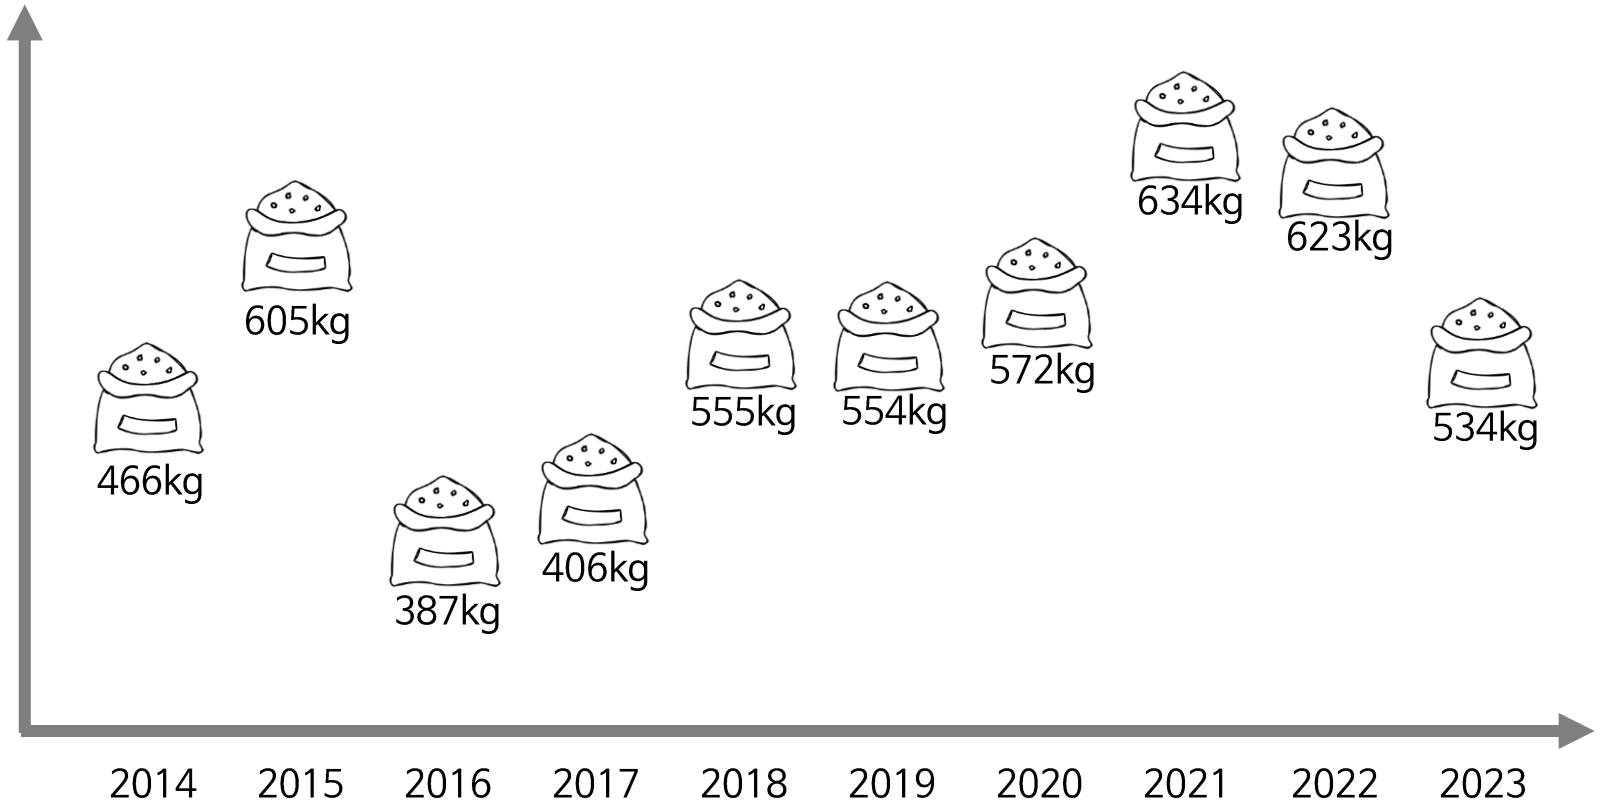
신박AI

농부는 수확량이라는 변수에 관심이 있었기 때문에, 일단 수확량의 특성에 대해 좀 더 알아보고자 했습니다.



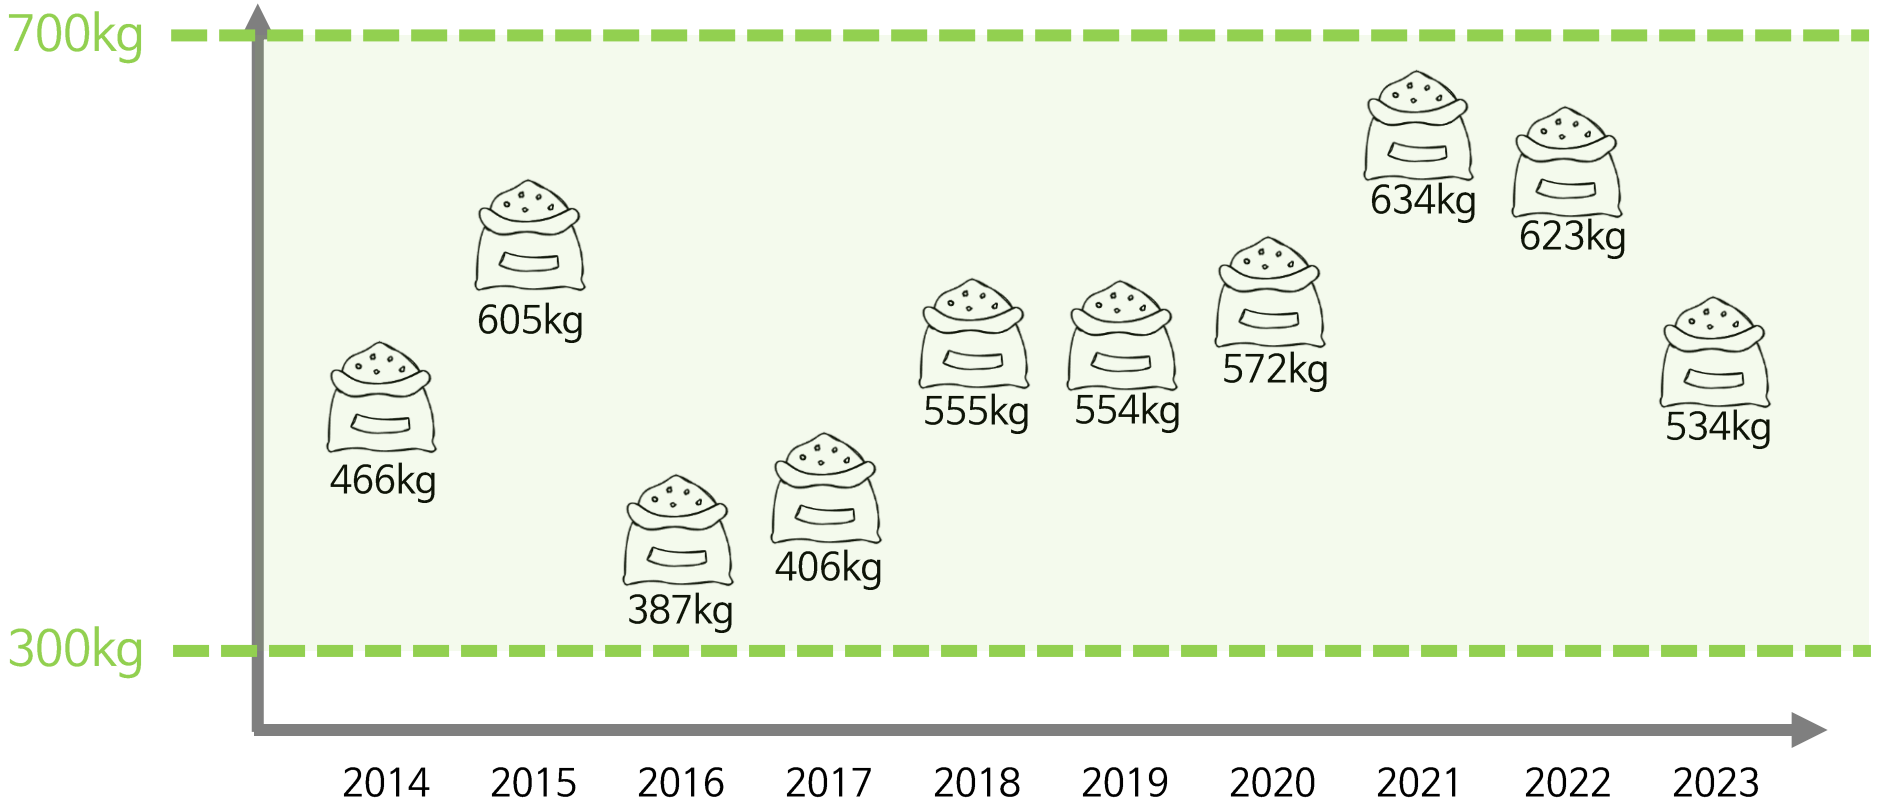
신박AI

그래서 그는 10년간의 데이터를 모았습니다.



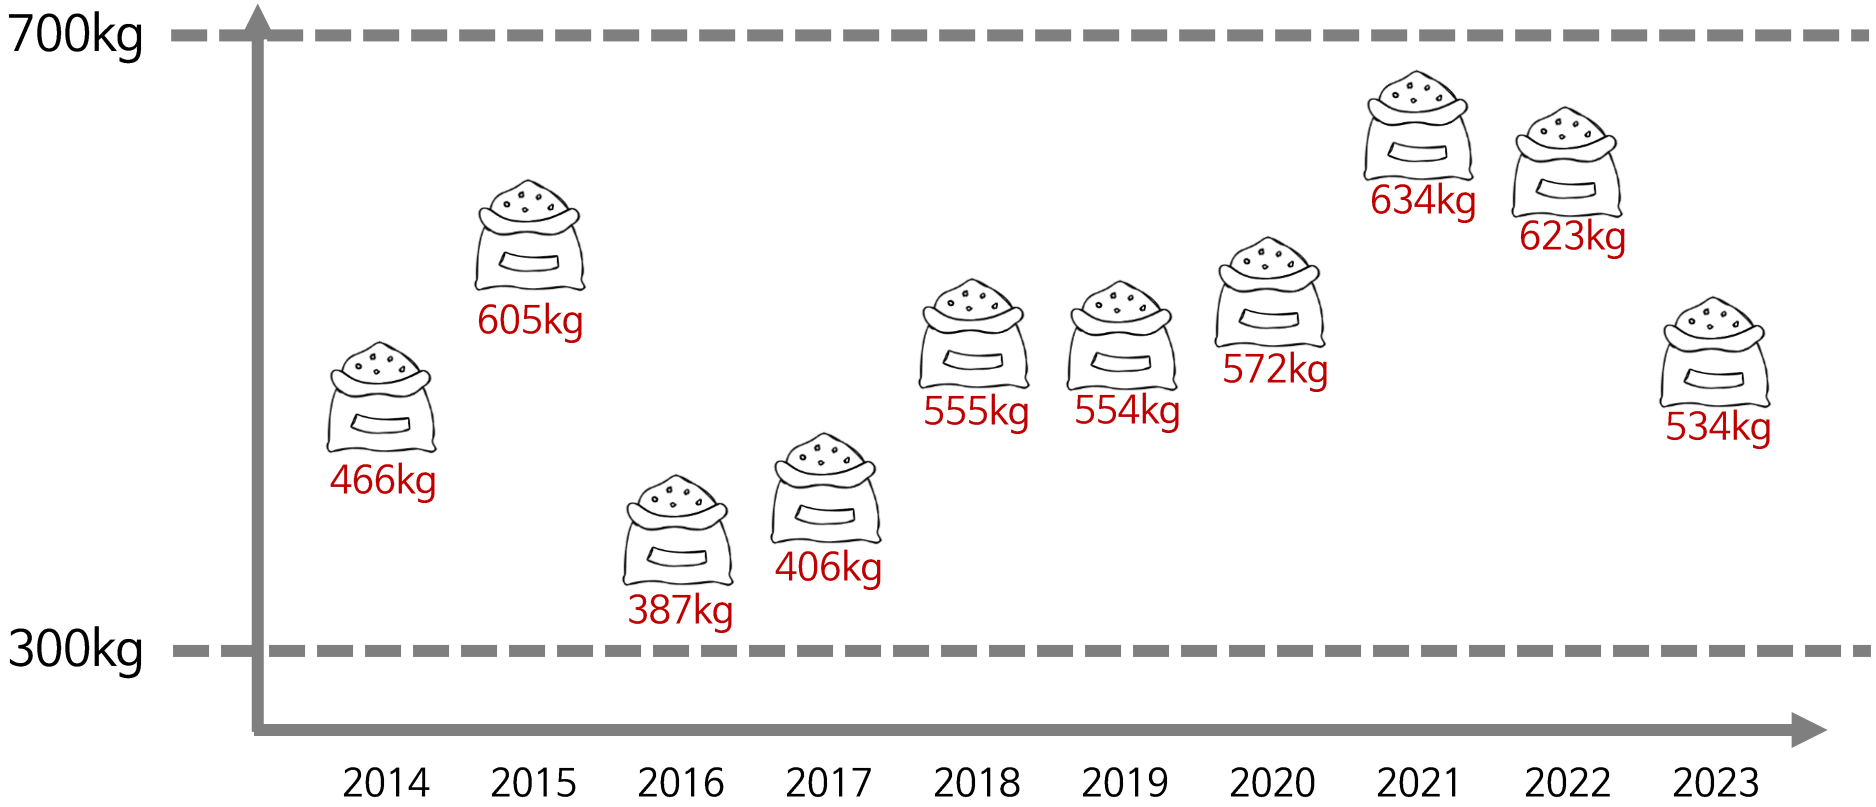
신박AI

이 데이터들의 집합, 즉 변량을 보니 수확량이 300kg에서 700kg 사이에 분포하고 있었습니다.



신박AI

이렇게 변수가 취할 수 있는 모든 값들 하나하나를 '변량'이라고 부릅니다.



신박AI

농부는 먼저 평균 수확량을 계산해보았습니다.

466kg 605kg 387kg 406kg 555kg 554kg 572kg 634kg 623kg 534kg

신박AI

농부는 먼저 평균 수확량을 계산해보았습니다.

$$\frac{466\text{kg} + 605\text{kg} + 387\text{kg} + 406\text{kg} + 555\text{kg} + 554\text{kg} + 572\text{kg} + 634\text{kg} + 623\text{kg} + 534\text{kg}}{10}$$

$$= 533.6\text{kg}$$

신박AI

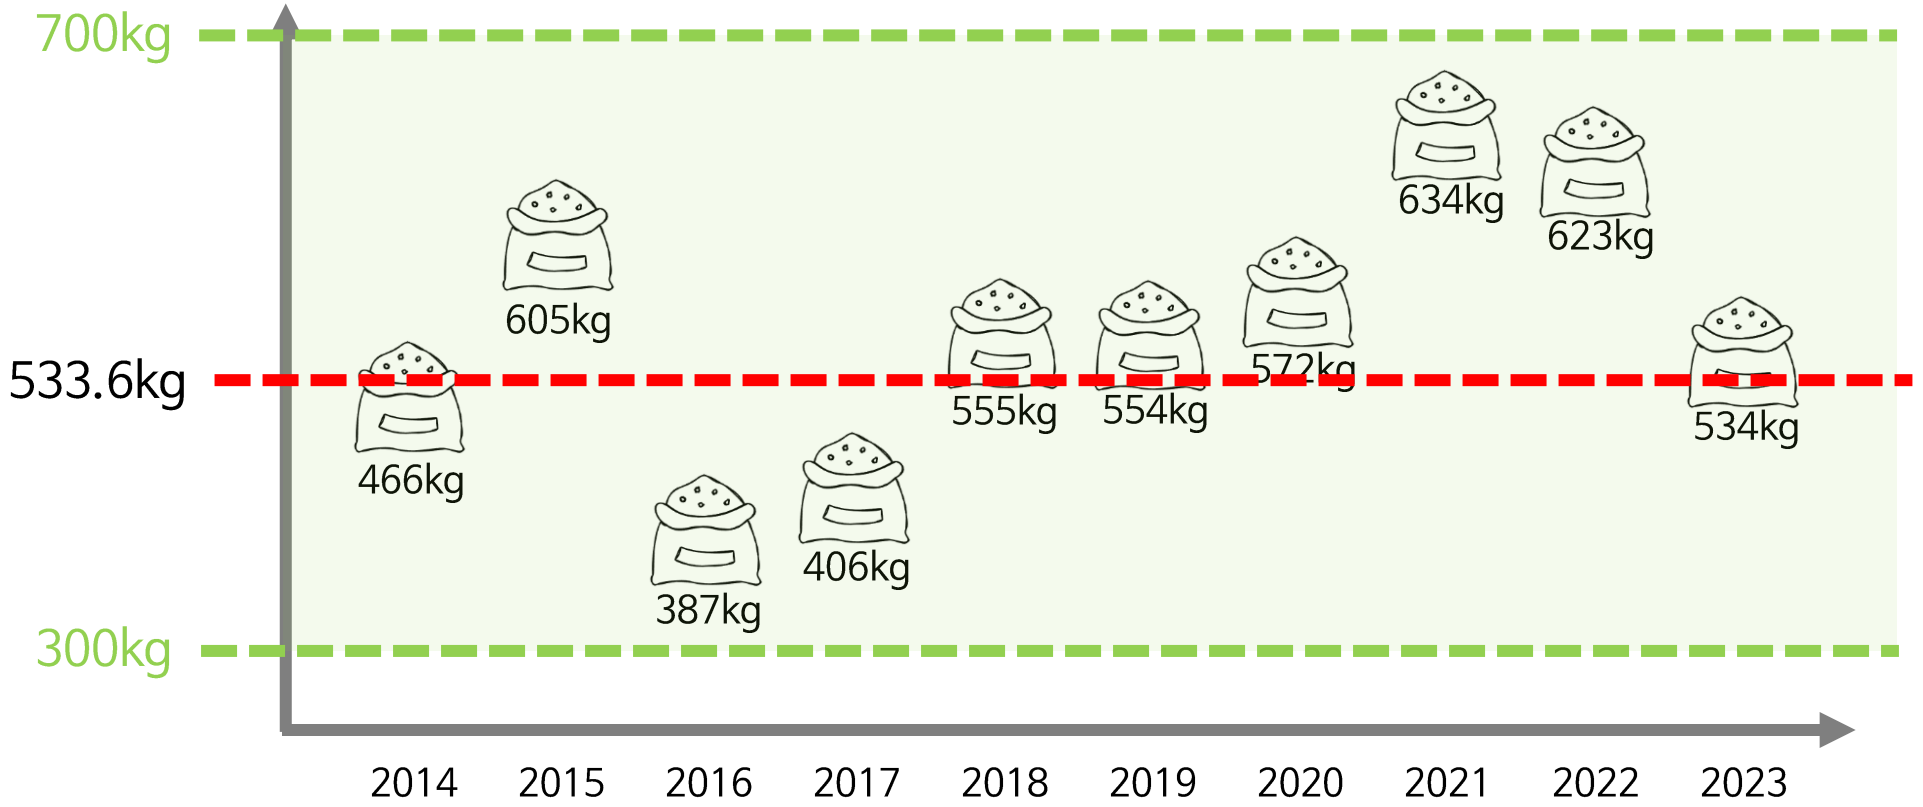
10년간의 수확량을 모두 더해서 10으로 나누니 533.6kg이 나왔습니다.

$$\frac{466\text{kg} + 605\text{kg} + 387\text{kg} + 406\text{kg} + 555\text{kg} + 554\text{kg} + 572\text{kg} + 634\text{kg} + 623\text{kg} + 534\text{kg}}{10}$$

$$= 533.6\text{kg}$$

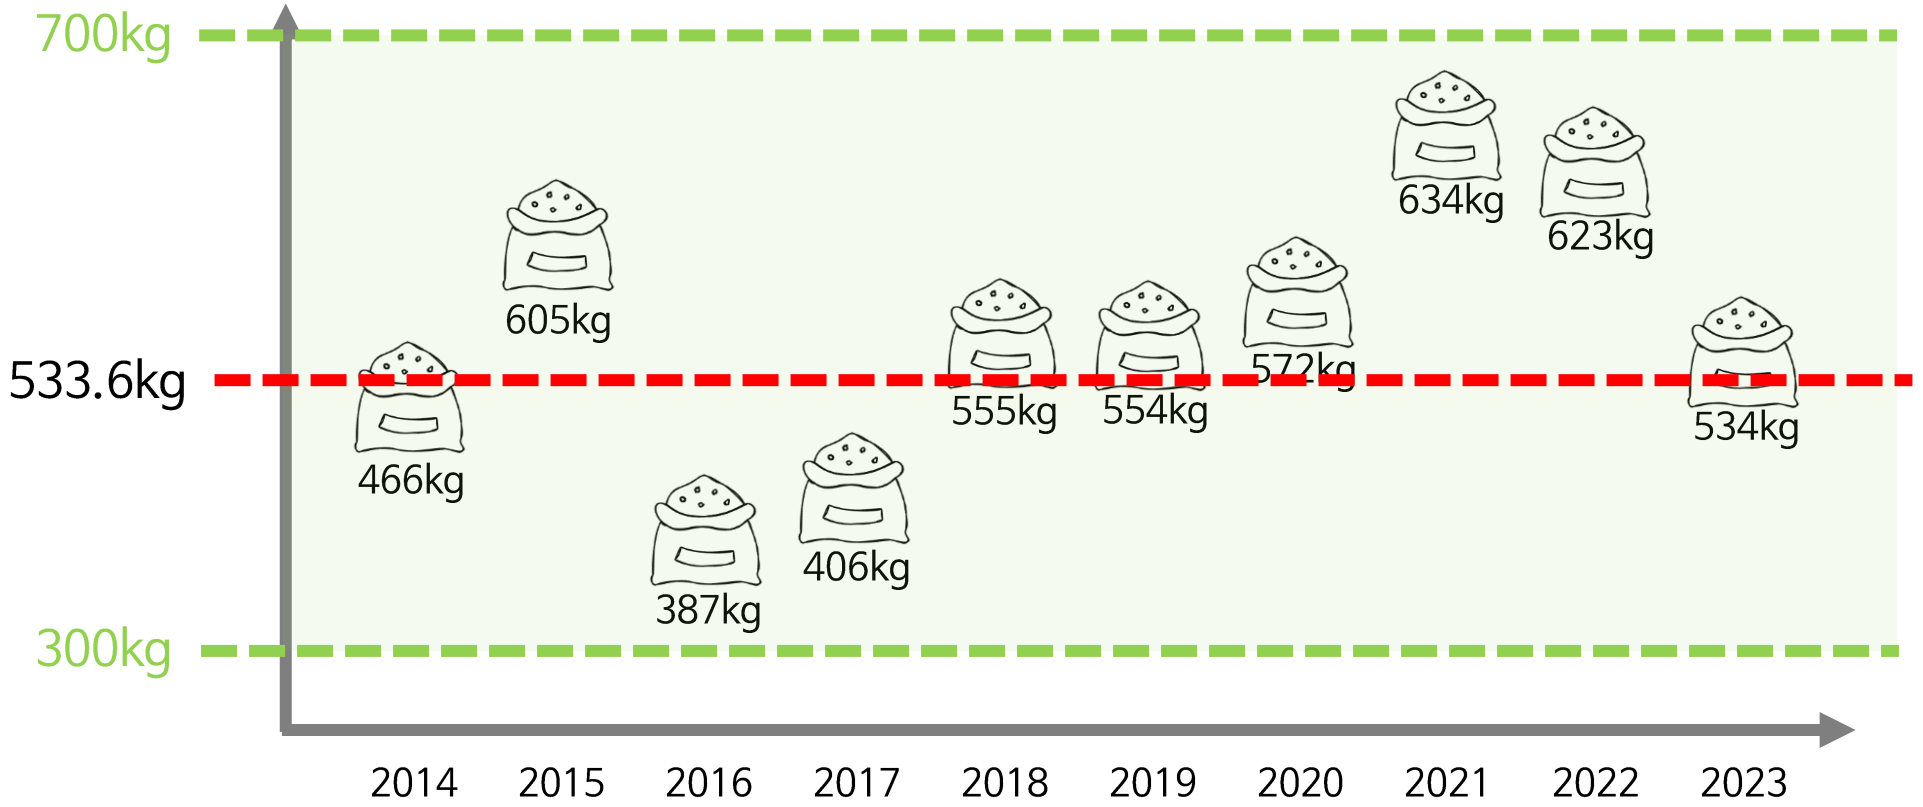
신박AI

10년간의 수확량을 모두 더해서 10으로 나누니 533.6kg이 나왔습니다.



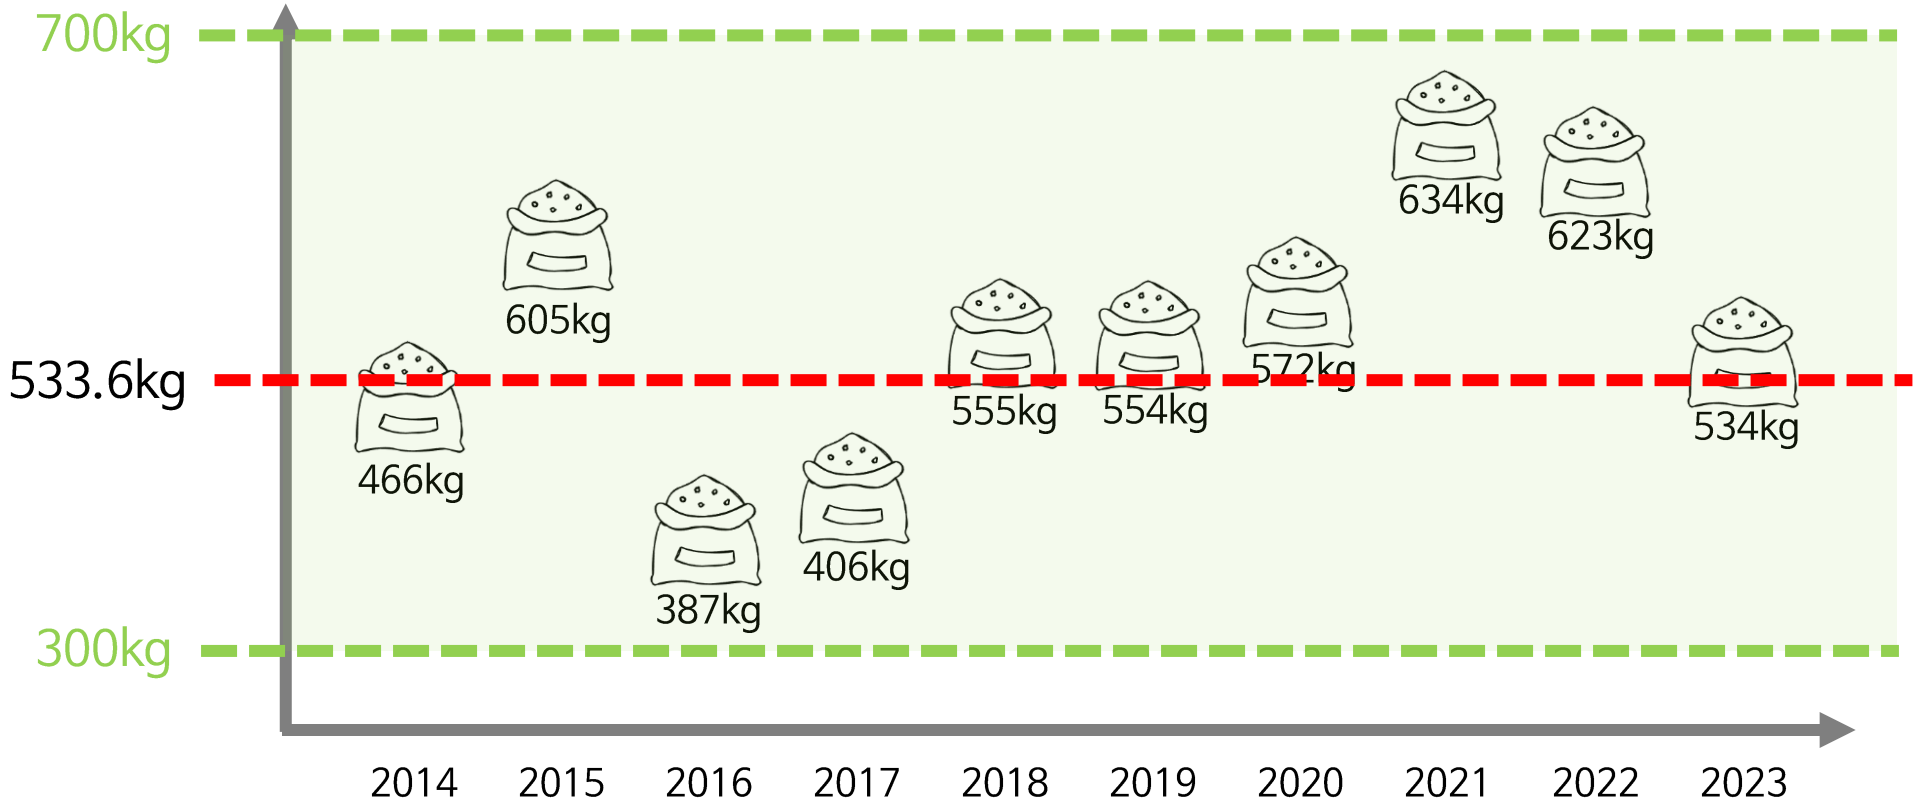
신박AI

이 533.6을 평균값이라고 합니다.



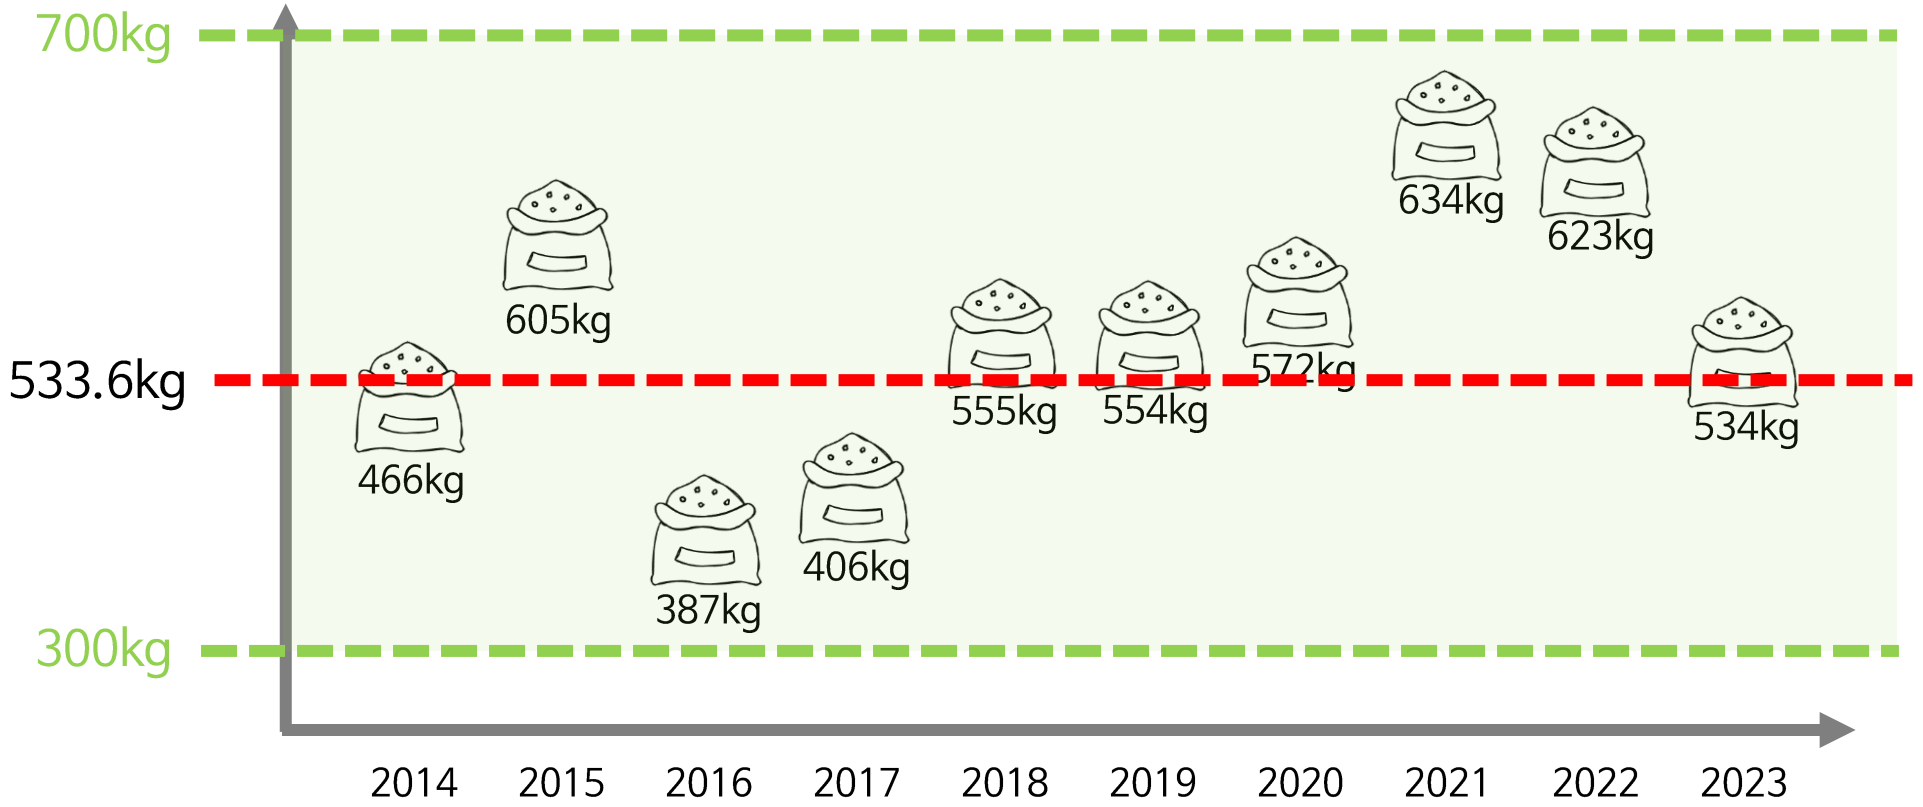
신박AI

모든 변량들을 더한 뒤, 변량의 개수만큼 나누어 구하는 이 평균값은,



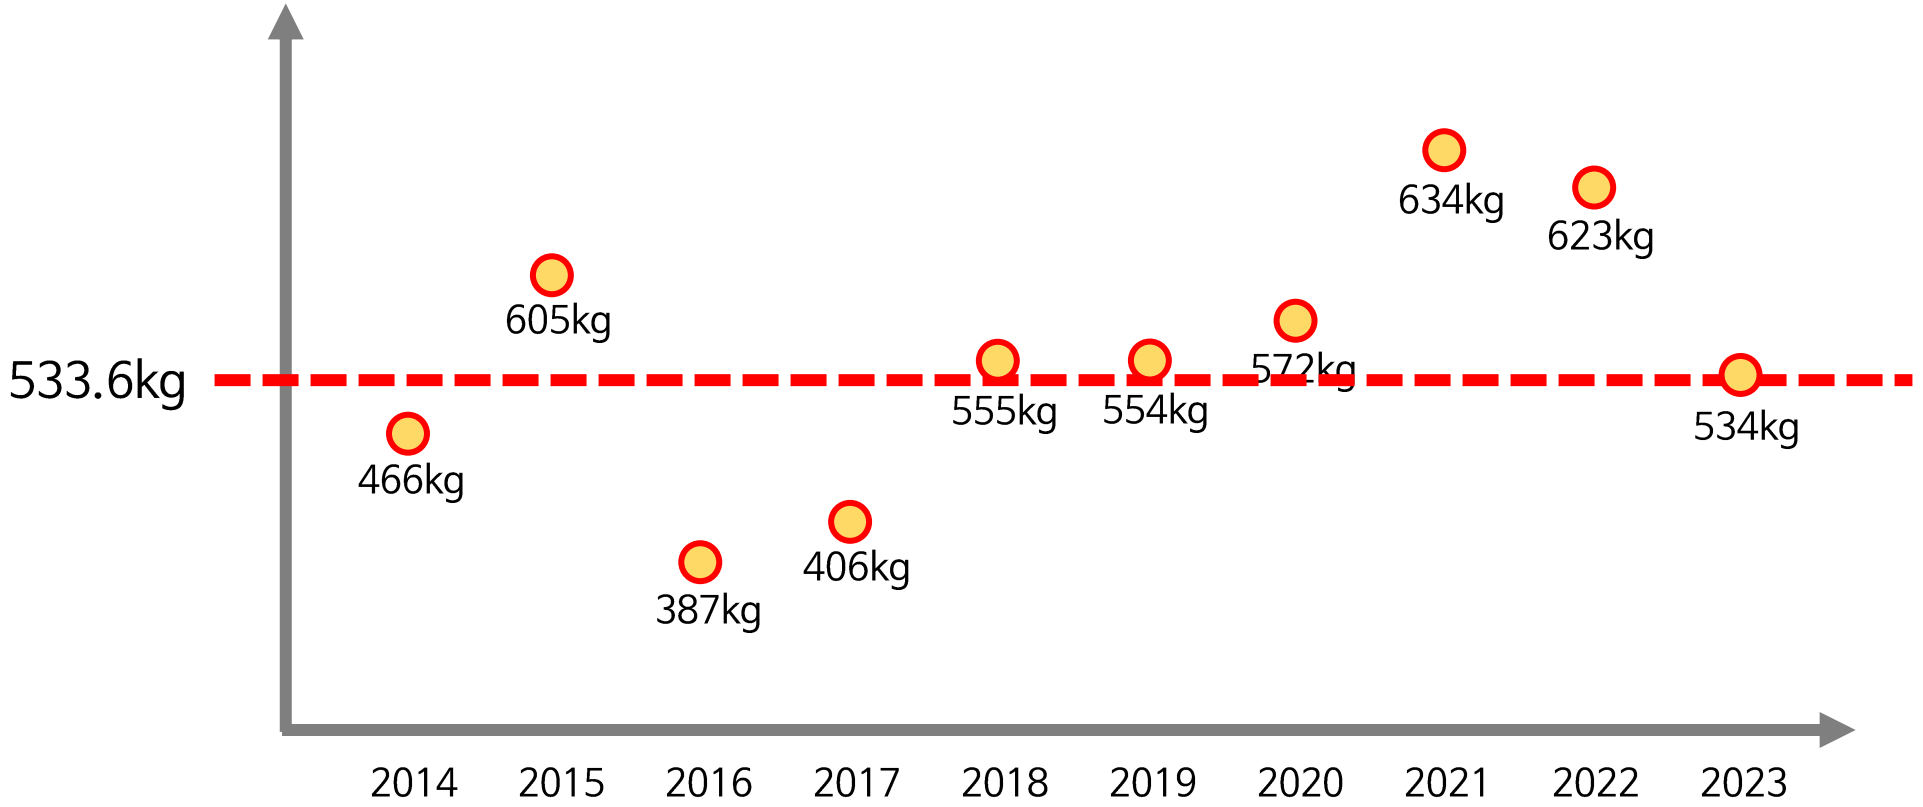
신박AI

데이터 집합의 특성을 대표하는 중요한 값이라 할 수 있습니다.



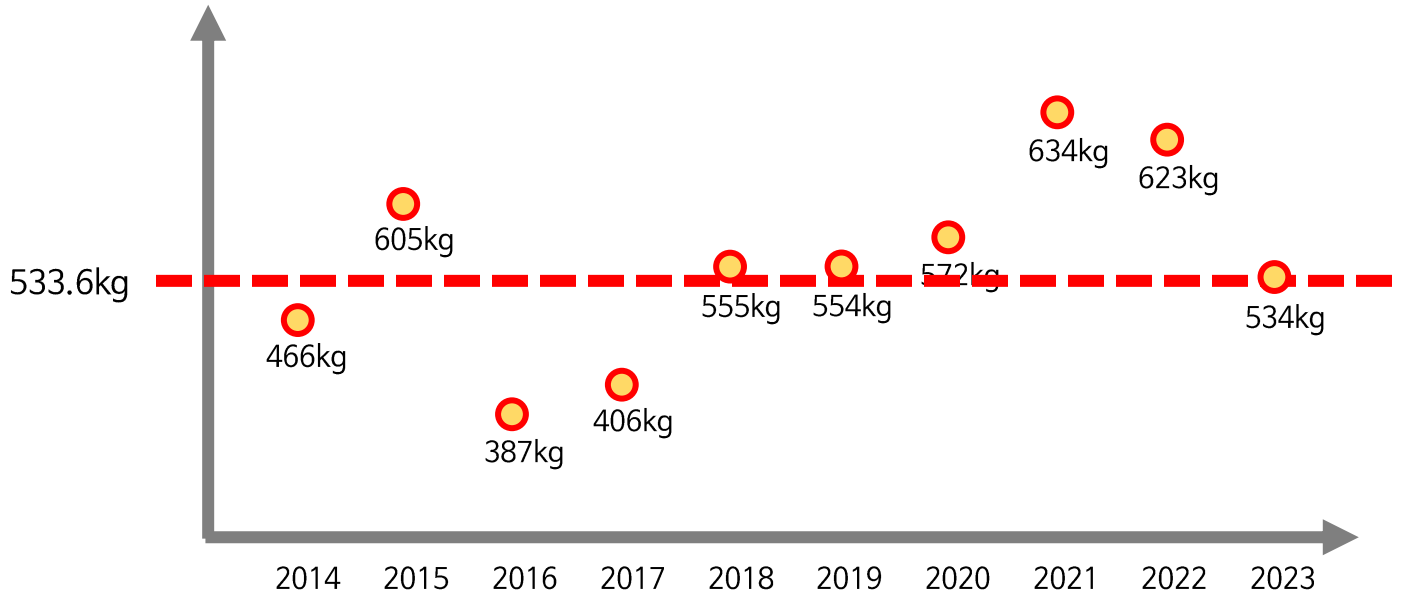
신박AI

데이터 집합의 특성을 대표하는 중요한 값이라 할 수 있습니다.



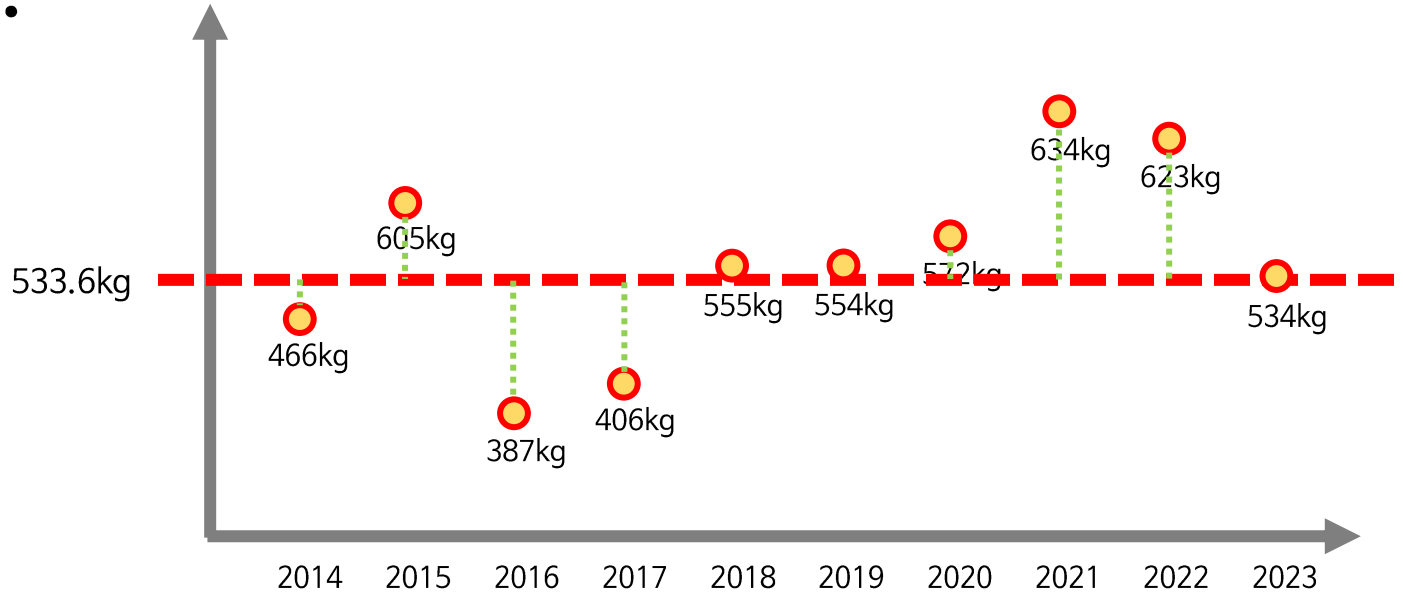
신박AI

데이터 집합의 특성을 대표하는 중요한 값이라 할 수 있습니다.



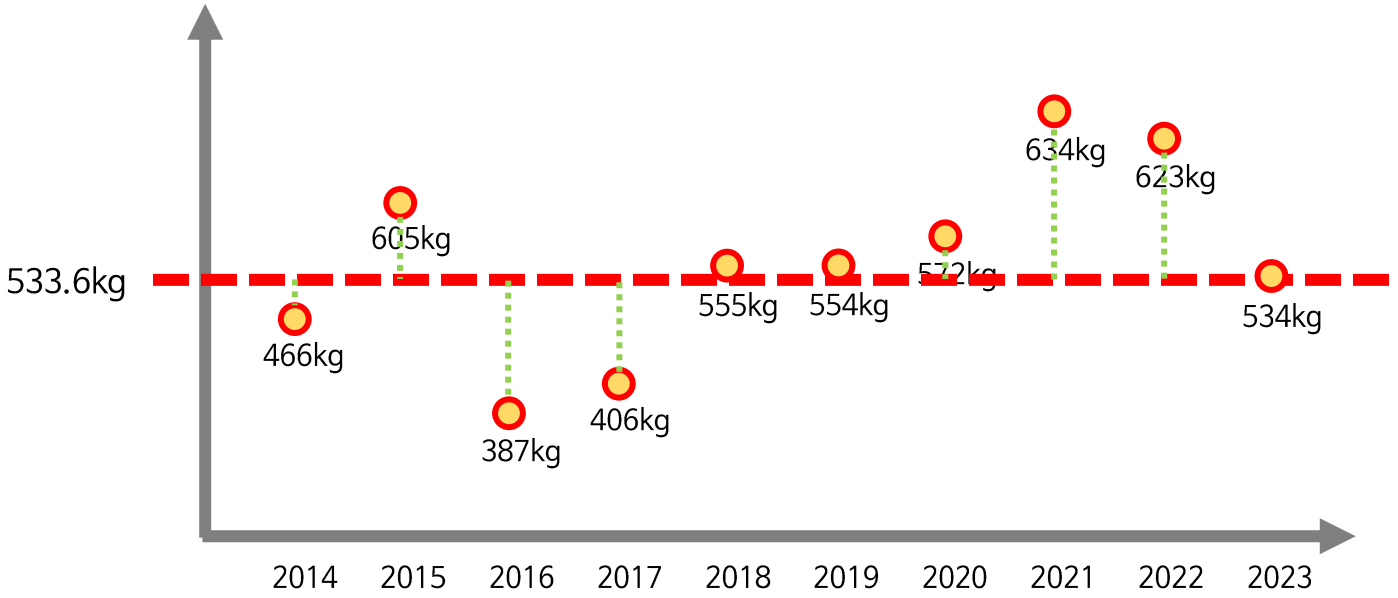
신박AI

또한 농부는 매년 수확량이 평균에서 얼마나 떨어져 있는지도 알고 싶어졌습니다.



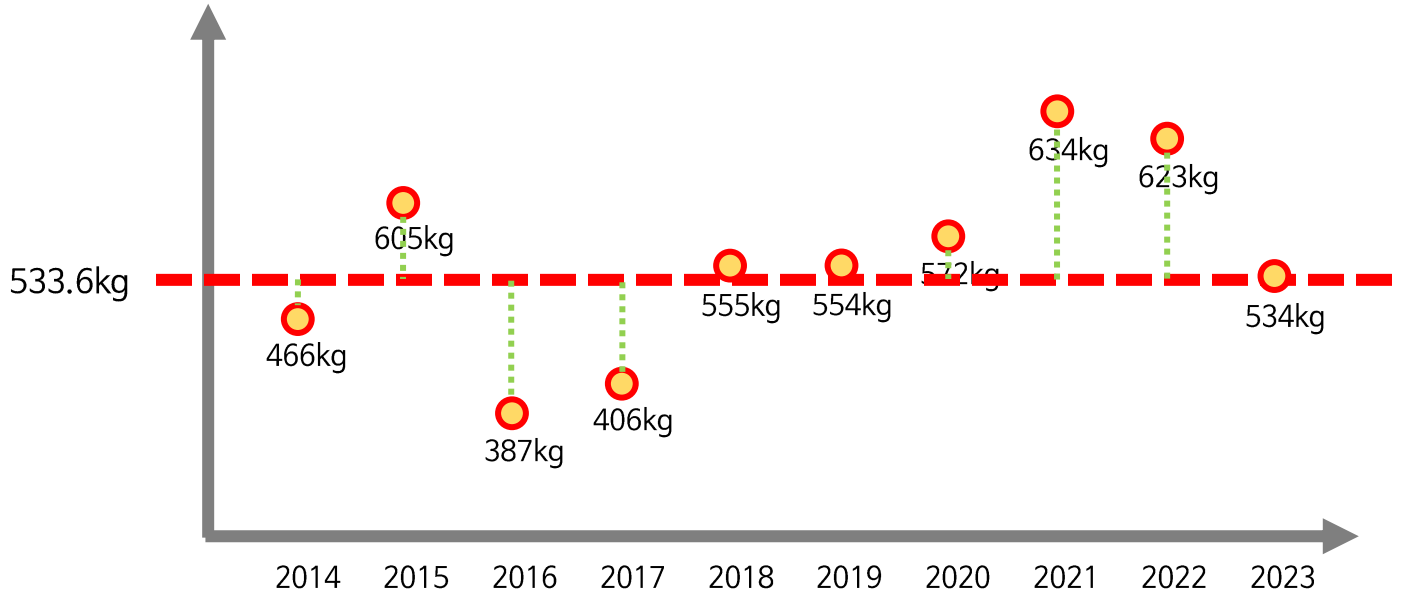
신박AI

이를 위해 분산과 표준편차를 계산하기 시작했습니다.



신박AI

분산은 각 수확량이 평균에서 얼마나 떨어져 있는지를 제곱한 값들의 평균이고,



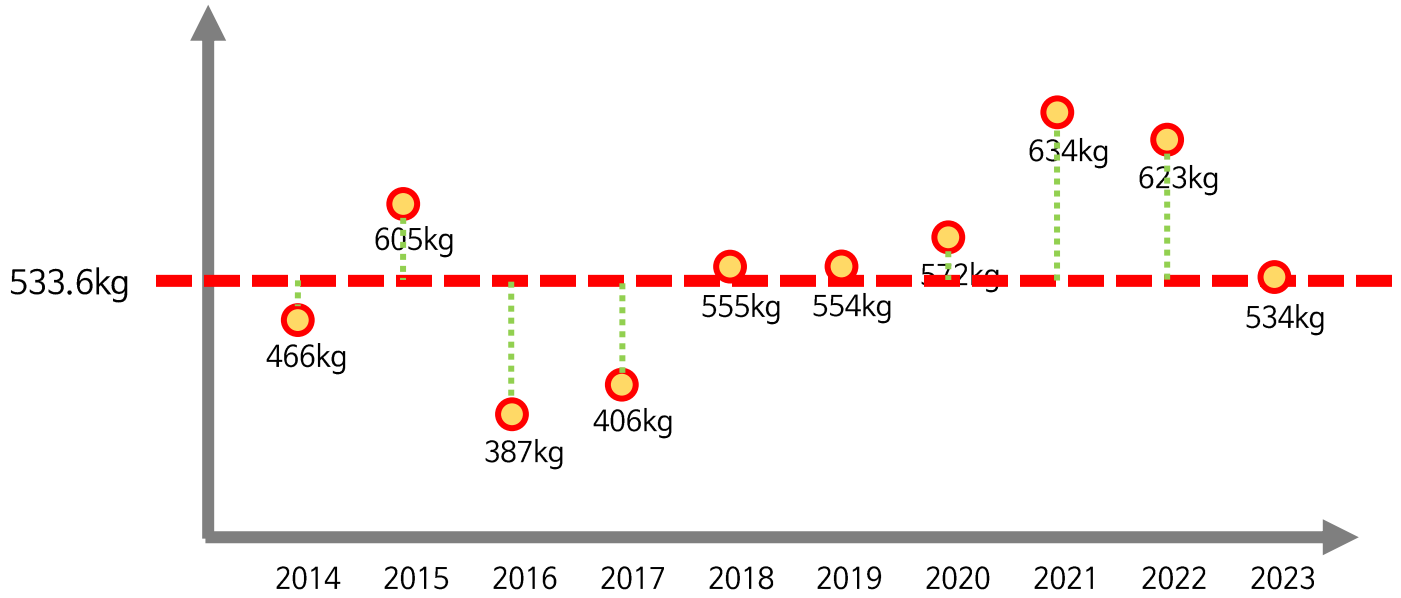
$$V = \frac{(466-533.6)^2+(605-533.6)^2+(387-533.6)^2+(406-533.6)^2+(555-533.6)^2+(554-533.6)^2+(572-533.6)^2+(634-533.6)^2+(623-533.6)^2+(534-533.6)^2}{10}$$

$$= \frac{4{,}569.76 + 5{,}097.96 + 21{,}491.56 + 16{,}281.76 + 457.96 + 416.16 + 1{,}474.56 + 10{,}080.16 + 7{,}992.36 + 0.16}{10}$$

$$= 6{,}786.24$$

신박AI

표준편차는 이 분산의 제곱근입니다.



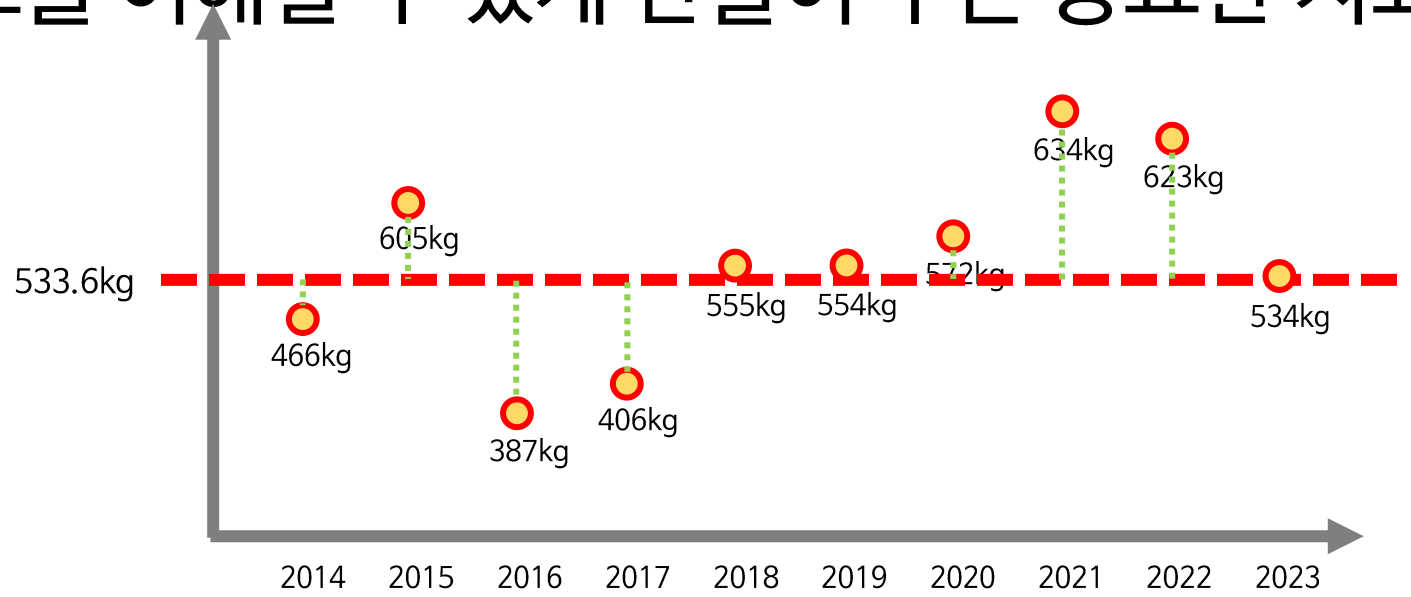
$$V = \frac{(466-533.6)^2+(605-533.6)^2+(387-533.6)^2+(406-533.6)^2+(555-533.6)^2+(554-533.6)^2+(572-533.6)^2+(634-533.6)^2+(623-533.6)^2+(534-533.6)^2}{10}$$

$$= \frac{4{,}569.76 + 5{,}097.96 + 21{,}491.56 + 16{,}281.76 + 457.96 + 416.16 + 1{,}474.56 + 10{,}080.16 + 7{,}992.36 + 0.16}{10}$$

$$\sigma = \sqrt{6{,}786.24} \quad = 82.37$$

신박AI

표준편차는 분산, 곧 차이의 제곱값을 보정하여 우리가 직관적으로 데이터의 분포를 이해할 수 있게 만들어 주는 중요한 지표입니다.



$$V = \frac{(466-533.6)^2+(605-533.6)^2+(387-533.6)^2+(406-533.6)^2+(555-533.6)^2+(554-533.6)^2+(572-533.6)^2+(634-533.6)^2+(623-533.6)^2+(534-533.6)^2}{10}$$

$$= \frac{4{,}569.76 + 5{,}097.96 + 21{,}491.56 + 16{,}281.76 + 457.96 + 416.16 + 1{,}474.56 + 10{,}080.16 + 7{,}992.36 + 0.16}{10}$$

$$\sigma = \sqrt{6{,}786.24} \quad = 82.37$$

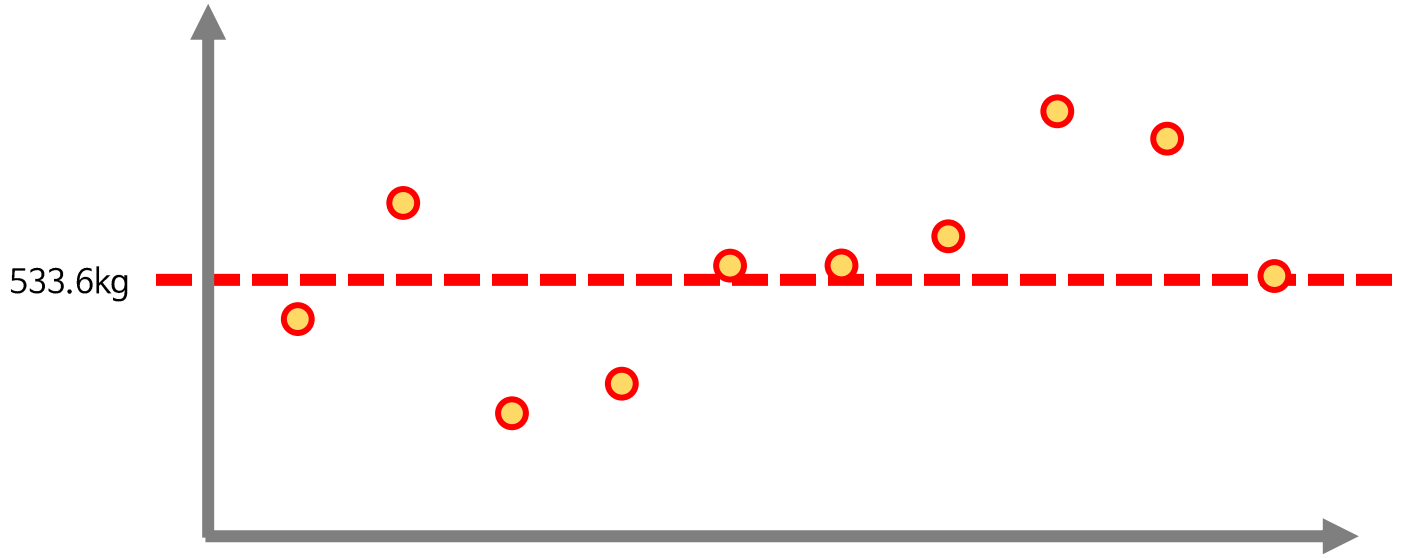
신박AI

이를 통해 해마다 특정 기간 내의 수확량의 변동이 얼마나 큰지 파악할 수 있었죠.



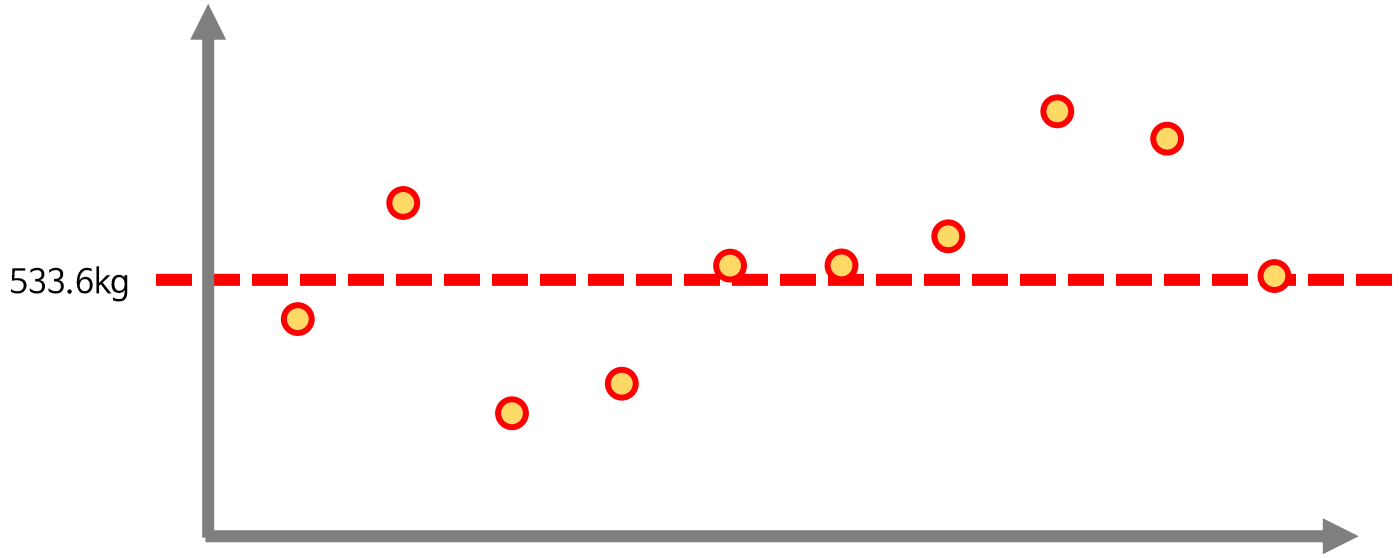
신박AI

이를 통해 해마다 특정 기간 내의 수확량의 변동이 얼마나 큰지 파악할 수 있었죠.



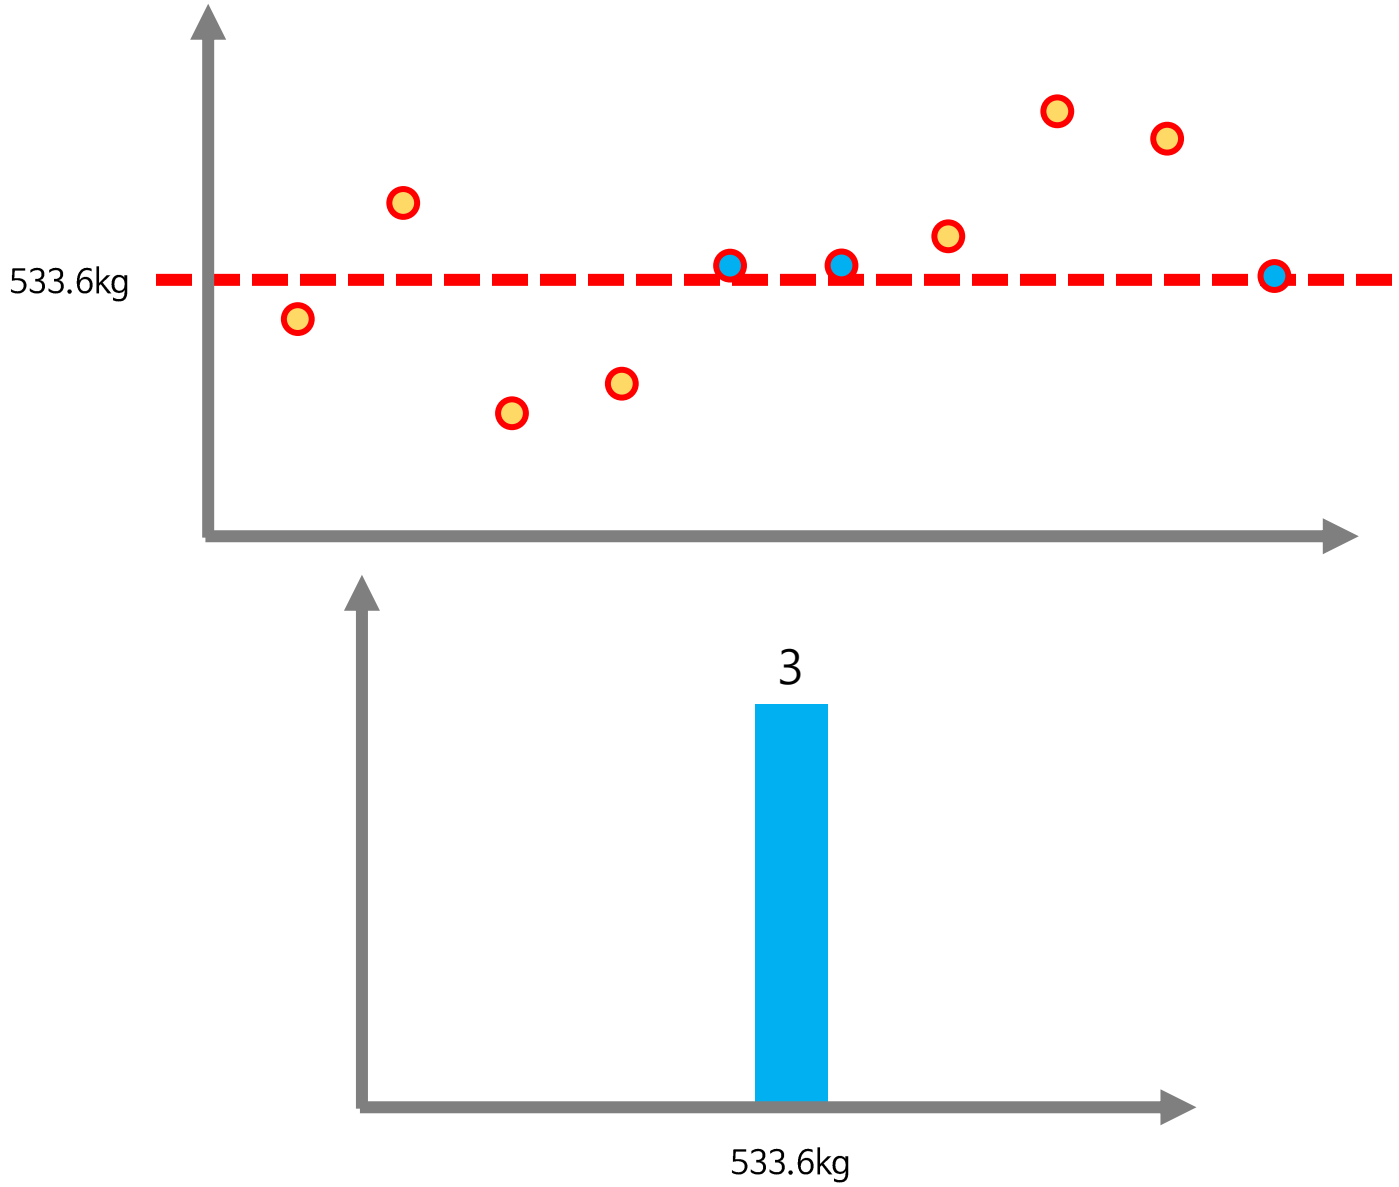
신박AI

그리고 가만히 수확량을 바라보다보니..



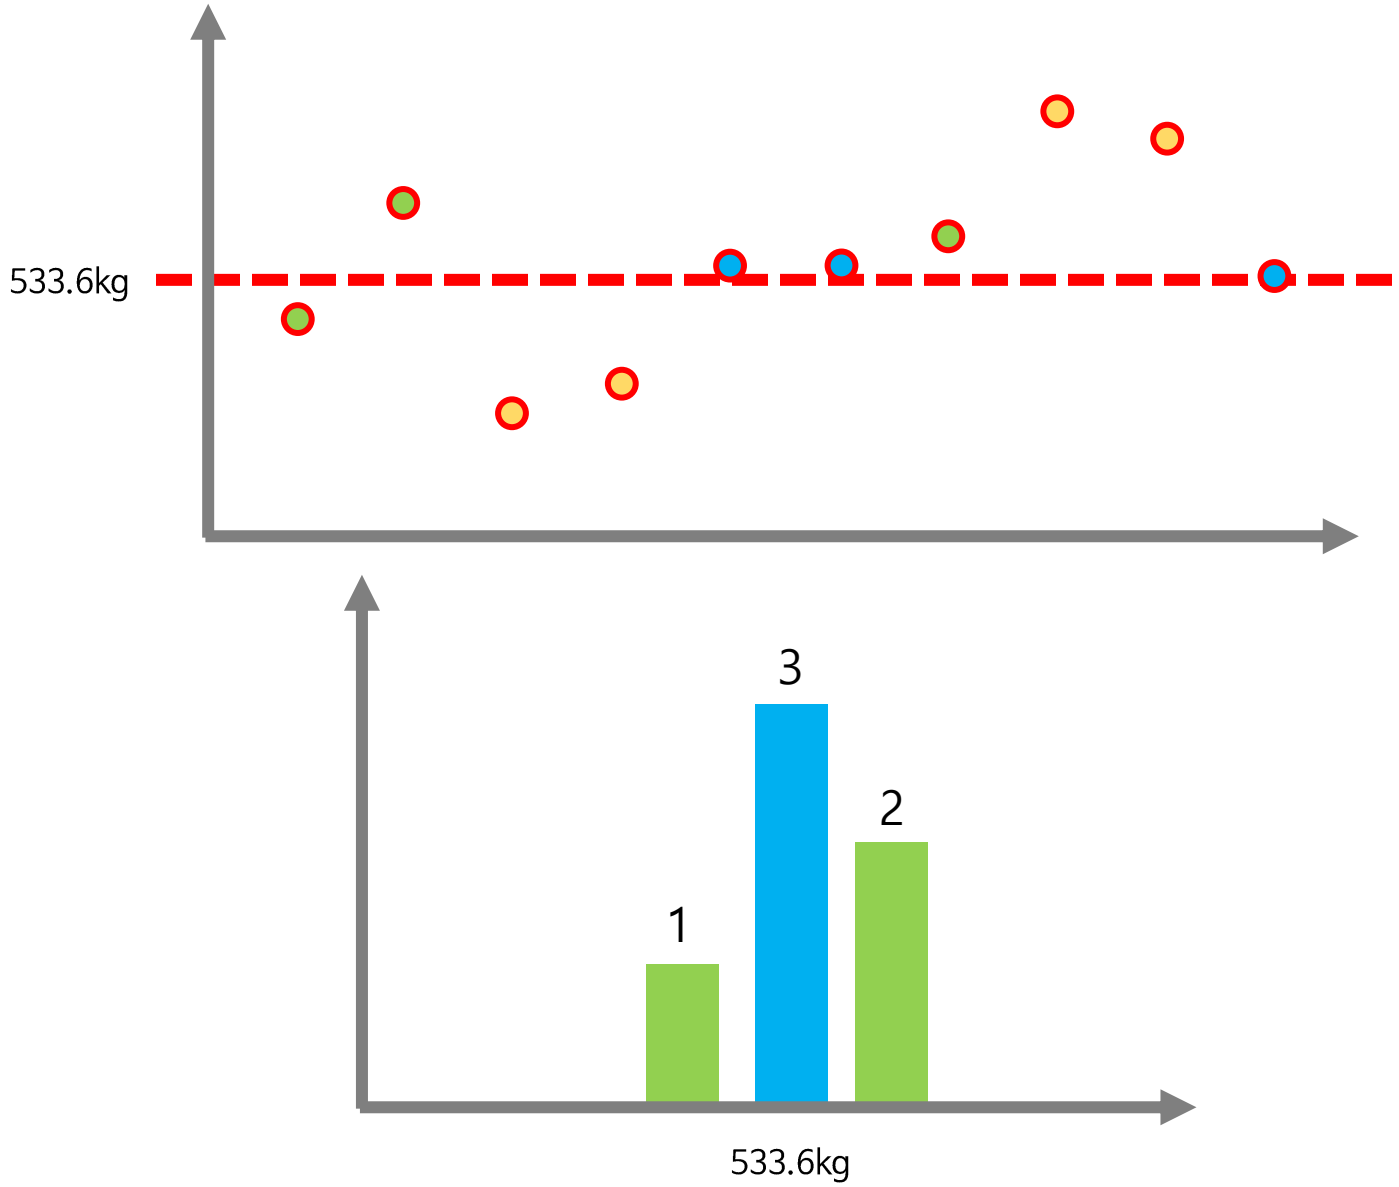
신박AI

평균에 가까운 수확량들이 제일 많고,



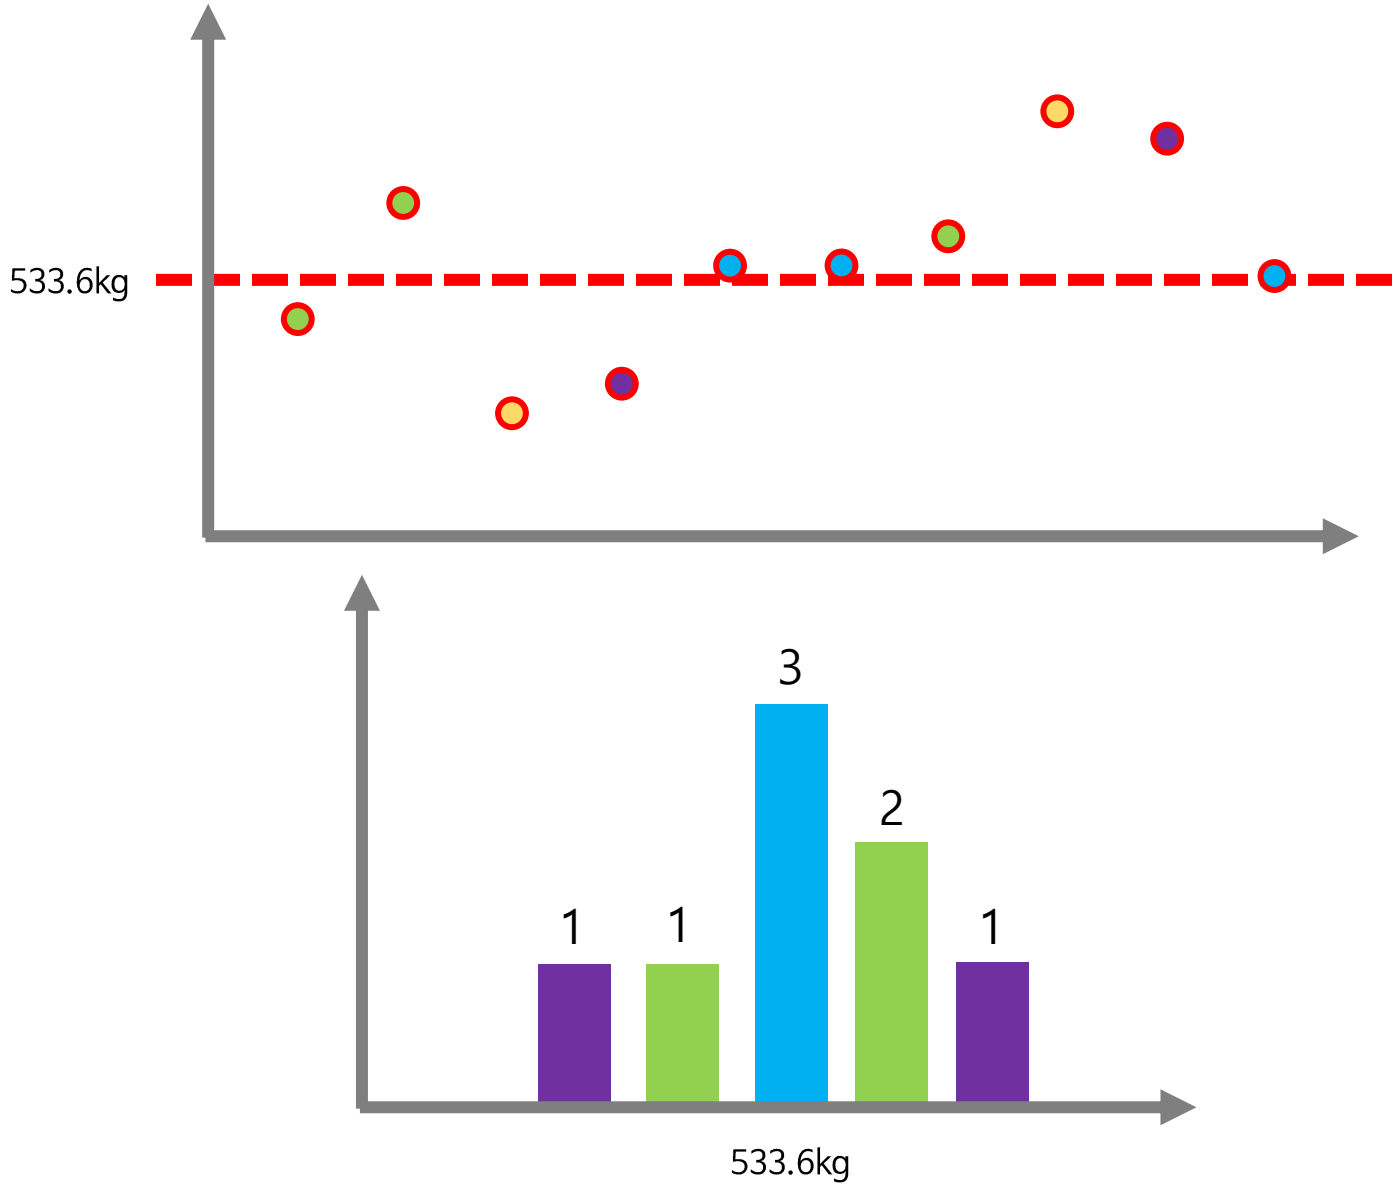
신박AI

평균에서 멀어질수록 그 빈도수가 줄어드는 경향을 발견하였습니다



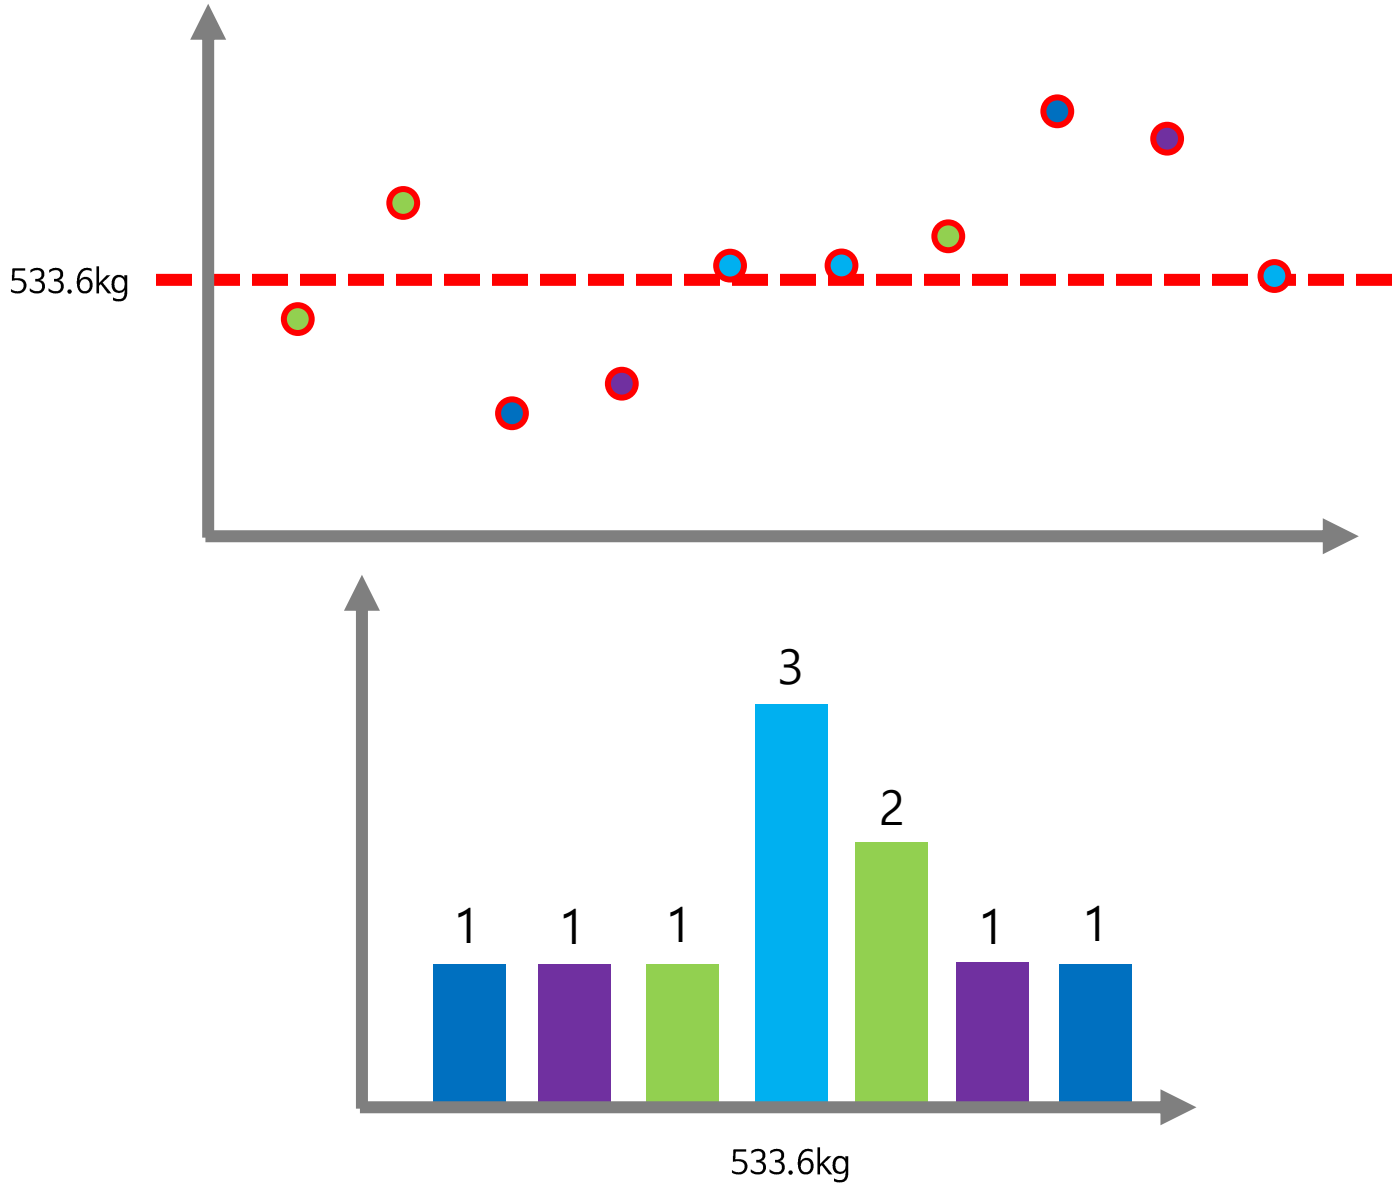
신박AI

평균에서 멀어질수록 그 빈도수가 줄어드는 경향을 발견하였습니다



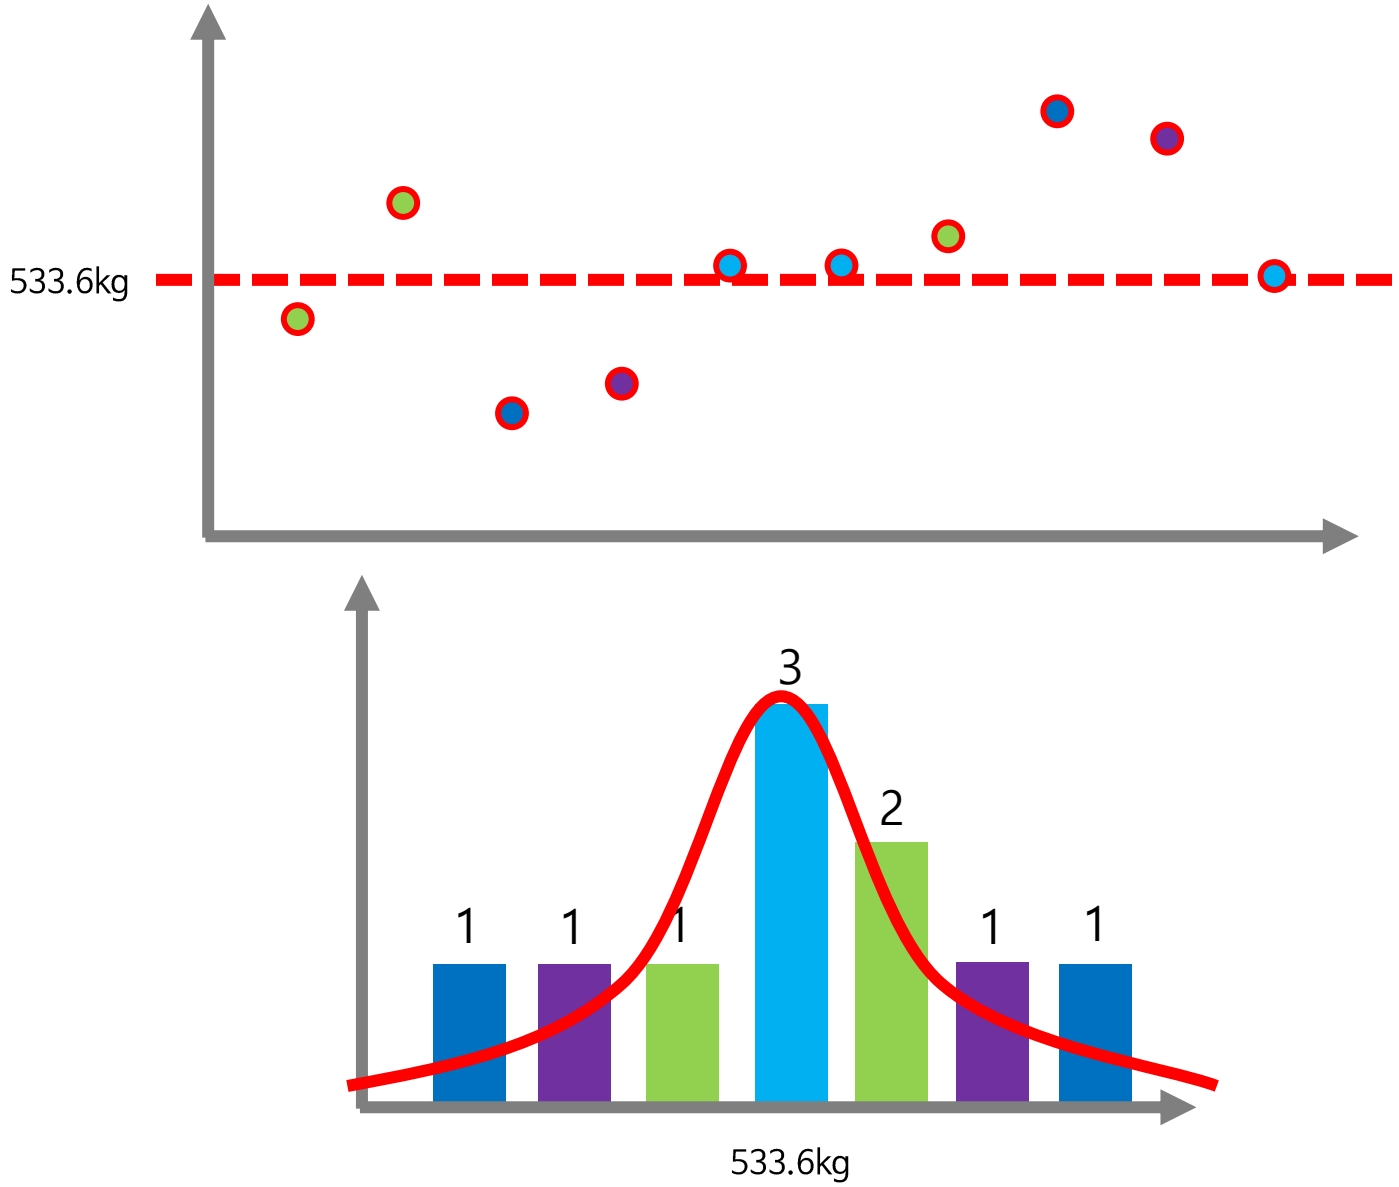
신박AI

평균에서 멀어질수록 그 빈도수가 줄어드는 경향을 발견하였습니다



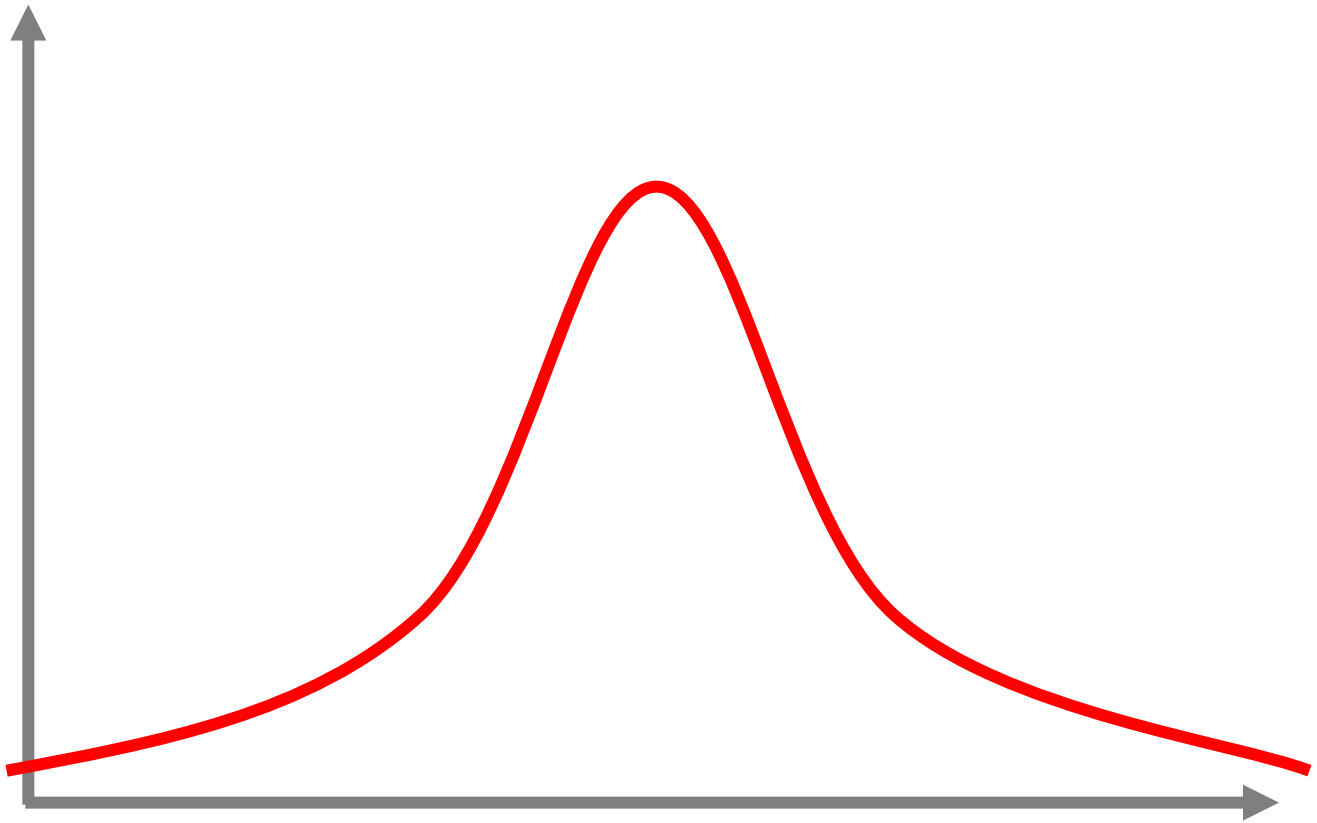
신박AI

그의 관찰 결과, 수확량의 분포가 종 모양을 이루는 것을 발견했습니다.



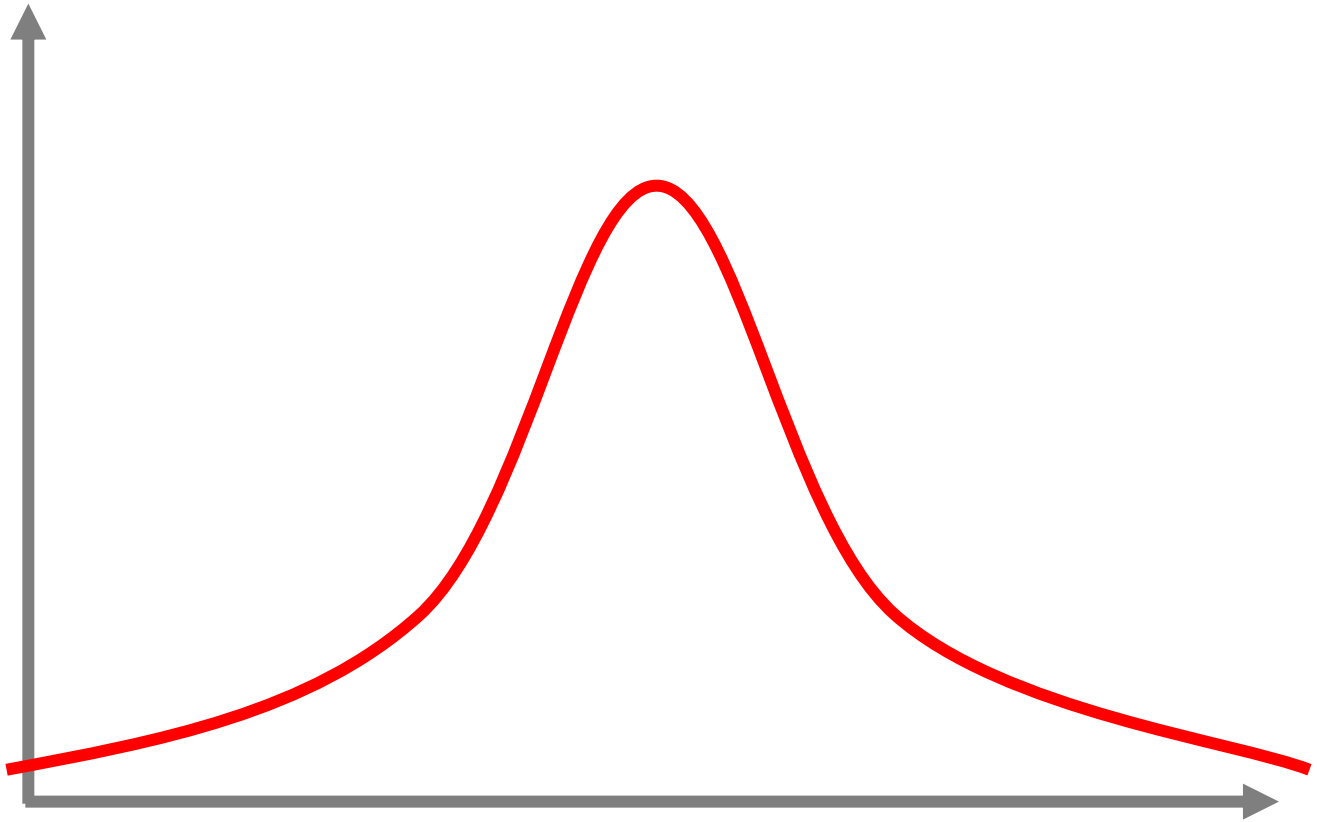
신박AI

그의 관찰 결과, 수확량의 분포가 종 모양을 이루는 것을 발견했습니다.



신박AI

이는 바로 정규분포였죠.



신박AI

정규분포에서는 평균을 중심으로 대칭적으로 값들이 분포하며, 평균에서 멀어질수록 빈도가 줄어듭니다.



신박AI

많은 자연 현상이 이러한 분포를 따른다는 것도 알게 되었습니다.



사람의 키와 몸무게

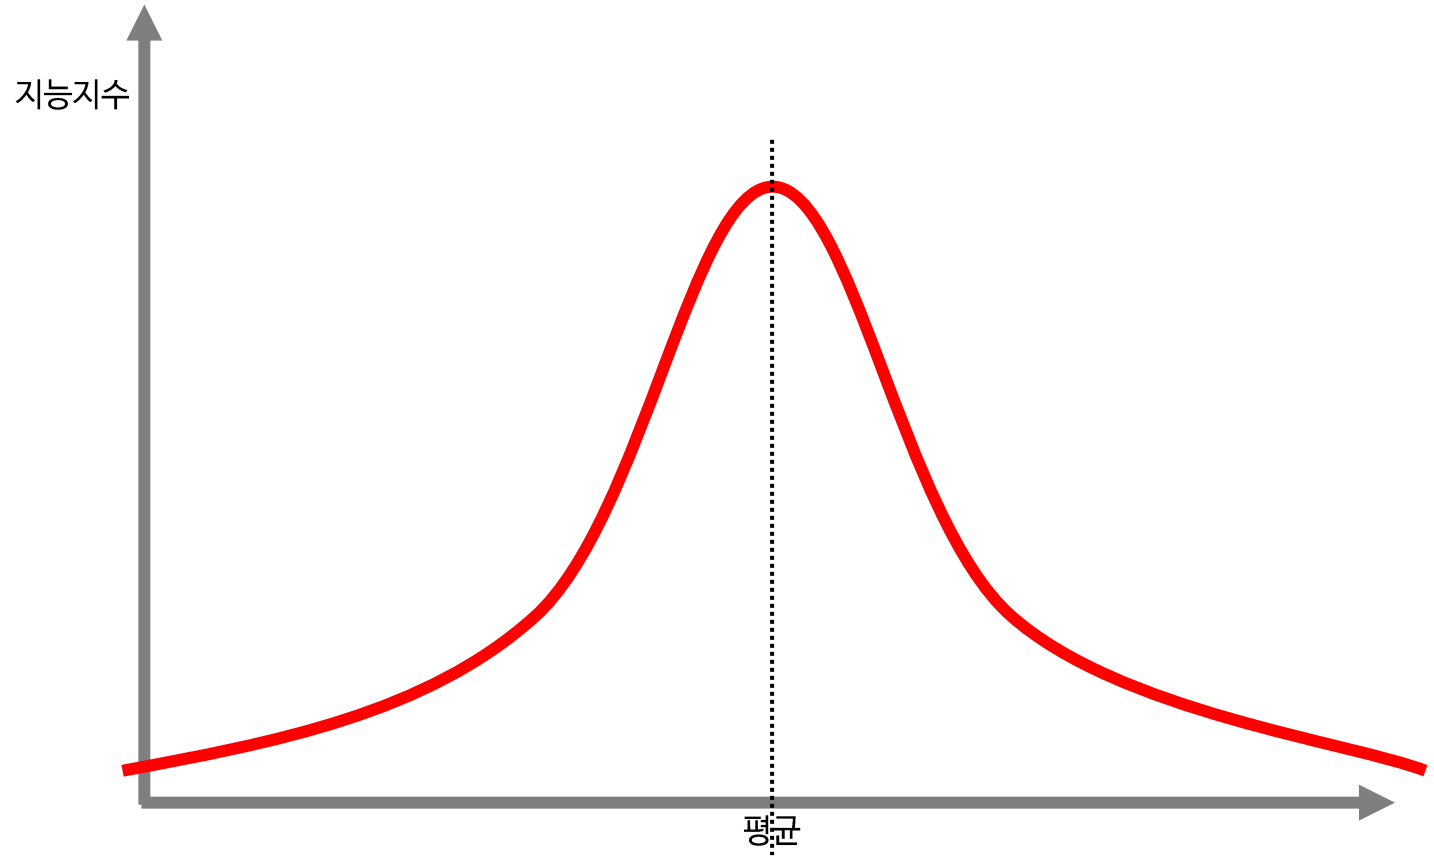
신박AI

많은 자연 현상이 이러한 분포를 따른다는 것도 알게 되었습니다.



신박AI

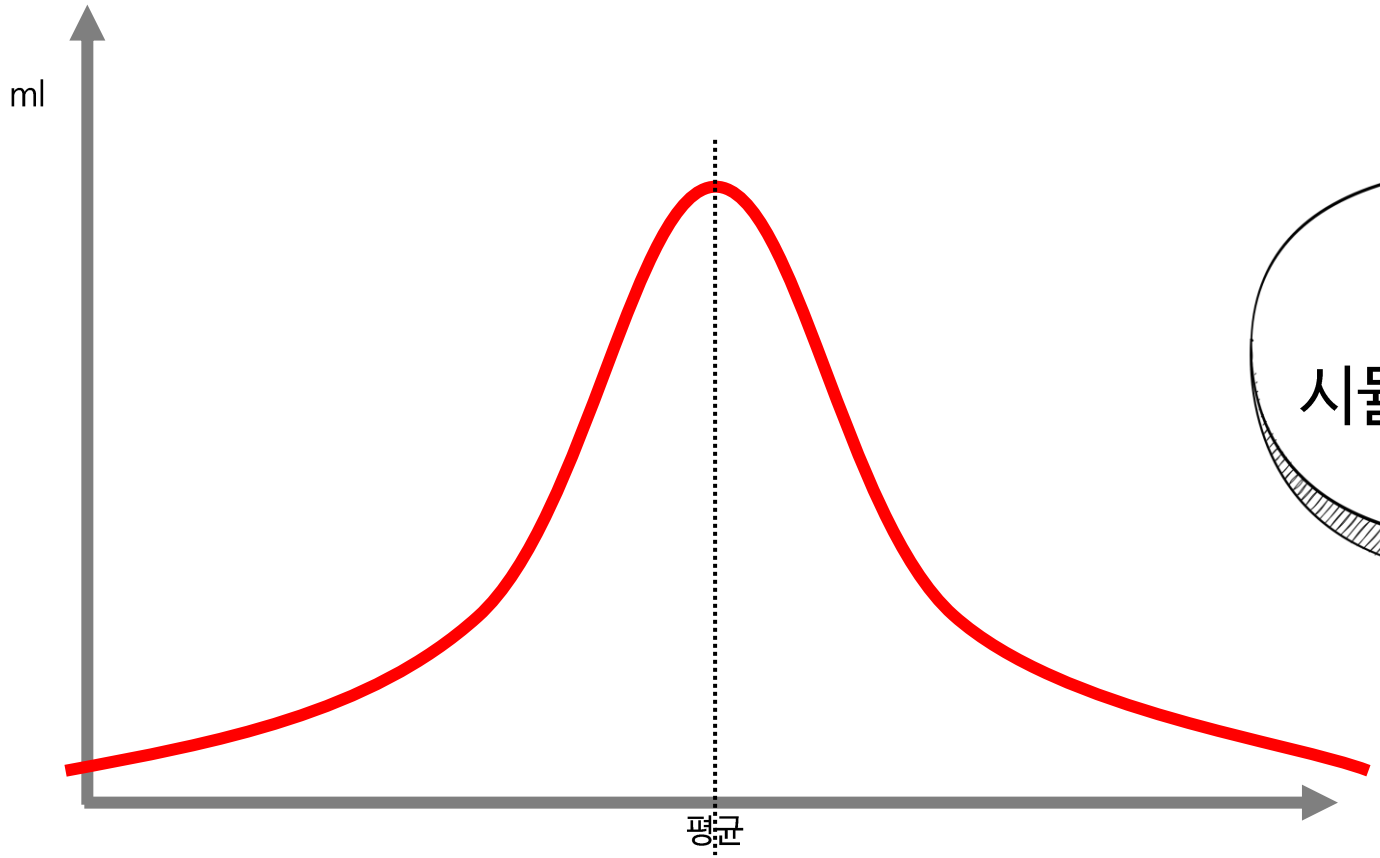
많은 자연 현상이 이러한 분포를 따른다는 것도 알게 되었습니다.



IQ (지능지수)

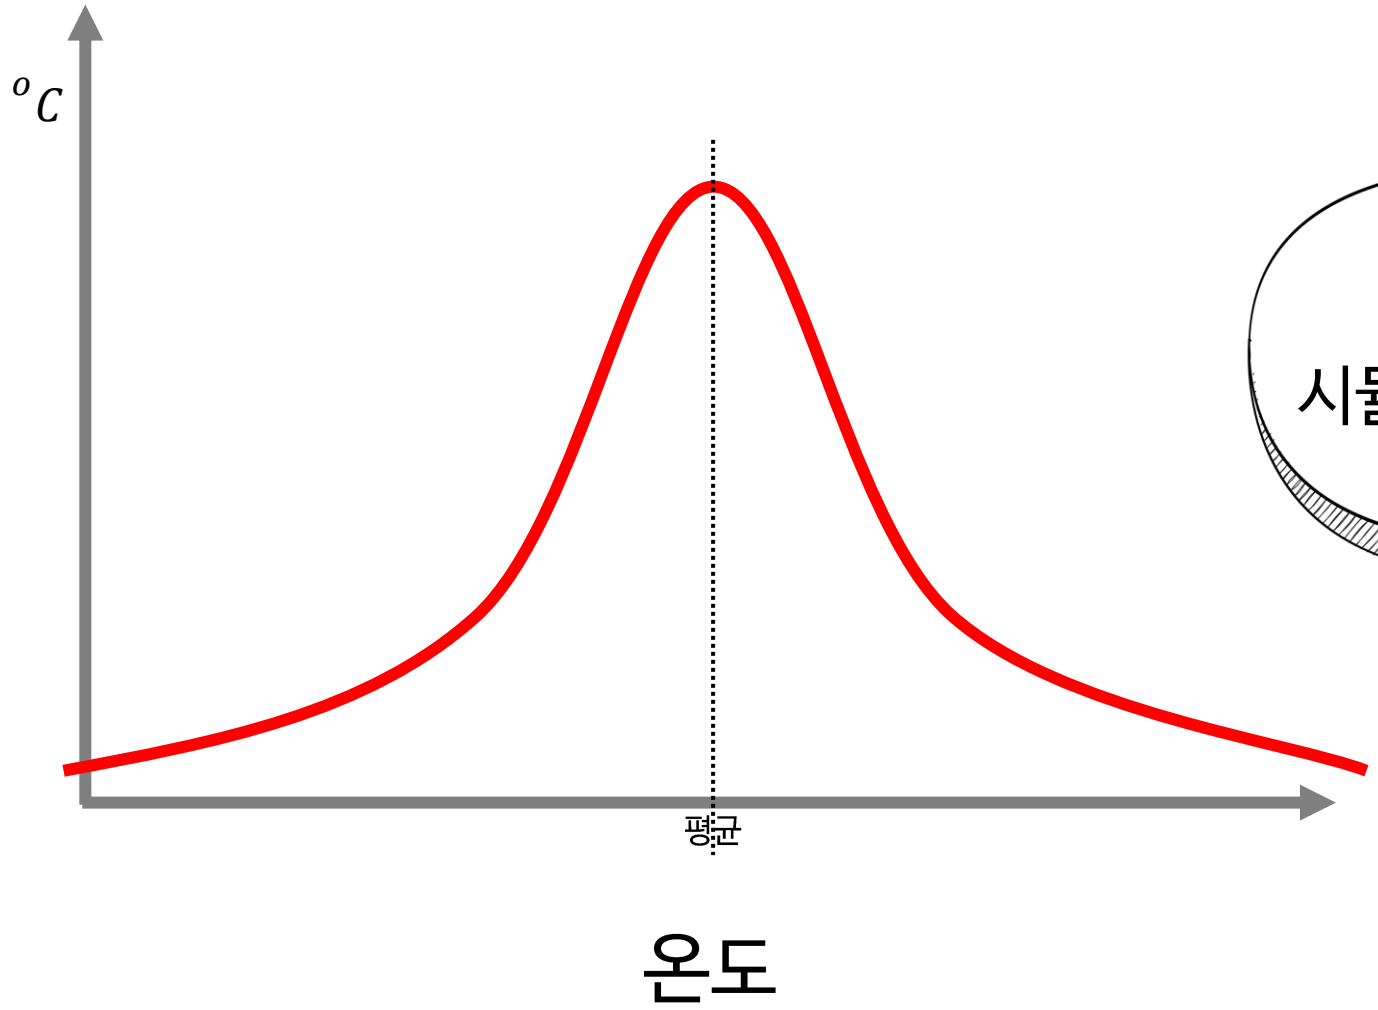
신박AI

많은 자연 현상이 이러한 분포를 따른다는 것도 알게 되었습니다.



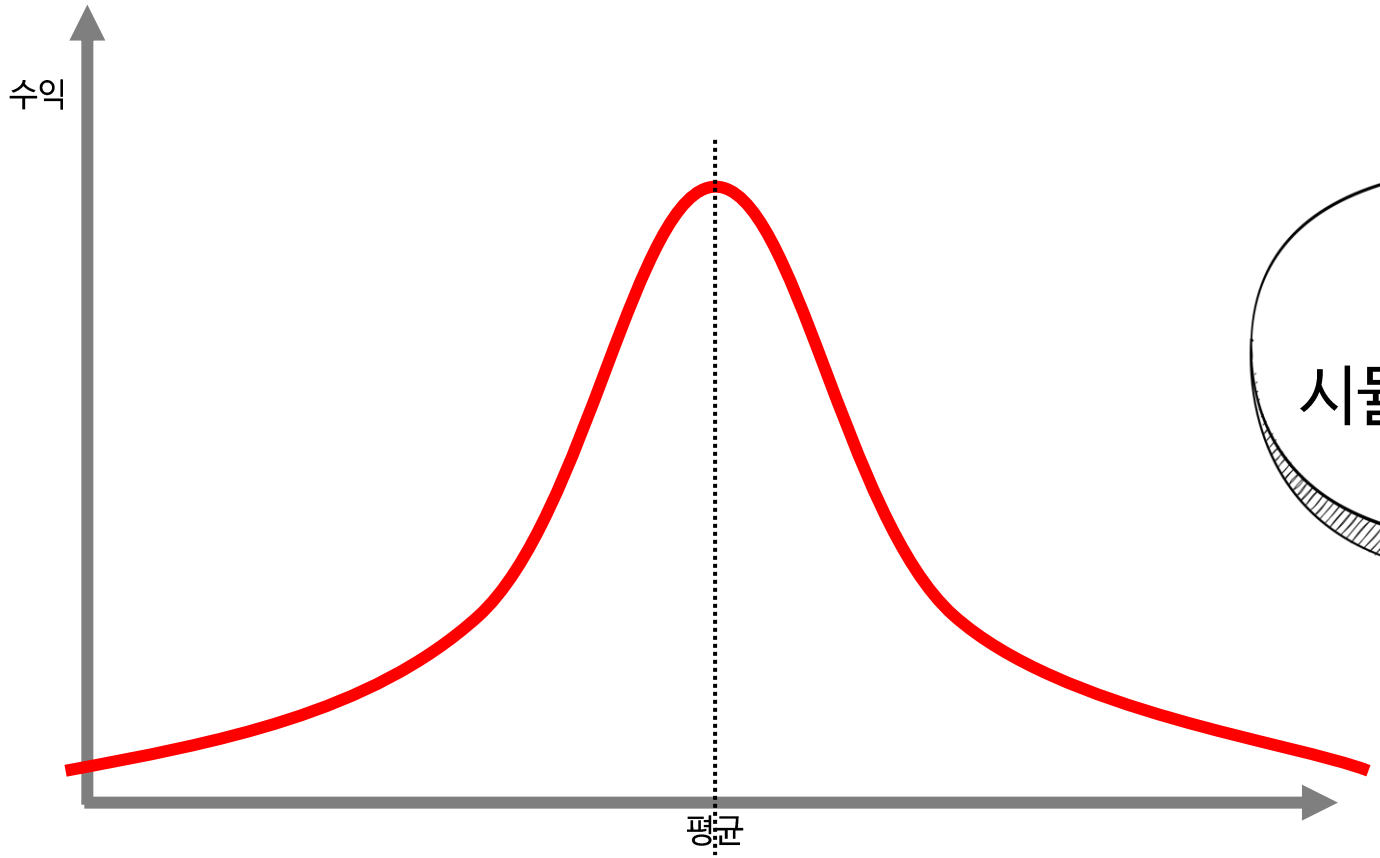


많은 자연 현상이 이러한 분포를 따른다는 것도 알게 되었습니다.





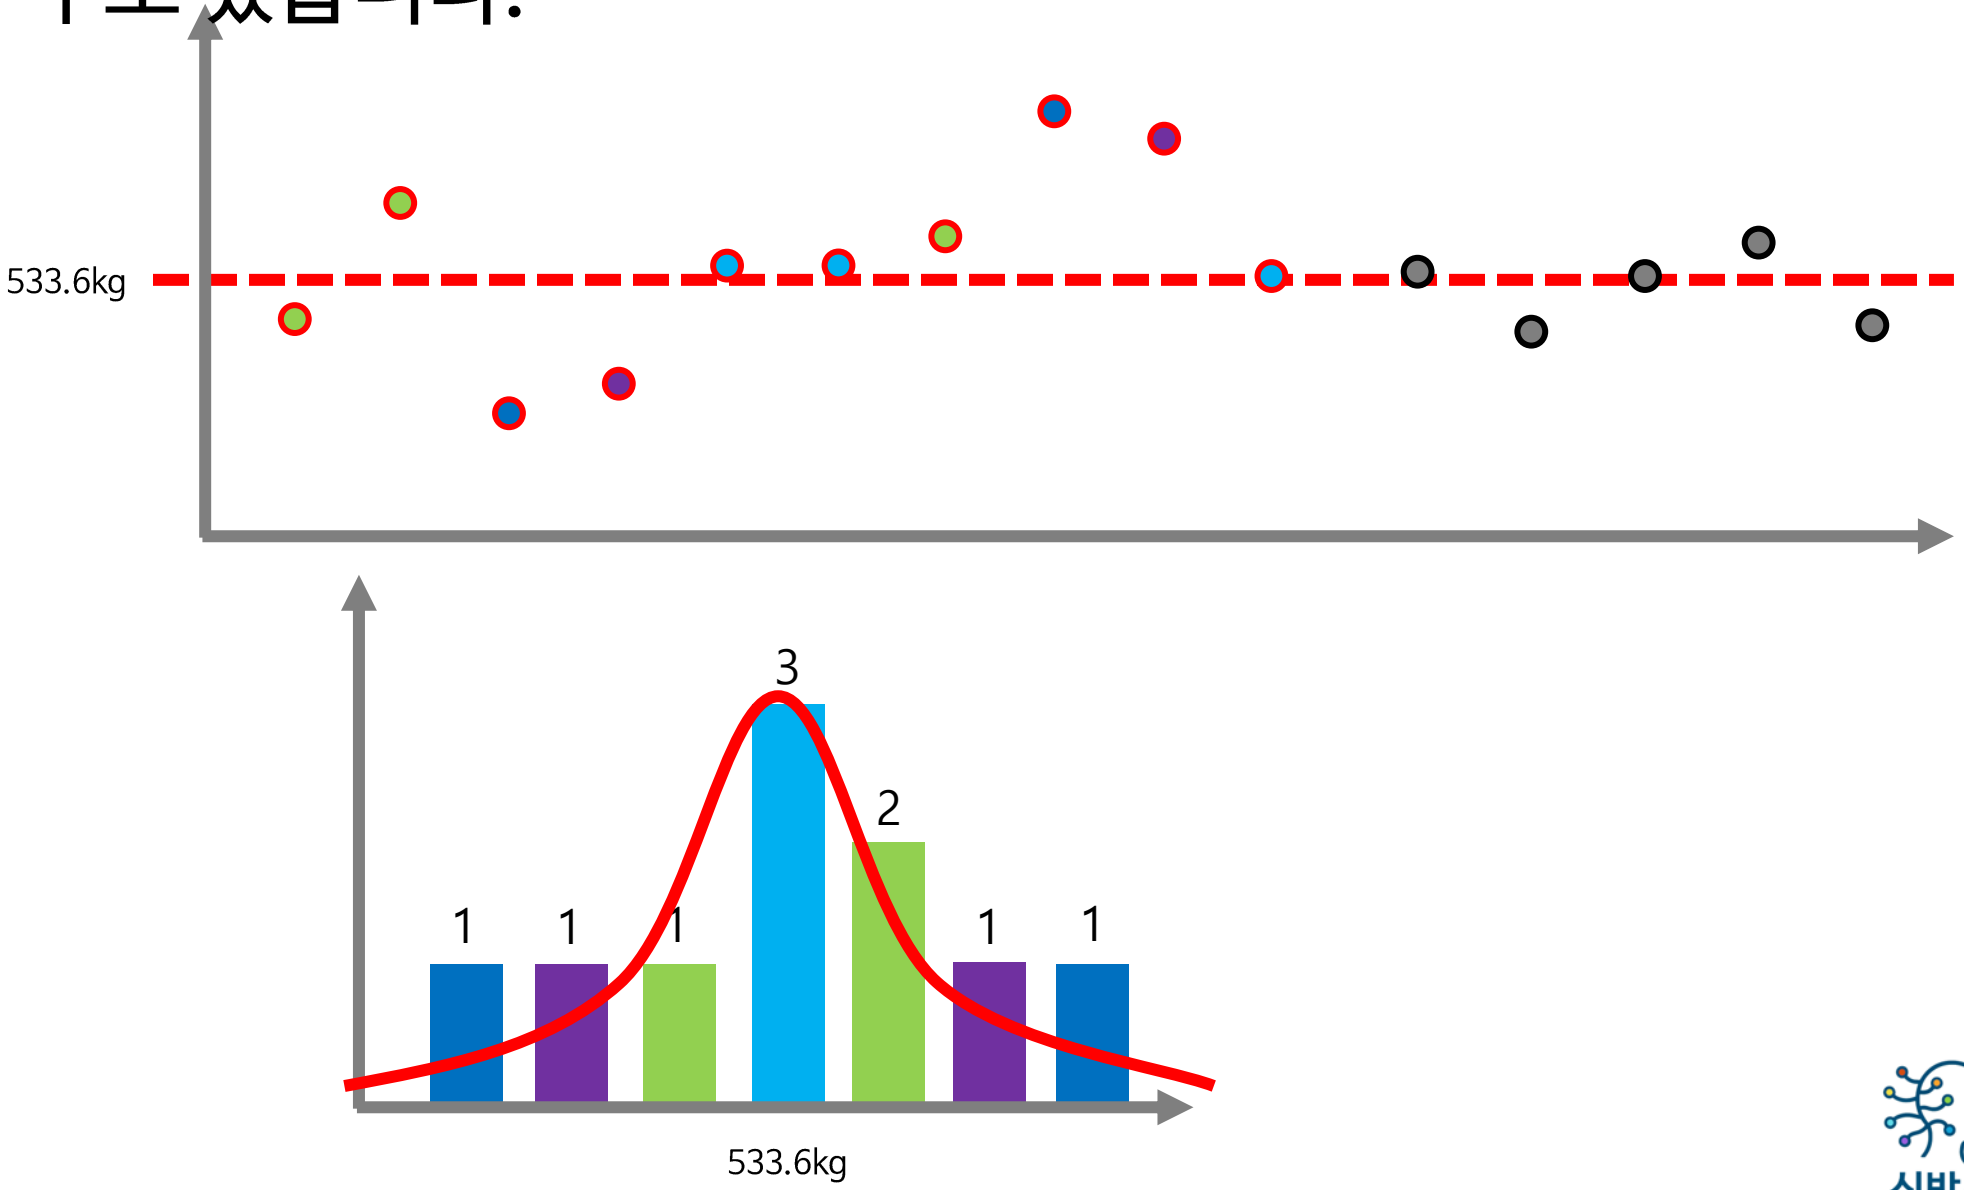
많은 자연 현상이 이러한 분포를 따른다는 것도 알게 되었습니다.



주식 시장의 일일 수익률



이로써 향후에 수확량도 자연스레 평균 근처에서 나올 확률이 더 높다는 것을 '예측' 할 수도 있습니다.



그리고 농부는 계속해서 이 수확량이라는 변수에 영향을 미칠 수 있는 여러 가지 요인들을 생각해보았습니다.

수확량은 왜 매년 다른걸까?



수확량에 미치는 요인은 뭘까?

어떻게 하면 수확량을 늘릴까? '

신박AI

날씨, 비료의 양, 씨앗의 질 등이 요인들이 될 수 있는데요,



강우량



비료의 양



씨앗 등급

신박AI

이러한 변수들을 독립변수라 부르고,







독립변수: 강우량 비료의 양 씨앗 등급

신박AI

이들의 영향을 받는 수확량을 종속변수라고 부릅니다.







독립변수: 강우량 비료의 양 씨앗 등급



종속변수: 수확량

신박AI

이들의 영향을 받는 수확량을 종속변수라고 부릅니다.

독립변수: 강우량 비료의 양 씨앗 등급

종속변수: 수확량

신박AI

여기서 중요한 개념이 등장합니다. 바로 독립변수와 종속변수의 구분입니다.

독립변수: 강우량 비료의 양 씨앗 등급

종속변수: 수확량

신박AI

독립변수란, 종속변수에 영향을 주는 변수이고,

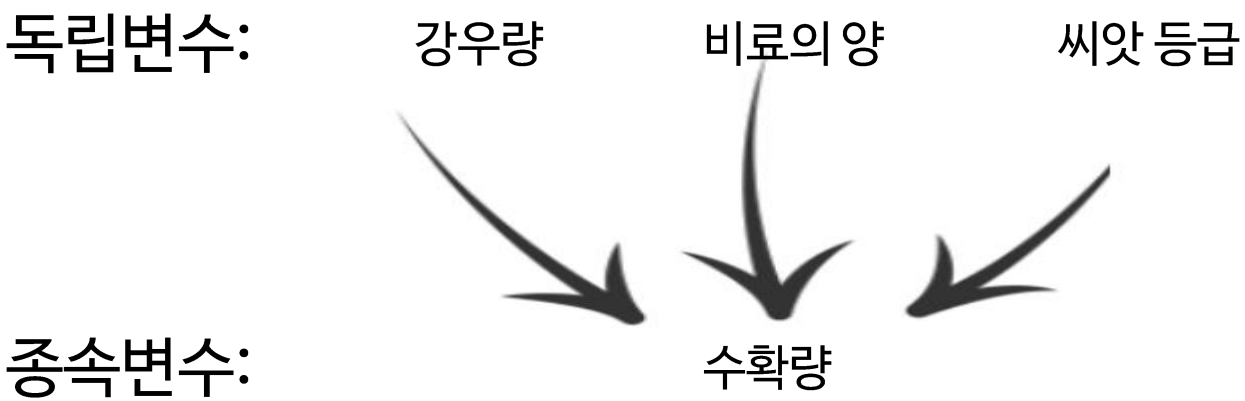
독립변수: 강우량 비료의 양 씨앗 등급



종속변수: 수확량

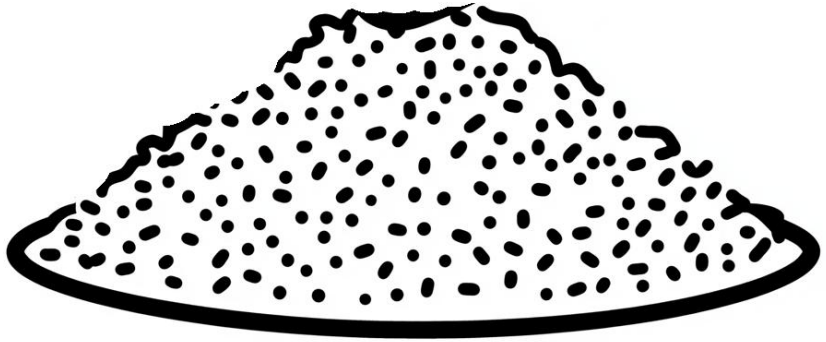
신박AI

종속변수란 독립변수를 조절할 때 그에 따라서 변화되는 변수를 말합니다.

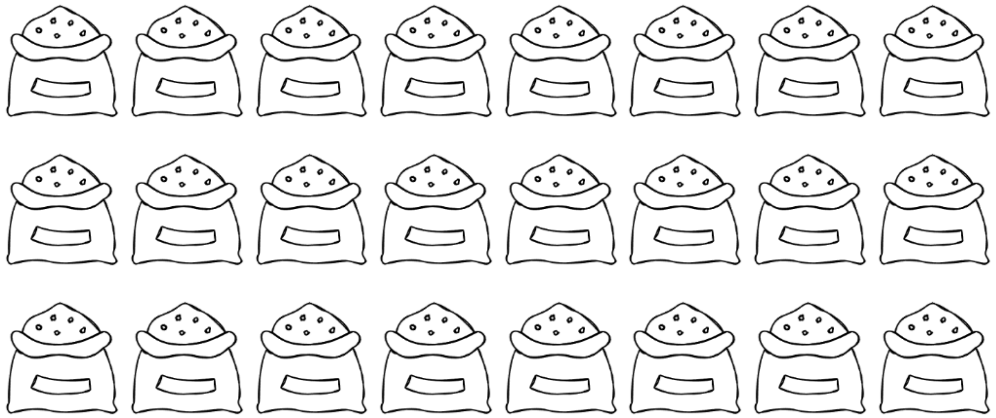


신박AI

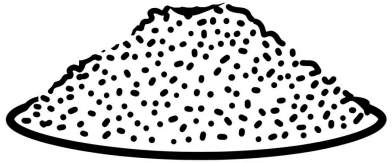
예를 들어, 농부가 비료의 양(독립변수)을 조절하면 수확량(종속변수)이 변하는 것이죠.



비료를 많이 주면..



수확량이 많고..



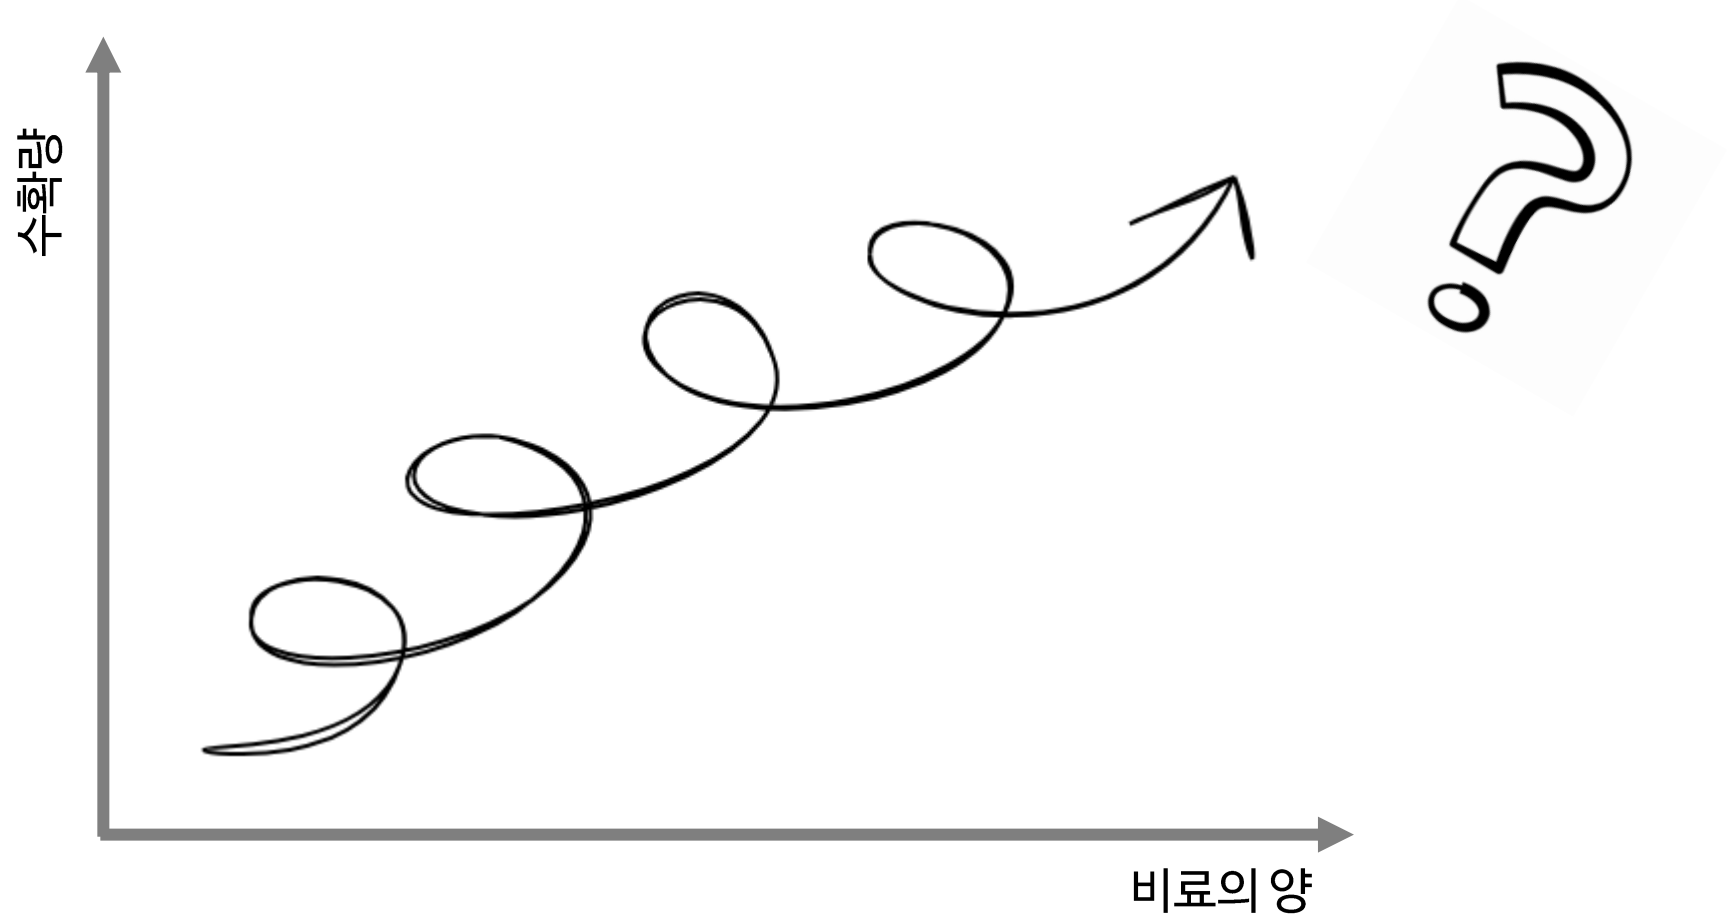
비료를 작게 주면..



수확량이 작지 않을까?

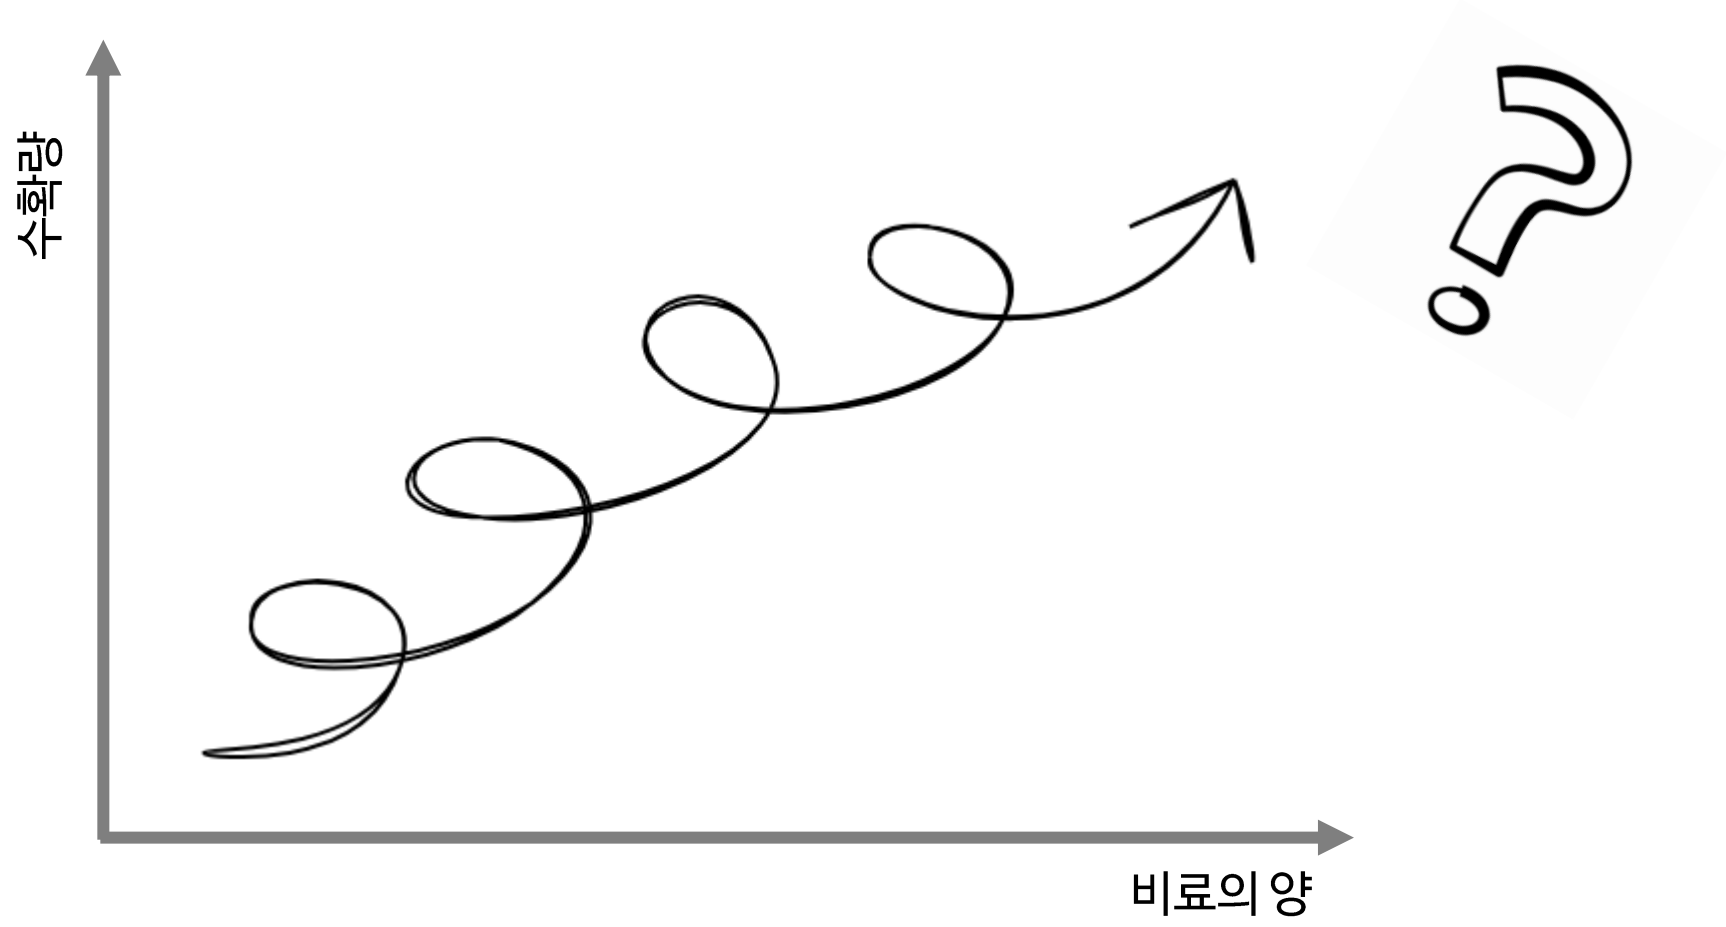
신박AI

그래서 농부는 비료의 양과 수확량 사이의 관계가 궁금해졌습니다.



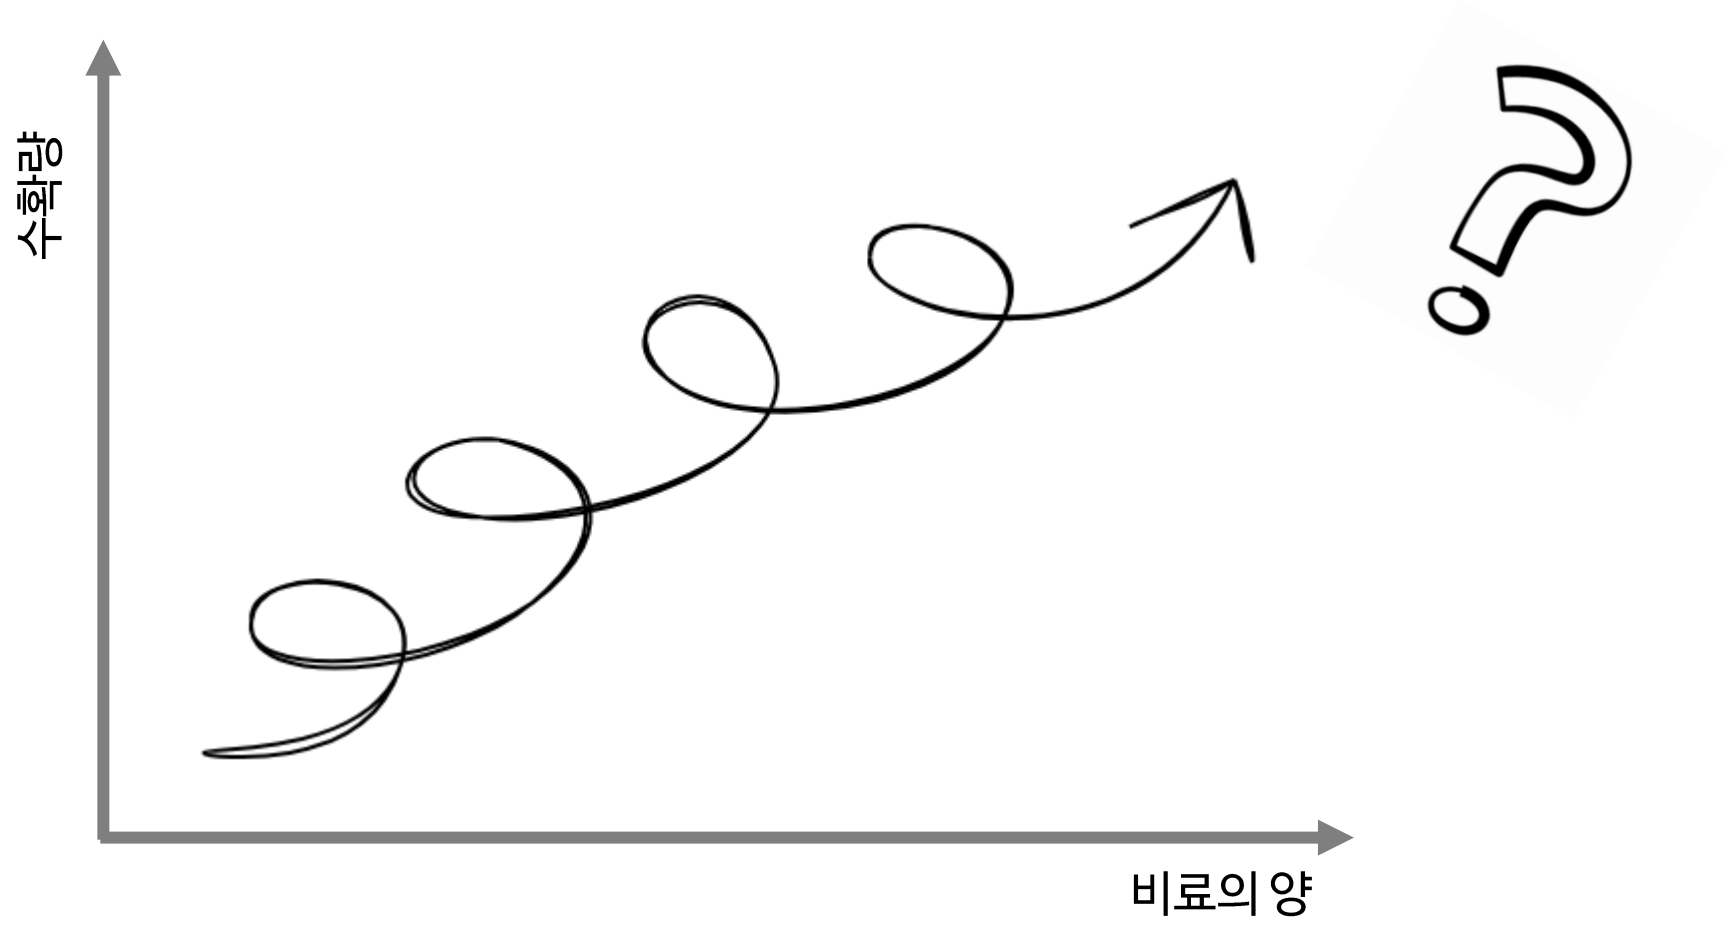
신박AI

두 변수 간의 상관관계를 분석해보니, 비료를 많이 줄수록 수확량이 증가하는 경향이 있었습니다.



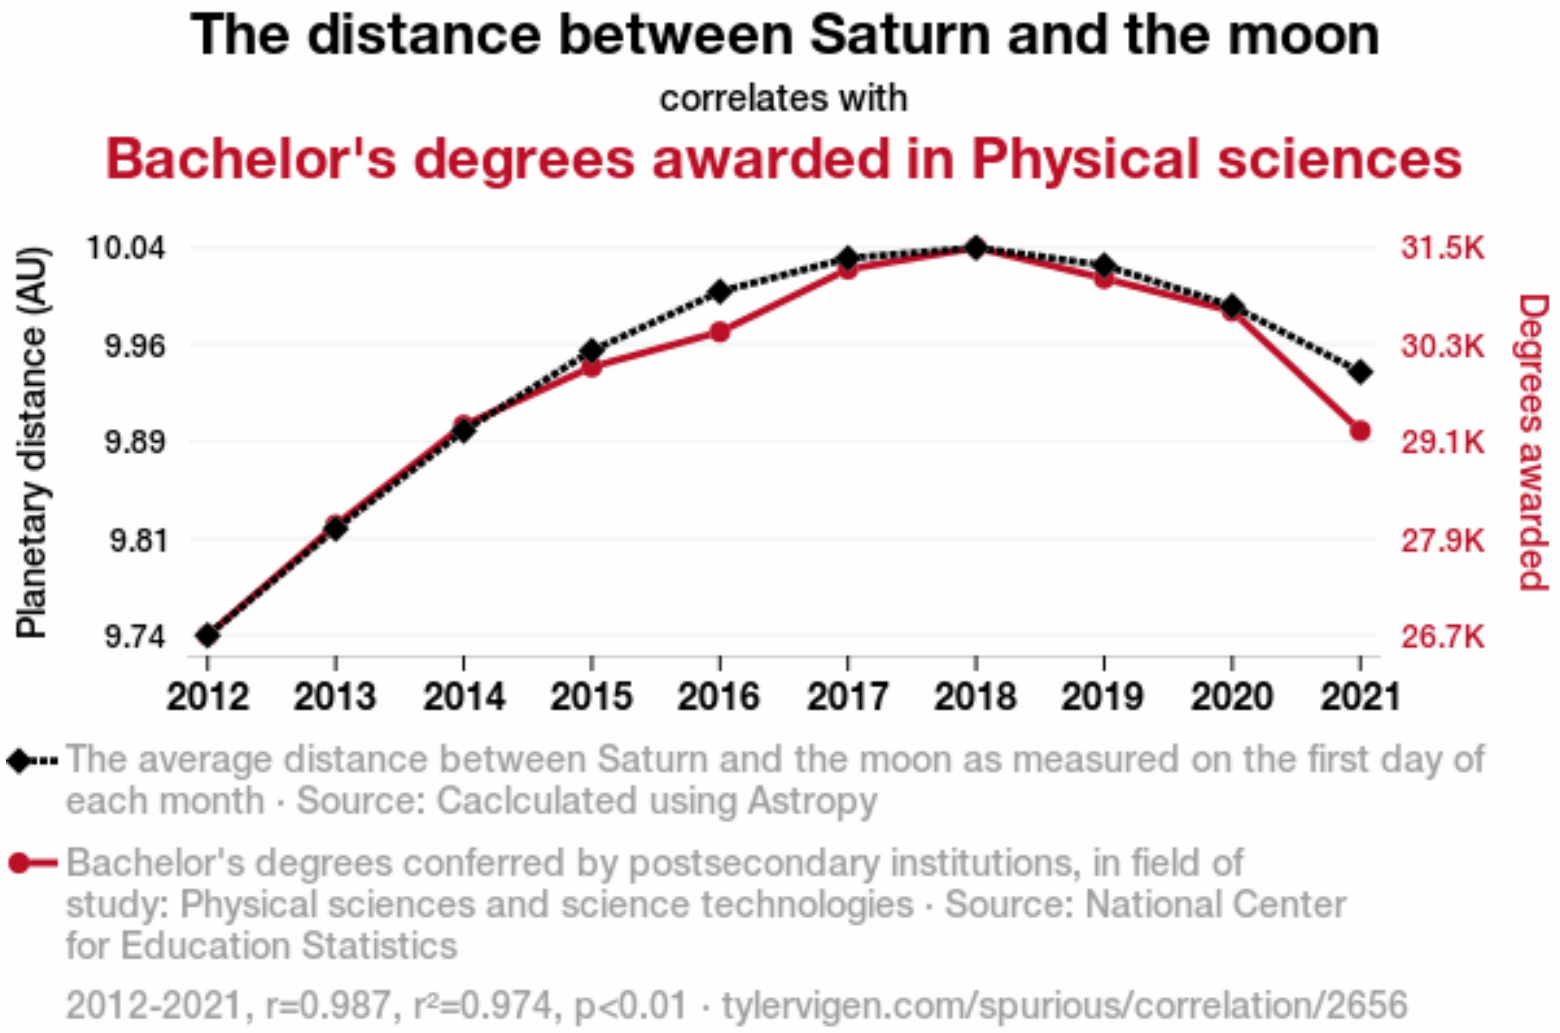
신박AI

하지만 그는 '상관관계가 곧 인과관계는 아니다'라는 점을 명심했습니다.



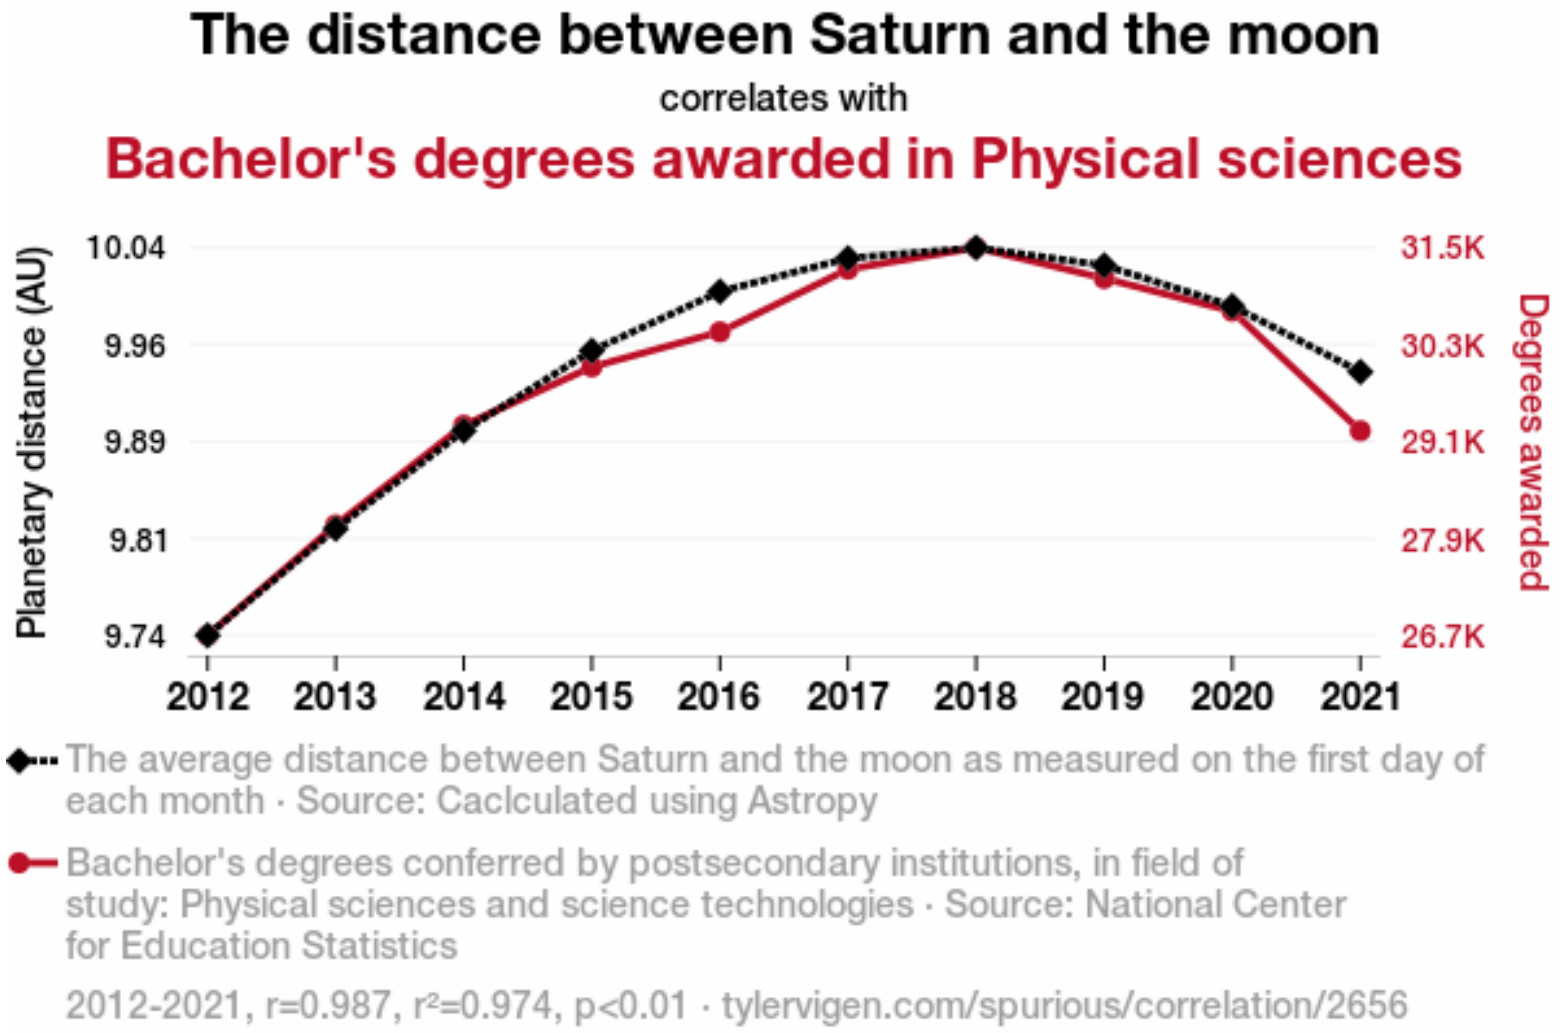
신박AI

예를 들어, 달-토성간 거리와 물리학 학사 졸업생수 사이에도 강력한 상관관계가 있지만,



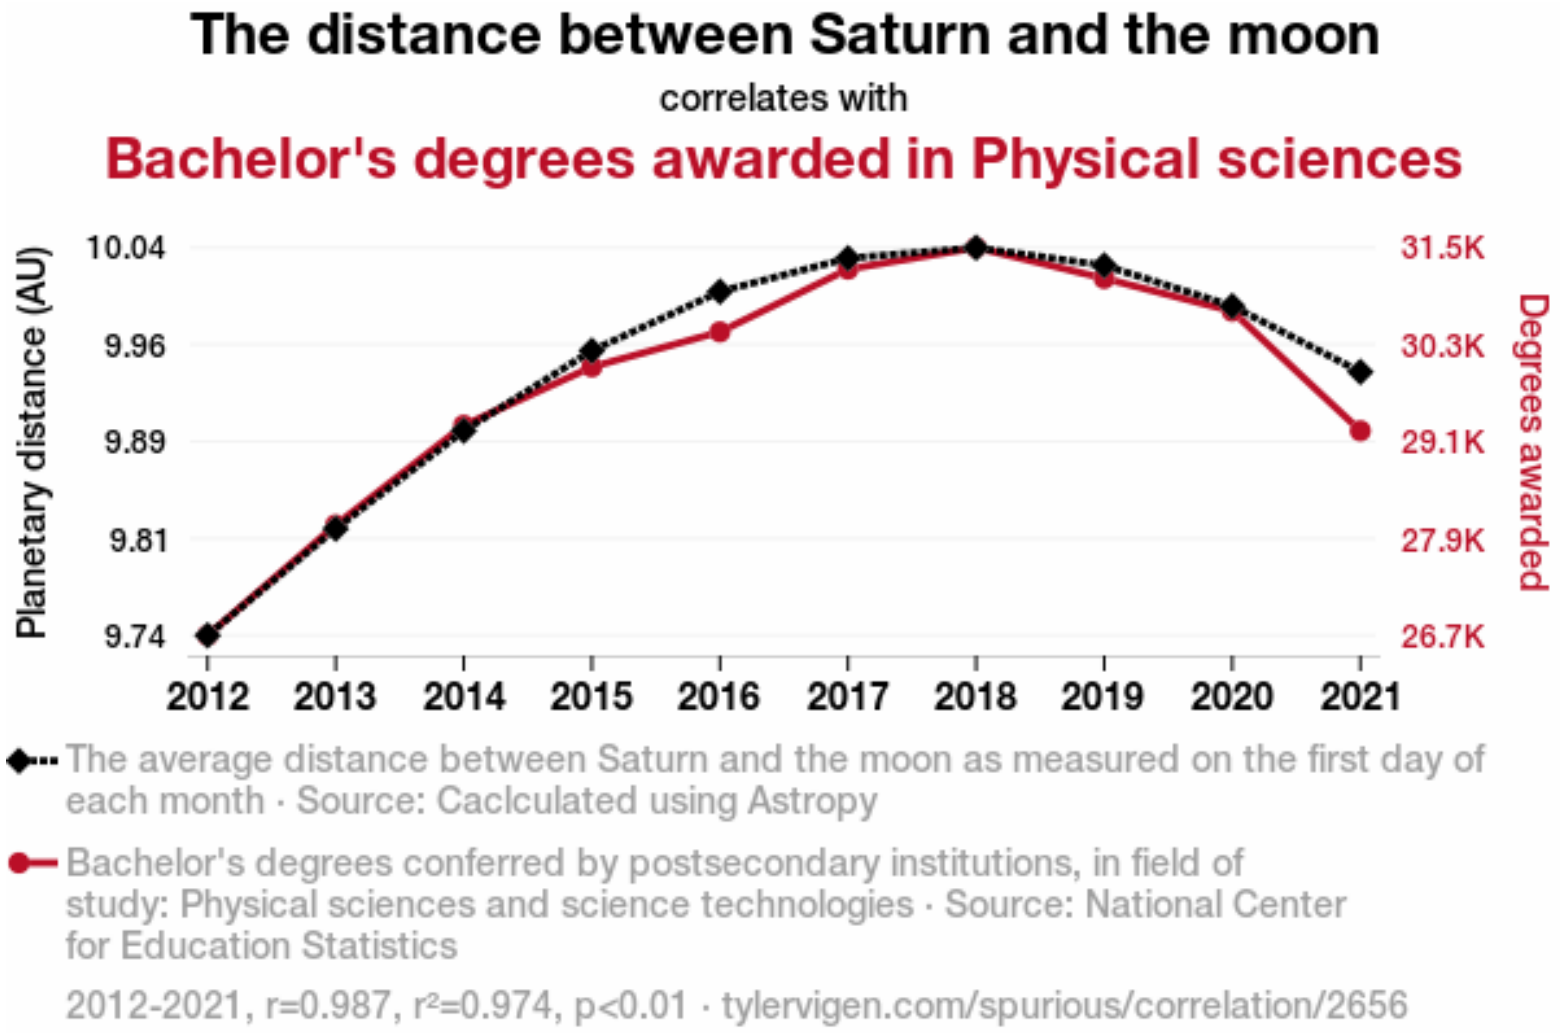
신박AI

이 사실을 두고, 토성과 달 사이의 중력 작용이 변동할 때, 그것이 학문적 영감의 우주적 파동을 만들어



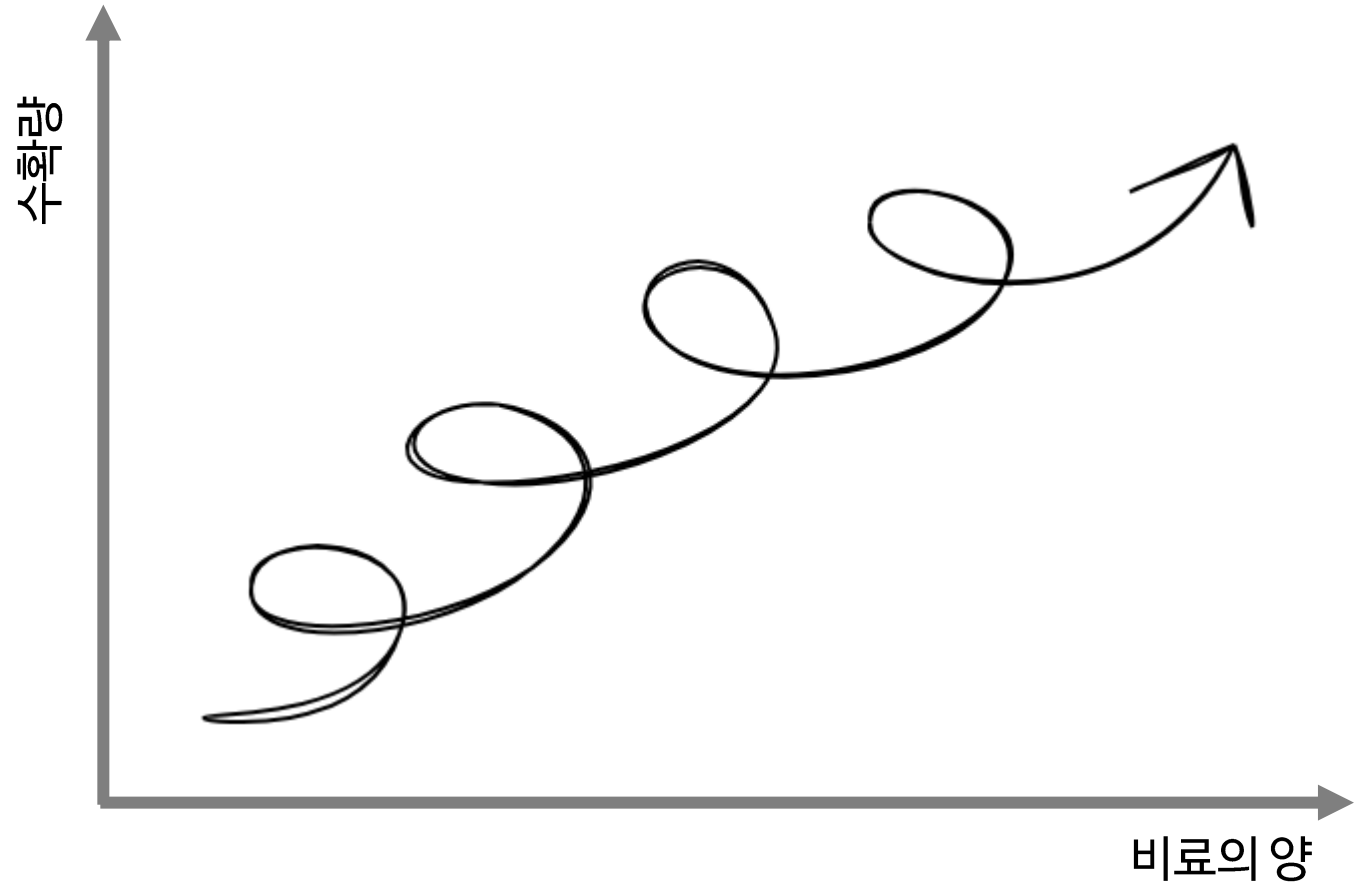
신박AI

지구상에 더 많은 학생들이 물리 과학과 과학 기술 분야의 학위를 추구하게 만든다고 생각하는 것은 비논리적입니다.



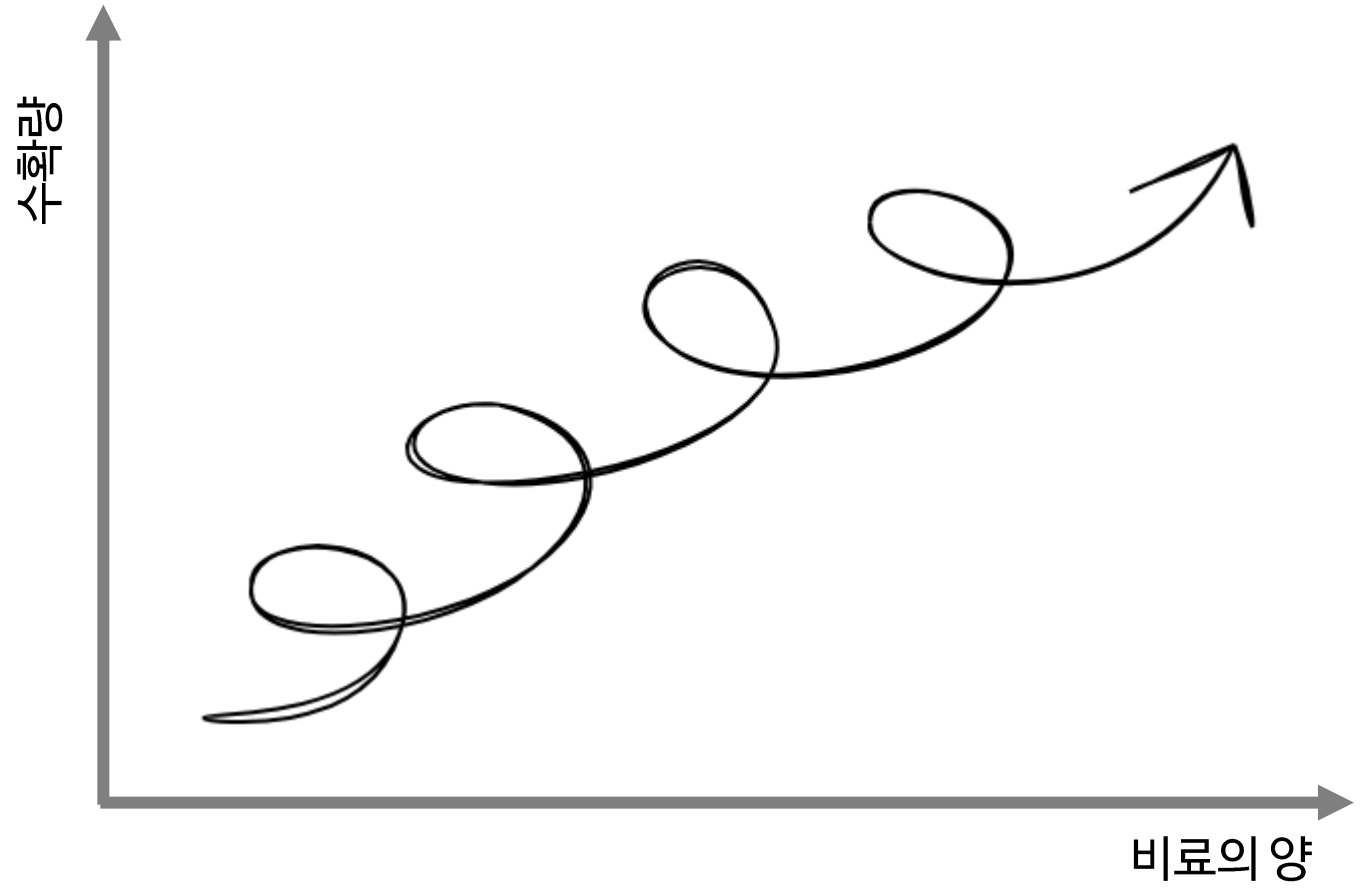
신박AI

이처럼 상관관계가 있다고 해서 반드시 직접적인 인과관계가 있는 것은 아닙니다.



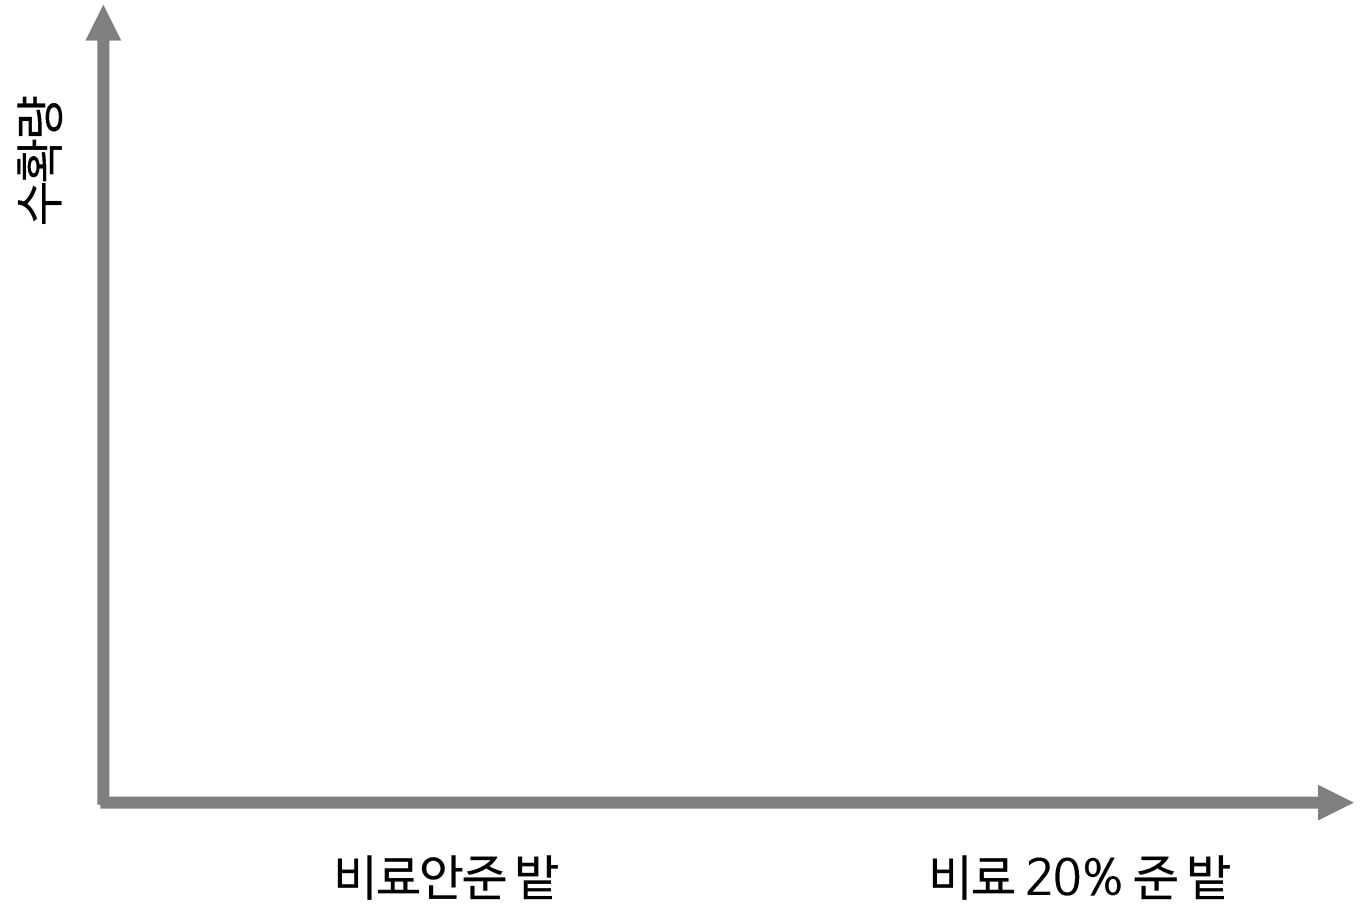
신박AI

그래서 농부는 비료의 양과 수확량간의 인과관계를 알기 위해서,



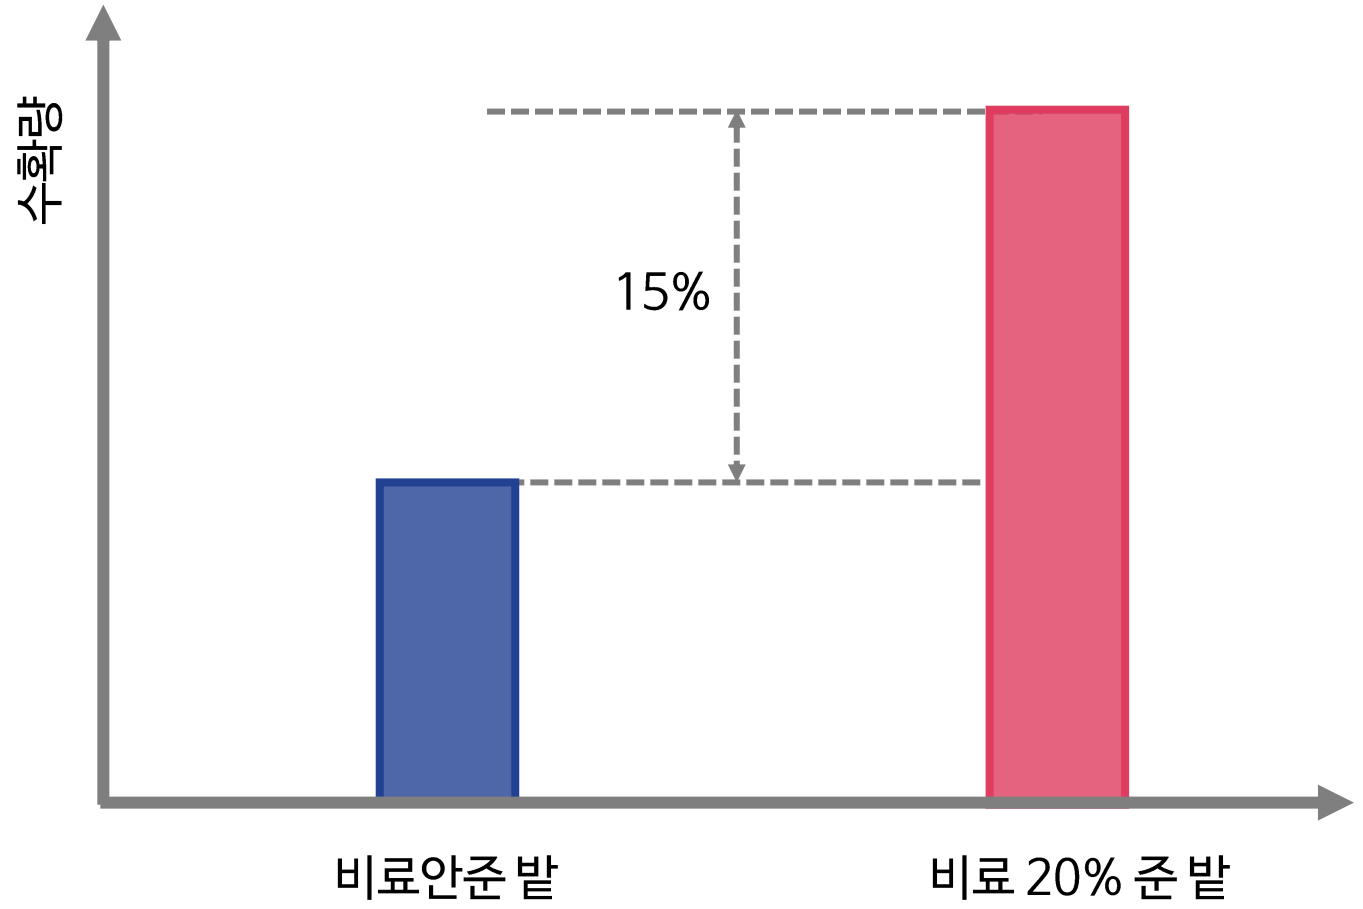
신박AI

농부는 엄정한 실험 절차에 착수하였고,



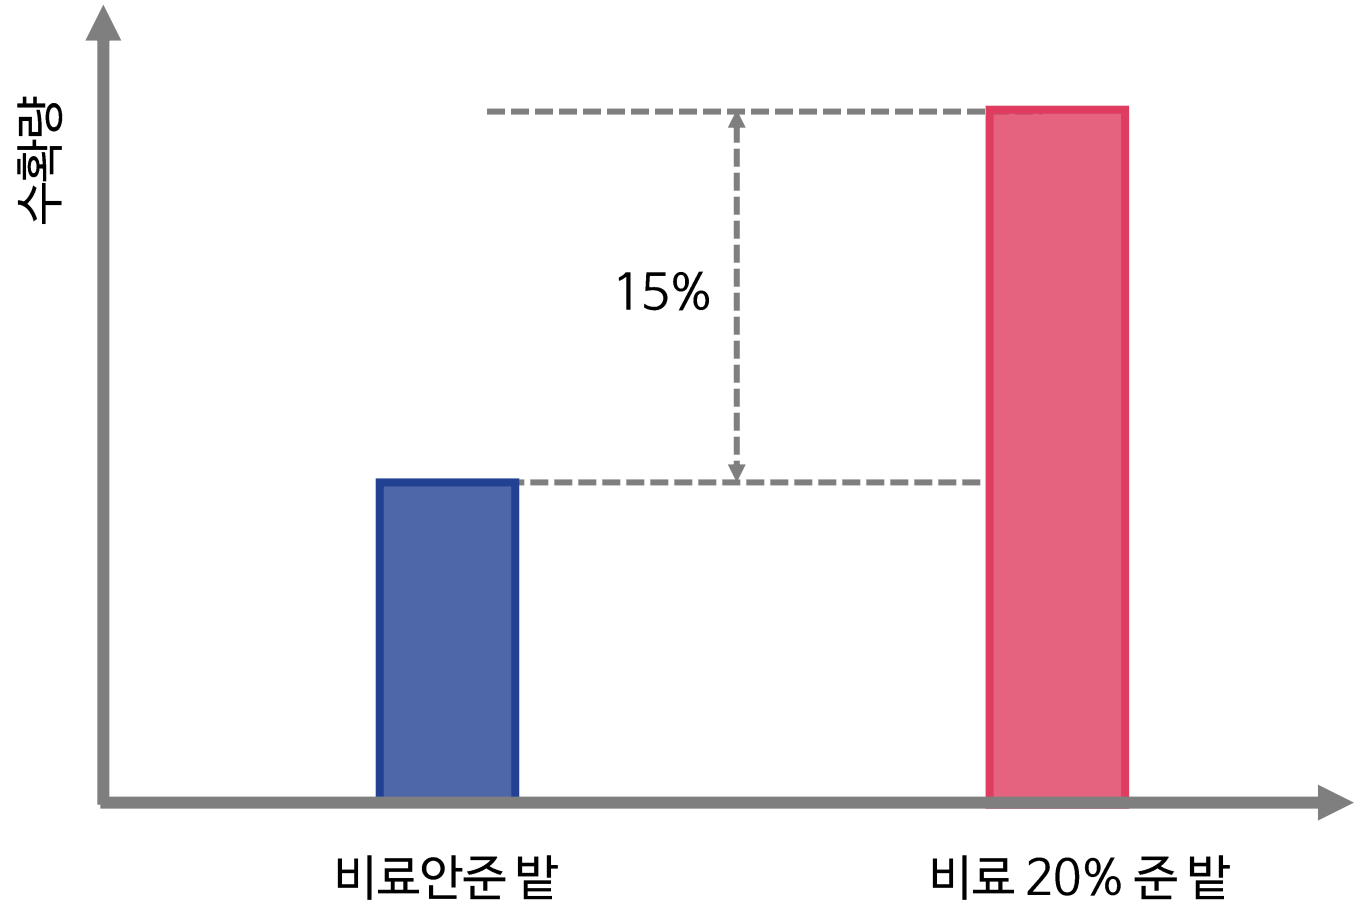
신박AI

농부는 '비료의 양을 20% 늘리면 수확량이 15% 증가할 것이다'라는 가설을 세웠습니다.



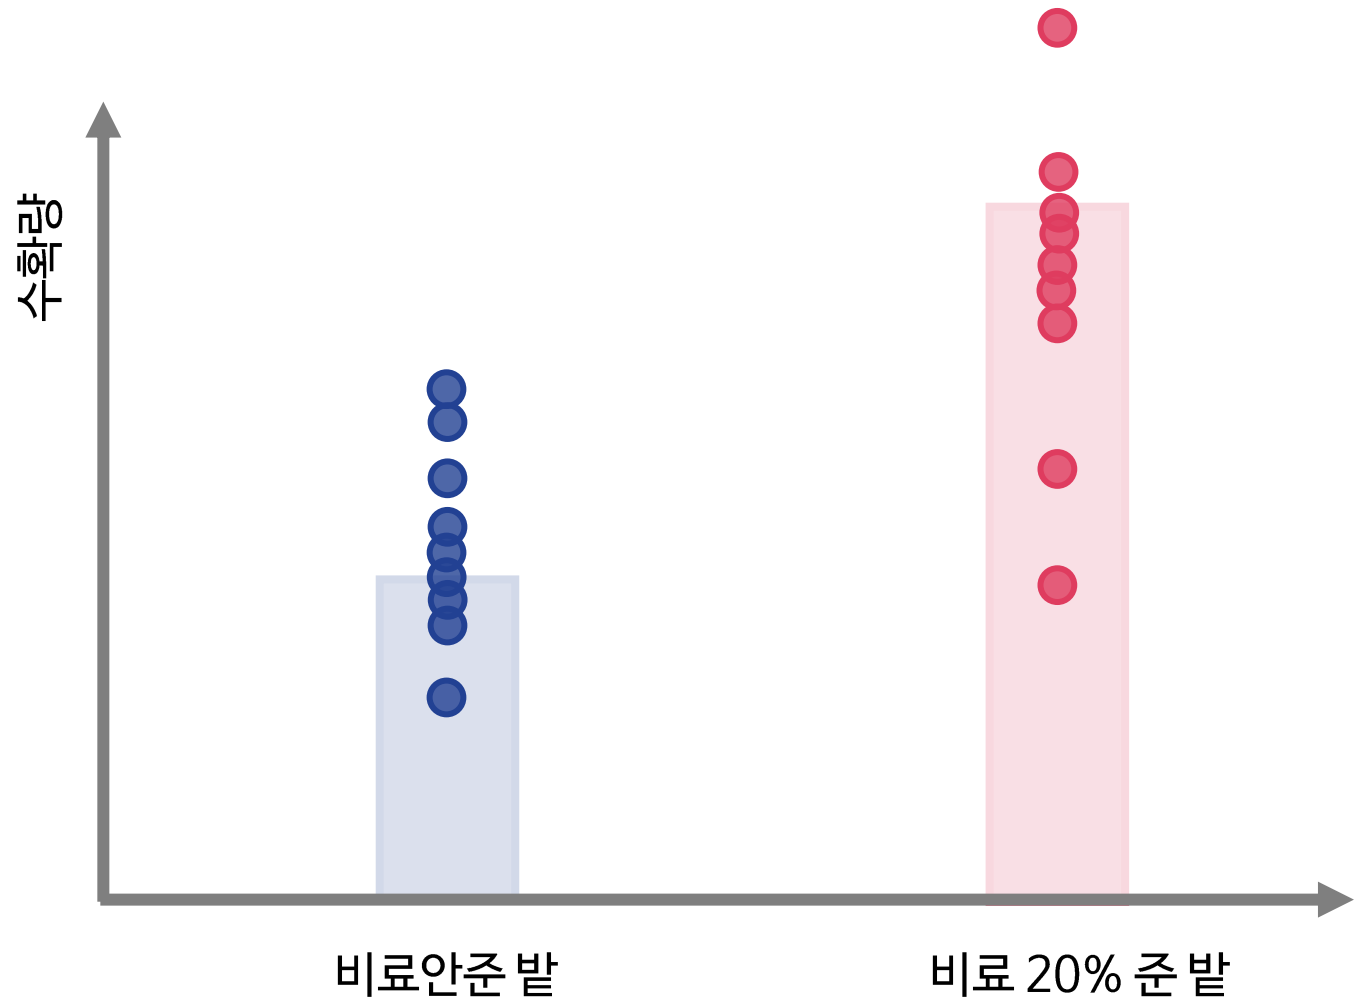
신박AI

이제 그는 이 가설을 검정해야 했습니다.



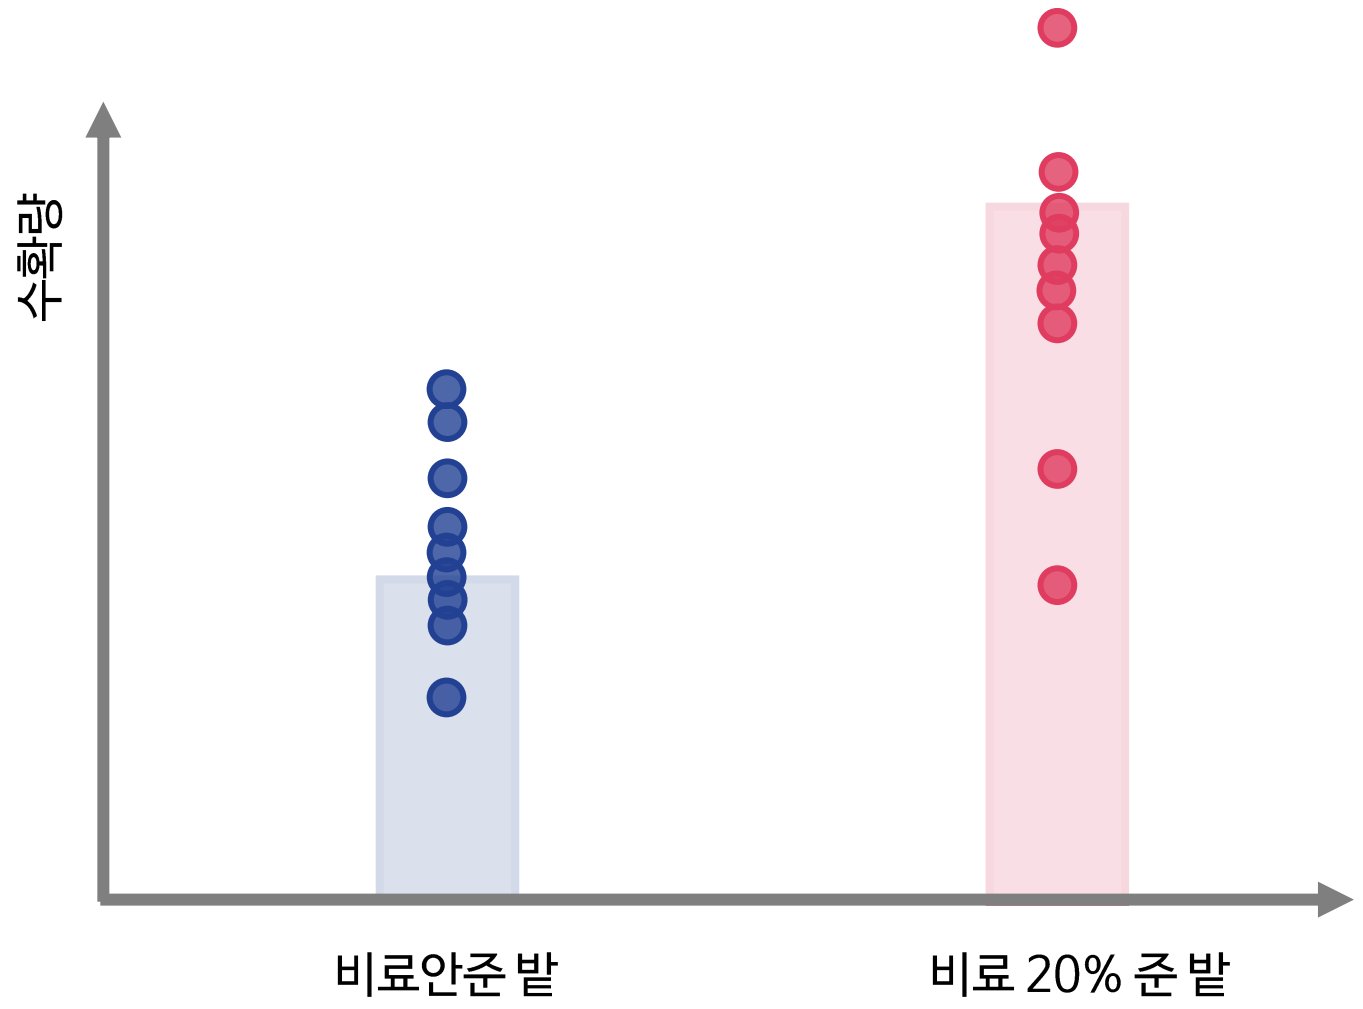
신박AI

가설검정을 위해 실험을 진행했지만, 결과가 항상 일관되지는 않았습니다.



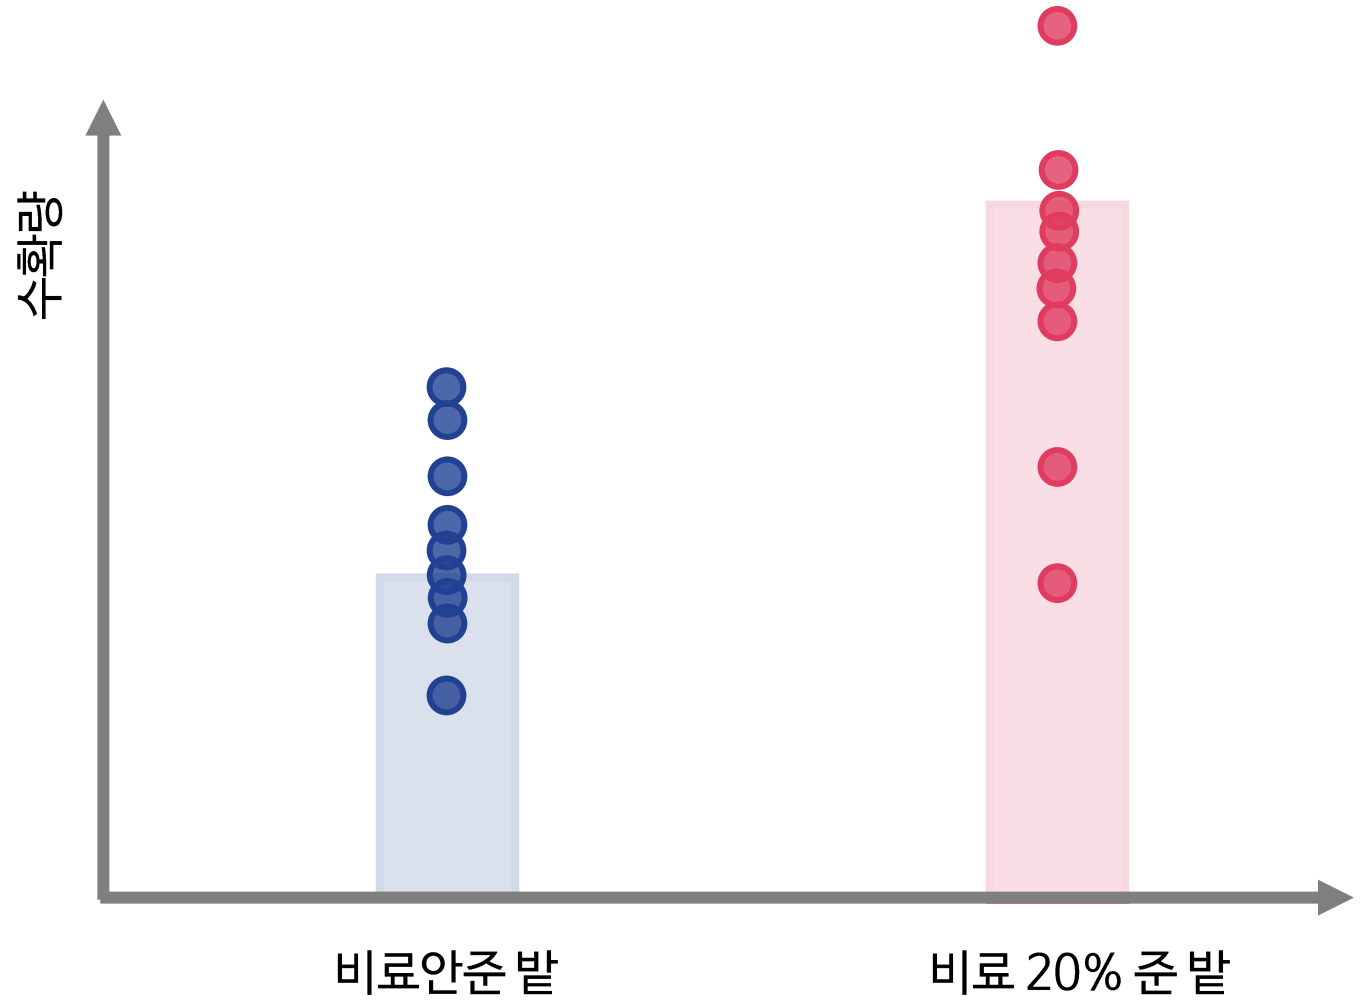
신박AI

어떤 때는 가설과 일치했고, 어떤 때는 그렇지 않았죠.



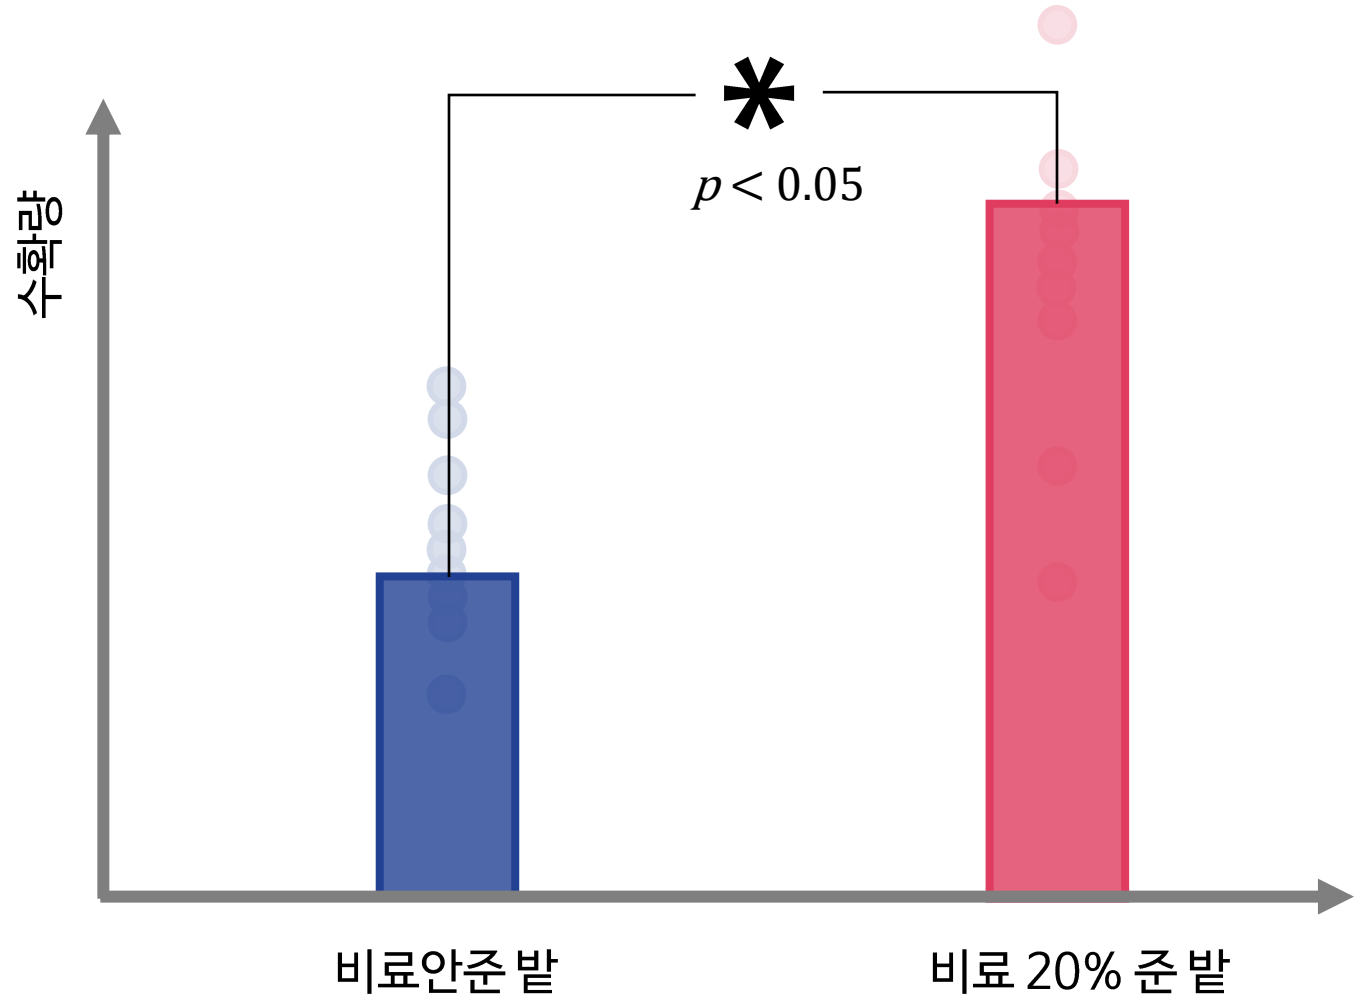
신박AI

이런 불확실성을 어떻게 다뤄야 할까요?



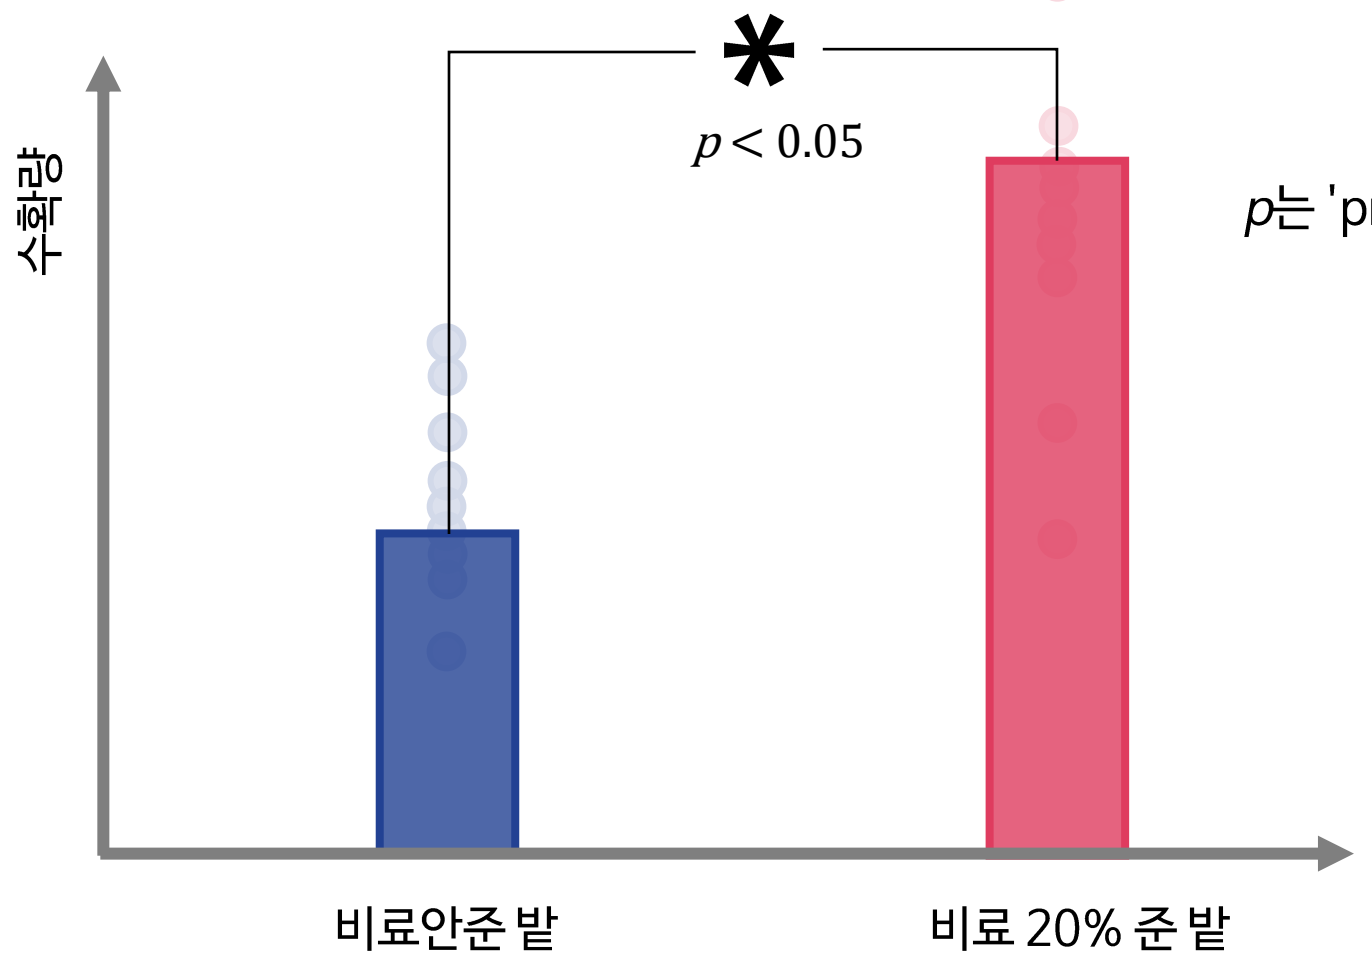
신박AI

여기서 p-값이 등장합니다.



신박AI

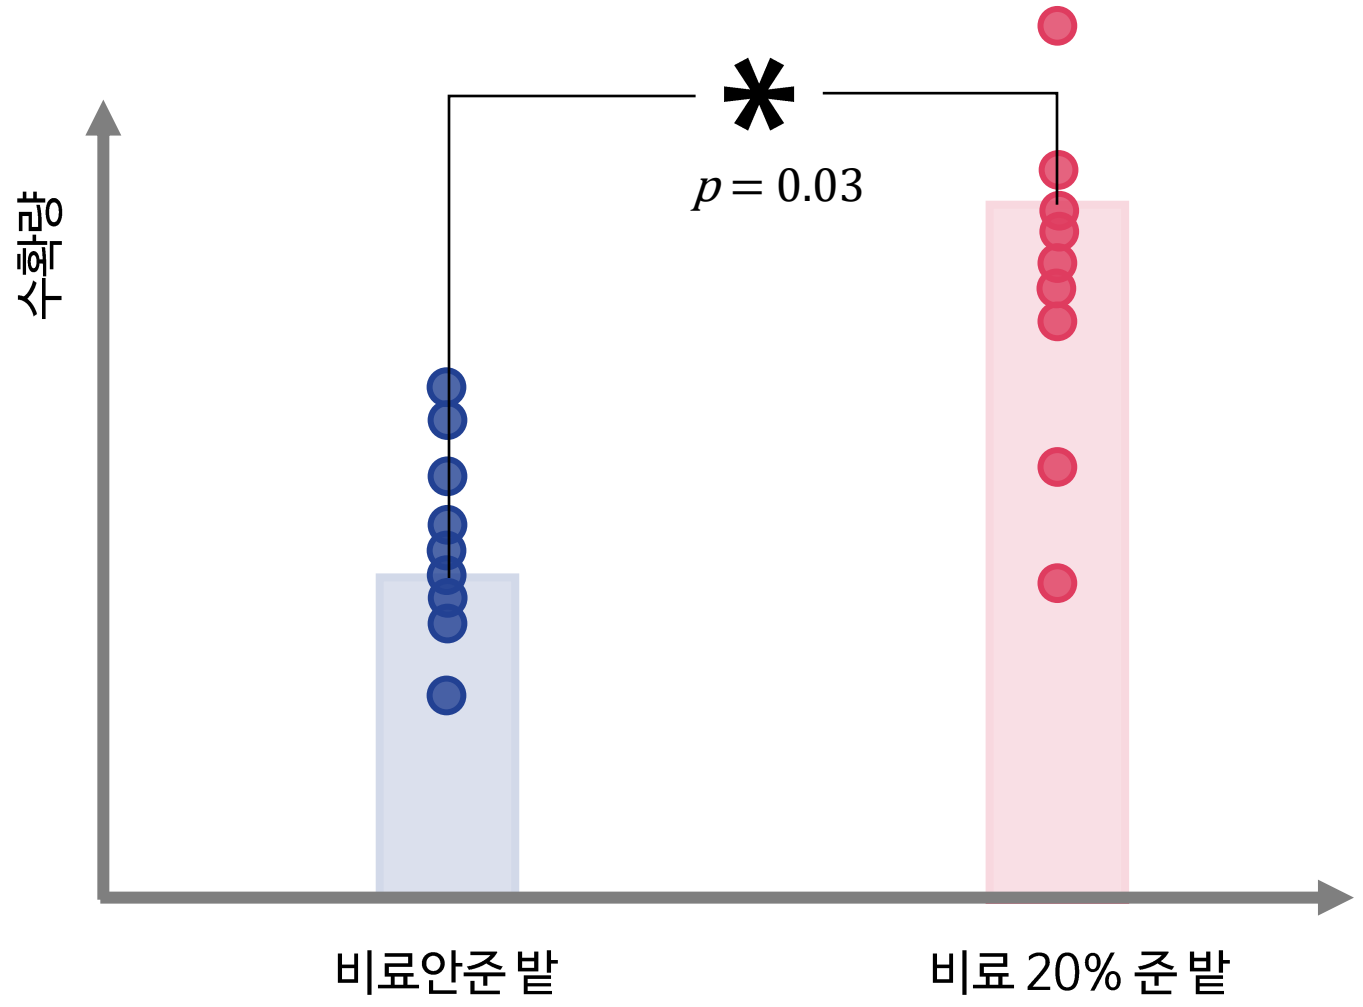
p-값은 우리의 가설이 틀렸다고 가정할 때, 관찰된 결과(또는 그보다 더 극단적인 결과)가 우연히 발생할 확률을 나타냅니다.



*p*는 'probability'의 약자입니다.

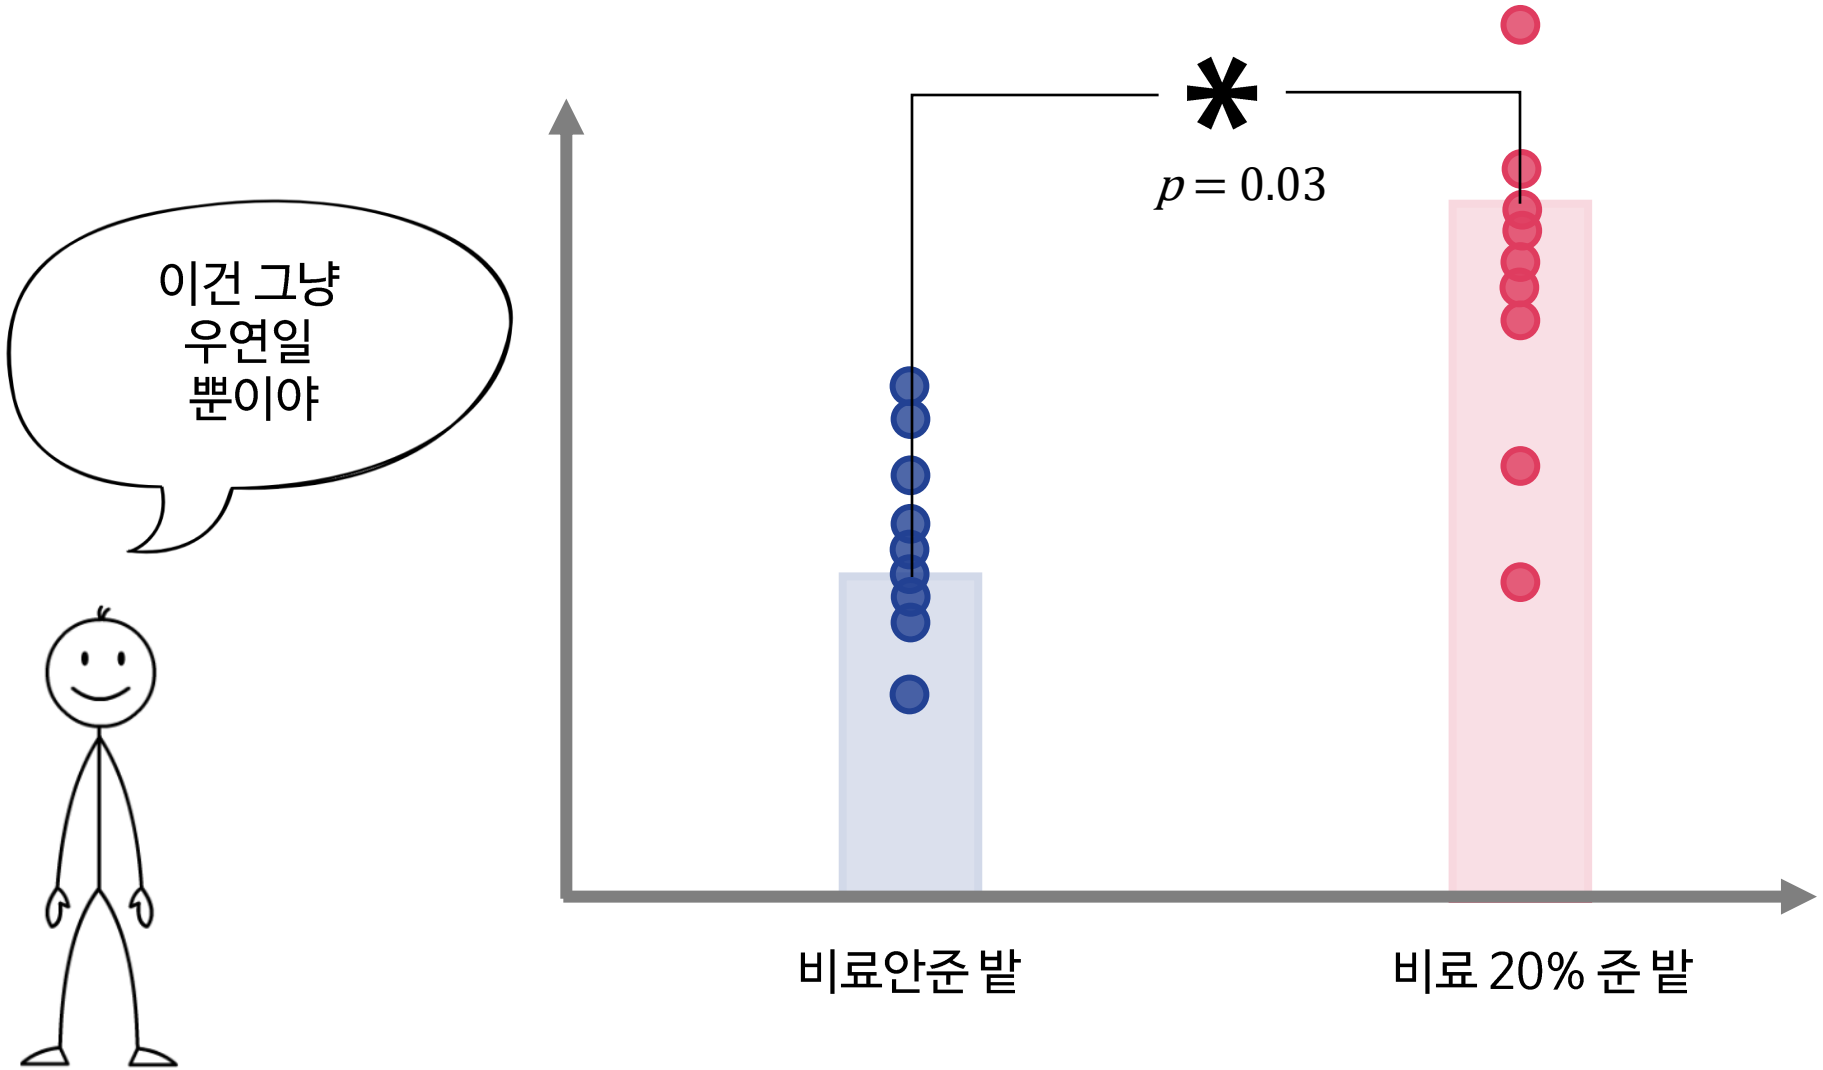
신박AI

예를 들어, p-값이 0.03이라면



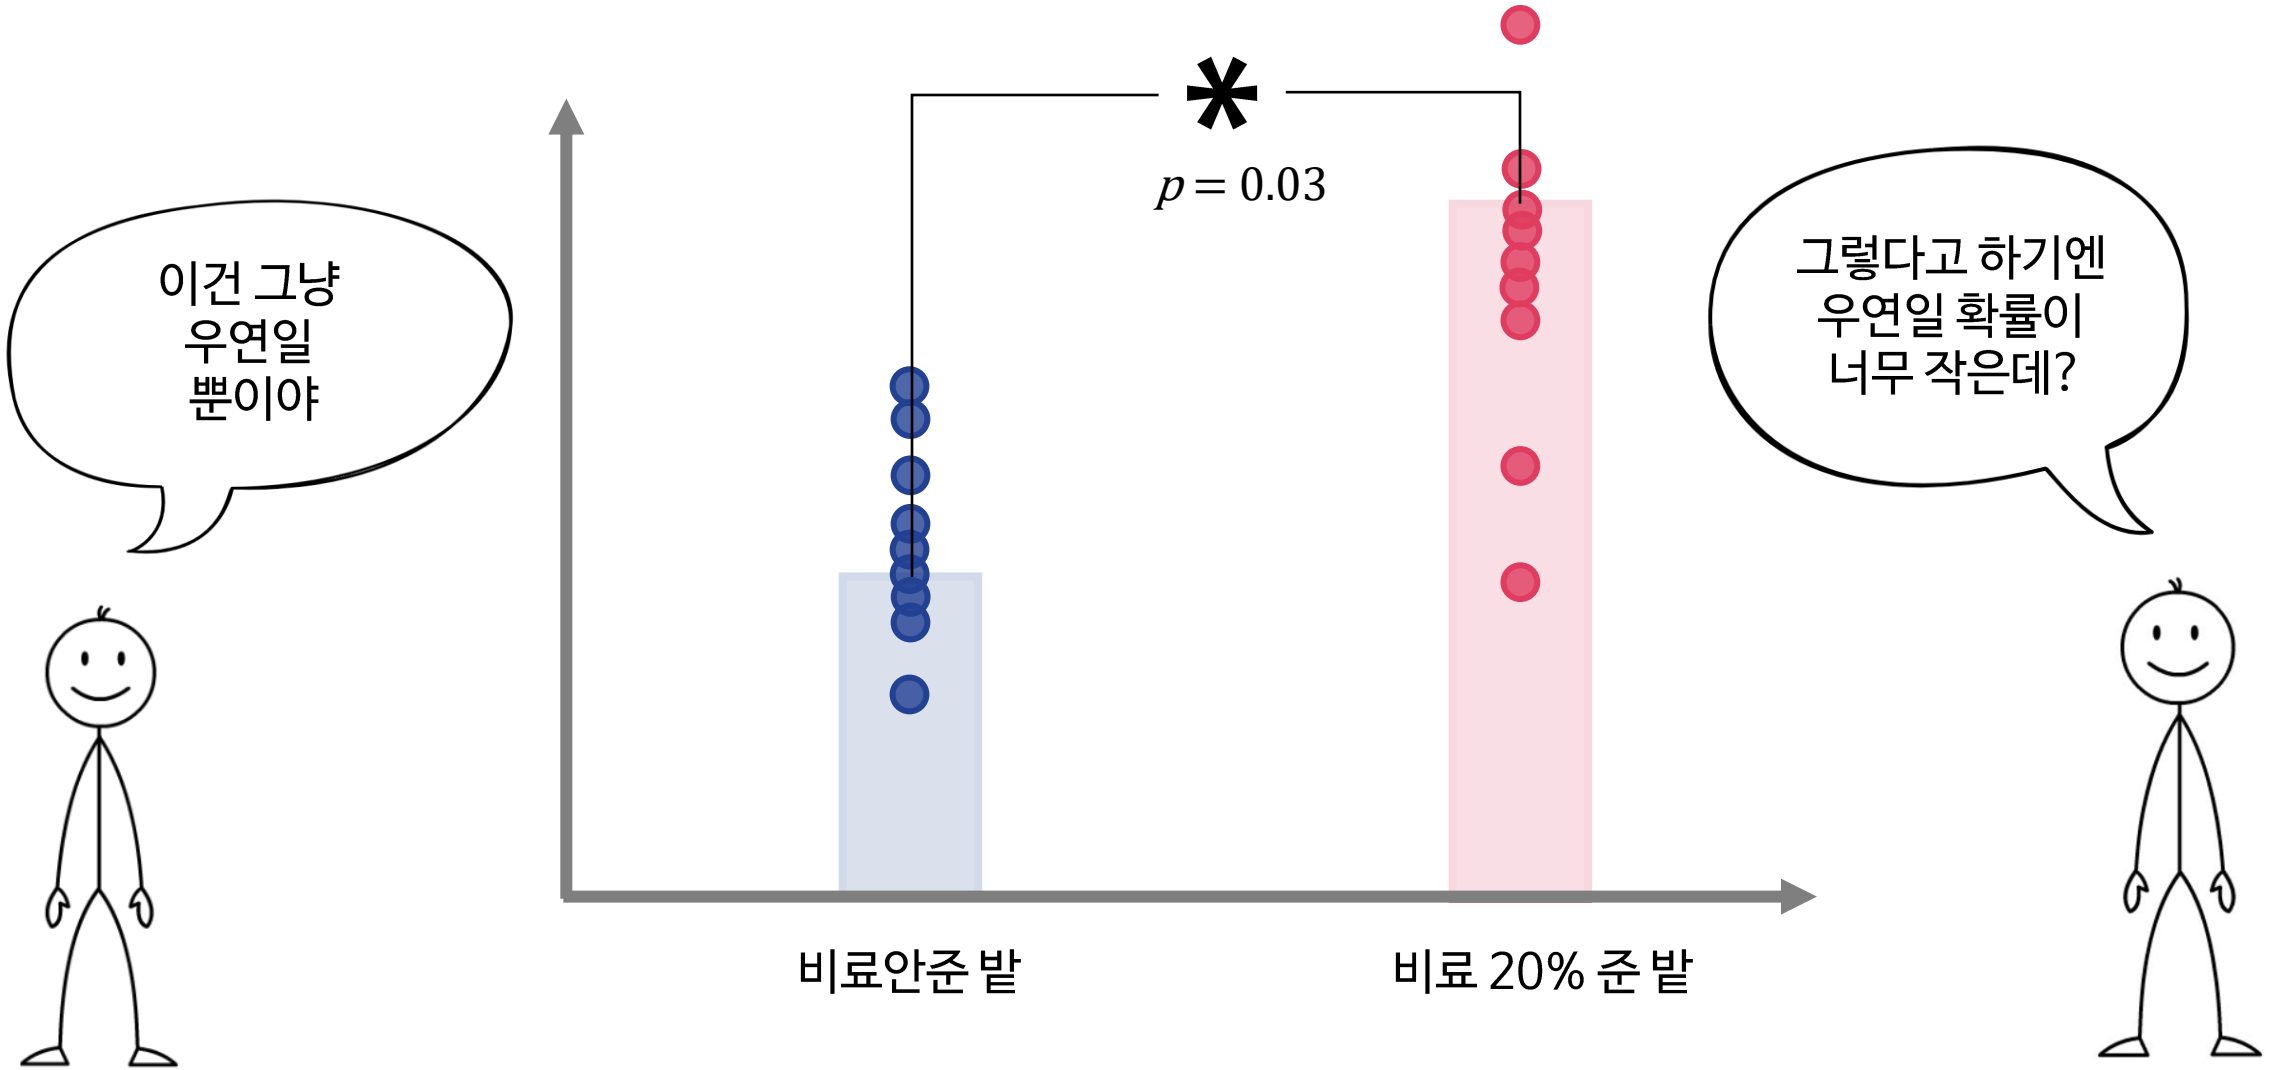
신박AI

비료 증가가 실제로 수확량 증가에 영향을 미치지 않는다고 가정했을 때,



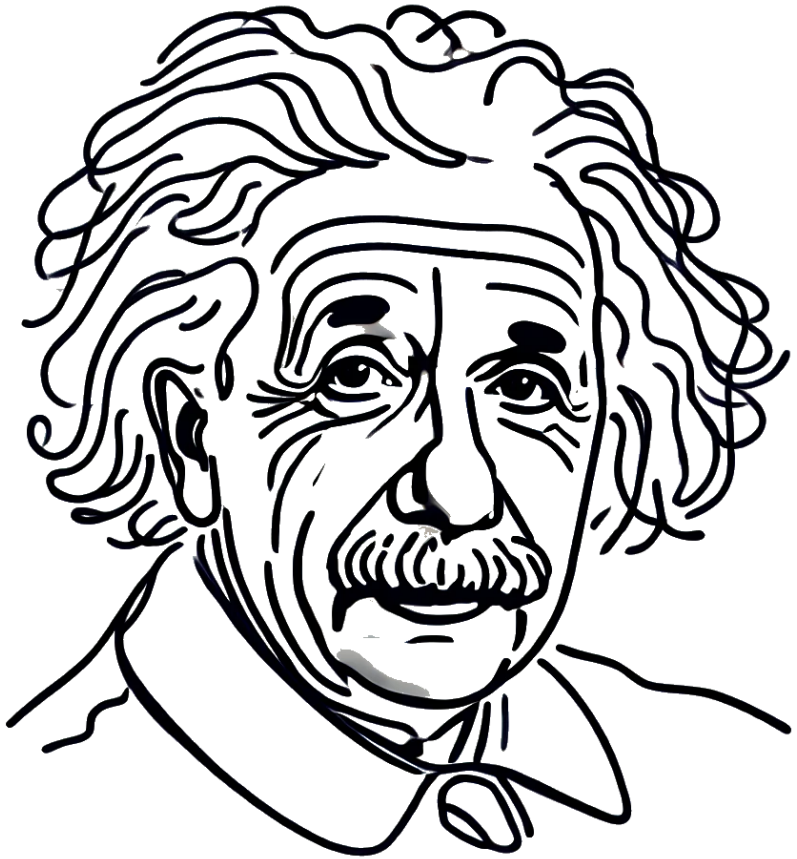
신박AI

우리가 관찰한 결과가 우연히 나올 확률이 3%라는 뜻입니다.



신박AI

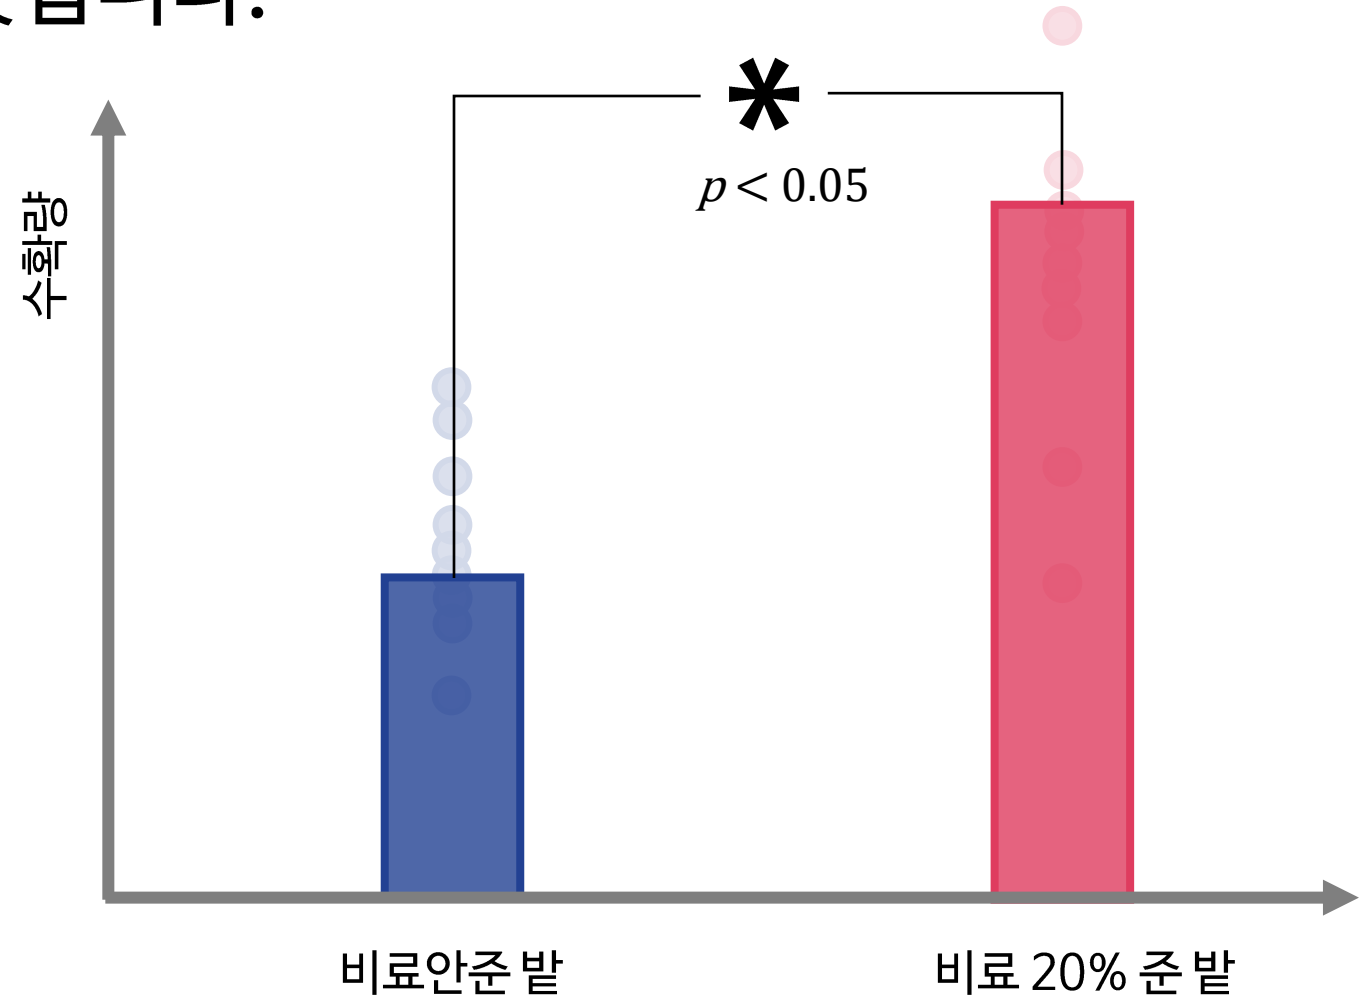
우연히 그런 결과가 나올 확률이 미미하기 때문에,



신은 주사위놀이 따위 하지 않는다네..

신박AI

우리는 비료 증가가 실제로 수확량 증가에 영향을 끼친다고 결론을 내리게 되는 것입니다.



신박AI

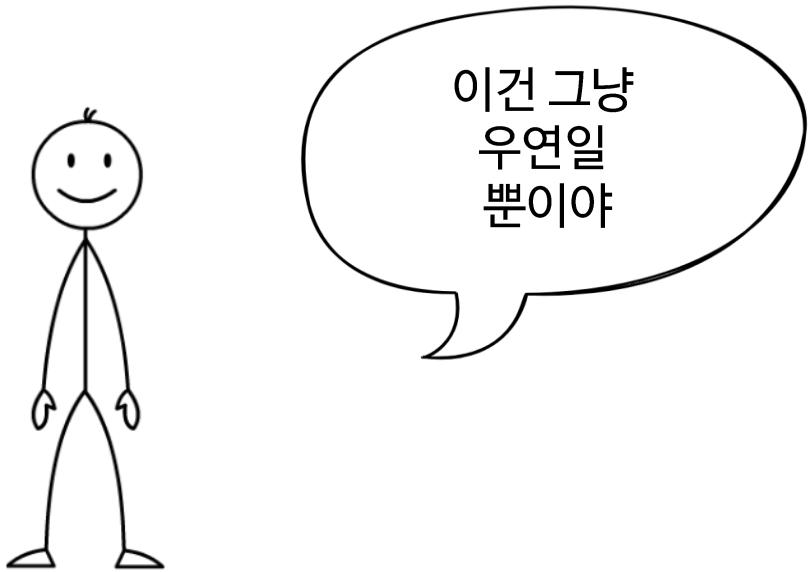
p-값의 해석은 귀무가설이 참이라는 것을 먼저 가정하고 실험을 한 뒤,

귀무가설

Null hypothesis

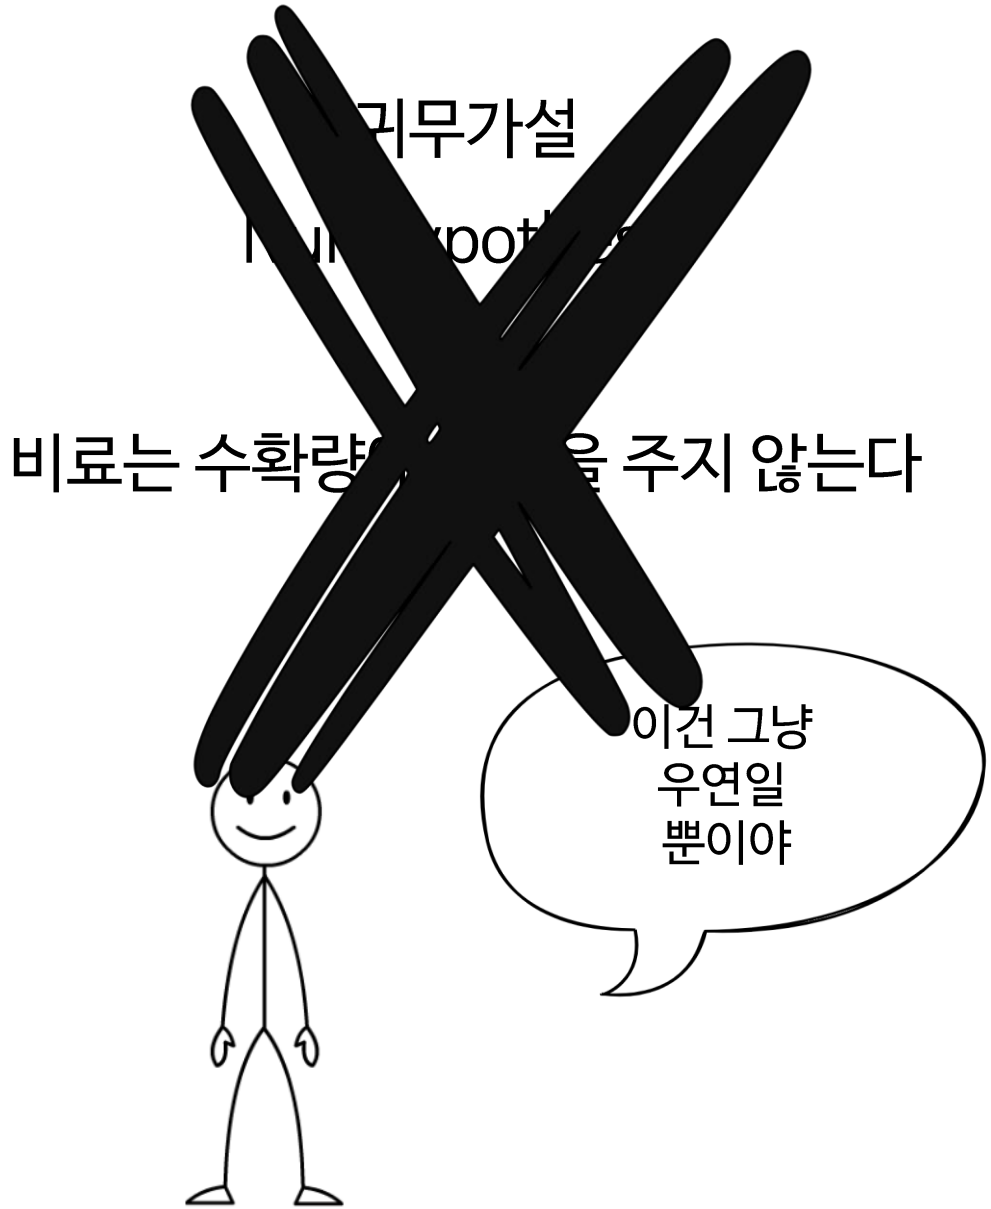
H_o

비료는 수확량에 영향을 주지 않는다



신박AI

p-값이 너무 작을 경우, 통상 0.05보다 작을 경우, 귀무가설을 기각하고



$$p < 0.05$$



신박AI

대립가설을 채택하는 방식으로 해석합니다.



대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

"비료 사용이 수확량 증가에 미치는
영향은 통계적으로 유의했다 ($p < 0.05$)."

신박AI

그런데 말입니다..

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

신박AI

비료가 수확량 증가에 영향을 준다는 사실을 보여주려면, 95% 이상 확률로 대립가설이 맞다는 사실만 보여주면 되지,

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

신박AI

왜 굳이 귀무가설을 가정하고, 귀무가설을 기각하고 이런 복잡한 절차로 설명하는 걸까요?

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

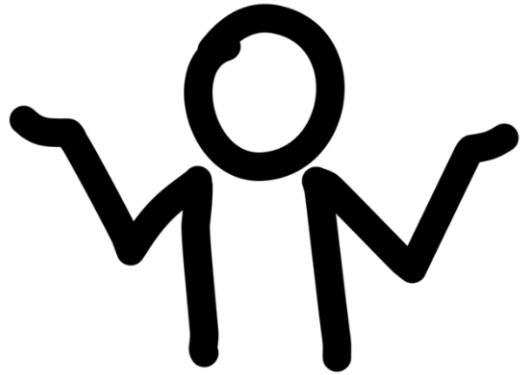
대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

왜 그리 꼬아서 설명을 한대..?



신박AI

그것은 과학적 보수주의 때문입니다.

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

신박AI

이는 법철학에서 논의되는 무죄추정의 원칙과 유사한 개념입니다.



무죄추정의 원칙:

피의자나 피고인이 유죄로
판결되기 전까지는 무죄로
간주한다는 개념

신박AI

그래서 모든 피의자는 기본적으로 무죄로 추정하고, 확실한 증거가 있을 때에만 유죄로 판결하게 됩니다.



무죄추정의 원칙:

피의자나 피고인이 유죄로 판결되기 전까지는 무죄로 간주한다는 개념

신박AI

이 원칙은 9명의 범죄자를 놓친다 해도, 단 한 명의 억울한 피의자가 발생하지 않게 하는 중요한 역할을 하고 있습니다.



무죄추정의 원칙:

피의자나 피고인이 유죄로 판결되기 전까지는 무죄로 간주한다는 개념

신박AI

마찬가지로 가설검증과 p-값 또한, 기본적으로 발견하고자 하는 사실을 틀렸다는 데에서 출발해서 (귀무가설)

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

신박AI

아주 확실한 통계학적 결과 (낮은 p-값)가 있을 때에만 실험 가설이 맞다는 판정을 내리게 됩니다.

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

신박AI

이는 9개의 과학적 발견을 놓치더라도, 단 하나의 잘못된 사실을 과학계에 들여놓지 않겠다는 의지를 담고 있습니다.

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

대립(실험)가설

Alternative Hypothesis

H_a

비료는 수확량에 영향을 준다.

신박AI

이렇게 농부는 통계의 기본 개념들을 하나씩 익혀가며, 자신의 농사 기술을 과학적으로 개선해 나갔습니다.



신박AI

그의 호기심에서 시작된 여정은 데이터를 수집하고, 분석하고, 해석하는 과정을 거쳐 더 나은 의사결정으로 이어졌습니다.



신박AI

여러분도 이제 농부처럼 주변 현상을
통계적인 시각으로 바라볼 준비가 되셨을
거라 믿습니다.

신박AI

오늘 배운 개념들은 농사뿐만 아니라 경제,
의학, 심리학, 머신러닝등 다양한 분야에서
폭넓게 활용될 수 있습니다.

신박AI

오늘 소개해드린 변수, 변량, 평균, 분산,
표준편차, 정규분포, 독립변수, 종속변수,
그리고 p-값 등 주요 개념들이

신박AI

영상을 시청해주시는 많은 분 들에게
머신러닝을 이해하는 데
작은 도움이 되길 바랍니다.

신박AI

영상 끝까지 시청해 주셔서 감사합니다.
그럼 다음 시간에 또 만나요!

신박AI

감사합니다!

좋은 하루 되세요!!

이 채널은 여러분의 관심과 사랑이 필요합니다



신박AI

‘좋아요’와 ‘구독’버튼은 강의 준비에 큰 힘이 됩니다!



신박AI

그리고 영상 자료를 사용하실때는
출처 '신박AI'를 밝혀주세요



신박AI



Copyright © by 신박Ai. All rights reserved

이 슬라이드 자료는 개인, 교실 수업, 교육 목적으로 사용할 수 있도록 라이선스가 부여되어 있습니다.
대학이나 학교 수업 등 비상업적 교육 환경에서 자유롭게 사용 및 수정이 가능합니다.
수강료를 받는 강의에서도 사용할 수 있지만, 슬라이드를 재판매 하거나 배포하거나 상업용 제품에 포함시키는 것은 허용되지 않습니다.
슬라이드를 유료 출판물, 상업용 온라인 강의, 혹은 영리 목적으로 사용하는 행위는 엄격히 금지되어 있습니다.
상업적 라이선스 관련 문의는 아래 이메일로 연락주시기 바랍니다: fusionlab.ai@gmail.com
독립적이고 모두에게 열린 교육을 지지해 주셔서 감사합니다.

신박AI